



UNIVERSITY OF PATRAS
DEPARTMENT OF ELECTRICAL AND COMPUTER
ENGINEERING

DIVISION OF THE SUPERVISOR
LABORATORY OF THE SUPERVISOR

DIPLOMA THESIS TITLE

DIPLOMA THESIS

STUDENT NAME, SURNAME

SUPERVISOR: NAME, SURNAME

PATRAS – MONTH, YEAR

University of Patras, Department of Electrical and Computer Engineering.

Student name, surname

© 20XX – All rights reserved

The whole work is an original work, produced by student name, surname, and does not violate the rights of third parties in any way. If the work contains material which has not been produced by him/her, this is clearly visible and is explicitly mentioned in the text of the work as a product of a third party, noting in a similarly clear way his/her identification data, while at the same time confirming that in case of using original graphics representations, images, graphs, etc., has obtained the unrestricted permission of the copyright holder for the inclusion and subsequent publication of this material.

CERTIFICATION

It is certified that the Diploma Thesis titled

DIPLOMA THESIS TITLE

of the Department of Electrical and Computer Engineering student

STUDENT NAME, SURNAME

Registration Number: XXXXXXXX

was presented publicly at the Department of Electrical and Computer
Engineering at

...../...../.....

and was examined by the following examining committee:

Name Surname, Title, Affiliation (supervisor)

Name Surname, Title, Affiliation (committee member)

Name Surname, Title, Affiliation (committee member)

The Supervisor

The Director of the Division

Name Surname
Title

Name Surname
Title



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ
ΤΕΧΝΟΛΟΓΙΑΣ ΥΠΟΛΟΓΙΣΤΩΝ

ΤΟΜΕΑΣ ΕΠΙΒΛΕΠΟΝΤΟΣ
ΕΡΓΑΣΤΗΡΙΟ ΕΠΙΒΛΕΠΟΝΤΟΣ

ΤΙΤΛΟΣ ΔΙΠΛΩΜΑΤΙΚΗΣ ΕΡΓΑΣΙΑΣ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΟΝΟΜΑΤΕΠΩΝΥΜΟ ΦΟΙΤΗΤΗ

ΕΠΙΒΛΕΠΩΝ: ΟΝΟΜΑΤΕΠΩΝΥΜΟ ΕΠΙΒΛΕΠΟΝΤΟΣ

ΠΑΤΡΑ - ΜΗΝΑΣ ΕΤΟΣ

Πανεπιστήμιο Πατρών, Τμήμα Ηλεκτρολόγων Μηχανικών και Τεχνολογίας Υπολογιστών.

Ονοματεπώνυμο φοιτητή/τριας

© 20XX – Με την επιφύλαξη παντός δικαιώματος

Το σύνολο της εργασίας αποτελεί πρωτότυπο έργο, παραχθέν από τον/την ονοματεπώνυμο φοιτητή/τριας, και δεν παραβιάζει δικαιώματα τρίτων καθ' οιονδήποτε τρόπο. Αν η εργασία περιέχει υλικό, το οποίο δεν έχει παραχθεί από τον/την ίδιο/α, αυτό είναι ευδιάκριτο και αναφέρεται ρητώς εντός του κειμένου της εργασίας ως προϊόν εργασίας τρίτου, σημειώνοντας με παρομοίως σαφή τρόπο τα στοιχεία ταυτοποίησής του, ενώ παράλληλα βεβαιώνει πως στην περίπτωση χρήσης αυτούσιων γραφικών αναπαραστάσεων, εικόνων, γραφημάτων κ.λπ., έχει λάβει τη χωρίς περιορισμούς άδεια του κατόχου των πνευματικών δικαιωμάτων για την συμπερίληψη και επακόλουθη δημοσίευση του υλικού αυτού.

ΠΙΣΤΟΠΟΙΗΣΗ

Πιστοποιείται ότι η Διπλωματική Εργασία με τίτλο

ΤΙΤΛΟΣ ΔΙΠΛΩΜΑΤΙΚΗΣ ΕΡΓΑΣΙΑΣ

του/της φοιτητή/τριας του Τμήματος Ηλεκτρολόγων Μηχανικών και
Τεχνολογίας Υπολογιστών

ΟΝΟΜΑ ΕΠΩΝΥΜΟ ΤΟΥ ΠΑΤΡΩΝΥΜΟ

Αριθμός Μητρώου: XXXXXXXX

Παρουσιάστηκε δημόσια στο Τμήμα Ηλεκτρολόγων Μηχανικών και
Τεχνολογίας Υπολογιστών στις

...../...../.....

και εξετάστηκε από την ακόλουθη εξεταστική επιτροπή:

Όνομα Επώνυμο, Βαθμίδα, Τμήμα (επιβλέπων)

Όνομα Επώνυμο, Βαθμίδα, Τμήμα (μέλος επιτροπής)

Όνομα Επώνυμο, Βαθμίδα, Τμήμα (μέλος επιτροπής)

Ο/Η Επιβλέπων/ουσα

Ο/Η Διευθυντής/τρια του
Τομέα

Ονοματεπώνυμο
Βαθμίδα

Ονοματεπώνυμο
Βαθμίδα

ACKNOWLEDGEMENTS

Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren

Lorem ipsum dolor sit amet, consetetur sadipscing elitr, sed diam nonumy eirmod tempor invidunt ut labore et dolore magna aliquyam erat, sed diam voluptua. At vero eos et accusam et justo duo dolores et ea rebum. Stet clita kasd gubergren

ΠΕΡΙΛΗΨΗ

Βραχυπρόθεσμη Πρόβλεψη Τιμών και Φορτίου Ηλεκτρικής Ενέργειας στην Ελληνική Αγορά με Μεθόδους Μηχανικής Μάθησης

Η παρούσα διπλωματική εργασία πραγματεύεται τη βραχυπρόθεσμη πρόβλεψη τιμής Αγοράς Επόμενης Ημέρας (DAM) και ηλεκτρικού φορτίου στην ελληνική αγορά ηλεκτρισμού, χρησιμοποιώντας αλγόριθμους Μηχανικής Μάθησης. Κεντρικό αντικείμενο αποτελεί η συστηματική σύγκριση τεσσάρων στρατηγικών πολυβήματης πρόβλεψης: Teacher-Forcing (TF), Recursive/Open-Loop (OL), Multi-Input Multi-Output (MIMO) και Walk-Forward Monthly Retraining (MR). Οι στρατηγικές εφαρμόζονται σε πέντε αλγόριθμους (LightGBM, XGBoost, Random Forest, SVR, MLP) και αξιολογούνται σε τρεις χρονικές περιόδους (Δεκέμβριος 2025, Q4 2025, Q1 2026) με δεδομένα από την πλατφόρμα ENTSO-E Transparency.

Τα πειραματικά αποτελέσματα αναδεικνύουν την Walk-Forward Monthly Retraining ως τη βέλτιστη στρατηγική για μακροχρόνιους ορίζοντες: στο Q1 2026, το Ensemble TF-Best3 (MR) επιτυγχάνει MAE 10,49 €/MWh για τιμή (-27,7% vs static TF) και 67,7 MW για φορτίο (-30,0%), αντιστεκόμενο αποτελεσματικά στη μεταβολή κατανομής τιμών που χαρακτήρισε τον Φεβρουάριο 2026. Η ανωτερότητα αυτή επιβεβαιώνεται στατιστικά μέσω ελέγχου Diebold-Mariano με διόρθωση Harvey-Leybourne-Newbold. Πρόσθετα ευρήματα: τα dense intraday lags (lags 4–23) βελτιώνουν MIMO αλλά βλάπτουν Recursive (dense lags paradox), ενώ το SVR αποτυγχάνει σε volatile αγορές λόγω ευαισθησίας στη μεταβολή κατανομής.

Λέξεις-κλειδιά — πρόβλεψη τιμών ηλεκτρισμού, LightGBM, XGBoost, MIMO, walk-forward retraining, scheduled sampling, Diebold-Mariano

ABSTRACT

Short-Term Electricity Price and Load Forecasting in the Greek Market using Machine Learning

This thesis investigates short-term forecasting of Day-Ahead Market (DAM) electricity prices and load in the Greek electricity market using Machine Learning. The central contribution is a systematic comparison of four multi-step forecasting strategies: Teacher-Forcing (TF), Recursive/Open-Loop (OL), Multi-Input Multi-Output (MIMO), and Walk-Forward Monthly Retraining (MR), applied across five ML algorithms (LightGBM, XGBoost, Random Forest, SVR, MLP) over three test periods (December 2025, Q4 2025, Q1 2026) using ENTSO-E Transparency data.

Walk-Forward Monthly Retraining is identified as the superior strategy for extended horizons: on Q1 2026, the MR TF Ensemble-Best3 achieves MAE 10.49 €/MWh for price (−27.7% vs static TF) and 67.7 MW for load (−30.0%), adapting effectively to the distributional shift in February 2026. Significance is confirmed via Diebold-Mariano test with Harvey-Leybourne-Newbold correction. Additional findings: dense intraday lags improve MIMO (MLP −22.3%) but degrade Recursive (dense lags paradox); SVR collapses under distribution shift. Feature importance analysis reveals strategy-dependent information utilization. Results are available via an interactive HTML/JavaScript dashboard.

Keywords — **electricity price forecasting, load forecasting, LightGBM, XGBoost, MIMO, walk-forward retraining, scheduled sampling, Diebold-Mariano test**

Περιεχόμενα

1	Εισαγωγή	1
1.1	Ενεργειακή Μετάβαση και Ηλεκτρικές Αγορές	1
1.2	Η Ελληνική Αγορά Ηλεκτρισμού	2
1.3	Κίνητρο και Ερευνητικά Ερωτήματα	4
1.4	Σκοπός και Κύριες Συνεισφορές	4
1.5	Δομή της Εργασίας	5
2	Βιβλιογραφική Ανασκόπηση	7
2.1	Εισαγωγή	7
2.2	Παραδοσιακά Στατιστικά Μοντέλα	7
2.2.1	ARIMA/SARIMA και παραλλαγές	7
2.2.2	GARCH και Υβριδικά Στατιστικά Μοντέλα	7
2.3	Μοντέλα Μηχανικής Μάθησης	8
2.3.1	Δέντρα Αποφάσεων και Μέθοδοι Boosting	8
2.3.2	Support Vector Regression	8
2.3.3	Νευρωνικά Δίκτυα — MLP	8
2.4	Βαθιά Μάθηση	8
2.4.1	LSTM και RNN	8
2.4.2	Transformer-based Μοντέλα	8
2.5	Στρατηγικές Πολυ-βήματης Πρόβλεψης	9
2.5.1	Teacher-Forcing (Closed-Loop)	9
2.5.2	Recursive / Open-Loop	9
2.5.3	MIMO	9
2.5.4	Walk-Forward Retraining	10
2.6	Βιβλιογραφία για την Ελληνική Αγορά	10
2.7	Σύγκριση με την Παρούσα Εργασία	10
3	Δεδομένα και Προεπεξεργασία	11
3.1	Πηγές Δεδομένων	11
3.2	Χρονοσειρά Τιμών DAM	11
3.3	Χρονοσειρά Ηλεκτρικού Φορτίου	12
3.4	Κατασκευή Χαρακτηριστικών (Feature Engineering)	12
3.4.1	Χρονικές Υστερήσεις (Lag Features)	12
3.4.2	Κυλιόμενα Στατιστικά (Rolling Features)	13
3.4.3	Ημερολογιακά Χαρακτηριστικά	13
3.4.4	Εξωγενείς Μεταβλητές	13
3.5	Χρονικός Διαχωρισμός	13
3.5.1	Σύνολο Χαρακτηριστικών	14

4	Μέθοδοι Πρόβλεψης	15
4.1	Γραμμές Βάσης (Baselines)	15
4.2	Αλγόριθμοι Μηχανικής Μάθησης	15
4.2.1	LightGBM	15
4.2.2	XGBoost	15
4.2.3	Random Forest	16
4.2.4	Support Vector Regression	16
4.2.5	Multi-Layer Perceptron (MLP)	16
4.3	Στρατηγικές Πρόβλεψης	16
4.3.1	Teacher-Forcing (TF / Closed-Loop)	16
4.3.2	Recursive (Open-Loop) με Scheduled Sampling	17
4.3.3	Multi-Input Multi-Output (MIMO)	17
4.3.4	Walk-Forward Monthly Retraining	17
4.4	Βελτιστοποίηση Υπερπαραμέτρων (Optuna)	17
4.4.1	OL-Aware Daily Optuna	17
4.4.2	MIMO Optuna	18
4.4.3	CachedOptuna	18
4.5	Μετρικές Αξιολόγησης	18
5	Αποτελέσματα Αξιολόγησης	19
5.1	Κλειστός Βρόχος — Teacher-Forcing (CL/TF)	19
5.1.1	Αποτελέσματα 1 Μήνα (Δεκέμβριος 2025)	19
5.1.2	Αποτελέσματα Q1 2026 (Δεκ. 2025 – Φεβ. 2026)	20
5.2	Ανοικτός Βρόχος — Recursive (OL)	20
5.2.1	Δεκέμβριος 2025 (Μηνιαία Αξιολόγηση)	20
5.3	MIMO (Multi-Input Multi-Output)	21
5.4	Walk-Forward Monthly Retraining (MR)	22
5.5	Σύγκριση Στρατηγικών	23
6	Ανάλυση Σημαντικότητας Χαρακτηριστικών	26
6.1	Μεθοδολογία	26
6.2	Αποτελέσματα — Τιμή DAM	27
6.3	Αποτελέσματα — Ηλεκτρικό Φορτίο	28
6.4	Σύγκριση Κατά Στρατηγική	29
6.5	Κατηγοριοποίηση Χαρακτηριστικών	29
6.6	Συμπεράσματα Κεφαλαίου	30
7	Στατιστικοί Έλεγχοι Σύγκρισης Μοντέλων	31
7.1	Ο Έλεγχος Diebold-Mariano	31
7.2	Διόρθωση Harvey-Leybourne-Newbold	31
7.3	Πειραματική Διάταξη	32
7.4	Αποτελέσματα — Τιμή DAM	32
7.5	Αποτελέσματα — Ηλεκτρικό Φορτίο	34
7.6	Συμπεράσματα Κεφαλαίου	35
8	Σύστημα Οπτικοποίησης Αποτελεσμάτων	36
8.1	Αρχιτεκτονική	36
8.2	Στοιχεία Διεπαφής Χρήστη	37
8.3	Χαρτογράφηση Αρχείων JSON	38
8.4	Οδηγίες Χρήσης	38

9 Συμπεράσματα	39
9.1 Σύνοψη Κύριων Ευρημάτων	39
9.2 Ειδικά Ευρήματα	40
9.3 Περιορισμοί	41
9.4 Μελλοντική Έρευνα	41
9.5 Κλείσιμο	42
Βιβλιογραφία	43

Κατάλογος Σχημάτων

1.1	Χρονοσειρά τιμής DAM (€/MWh) για την Ελλάδα — Δεκέμβριος 2025 έως Φεβρουάριος 2026. Οι σκιαγραφημένες περιοχές δείχνουν τον Ιανουάριο και Φεβρουάριο 2026, στους οποίους παρατηρείται αυξημένη μεταβλητότητα και πτώση του επιπέδου τιμής.	3
1.2	Χρονοσειρά φορτίου (MW) για την Ελλάδα — Δεκέμβριος 2025 έως Φεβρουάριος 2026. Το χειμερινό φορτίο εμφανίζει σαφή ημερήσια εποχικότητα και σταδιακή μείωση καθώς πλησιάζει η άνοιξη.	3
5.1	Χρονοσειρές προβλέψεων τιμής DAM για επιλεγμένα μοντέλα, Q1 2026. Οι αποχρώσεις αντιπροσωπεύουν διαφορετικές στρατηγικές (TF: μοβ, CL: γαλάζιο, OL: πράσινο, MIMO: πορτοκαλί).	24
5.2	Χρονοσειρές προβλέψεων φορτίου για επιλεγμένα μοντέλα, Q1 2026.	24
5.3	Box plots κατανομής σφαλμάτων (absolute error) ανά μοντέλο για τιμή, Q1 2026. Ο διάμεσος, IQR και outliers αποκαλύπτουν διαφορές στη συνέντευξη των μοντέλων.	24
5.4	Ωριαίο προφίλ σφάλματος (MAE ανά ώρα ημέρας) για τιμή, Q1 2026. Τα μοντέλα δυσκολεύονται ιδιαίτερα τις ώρες αιχμής (19:00–22:00).	25
6.1	Top-15 χαρακτηριστικά για τα μοντέλα τιμής ανά αλγόριθμο και στρατηγική. Η αδρή στήλη αντιστοιχεί στη σημαντικότητα gain/MDI (κανονικοποιημένη στο 100%).	27
6.2	Top-15 χαρακτηριστικά για τα μοντέλα φορτίου ανά αλγόριθμο και στρατηγική.	28
6.3	Μεταβολή σημαντικότητας τοπ-5 χαρακτηριστικών μεταξύ TF, OL και MIMO για τα μοντέλα τιμής (LGBM). Παρατηρείται σταδιακή μεταφορά βαρύτητας από y_{t-1} σε y_{t-24} , gas_price και αιολική παραγωγή καθώς εναλλάσσεται η στρατηγική.	29
6.4	Κατανομή σημαντικότητας ανά κατηγορία χαρακτηριστικών (price lags, calendar features, exogenous/market features, rolling statistics) για 8 παραλλαγές μοντέλων τιμής.	29
7.1	Χάρτης θερμότητας DM ελέγχου για τιμή DAM (Q1 2026). Κάθε κελί (i, j) χρωματίζεται σκούρο μπλε αν το μοντέλο i είναι στατιστικά σημαντικά καλύτερο από το j ($p < 0,05$), ανοιχτό μπλε για $p < 0,10$, λευκό για μη σημαντική διαφορά.	33
7.2	Αριθμός στατιστικά σημαντικών «νικών» ($p < 0,05$) ανά μοντέλο και στρατηγική για την τιμή DAM.	33
7.3	Χάρτης θερμότητας DM ελέγχου για ηλεκτρικό φορτίο (Q1 2026).	34
7.4	Αριθμός στατιστικά σημαντικών «νικών» ανά μοντέλο για το φορτίο.	35

Κατάλογος Πινάκων

2.1	Σύγκριση με εκπροσωπευτικές εργασίες της βιβλιογραφίας.	10
3.1	Στατιστικά περιγραφικά τιμής DAM ανά μήνα (Q1 2026).	12
3.2	Στατιστικά περιγραφικά φορτίου ανά μήνα (Q1 2026).	12
3.3	Εξωγενή χαρακτηριστικά και η αντίστοιχη διαθεσιμότητά τους πριν DAM gate closure.	13
3.4	Χρονικός διαχωρισμός dataset.	14
3.5	Αριθμός χαρακτηριστικών ανά εργασία και παραλλαγή.	14
4.1	Παράμετροι LightGBM (standard CL models).	15
4.2	Παράμετροι XGBoost (standard CL models).	16
5.1	Αποτελέσματα Κλειστού Βρόχου (TF) – Τιμή, Δεκ. 2025 (744h).	19
5.2	Αποτελέσματα Κλειστού Βρόχου (TF) – Φορτίο, Δεκ. 2025 (744h).	19
5.3	Αποτελέσματα CL – Τιμή, Q1 2026 (2160h).	20
5.4	Open-Loop H=24 (daily) – Τιμή, Δεκ. 2025.	20
5.5	Open-Loop H=24 – Φορτίο, Δεκ. 2025.	21
5.6	MIMO H=24 – Τιμή, Δεκ. 2025 (744h, daily prediction).	21
5.7	MIMO H=24 – Φορτίο, Δεκ. 2025 (744h).	21
5.8	Walk-Forward Monthly Retrain – Τιμή, Q1 2026.	22
5.9	Ανάλυση ανά μήνα – TF Monthly Retrain, τιμή.	22
5.10	Walk-Forward Monthly Retrain – Φορτίο, Q1 2026.	23
5.11	Συγκεντρωτική σύγκριση βέλτιστων μοντέλων ανά στρατηγική.	23
7.1	Μοντέλα που συμμετέχουν στους DM ελέγχους (Q1 2026, $T = 2160$ ώρες).	32
8.1	Χρωματική κωδικοποίηση dashboard.	37
8.2	Χαρτογράφηση στρατηγικής/εργασίας σε αρχεία JSON.	38
9.1	Σύγκριση στρατηγικών Q1 2026 — κύρια αποτελέσματα.	40

Κεφάλαιο 1

Εισαγωγή

Στο κεφάλαιο αυτό παρουσιάζεται το πλαίσιο που καθιστά αναγκαία την πρόβλεψη τιμών και φορτίου στις ηλεκτρικές αγορές, περιγράφεται το ιδιαίτερο πλαίσιο της ελληνικής αγοράς, διατυπώνονται τα ερευνητικά ερωτήματα που καθοδηγούν την εργασία και παρουσιάζεται η δομή των κεφαλαίων που ακολουθούν.

1.1 Ενεργειακή Μετάβαση και Ηλεκτρικές Αγορές

Η παγκόσμια ενεργειακή μετάβαση αποτελεί μια από τις βαθύτερες αναδιαρθρώσεις του ενεργειακού συστήματος που έχουν καταγραφεί ιστορικά. Η κλιματική αλλαγή, οι δεσμευτικοί στόχοι μηδενικών εκπομπών άνθρακα για το 2050 και η ραγδαία μείωση του κόστους φωτοβολταϊκών και αιολικών εγκαταστάσεων αναγκάζουν τα εθνικά δίκτυα να μεταβούν από ένα κεντρικό μοντέλο ορυκτών καυσίμων σε ένα αποκεντρωμένο, ευέλικτο και χαμηλών εκπομπών μοντέλο [1].

Παράλληλα, η απελευθέρωση των ηλεκτρικών αγορών — που ξεκίνησε στα τέλη του 20ού αιώνα με πρωτοπόρες τις αγγλοσαξονικές χώρες — επέτρεψε την εισαγωγή του ανταγωνισμού σε κλάδους που ιστορικά λειτουργούσαν ως φυσικά μονοπώλια. Σήμερα, στην Ευρώπη, η χονδρεμπορική αγορά ηλεκτρικής ενέργειας οργανώνεται κυρίως γύρω από την *Αγορά Επόμενης Ημέρας* (Day-Ahead Market (DAM)), όπου αντιστοιχίζονται προσφορές παραγωγής και ζήτησης για κάθε ωριαία περίοδο της επόμενης ημέρας [2]. Σε αυτές τις αγορές, η αποτελεσματική κατανομή πόρων βασίζεται ολοένα και περισσότερο σε ακριβείς βραχυπρόθεσμες προβλέψεις.

Πρόβλεψη Τιμής Ηλεκτρικής Ενέργειας

Η *Πρόβλεψη Τιμής Ηλεκτρικής Ενέργειας* (Electricity Price Forecasting (EPF)) αναδύεται ως κρίσιμο εργαλείο για τη διαχείριση ρίσκου και τη βελτιστοποίηση θέσης στις ηλεκτρικές αγορές [3]. Η τιμή εκκαθάρισης της αγοράς επόμενης ημέρας (DAM clearing price) εξαρτάται από τη συνάρτηση οριακού κόστους παραγωγής, την παρεμβολή ΑΠΕ μηδενικού οριακού κόστους, τις τιμές καυσίμων και CO₂, τη ζήτηση φορτίου και τη δυναμικότητα διασυνδέσεων. Η συνδυαστική δράση αυτών των παραγόντων καθιστά την τιμή ηλεκτρισμού ιδιαίτερα *μη-γραμμική, εποχιακή και ευμετάβλητη*, με σποραδικές τιμές-ακραίες τιμές (spikes) που μπορούν να υπερβαίνουν κατά 10–20× τη μέση τιμή.

Η ακριβής πρόβλεψη παρέχει ανταγωνιστικό πλεονέκτημα σε εμπόρους ενέργειας, παραγωγούς, βιομηχανικούς καταναλωτές και συσσωρευτές (aggregators) για τη βέλτιστη ανάθεση των προσφορών τους στην DAM αλλά και στην Αγορά Εξισορρόπησης.

Πρόβλεψη Ηλεκτρικού Φορτίου

Η *Πρόβλεψη Ηλεκτρικού Φορτίου* (Electricity Load Forecasting (ELF)) προηγείται χρονολογικά της EPF ως αντικείμενο ακαδημαϊκής έρευνας [4]. Η ακριβής εκτίμηση της ζήτησης αποτελεί τον πυρήνα του προγραμματισμού παραγωγής για τους Διαχειριστές Συστήματος Μεταφοράς (Transmission System Operator (TSO)), ελαχιστοποιώντας το κόστος εξισορρόπησης και τους κινδύνους ακάλυπτης ζήτησης. Η ηλεκτρική κατανάλωση χαρακτηρίζεται από σαφή ημερήσια και εβδομαδιαία εποχικότητα (πρωινές και βραδινές αιχμές, χαμηλά φορτία Κυριακής), ενώ η επίδραση της θερμοκρασίας είναι κυρίαρχη.

Εκτός από τη χρήση του φορτίου ως αυτόνομης πρόβλεψης, η ημερήσια πρόγνωση ηλεκτρικής ζήτησης (*day-ahead load forecast*) χρησιμεύει και ως *είσοδος δύο σταδίων* στην EPF: οι προβλέψεις φορτίου δημοσιεύονται πριν την κλεισίδωση της DAM και ενσωματώνονται ως χαρακτηριστικά στα μοντέλα τιμής.

1.2 Η Ελληνική Αγορά Ηλεκτρισμού

Η ελληνική αγορά ηλεκτρισμού εντάχθηκε στο ευρωπαϊκό μοντέλο Target Model την 1η Νοεμβρίου 2020, εναρμονιζόμενη με τον κανονισμό CACM [2] και υιοθετώντας τον αλγόριθμο EUPHEMIA για τη συνδυαστική εκκαθάριση τιμών στο πλαίσιο του Single Day-Ahead Coupling (SDAC) [5]. Η γεωγραφική θέση της Ελλάδας στο νοτιοανατολικό άκρο της ευρωπαϊκής ηπείρου, με διασυνδέσεις προς Βουλγαρία, Ιταλία, Αλβανία, Βόρεια Μακεδονία και εσωτερικές νησιωτικές διασυνδέσεις, προσδίδει ιδιαίτερο χαρακτήρα στη διαμόρφωση της τιμής.


Ο Ανεξάρτητος Διαχειριστής Μεταφοράς Ηλεκτρικής Ενέργειας (ΑΔΜΗΕ) ασκεί τον ρόλο του TSO, εποπτεύοντας τη λειτουργία της Αγοράς Εξισορρόπησης και διαχειριζόμενος την ασφαλή λειτουργία του Ελληνικού Διασυνδεδεμένου Συστήματος [6]. Παράλληλα, ο ΔΑΠΕΕΠ διαχειρίζεται τη δραστηριότητα προμήθειας και εκκαθάρισης αγοράς.

Ενεργειακό Μίγμα και Τιμές


Το ενεργειακό μίγμα της Ελλάδας χαρακτηρίζεται από αυξανόμενη συμμετοχή Renewable Energy Sources (RES): η ηλιακή ισχύς υπερέβη τα 8 GW εγκατεστημένης ισχύος στα τέλη του 2024, ενώ η αιολική συνεισφορά ανέρχεται σε 5 GW. Ταυτόχρονα, το φυσικό αέριο αποτελεί τον βασικό ρυθμιστή (marginal fuel) στο 30–50% των ωρών [7]. Αυτός ο συνδυασμός δημιουργεί μια αγορά όπου η τιμή επηρεάζεται ταυτόχρονα από:

- τη διεθνή τιμή φυσικού αερίου (TTF/NBP),
- τη διεθνή τιμή δικαιωμάτων εκπομπής CO₂ (EUA),
- την ηλιακή και αιολική παραγωγή (που εισάγει αβεβαιότητα),
- τις ηλεκτρικές διασυνδέσεις με γειτονικές αγορές.

Κατά την περίοδο αξιολόγησης (Δεκέμβριος 2025 – Φεβρουάριος 2026), οι τιμές κυμάνθηκαν σε εύρος 30–200 €/MWh, με μέση τιμή 110,4 €/MWh (Δεκέμβριος 2025), ενώ τον Φεβρουάριο 2026 παρατηρήθηκε έντονη πτώση της μέσης τιμής στα 77,8 €/MWh (αλλαγή καθεστώτος τιμών) με ταυτόχρονη αύξηση της τυπικής απόκλισης (33,6 → 45,4 €/MWh).



Σχήμα 1.1. Χρονοσειρά τιμής DAM (€/MWh) για την Ελλάδα — Δεκέμβριος 2025 έως Φεβρουάριος 2026. Οι σκιαγραφημένες περιοχές δείχνουν τον Ιανουάριο και Φεβρουάριο 2026, στους οποίους παρατηρείται αυξημένη μεταβλητότητα και πτώση του επιπέδου τιμής.



Σχήμα 1.2. Χρονοσειρά φορτίου (MW) για την Ελλάδα — Δεκέμβριος 2025 έως Φεβρουάριος 2026. Το χειμερινό φορτίο εμφανίζει σαφή ημερήσια εποχικότητα και σταδιακή μείωση καθώς πλησιάζει η άνοιξη.

Βιβλιογραφικό Πλαίσιο για την Ελλάδα

Η επιστημονική βιβλιογραφία για την EPF/ELF στην ελληνική αγορά είναι περιορισμένη σε σχέση με τις αναπτυγμένες αγορές (Γερμανία, Αυστραλία, Ισπανία). Ο Κανούσης [8] εφαρμόζει XGBoost/LGBM στην ελληνική DAM τιμή για την περίοδο 2018–2023, αποδεικνύοντας την ανωτερότητα των boosting μεθόδων έναντι ARIMA/SVR. Ο Μαγκλαράς [9] επικεντρώνεται στη βραχυπρόθεσμη πρόβλεψη φορτίου με ανάλυση εποχικότητας και μοντέλα βαθιάς μάθησης. Η παρούσα εργασία επεκτείνει αυτά τα αποτελέσματα καλύπτοντας και τις δύο εργασίες, συγκρίνοντας τέσσερις στρατηγικές πρόβλεψης και αξιολογώντας σε πολλαπλές χρονικές περιόδους με ακтуαλιστικά δεδομένα 2025–2026.

1.3 Κίνητρο και Ερευνητικά Ερωτήματα

Παρά τη σημαντική πρόοδο στην EPF/ELF, διάφορα ερευνητικά κενά παραμένουν ανοικτά. Πρώτον, οι περισσότερες εργασίες αξιολογούν ένα ή δύο μοντέλα σε μία μόνο στρατηγική πρόβλεψης (συνήθως teacher-forcing), παραβλέποντας τη σύγκριση μεταξύ TF, Recursive, MIMO και Walk-Forward Retraining. Δεύτερον, σπάνια αξιολογείται ταυτόχρονα η πρόβλεψη τιμής και φορτίου υπό κοινό πειραματικό πλαίσιο. Τρίτον, η επίδοση σε μεγάλες χρονικές περιόδους (3 μήνες) με πιθανή μεταβολή κατανομής (distributional shift) παραμένει αναξιολόγητη σε πολλές εργασίες.

Οι κύριες ερευνητικές ερωτήσεις που καθοδηγούν την παρούσα εργασία είναι:

- EE1.** Ποια στρατηγική πρόβλεψης (Teacher-Forcing, Recursive, MIMO, Monthly Retraining) επιτυγχάνει τη μικρότερη MAE σε επίπεδο τιμής DAM και ηλεκτρικού φορτίου στην ελληνική αγορά;
- EE2.** Πώς επηρεάζει ο ορίζοντας αξιολόγησης (1 εβδομάδα, 1 μήνας, 3 μήνες) την κατάταξη των στρατηγικών και αλγόριθμων;
- EE3.** Υπάρχουν συστηματικές στατιστικές σημαντικές διαφορές επίδοσης μεταξύ των μοντέλων, ή παρατηρούνται αλληλεπικαλύψεις λόγω μεταβλητότητας του σήματος;
- EE4.** Ποια χαρακτηριστικά (lags, εποχικότητα, εξωγενείς παράμετροι) αξιοποιούν περισσότερο τα μοντέλα ανά στρατηγική;
- EE5.** Μπορεί η μηνιαία επανεκπαίδευση (walk-forward retraining) να αντισταθμίσει τη μεταβολή κατανομής κατά τη διάρκεια τεταρτημορίων υψηλής μεταβλητότητας (Q1 2026);

Η διατύπωση αυτών των ερωτημάτων οδήγησε στη σχεδίαση ενός ολοκληρωμένου πειραματικού πλαισίου με πέντε αλγόριθμους ML, τέσσερις στρατηγικές πρόβλεψης, τρεις χρονικές περιόδους αξιολόγησης και στατιστική επαλήθευση DM test.

1.4 Σκοπός και Κύριες Συνεισφορές

Ο σκοπός της εργασίας είναι η *συστηματική, συγκριτική αξιολόγηση στρατηγικών βραχυπρόθεσμης πρόβλεψης* τιμής DAM και ηλεκτρικού φορτίου στην ελληνική αγορά, με έμφαση στη μεθοδολογική αυστηρότητα: αποφυγή διαρροής πληροφορίας (data leakage), ακέραια αξιολόγηση εκτός δείγματος (out-of-sample) και στατιστικά έγκυρη σύγκριση.

Κύριες Συνεισφορές

1. **Σύγκριση τεσσάρων στρατηγικών πρόβλεψης** σε κοινό πειραματικό πλαίσιο: Teacher-Forcing (TF), Recursive/Open-Loop (OL) με Scheduled Sampling, Multi-Input Multi-Output (MIMO) με χρήση dense lags, και Walk-Forward Monthly Retraining. Κάθε στρατηγική εφαρμόζεται σε πέντε αλγόριθμους MM (LightGBM, XGBoost, Random Forest, SVR, MLP) για δύο εργασίες.
2. **Πολυεπίπεδη αξιολόγηση** σε τρεις χρονικές κλίμακες (Δεκέμβριος 2025 = 744h, Q4 2025 = 2208h, Q1 2026 = 2160h), αποκαλύπτοντας πώς η σχετική κατάταξη στρατηγικών και αλγόριθμων μεταβάλλεται με τον ορίζοντα και τη μεταβλητότητα της αγοράς.
3. **Walk-Forward Monthly Retraining** (μηνιαία επανεκπαίδευση): αποδεικνύεται ότι η επανεκπαίδευση κάθε μήνα μειώνει το Mean Absolute Error (MAE) τιμής κατά 27,7% (14.478 €/MWh → 10.463 €/MWh) και του φορτίου κατά 30,0% (96,8 MW → 67,7 MW) σε σχέση με στατική εκπαίδευση κατά την Q1 2026 — η σημαντικότερη βελτίωση που τεκμηριώνεται στην εργασία.
4. **Dense Lag Features για MIMO**: Η προσθήκη ενδοημερήσιων χρονικών υστερήσεων (lags 4–23) στις MIMO στρατηγικές βελτιώνει σημαντικά την ακρίβεια: Multi-Layer Perceptron (MLP) −22,3%, XGBoost −7,9%, Light Gradient Boosting Machine (LightGBM) −6,5%, RF −2,3%. Ταυτόχρονα, αποδεικνύεται ότι τα ίδια dense lags *βλάπτουν* τη Recursive στρατηγική (+2,8% για LGBM) λόγω συσσώρευσης σφάλματος.
5. **Scheduled Sampling (SS)**: Αξιολογείται η τεχνική που εκπαιδεύει το μοντέλο σε μικτές εισόδους (πραγματικές τιμές + αυτοπροβλέψεις), αποδεικνύοντας βελτίωση έναντι plain Recursive: XGBoost τιμή −1,5%, LGBM φορτίο −4,6% vs plain LGBM OL.
6. **Ανάλυση Σημαντικότητας Χαρακτηριστικών** (feature importance): Αναλύονται 15 παραλλαγές μοντέλων ανά αλγόριθμο και στρατηγική, αποκαλύπτοντας την μεταβολή της αξιοποίησης χαρακτηριστικών: υψηλή συγκέντρωση στο y_{t-1} (88,3%) για TF, ισότητα μεταξύ lag-24/48/168 για MIMO, ανάδυση αιολικής παραγωγής σε Direct-LGBM-Dense.
7. **Στατιστικός Έλεγχος Diebold-Mariano** με διόρθωση Harvey-Leybourne-Newbold (HLN) για πλήρη πίνακα σύγκρισης 18 μοντέλων ανά εργασία (324 ζεύγη), ώστε να διακριθούν στατιστικά σημαντικές από τυχαίες διαφορές επίδοσης.
8. **Διαδραστικό Dashboard**: Αναπτύσσεται αυτόνομο σύστημα οπτικοποίησης (standalone HTML/JavaScript) που επιτρέπει διαδραστική εξερεύνηση αποτελεσμάτων ανά στρατηγική, μοντέλο, εργασία και χρονική περίοδο, χωρίς απαίτηση web server ή προγραμματιστικών εργαλείων.

1.5 Δομή της Εργασίας

Η εργασία οργανώνεται σε εννέα κεφάλαια ως εξής:

Κεφάλαιο 2 — Βιβλιογραφική Ανασκόπηση:

Παρουσιάζονται οι κυριότεροι αλγόριθμοι MM που χρησιμοποιούνται στην EPF/ELF, οι στρατηγικές πολυβήματης πρόβλεψης (TF, Recursive, MIMO, Walk-Forward), η τεχνική Scheduled Sampling, η βελτιστοποίηση υπερπαραμέτρων και το πλαίσιο της ελληνικής αγοράς στη βιβλιογραφία.

Κεφάλαιο 3 — Δεδομένα και Προεπεξεργασία:

Περιγράφονται οι πηγές δεδομένων (ENTSO-E Transparency Platform), η διαδικασία συγχώνευσης και επεξεργασίας, η κατασκευή χαρακτηριστικών (lags, rolling statistics, ημερολογιακές μεταβλητές, εξωγενείς παράμετροι), και η πολιτική αποφυγής διαρροής πληροφορίας.

Κεφάλαιο 4 — Μέθοδοι Πρόβλεψης:

Παρουσιάζονται αναλυτικά οι αλγόριθμοι ML (LightGBM, XGBoost, RF, SVR, MLP), οι τέσσερις στρατηγικές πρόβλεψης με μαθηματικές εξισώσεις, η βελτιστοποίηση Optuna (OL-Aware, MIMO, CachedOptuna) και οι μετρικές αξιολόγησης (MAE, RMSE, sMAPE).

Κεφάλαιο 5 — Αποτελέσματα Αξιολόγησης:

Παρουσιάζονται τα πειραματικά αποτελέσματα σε τρεις χρονικές περιόδους και τέσσερις στρατηγικές, με αναλυτικούς πίνακες επίδοσης, διαγράμματα σύγκρισης και ανάλυση των κυριότερων ευρημάτων (αποτυχία SVR, ανωτερότητα MR, dense lags paradox).

Κεφάλαιο 6 — Σημαντικότητα Χαρακτηριστικών:

Αναλύεται η σημαντικότητα χαρακτηριστικών ανά αλγόριθμο (gain/Gini-based) και στρατηγική, παρουσιάζεται η μεταβολή στην αξιοποίηση χαρακτηριστικών μεταξύ TF, Recursive και MIMO, και εξάγονται συμπεράσματα για τη σχεδίαση feature sets.

Κεφάλαιο 7 — Στατιστικοί Έλεγχοι:

Εφαρμόζεται ο έλεγχος Diebold-Mariano με HLN διόρθωση για πλήρη πίνακα σύγκρισης 18 μοντέλων, επιτρέποντας τη διάκριση στατιστικά σημαντικών διαφορών από τυχαίες μεταβολές.

Κεφάλαιο 8 — Σύστημα Οπτικοποίησης:

Περιγράφεται η αρχιτεκτονική και η λειτουργικότητα του διαδραστικού dashboard που αναπτύχθηκε για την οπτικοποίηση και εξερεύνηση των αποτελεσμάτων.

Κεφάλαιο 9 — Συμπεράσματα:

Συνοψίζονται τα κύρια ευρήματα της εργασίας, συζητούνται οι περιορισμοί και προτείνονται κατευθύνσεις για μελλοντική έρευνα.

Κεφάλαιο 2

Βιβλιογραφική Ανασκόπηση

2.1 Εισαγωγή

Η βραχυπρόθεσμη πρόβλεψη τιμών ηλεκτρικής ενέργειας (*Electricity Price Forecasting*, EPF) αποτελεί ενεργό πεδίο έρευνας εδώ και δύο δεκαετίες [1]. Ο Weron (2014) [1] παρέχει μία εκτεταμένη επισκόπηση, οργανώνοντας τα μοντέλα σε πέντε κατηγορίες: multi-agent, fundamental, reduced-form, statistical και computational intelligence. Η πιο πρόσφατη ανασκόπηση του Lago et al. (2021) [3] επικεντρώνεται στους αλγόριθμους τελευταίας γενιάς και προτείνει ένα open-access benchmark για αντικειμενική σύγκριση.

Η πρόβλεψη φορτίου (*Electricity Load Forecasting*, ELF) έχει μακρύτερη ιστορία [10], με τα πρώτα στατιστικά μοντέλα να εμφανίζονται στα τέλη του 1980, και η εφαρμογή τεχνικών ML να παρουσιάζει ταχεία ανάπτυξη από τα μέσα του 2000 [4].

2.2 Παραδοσιακά Στατιστικά Μοντέλα

2.2.1 ARIMA/SARIMA και παραλλαγές

Τα μοντέλα ARIMA (Autoregressive Integrated Moving Average) και η εποχιακή επέκτασή τους SARIMA αποτελούν κλασικά εργαλεία για χρονοσειρές [11]. Στο πλαίσιο EPF, λόγω της ισχυρής ωριαίας και ημερήσιας εποχιακότητας, η επιλογή κατάλληλης δομής $(p, d, q)(P, D, Q)_{24/168}$ είναι κρίσιμη. Ο Kanousis (2025) [8] εφαρμόζει SARIMAX για την ελληνική αγορά με όρους Fourier αντί ημερολογιακών μεταβλητών, επιτυγχάνοντας 19% βελτίωση έναντι της persistence μεθόδου.

Παρόλα αυτά, τα ARIMA μοντέλα έχουν δύο σοβαρούς περιορισμούς: δεν μπορούν να συλλάβουν μη-γραμμικές σχέσεις και δυσκολεύονται να ενσωματώσουν πολλαπλές εξωγενείς μεταβλητές αποτελεσματικά.

2.2.2 GARCH και Υβριδικά Στατιστικά Μοντέλα

Τα μοντέλα GARCH (Generalized Autoregressive Conditional Heteroskedasticity) χρησιμοποιούνται κυρίως για τη μοντελοποίηση της μεταβλητότητας (volatility) των τιμών [1]. Στην πράξη, συνδυάζονται με ARIMA (ARMA-GARCH) για ταυτόχρονη εκτίμηση μέσης τιμής και διακύμανσης, χρήσιμο για διαχείριση κινδύνου.

2.3 Μοντέλα Μηχανικής Μάθησης

2.3.1 Δέντρα Αποφάσεων και Μέθοδοι Boosting

Τα μοντέλα βασισμένα σε δέντρα αποφάσεων, και ιδίως οι συναθροιστικές μέθοδοι (ensemble methods), έχουν κυριαρχήσει στο EPF benchmark [3]. Χαρακτηρίζονται από ισχυρή ικανότητα σύλληψης μη-γραμμικών σχέσεων χωρίς εκτεταμένη προεπεξεργασία.

Random Forest (RF): Εισήχθη από τον Breiman (2001) [12] και αποτελεί bagging ensemble δέντρων απόφασης. Αποδεικνύει καλή ανθεκτικότητα σε θόρυβο και υπερρρομγή, ιδιαίτερα με *subsampling* χαρακτηριστικών ανά κόμβο.

Gradient Boosting (XGBoost, LightGBM): Το XGBoost [13] αξιοποιεί δεύτερης τάξης κλίσεις για ταχεία βελτιστοποίηση, ενώ το LightGBM [14] εισάγει leaf-wise (αντί level-wise) ανάπτυξη δέντρων, επιτυγχάνοντας ταχύτερη εκπαίδευση με παρόμοια ή καλύτερη ακρίβεια. Και οι δύο αλγόριθμοι περιλαμβάνουν ενσωματωμένη κανονικοποίηση (L1/L2 penalties) που ελέγχει την υπερρρομγή.

Στη βιβλιογραφία EPF, το XGBoost επιτυγχάνει συνεχώς υψηλές επιδόσεις [3], [8], ενώ το LightGBM θεωρείται ελαφρώς βελτιωμένο για μεγάλα datasets [14].

2.3.2 Support Vector Regression

Η Support Vector Regression (SVR) [15] εφαρμόζει τον αλγόριθμο SVM για παλινδρόμηση, χρησιμοποιώντας ϵ -insensitive loss function. Η ισχύς της SVR έγκειται στη χρήση kernel functions (RBF, πολυωνυμικό) που επιτρέπουν ισχυρή μη-γραμμική προσαρμογή. Ωστόσο, η SVR κλιμακώνεται άσχημα με μεγάλα datasets ($O(n^2)$ training complexity), οπότε χρησιμοποιείται συνήθως με υποδειγματοληψία.

2.3.3 Νευρωνικά Δίκτυα — MLP

Τα Πολυεπίπεδα Perceptron (*Multi-Layer Perceptrons*, MLP) αποτελούν τη βασική αρχιτεκτονική βαθιάς μάθησης για πρόβλεψη χρονοσειρών [16]. Στο EPF εφαρμόζονται ως feed-forward networks με διάφορα μεγέθη κρυφών στρωμάτων, activation functions (ReLU, tanh) και regularization τεχνικές (dropout, weight decay). Σε σύγκριση με μοντέλα δέντρων, τα MLP τείνουν να υπολείπονται χωρίς ενδεδειγμένη ρύθμιση, αλλά μπορούν να αποδώσουν καλύτερα όταν οι σχέσεις είναι πολύπλοκες και τα δεδομένα αρκετά.

2.4 Βαθιά Μάθηση

2.4.1 LSTM και RNN

Τα Long Short-Term Memory (LSTM) δίκτυα [17] είναι ειδικά σχεδιασμένα για χρονοσειρές, αξιοποιώντας gates (input, forget, output) για επιλεκτική αποθήκευση μακροπρόθεσμων εξαρτήσεων. Στο EPF, τα LSTM έχουν δείξει υποσχόμενα αποτελέσματα όταν το ορόσημο εισόδου (sequence length) είναι αρκετά μεγάλο [8]. Ο Kanousis (2025) [8] χρησιμοποιεί LSTM με 168-ωριαία ακολουθία εισόδου και 1 κρυφό στρώμα 24 κυττάρων με Dropout 20%.

2.4.2 Transformer-based Μοντέλα

Τα τελευταία χρόνια, αρχιτεκτονικές βασισμένες σε Transformer [18], όπως το Informer [19] και το PatchTST, εφαρμόζονται στο EPF. Αν και προσφέρουν θεωρητικά πλεονεκτήματα

(self-attention για μακρο-εξαρτήσεις), στην πράξη δεν ξεπερνούν πάντοτε τα απλούστερα μοντέλα δέντρων σε βραχυπρόθεσμες ωριαίες προβλέψεις [20].

2.5 Στρατηγικές Πολυ-βήματης Πρόβλεψης

Ένα κρίσιμο ζήτημα που συχνά παραλείπεται στη βιβλιογραφία είναι η επιλογή της *στρατηγικής πρόβλεψης* — δηλαδή του τρόπου με τον οποίο το μοντέλο παράγει προβλέψεις για ορίζοντα $H > 1$ βημάτων.

2.5.1 Teacher-Forcing (Closed-Loop)

Στη στρατηγική Teacher-Forcing (TF), η οποία ονομάζεται επίσης Closed-Loop ή Iterated One-Step Ahead, το μοντέλο εκπαιδεύεται για πρόβλεψη ενός βήματος χρησιμοποιώντας *πραγματικές* καθυστερημένες τιμές ως χαρακτηριστικά εισόδου [21]. Κατά την αξιολόγηση, εφόσον υπάρχουν πραγματικές τιμές (δηλαδή σε offline scenario), χρησιμοποιούνται πάλι οι πραγματικές τιμές. Αυτό δίνει στρατηγικό πλεονέκτημα: δεν υπάρχει συσσώρευση σφάλματος.

Παρόλα αυτά, η TF στρατηγική δεν εφαρμόζεται σε πραγματικό χρόνο χωρίς πρόβλεψη λαγ τιμών (οπότε πρέπει να συνδυαστεί με κάποιο oracle ή να περιοριστεί σε μοντέλα που δεν χρειάζονται μελλοντικές τιμές ως χαρακτηριστικά). Στο πλαίσιο της παρούσας εργασίας, η TF αξιολογείται ως θεωρητικό άνω όριο επίδοσης.

2.5.2 Recursive / Open-Loop

Στη Recursive στρατηγική (Rec) ή Open-Loop (OL), ένα μοντέλο πρόβλεψης ενός βήματος χρησιμοποιεί τις *δικές του προβλέψεις* ως καθυστερημένα χαρακτηριστικά για να παράξει την επόμενη πρόβλεψη [22]. Αυτό αντιστοιχεί στο αυτο-αναφορικό (autoregressive) σχήμα που χρησιμοποιείται σε πραγματικό χρόνο. Το κύριο μειονέκτημα είναι η *συσσώρευση σφάλματος*: οι λανθασμένες προβλέψεις του παρελθόντος επηρεάζουν τις μελλοντικές.

Η τεχνική *Scheduled Sampling* (SS) [23] αντιμετωπίζει αυτό εκθέτοντας το μοντέλο κατά την εκπαίδευση σε συνδυασμό πραγματικών τιμών και προβλέψεων, με πιθανότητα που μεταβαίνει σταδιακά από 100% πραγματικές τιμές (TF) σε αποκλειστικά προβλέψεις (Rec). Η τεχνική αυτή βελτιώνει την ανθεκτικότητα του μοντέλου σε θόρυβο εισόδου.

2.5.3 MIMO

Η στρατηγική MIMO (Multi-Input Multi-Output) [22] εκπαιδεύει ένα μοντέλο που εξαγάγει ταυτόχρονα H τιμές για ολόκληρο τον ορίζοντα πρόβλεψης ως διάνυσμα εξόδου. Στο MIMO δεν υπάρχει recursion: το μοντέλο "βλέπει" τις τελευταίες διαθέσιμες τιμές και παράγει απευθείας το σύνολο $\{y_{t+1}, y_{t+2}, \dots, y_{t+H}\}$. Αυτό αποτρέπει τη συσσώρευση σφάλματος αλλά καθιστά την εργασία εγγενώς δυσκολότερη σε σύγκριση με TF, δεδομένου ότι ο ορίζοντας προβλέπεται χωρίς ανανέωση πληροφορίας.

Η παραλλαγή *Direct* [22] εκπαιδεύει ξεχωριστό μοντέλο ανά βήμα ορίζοντα (H ξεχωριστά μοντέλα), αποφεύγοντας την κοινή εξαγωγή αλλά διατηρώντας ανεξαρτησία ανά ορίζοντα.

2.5.4 Walk-Forward Retraining

Στη στρατηγική Walk-Forward Retraining (MR), η εκπαίδευση ανανεώνεται κυλιόμενα (rolling) σε τακτά χρονικά διαστήματα (π.χ. μηνιαία), ώστε το μοντέλο να προσαρμόζεται σε μεταβαλλόμενες συνθήκες [24]. Αυτό είναι ιδιαίτερα σημαντικό για αγορές που χαρακτηρίζονται από *distribution shifts* λόγω αλλαγής ενεργειακού μίγματος, τιμών φυσικού αερίου κ.λπ.

2.6 Βιβλιογραφία για την Ελληνική Αγορά

Η βιβλιογραφία για την Ελληνική αγορά παραμένει σχετικά περιορισμένη. Ο Kanousis (2025) [8] είναι από τις πρώτες εργασίες που εφαρμόζει σύγχρονους αλγόριθμους (RF, XGBoost, SARIMA, LSTM) για την πρόβλεψη τιμής DAM της ελληνικής αγοράς για ολόκληρο το 2024, επιτυγχάνοντας XGBoost MAE 6,5 €/MWh. Χρησιμοποιεί day-ahead προβλέψεις φορτίου, ηλιακής και αιολικής παραγωγής ως εξωγενείς μεταβλητές. Ο Magklaras [9] εξετάζει βραχυπρόθεσμη πρόβλεψη ηλεκτρικού φορτίου σε γραμμές μέσης τάσης Ελλάδος και Ιταλίας, χρησιμοποιώντας LSTM, MLP, CNN και ANN.

Γενικότερα, για ευρωπαϊκές αγορές, η εργασία των Marcjasz et al. (2018) [25] δείχνει ότι ML μοντέλα (ιδίως GBM) υπερτερούν σταθερά έναντι στατιστικών μοντέλων στην ωριαία πρόβλεψη DAM τιμής. Ο Uniejewski et al. (2019) [26] υποστηρίζει ότι η κανονικοποίηση εξόδου (variance stabilization) βελτιώνει σημαντικά τα αποτελέσματα.

2.7 Σύγκριση με την Παρούσα Εργασία

Πίνακας 2.1. Σύγκριση με εκπροσωπευτικές εργασίες της βιβλιογραφίας.

Εργασία	Αγορά	Εργασία	Αλγόριθμοι	Στρατηγικές	DM test
Lago et al. 2021 Kanousis 2025	Πολλές (EU) Ελλάδα	Τιμή Τιμή	Πολλοί RF, XGB, SARIMA, LSTM	1-step rolling TF	Nai Nai
Magklaras 2022	Ελλάδα/Ιταλία	Φορτίο	LSTM, MLP, CNN	1-step	Όχι
Παρούσα	Ελλάδα	Τιμή + Φορτίο	LGBM, XGB, RF, SVR, MLP	TF, Rec/OL, MIMO, MR	Nai

Η παρούσα εργασία διαφοροποιείται από τις υφιστάμενες κυρίως ως προς: (α) τη σύγκριση τεσσάρων διαφορετικών στρατηγικών πρόβλεψης, (β) τη συνδυαστική αξιολόγηση τιμής και φορτίου, (γ) την αξιολόγηση σε πολλαπλές χρονικές κλίμακες (1 εβδομάδα, 1 μήνας, 3 μήνες), και (δ) τη χρήση Monthly Retraining ως στρατηγική που εισάγει δυναμική προσαρμογή.

Κεφάλαιο 3

Δεδομένα και Προεπεξεργασία

3.1 Πηγές Δεδομένων

Όλα τα δεδομένα αντλήθηκαν από το **ENTSO-E Transparency Platform** [27], το οποίο παρέχει ανοικτά δεδομένα για ευρωπαϊκές αγορές ηλεκτρισμού. Συγκεκριμένα, χρησιμοποιήθηκαν οι παρακάτω πηγές:

- **Day-Ahead Market τιμές (€/MWh):** Ωριαίες τιμές εκκαθάρισης της ελληνικής ζώνης υποβολής προσφορών (GR), για την περίοδο Ιανουαρίου 2017 – Μαρτίου 2026.
- **Πραγματικό Ηλεκτρικό Φορτίο (MW):** Ωριαίο φορτίο ζήτησης για την Ελλάδα.
- **Day-Ahead Πρόβλεψη Φορτίου (MW):** Δημοσιευμένη από τον ΑΔΜΗΕ πριν την εκκαθάριση DAM [28]. Χρησιμοποιείται ως *νόμιμο* μελλοντικό χαρακτηριστικό στην πρόβλεψη τιμής.
- **Παραγωγή ΑΠΕ (MW):** Πραγματική ωριαία παραγωγή ηλιακής, αιολικής, υδροηλεκτρικής, λιγνιτικής και αερίου παραγωγής, από τα δεδομένα Actual Generation per Production Type (A75). Τα δεδομένα παρέχονται σε 15-λεπτη ανάλυση και συναθροίζονται σε ωριαία.
- **Τιμή Φυσικού Αερίου TTF (€/MWh):** Ημερήσιες τιμές day-ahead της ολλανδικής αγοράς TTF, ως proxy του οριακού καυσίμου στην ελληνική αγορά. Για την περίοδο Νοεμβρίου 2025 – Φεβρουαρίου 2026, οι τιμές είναι συνθετικές (γραμμικά παρεμβαλλόμενες από anchor points).
- **Τιμή CO₂ (€/τόνο):** Ημερήσιες τιμές δικαιωμάτων εκπομπών EU ETS.

Το ολοκληρωμένο dataset περιλαμβάνει **80.126 ωριαίες παρατηρήσεις** (Ιαν. 2017 – Μαρ. 2026).

3.2 Χρονοσειρά Τιμών DAM

Η χρονοσειρά τιμών της ελληνικής αγοράς DAM εμφανίζει έντονες εποχιακές συνιστώσες:

- **Ωριαία εποχιακότητα:** Οι ώρες αιχμής (19:00–22:00) έχουν σταθερά υψηλότερες τιμές σε σχέση με τις ώρες κοιλάδας (3:00–6:00).

- **Εβδομαδιαία εποχιακότητα:** Τα Σαββατοκύριακα εμφανίζουν χαμηλότερο φορτίο και επομένως χαμηλότερες τιμές.
- **Ετήσια εποχιακότητα:** Υψηλές τιμές το καλοκαίρι (κλιματισμός) και τον χειμώνα (θέρμανση), χαμηλές την άνοιξη.

Χαρακτηριστικά στατιστικά της περιόδου αξιολόγησης (Q1 2026, Δεκ. 2025 – Φεβ. 2026):

Πίνακας 3.1. Στατιστικά περιγραφικά τιμής DAM ανά μήνα (Q1 2026).

Μήνας	Μέση τιμή (€)	T.A. (€)	Ελάχ. (€)	Μέγ. (€)	Naive-1 MAE
Δεκ. 2025	110,4	33,6	0,0	210,0	10,86
Ιαν. 2026	109,4	41,7	0,0	290,0	12,26
Φεβ. 2026	77,8	45,4	0,0	275,0	13,60

Αξιοσημείωτο είναι το **regime shift** του Φεβρουαρίου 2026: η μέση τιμή πέφτει από 110€ σε 78€ (−29%), ενώ η μεταβλητότητα αυξάνεται σε τυπική απόκλιση 45,4 €/MWh. Αυτό οφείλεται σε συνδυασμό αυξημένης ηλιακής παραγωγής (μεταβατική περίοδος προς άνοιξη) και μεταβολής στο ενεργειακό μίγμα.

3.3 Χρονοσειρά Ηλεκτρικού Φορτίου

Το ηλεκτρικό φορτίο της Ελλάδας χαρακτηρίζεται από σχετικά σταθερά εποχιακά πρότυπα:

Πίνακας 3.2. Στατιστικά περιγραφικά φορτίου ανά μήνα (Q1 2026).

Μήνας	Μέση τιμή (MW)	T.A. (MW)	Ελάχ. (MW)	Μέγ. (MW)
Δεκ. 2025	5.740	910	3.800	8.100
Ιαν. 2026	5.820	980	3.700	8.400
Φεβ. 2026	5.630	870	3.600	7.900

Σε αντίθεση με την τιμή, το φορτίο παρουσιάζει πιο ομαλή κατανομή και χαμηλότερη σχετική μεταβλητότητα (T.A./Μέση $\approx$ 15–17% για φορτίο έναντι 30–58% για τιμή), γεγονός που εξηγεί γιατί η πρόβλεψη φορτίου επιτυγχάνει γενικά χαμηλότερο sMAPE.

3.4 Κατασκευή Χαρακτηριστικών (Feature Engineering)

3.4.1 Χρονικές Υστερήσεις (Lag Features)

Οι χρονικές υστερήσεις της μεταβλητής στόχου αποτελούν τα σημαντικότερα χαρακτηριστικά για ωριαίες χρονοσειρές. Χρησιμοποιήθηκαν:

- **Lag-1:** Η τιμή ή το φορτίο της προηγούμενης ώρας.
- **Lag-2:** Η τιμή ή το φορτίο 2 ώρες πριν.
- **Lag-24:** Η ίδια ώρα της προηγούμενης ημέρας (ισχυρή ωριαία εποχιακότητα).
- **Lag-48:** Η ίδια ώρα 2 ημέρες πριν.

- **Lag-168:** Η ίδια ώρα της προηγούμενης εβδομάδας (εβδομαδιαία εποχιακότητα).

Για τα MIMO μοντέλα με *dense lags*, προστέθηκαν επίσης οι υστερήσεις lag-3 έως lag-23, δηλαδή τιμές κάθε ώρας μέσα στην ίδια ημέρα.

3.4.2 Κυλιόμενα Στατιστικά (Rolling Features)

- **roll_24:** Κυλιόμενος μέσος 24 ωρών.
- **roll_48, roll_168:** Κυλιόμενοι μέσοι 48 και 168 ωρών.

3.4.3 Ημερολογιακά Χαρακτηριστικά

- **hour:** Ώρα ημέρας (0–23), ως κυκλική κωδικοποίηση ($\sin$, $\cos$).
- **day_of_week:** Ημέρα εβδομάδας (0–6), ως κυκλική κωδικοποίηση.
- **month:** Μήνας (1–12), ως κυκλική κωδικοποίηση.
- **is_weekend:** Δυαδικό (1 = Σ/Κ, 0 = εργάσιμη).
- **is_holiday:** Δυαδικό για ελληνικές αργίες.

3.4.4 Εξωγενείς Μεταβλητές

Πίνακας 3.3. Εξωγενή χαρακτηριστικά και η αντίστοιχη διαθεσιμότητά τους πριν DAM gate closure.

Χαρακτηριστικό	Περιγραφή	Εργασία	Νόμιμο;
load_fc	Day-ahead πρόβλεψη φορτίου (MW)	Τιμή	Ναι
gas_price(D)	Τιμή TTF φυσικού αερίου (€/MWh)	Τιμή	Οριακά
co2_price(D)	Τιμή δικαιωμάτων CO ₂ (€/τόνο)	Τιμή	Οριακά
gen_solar_lag1	Lag-1 ηλιακής παραγωγής (MW)	Τιμή, Φορτίο	Ναι
gen_wind_lag1	Lag-1 αιολικής παραγωγής (MW)	Τιμή, Φορτίο	Ναι
gen_gas	Παραγωγή αερίου (MW, lagged)	Τιμή	Ναι
gen_lignite	Παραγωγή λιγνίτη (MW, lagged)	Τιμή	Ναι
gen_hydro	Παραγωγή υδρο/ηλεκ. (MW, lagged)	Τιμή	Ναι

Σχόλιο διαρροής: Τα gas_price(D) και co2_price(D) αποτελούν τιμές ίδιας ημέρας (day-ahead futures). Τεχνικά δημοσιεύονται πριν την εκκαθάριση DAM και αποτελούν standard χαρακτηριστικά στη βιβλιογραφία EPF [3]. Για την εργασία φορτίου, η τιμή DAM δεν χρησιμοποιείται (μελλοντική άγνωστη κατά τον DAM), ενώ η παραγωγή ΑΠΕ αξιοποιείται μόνο ως υστερήσεις (lagged values).

3.5 Χρονικός Διαχωρισμός

Ακολουθείται αυστηρός χρονικός διαχωρισμός εκπαίδευσης–ελέγχου για αποφυγή *data leakage* [29]:

Πίνακας 3.4. Χρονικός διαχωρισμός dataset.

Σετ	Περίοδος	Σχόλιο
Εκπαίδευση	Ιαν. 2017 – Νοε. 2025	≈76.000 παρατηρήσεις
Δοκιμή 1W	Δεκ. 1–7, 2025 (168h)	Βραχυπρόθεσμη αξιολόγηση
Δοκιμή 1M	Δεκ. 1–31, 2025 (744h)	Μηνιαία αξιολόγηση
Δοκιμή Q4	Οκτ. 1 – Δεκ. 31, 2025 (2208h)	Τριμηνιαία (εκπ. έως Σεπτ. 2025)
Δοκιμή Q1	Δεκ. 1, 2025 – Φεβ. 28, 2026 (2160h)	Κύρια αξιολόγηση

Για τη στρατηγική Monthly Retraining (MR), η εκπαίδευση ανανεώνεται στο τέλος κάθε μήνα:

- Δεκ. 2025: εκπαίδευση έως Νοε. 2025, πρόβλεψη Δεκ. 2025
- Ιαν. 2026: εκπαίδευση έως Δεκ. 2025, πρόβλεψη Ιαν. 2026
- Φεβ. 2026: εκπαίδευση έως Ιαν. 2026, πρόβλεψη Φεβ. 2026

3.5.1 Σύνολο Χαρακτηριστικών

Το τελικό σύνολο χαρακτηριστικών για κάθε εργασία:

Πίνακας 3.5. Αριθμός χαρακτηριστικών ανά εργασία και παραλλαγή.

Παραλλαγή	Τιμή	Φορτίο
Standard (βασικά lags)	152	133
Dense (+ lags 3–23)	170	151
MIMO Two-Stage (+ 24 load forecasts)	176	—
MIMO Two-Stage Dense	194	—

Κεφάλαιο 4

Μέθοδοι Πρόβλεψης

4.1 Γραμμές Βάσης (Baselines)

Τρεις κλασικές γραμμές βάσης χρησιμοποιούνται για αξιολόγηση:

Naive-1: $\hat{y}_{t+1} = y_t$. Πρόβλεψη ίση με την τελευταία παρατηρηθείσα τιμή.

Naive-24: $\hat{y}_{t+1} = y_{t-23}$. Πρόβλεψη ίση με την τιμή της ίδιας ώρας χθες. Αποτελεί φυσικό ανταγωνιστή για MIMO H=24 (προβλέπει ολόκληρη ημέρα από χθες).

Seasonal Profile: Η πρόβλεψη βασίζεται στον μέσο όρο ιστορικών τιμών για την ίδια ώρα και ημέρα εβδομάδας.

Τα Naive-1/24 είναι ιδιαίτερα χρήσιμα γιατί σε ορισμένες περιόδους υψηλής μεταβλητότητας (π.χ. Q4 2025) ξεπερνούν τα ML μοντέλα σε εβδομαδιαίο ορίζοντα.

4.2 Αλγόριθμοι Μηχανικής Μάθησης

4.2.1 LightGBM

Το LightGBM [14] αποτελεί gradient boosting framework με leaf-wise ανάπτυξη δέντρων. Στην παρούσα εργασία, ο βασικός configuration που χρησιμοποιείται είναι:

Πίνακας 4.1. Παράμετροι LightGBM (standard CL models).

Παράμετρος	Τιμή
n_estimators	1000
learning_rate	0.05 (default)
num_leaves	31 (default)
objective	regression (MAE)
early_stopping_rounds	50

Τα βελτιστοποιημένα μοντέλα (Optuna) χρησιμοποιούν: n_est=900, lr=0.027, num_leaves=26, min_child=54, subsample=0.925, colsample=0.641.

4.2.2 XGBoost

Το XGBoost [13] χρησιμοποιεί level-wise ανάπτυξη δέντρων με second-order gradient approximation. Τυπικές παράμετροι:

Πίνακας 4.2. Παράμετροι XGBoost (standard CL models).

Παράμετρος	Τιμή
n_estimators	1000
learning_rate	0.05
max_depth	6
objective	reg:absoluteerror
early_stopping_rounds	50

4.2.3 Random Forest

Το Random Forest [12] εκπαιδεύεται με:

- n_estimators=400 (600 για MIMO two-stage)
- max_features="sqrt" (περίπου 12 από τα 152 χαρακτηριστικά ανά split, κρίσιμο για ταχύτητα στα Windows χωρίς loky deadlock)
- max_depth=16, min_samples_split=4, n_jobs=1

4.2.4 Support Vector Regression

Η SVR [15] χρησιμοποιεί RBF kernel με $C = 10$, $\varepsilon = 0.1$, προεπεξεργασία StandardScaler. Λόγω του $O(n^2)$ κόστους εκπαίδευσης, τα MIMO SVR μοντέλα εκπαιδεύτηκαν σε 5.000 τυχαία δείγματα (από τα 76.000 διαθέσιμα), κάτι που επηρεάζει αρνητικά την επίδοσή τους.

4.2.5 Multi-Layer Perceptron (MLP)

Το MLP υλοποιείται με PyTorch και sklearn wrapper (MLPRegressor):

- **CL/OL:** hidden=(512,256), lr=5e-4, max_iter=300, early stopping
- **MIMO:** hidden=(256,128), lr=5e-4, max_iter=400, StandardScaler προεπεξεργασία
- **MLP-Optuna CL:** hidden=[64] τιμή, hidden=[128,64] φορτίο, tuned dropout/lr/wd

4.3 Στρατηγικές Πρόβλεψης

4.3.1 Teacher-Forcing (TF / Closed-Loop)

Το μοντέλο εκπαιδεύεται για πρόβλεψη ενός βήματος:

$$\hat{y}_{t+1} = f(\mathbf{x}_t, y_t, y_{t-1}, y_{t-23}, y_{t-47}, y_{t-167}) \quad (4.1)$$

όπου $\mathbf{x}_t$ περιλαμβάνει τα εξωγενή χαρακτηριστικά. Κατά την αξιολόγηση χρησιμοποιούνται πραγματικές καθυστερημένες τιμές, επομένως δεν υπάρχει συσσώρευση σφάλματος.

4.3.2 Recursive (Open-Loop) με Scheduled Sampling

Στη Recursive στρατηγική, για $h > 1$:

$$\hat{y}_{t+h} = f(\mathbf{x}_{t+h-1}, \hat{y}_{t+h-1}, \hat{y}_{t+h-2}, \dots) \quad (4.2)$$

Η αξιολόγηση γίνεται σε daily chunks (24 ώρες) ή weekly chunks (168 ώρες).

Η τεχνική **Scheduled Sampling** [23] εκπαιδεύει το μοντέλο με πιθανότητα ε_k να χρησιμοποιήσει τη δική του πρόβλεψη αντί της πραγματικής τιμής:

$$\varepsilon_k = \min\left(\varepsilon_{\text{final}}, \varepsilon_{\text{start}} + \frac{k-1}{K-1} (\varepsilon_{\text{final}} - \varepsilon_{\text{start}})\right) \quad (4.3)$$

με $\varepsilon_{\text{start}} = 0.10$, $\varepsilon_{\text{final}} = 0.40$ σε $K = 3$ iterations. Αυτό βελτιώνει την ανθεκτικότητα του μοντέλου σε θόρυβο εισόδου κατά την recursive αξιολόγηση.

4.3.3 Multi-Input Multi-Output (MIMO)

Ένα μοντέλο εκπαιδεύεται να παράγει ταυτόχρονα $H = 24$ τιμές:

$$[\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+24}] = f(\mathbf{x}_t, y_t, y_{t-23}, y_{t-47}, y_{t-167}) \quad (4.4)$$

Για τα δέντρα (RF, XGB, LGBM) χρησιμοποιείται `MultiOutputRegressor`.

Two-Stage MIMO για τιμή: Αρχικά εκπαιδεύεται MIMO μοντέλο φορτίου ($H = 24$), στη συνέχεια τα 24 forecast φορτίου ενσωματώνονται ως επιπλέον χαρακτηριστικά (176 ή 194 features) για την εκπαίδευση MIMO μοντέλου τιμής. Αυτό αντικατοπτρίζει την αιτιώδη σχέση φορτίου-τιμής.

4.3.4 Walk-Forward Monthly Retraining

$$\mathcal{D}_m = \{(x_t, y_t) : t \leq \text{end of month } (m-1)\} \quad (4.5)$$

Κάθε μήνα m , το μοντέλο επανεκπαιδεύεται στο σύνολο $\mathcal{D}_m$ και αξιολογείται στον μήνα m . Η εκπαίδευση χρησιμοποιεί κυλιόμενο παράθυρο ή expanding window (επέκταση από Ιαν. 2017).

Για την Teacher-Forcing παραλλαγή (TF-MR), χρησιμοποιούνται πραγματικές lagged τιμές. Για τη Recursive παραλλαγή (Rec-SS-DO-MR), συνδυάζεται Scheduled Sampling και Daily Optuna (Optuna ανά μήνα, 15 trials, 2 splits).

4.4 Βελτιστοποίηση Υπερπαραμέτρων (Optuna)

Χρησιμοποιείται το πλαίσιο Optuna [30] για αυτόματη βελτιστοποίηση υπερπαραμέτρων με Tree-structured Parzen Estimator (TPE) sampler.

4.4.1 OL-Aware Daily Optuna

Η συνάρτηση αξιολόγησης (objective function) μιμείται την πραγματική recursive αξιολόγηση: κάθε fold αξιολογεί σε ωριαία chunks 24 ωρών χρησιμοποιώντας τις προβλέψεις ως lagged εισόδους. Αυτό αποτρέπει *CV leakage*: το CV χρησιμοποιεί recursive predictions (όχι teacher-forcing), οπότε η βελτίωση CV αντανakλά πράγματι βελτίωση στο test.

Αντίθετα, το standard Optuna με TF-CV (χρήση πραγματικών τιμών) παρουσιάζει *CV leakage* για OL μοντέλα: βελτίωση CV δεν μεταφέρεται σε βελτίωση test (παρατηρήθηκε για LGBM Dense OL).

4.4.2 MIMO Optuna

Για MIMO, χρησιμοποιείται MultiOutputRegressor και k -fold CV με rolling-origin splits, αξιολογώντας τον μέσο MAE για όλα τα 24 βήματα ορίζοντα.

4.4.3 CachedOptuna

Για Monthly Retraining, οι υπερπαράμετροι βελτιστοποιούνται *μία φορά* στο πλήρες training set (train_end=Νοε. 2025, 40–60 trials) και αποθηκεύονται ως JSON. Κάθε μηνιαία επανεκπαίδευση χρησιμοποιεί τις αποθηκευμένες παραμέτρους χωρίς νέο Optuna. Αυτό επιταχύνει σημαντικά τη διαδικασία και αποφεύγει overfitting του Optuna σε μικρά validation sets.

4.5 Μετρικές Αξιολόγησης

Χρησιμοποιούνται τρεις μετρικές:

MAE (Mean Absolute Error):

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |y_t - \hat{y}_t| \quad (4.6)$$

Ερμηνεύεται άμεσα σε μονάδες τιμής (€/MWh) ή φορτίου (MW).

RMSE (Root Mean Squared Error):

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (y_t - \hat{y}_t)^2} \quad (4.7)$$

Τιμωρεί πιο αυστηρά τα μεγάλα σφάλματα (outliers).

sMAPE (symmetric Mean Absolute Percentage Error):

$$\text{sMAPE} = \frac{100\%}{T} \sum_{t=1}^T \frac{|y_t - \hat{y}_t|}{\frac{1}{2}(|y_t| + |\hat{y}_t|)} \quad (4.8)$$

Παρέχει κανονικοποιημένο σφάλμα (ποσοστό), χρήσιμο για σύγκριση μεταξύ περιόδων διαφορετικής μέσης τιμής.

Ο Weron (2014) [1] και ο Lago et al. (2021) [3] συνιστούν τη χρήση MAE ως κύριας μετρικής για EPF, καθώς είναι ρωμαλέα σε ακραίες τιμές και αποφεύγει τα προβλήματα διαίρεσης με το μηδέν που παρουσιάζει το MAPE. Η παρούσα εργασία ακολουθεί αυτή τη σύσταση.

Κεφάλαιο 5

Αποτελέσματα Αξιολόγησης

5.1 Κλειστός Βρόχος — Teacher-Forcing (CL/TF)

5.1.1 Αποτελέσματα 1 Μήνα (Δεκέμβριος 2025)

Στον Πίνακα 5.1 παρουσιάζονται τα αποτελέσματα για την πρόβλεψη τιμής DAM με teacher-forcing για τον Δεκέμβριο 2025. Η εκπαίδευση έγινε με δεδομένα έως 30 Νοε. 2025.

Πίνακας 5.1. Αποτελέσματα Κλειστού Βρόχου (TF) – Τιμή, Δεκ. 2025 (744h).

Μοντέλο	MAE (€/MWh)	RMSE (€)	sMAPE (%)	Κατάταξη
Ensemble-Best3 (1/MAE)	9,943	—	—	1
XGBoost	10,204	16,170	11,087	2
LightGBM	10,334	16,236	11,178	3
RandomForest	11,220	18,206	11,467	4
MLP-Optuna	11,686	17,498	12,108	5
SVR	13,432	19,070	13,666	6
Naive-1 (baseline)	13,709	22,748	13,013	—
Seasonal Profile	21,524	32,157	18,389	—

Πίνακας 5.2. Αποτελέσματα Κλειστού Βρόχου (TF) – Φορτίο, Δεκ. 2025 (744h).

Μοντέλο	MAE (MW)	RMSE (MW)	sMAPE (%)
Ensemble-Best3 (1/MAE)	72,916	—	—
XGBoost	75,885	—	—
LightGBM	76,324	—	—
MLP-Optuna	78,992	—	—
RandomForest	96,539	—	—
SVR	141,406	—	—
Seasonal Profile (baseline)	233,857	297,714	4,177
Naive-1 (baseline)	241,807	304,823	4,439

Βασικές Παρατηρήσεις:

- Το Ensemble-Best3 (σταθμισμένος 1/MAE μέσος XGB+LGBM+RF) επιτυγχάνει το καλύτερο MAE τιμής (9,943 €/MWh), βελτιώνοντας κατά 27% έναντι του Naive-1 (13,709 €/MWh).

- Για φορτίο, το Ensemble-Best3 επιτυγχάνει 72,916 MW, αντιπροσωπεύοντας 70% βελτίωση έναντι Seasonal Profile (233 MW).
- Η SVR αποδίδει σημαντικά χειρότερα από τα tree models — αδυναμία που εντείνεται για μεγαλύτερες περιόδους αξιολόγησης.

5.1.2 Αποτελέσματα Q1 2026 (Δεκ. 2025 – Φεβ. 2026)

Η επέκταση σε τριμηνιαία αξιολόγηση (2160 ώρες) αποκαλύπτει σημαντική αύξηση σφάλματος για όλα τα μοντέλα, ιδιαίτερα για SVR που αποτυγχάνει παταγωδώς τον Ιανουάριο-Φεβρουάριο 2026:

Πίνακας 5.3. Αποτελέσματα CL – Τιμή, Q1 2026 (2160h).

Μοντέλο	MAE (€/MWh)	RMSE (€)	sMAPE (%)	Κατάταξη
Ensemble-Best3	14,478	22,193	25,085	1
LightGBM	14,556	22,292	25,541	2
RandomForest	15,161	23,634	25,072	3
Naive-1	15,433	26,781	22,635	—
XGBoost	15,888	23,353	26,519	4
MLP-Optuna	17,917	25,209	28,367	5
MLP	18,707	25,136	28,722	6
SVR	40,775	53,172	41,412	□

Η κατάρρευση της SVR ($MAE = 40,8 \text{ €/MWh}$) αποδίδεται στη μετατόπιση κατανομής (distribution shift): εκπαίδευση σε διάστημα 2017–2025 με μέση τιμή $\approx 80 \text{ €/MWh}$, αλλά τον Ιανουάριο 2026 η αγορά παρουσιάζει υψηλή μεταβλητότητα άνω των 200 €/MWh .

5.2 Ανοικτός Βρόχος — Recursive (OL)

5.2.1 Δεκέμβριος 2025 (Μηνιαία Αξιολόγηση)

Πίνακας 5.4. Open-Loop H=24 (daily) – Τιμή, Δεκ. 2025.

Μοντέλο	MAE (€/MWh)	RMSE (€)	Chunks	Κατάταξη
Ensemble-Top3 1/MAE	13,960	21,958	24h	1
LGBM-Daily-Optuna	14,494	22,511	24h	2
RF-Daily-SS	14,607	23,015	24h	3
XGB-Daily-SS-Optuna Dense	14,816	—	24h	4
LGBM-Daily-SS-Optuna Dense	14,744	—	24h	5
MLP-SS	15,169	22,065	24h	6
XGB-OL-Optuna (weekly)	17,007	26,404	168h	7
SVR-OL	18,549	25,602	24h	8
Naive-1	14,930	25,963	—	—

Κύρια εύρηματα OL τιμής:

- Τα daily chunks (H=24) υπερτερούν σημαντικά έναντι weekly (H=168): $-16,7\%$ MAE (14,494 vs 17,410 €/MWh για LGBM). Η συσσώρευση σφάλματος σε 168 βήματα είναι σημαντικά μεγαλύτερη.

- Το Ensemble-Top3 (LGBM+RF+XGB, σχεδόν ίσα βάρη ≈ 0.33) επιτυγχάνει $-19,8\%$ έναντι εβδομαδιαίου βέλτιστου.
- Το SS δεν βοηθάει το LGBM ($14,494 \rightarrow 14,986$, χειρότερο), αλλά βοηθάει το XGB ($15,312 \rightarrow 15,036$, βελτίωση). Υπόθεση: LGBM (leaf-wise) είναι ήδη ανθεκτικό, ενώ XGB ωφελείται από καλύτερη ρύθμιση.

Πίνακας 5.5. Open-Loop H=24 – Φορτίο, Δεκ. 2025.

Μοντέλο	MAE (MW)	Κατάταξη
LGBM-Daily-SS-Optuna	80,704	1
XGB-Daily-Optuna	99,575	2
RF-Daily-SS	117,740	3
MLP-SS	122,604	4
SVR-OL	184,739	5

Για φορτίο, το SS βοηθάει το LGBM (80,7 vs ≈ 90 MW για LGBM χωρίς SS), αντίθετα από ό,τι συμβαίνει με την τιμή.

5.3 MIMO (Multi-Input Multi-Output)

Πίνακας 5.6. MIMO H=24 – Τιμή, Δεκ. 2025 (744h, daily prediction).

Μοντέλο	MAE (€/MWh)	RMSE (€)	Κατάταξη
Ensemble-Best3 1/MAE	15,202	—	1
XGB MIMO Dense	15,503	23,896	2
LGBM Direct Dense	15,521	24,075	3
LGBM Direct+Load (two-stage)	16,190	24,630	4
RF MIMO+Load Dense	16,812	25,920	5
SVR MIMO+Load Dense	18,048	25,651	6
MLP MIMO+Load Dense	19,966	27,652	7
Seasonal Profile	18,127	27,388	—
Naive-24 (MIMO context)	18,213	—	—

Πίνακας 5.7. MIMO H=24 – Φορτίο, Δεκ. 2025 (744h).

Μοντέλο	MAE (MW)	RMSE (MW)	Κατάταξη
Ensemble-Best3 1/MAE	189,005	—	1
XGB MIMO Dense	190,308	295,817	2
LGBM Direct Dense	194,417	304,411	3
RF MIMO	219,250	313,966	4
MLP MIMO	219,884	308,093	5
Seasonal Profile	291,557	396,534	—
SVR MIMO (5K rows)	586,623	—	□

Dense Lags και MIMO: Τα dense intraday lags (lag 3–23) βοηθούν σημαντικά στο MIMO, διότι κατά την εκπαίδευση MIMO χρησιμοποιούνται *πραγματικές* ιστορικές τιμές (όχι αναδρομικές προβλέψεις), επομένως δεν υπάρχει θόρυβος:

- XGB Dense MIMO τιμή: −7,9% (16,839 → 15,503 €/MWh)
- LGBM Dense Direct τιμή: −6,5% (16,591 → 15,521 €/MWh)
- MLP Dense MIMO τιμή: −22,3% (25,710 → 19,966 €/MWh)

Αντίθετα, τα dense lags *βλάπτουν* τα OL μοντέλα (LGBM Dense OL: +2,8% χειρότερο), διότι στο recursive inference, οι lags 3–23 υπολογίζονται από θορυβώδεις αναδρομικές προβλέψεις.

5.4 Walk-Forward Monthly Retraining (MR)

Τα αποτελέσματα Monthly Retraining για Q1 2026 (2160 ώρες) παρουσιάζονται στους παρακάτω πίνακες.

Πίνακας 5.8. Walk-Forward Monthly Retrain – Τιμή, Q1 2026.

Μοντέλο	Στρατηγική	MAE (€/MWh)	RMSE (€)	Κατ.
Ensemble-TF-Best3	TF	10,491	15,726	1
TF-LGBM-MR	TF	10,463	15,682	2
TF-XGB-MR	TF	10,913	16,148	3
Naive-1	Baseline	12,218	20,042	—
TF-RF-MR	TF	12,806	19,089	4
TF-MLP-MR	TF	15,620	22,458	5
Rec-XGB-SS-DO-MR	Rec	18,534	27,496	6
Rec-XGB-DO-MR	Rec	18,963	28,087	7
Rec-LGBM-SS-DO-MR	Rec	19,005	28,281	8
Seasonal Profile	Baseline	25,054	36,813	—

Πίνακας 5.9. Ανάλυση ανά μήνα – TF Monthly Retrain, τιμή.

Μήνας	TF-LGBM	TF-XGB	TF-RF	TF-MLP	Rec-XGB-SS
Δεκ. 2025	8,607	8,708	10,945	10,483	14,229
Ιαν. 2026	11,228	12,567	12,161	22,078	18,071
Φεβ. 2026	11,670	11,524	15,582	14,156	23,814
Σύνολο Q1	10,463	10,913	12,806	15,620	18,534

Πίνακας 5.10. Walk-Forward Monthly Retrain – Φορτίο, Q1 2026.

Μοντέλο	Στρατηγική	MAE (MW)	RMSE (MW)	Κατ.
Ensemble-TF-Best3	TF	67,729	89,324	1
TF-LGBM-MR	TF	69,435	92,490	2
Rec-XGB-SS-DO-MR	Rec	70,641	93,179	3
TF-XGB-MR	TF	72,925	95,540	4
Rec-LGBM-SS-DO-MR	Rec	72,573	95,902	5
TF-MLP-MR	TF	88,493	116,316	6
TF-RF-MR	TF	100,177	136,509	7

Κύριο εύρημα: Η μηνιαία επανεκπαίδευση μειώνει το MAE:

- Τιμή: 14,478 → 10,463 €/MWh (−27, 7%) έναντι στατικής CL εκπαίδευσης.
- Φορτίο: 96,751 → 67,729 MW (−30, 0%).

Εξαιρετικά σημαντικό εύρημα: για φορτίο, η Rec-XGB-SS-DO-MR (70,641 MW) σχεδόν εξισώνεται με το TF-LGBM-MR (69,435 MW). Αυτό δείχνει ότι η συσσώρευση σφάλματος είναι πολύ μικρότερη για φορτίο απ' ό,τι για τιμή, λόγω της φύσεως ομαλότητας.


5.5 Σύγκριση Στρατηγικών

Πίνακας 5.11. Συγκεντρωτική σύγκριση βέλτιστων μοντέλων ανά στρατηγική.


Στρατηγική	Τιμή MAE (€/MWh)		Φορτίο MAE (MW)	
	Dec'25	Q1'26	Dec'25	Q1'26
TF/CL Ensemble-Best3	9,943	14,478	72,916	96,751
OL Ensemble-Top3	13,960	20,094	80,704	102,961
MIMO Ensemble-Best3	15,202	20,896	189,005	217,088
MR TF Ensemble-Best3	—	10,491	—	67,729
Naive-1	14,930	15,433	241,807	—

Από τον Πίνακα 5.11 προκύπτουν τα εξής:


1. **TF/CL > OL > MIMO** για τιμή: Η teacher-forcing στρατηγική υπερτερεί σαφώς, επιβεβαιώνοντας ότι ο βασικός περιοριστικός παράγοντας για OL/MIMO είναι η απουσία πρόσβασης στις πραγματικές lagged τιμές κατά την πρόβλεψη.
2. **CL > OL για φορτίο:** Η διαφορά TF vs OL είναι μικρή για φορτίο (+10, 7% Dec, +6, 4% Q1), σε αντίθεση με τιμή (+40, 4% Dec, +38, 8% Q1).
3. **Monthly Retraining:** Η πλέον αποδοτική στρατηγική για μεγάλους ορίζοντες (3 μήνες), μειώνοντας σημαντικά τις επιπτώσεις της αλλαγής κατανομής.
4. **Daily (H=24) » Weekly (H=168) για OL:** Η ημερήσια αξιολόγηση μειώνει δραματικά το σφάλμα έναντι της εβδομαδιαίας (−16, 7% για τιμή Dec) λόγω μικρότερης συσσώρευσης.




Σχήμα 5.1. Χρονοσειρές προβλέψεων τιμής DAM για επιλεγμένα μοντέλα, Q1 2026. Οι αποχρώσεις αντιπροσωπεύουν διαφορετικές στρατηγικές (TF: μοβ, CL: γαλάζιο, OL: πράσινο, MIMO: πορτοκαλί).



Σχήμα 5.2. Χρονοσειρές προβλέψεων φορτίου για επιλεγμένα μοντέλα, Q1 2026.



Σχήμα 5.3. Box plots κατανομής σφαλμάτων (absolute error) ανά μοντέλο για τιμή, Q1 2026. Ο διάμεσος, IQR και outliers αποκαλύπτουν διαφορές στη συνέπεια των μοντέλων.



Σχήμα 5.4. Ωριαίο προφίλ σφάλματος (MAE ανά ώρα ημέρας) για τιμή, Q1 2026. Τα μοντέλα δυσκολεύονται ιδιαίτερα τις ώρες αιχμής (19:00–22:00).

Κεφάλαιο 6

Ανάλυση Σημαντικότητας Χαρακτηριστικών

Η ανάλυση σημαντικότητας χαρακτηριστικών (feature importance analysis) προσφέρει ερμηνευσιμότητα στα μοντέλα ML, αποκαλύπτοντας ποιοι παράγοντες οδηγούν τις προβλέψεις. Στην παρούσα εργασία, εξετάζουμε πώς η στρατηγική πρόβλεψης (TF/Recursive/MIMO) αλλάζει τη βαρύτητα που αποδίδουν τα μοντέλα σε χρονικές υστερήσεις, εξωγενείς παραμέτρους και ημερολογιακά χαρακτηριστικά.

6.1 Μεθοδολογία

Gain-Based Feature Importance (LGBM / XGBoost)

Για τους αλγόριθμους LightGBM και XGBoost, χρησιμοποιείται η σημαντικότητα βάσει κέρδους πληροφορίας (gain): σε κάθε διαχωριστικό κόμβο δένδρου, το gain μετρά τη μέση μείωση της αντικειμενικής συνάρτησης (MSE) λόγω του συγκεκριμένου χαρακτηριστικού, σταθμισμένη από τον αριθμό δειγμάτων που περνούν από τον κόμβο. Η κανονικοποιημένη αθροιστική συνεισφορά κάθε χαρακτηριστικού προκύπτει ως [14]:

$$\text{Importance}(f) = \frac{\sum_t \text{gain}(t, f) \cdot \mathbb{I}[\text{feature}(t) = f]}{\sum_{f'} \sum_t \text{gain}(t, f')} \quad (6.1)$$

Gini Impurity Importance (Random Forest)


Για το Random Forest, χρησιμοποιείται η μέση μείωση ακαθαρσίας Gini (MDI) σε όλα τα δένδρα του δάσους [12]. Η μέθοδος αυτή τείνει να ευνοεί χαρακτηριστικά με υψηλή πληροφορία (όπως συνεχείς μεταβλητές με πολλές τιμές), γεγονός που λαμβάνεται υπόψη στην ερμηνεία.

Εξαγωγή για 15 Παραλλαγές

Εξάγεται feature importance για 15 μοντέλα, κατηγοριοποιημένα ανά στρατηγική:

- **TF/CL:** LGBM-CL, XGB-CL, RF-CL (152 χαρακτηριστικά τιμής, 133 φορτίου)
- **Recursive/OL:** LGBM-OL-Daily-Optuna, XGB-OL-SS-Dense
- **MIMO Direct:** LGBM-Direct-Dense (170 χαρακτηριστικά)
- **MIMO Multi-output:** XGB-MIMO-Dense, RF-MIMO-two-stage

6.2 Αποτελέσματα — Τιμή DAM



Σχήμα 6.1. Top-15 χαρακτηριστικά για τα μοντέλα τιμής ανά αλγόριθμο και στρατηγική. Η αδρή στήλη αντιστοιχεί στη σημαντικότητα gain/MDI (κανονικοποιημένη στο 100%).

Teacher-Forcing / Closed-Loop

Στα μοντέλα TF/CL, παρατηρείται έντονη *συγκέντρωση* στη χρονική υστέρηση y_{t-1} :

- **LGBM-CL:** $y_{t-1} = 88,3\%$ της συνολικής σημαντικότητας. Ακολουθούν y_{t-24} (3,1%), gas_price (2,0%) και y_{t-168} (1,4%).
- **XGB-CL:** Λιγότερο ακραία συγκέντρωση· $y_{t-1} = 52\%$, $y_{t-24} = 12\%$, $gas_price = 8\%$.
- **RF-CL:** Πιο ομοιόμορφη κατανομή· $y_{t-1} = 28\%$, με σημαντική παρουσία y_{t-24} , y_{t-48} , gas_price .

Η κυριαρχία του y_{t-1} στο LGBM-CL είναι αναμενόμενη: στη στρατηγική TF, οι πραγματικές lagged τιμές παρέχονται στο μοντέλο, και η τιμή ηλεκτρισμού παρουσιάζει σημαντική αυτοσυσχέτιση ($\rho \approx 0,87$ για lag-1).

Recursive / Open-Loop

Στα OL μοντέλα, η σημαντικότητα ανακατανέμεται:

- **LGBM-Daily-Optuna:** $y_{t-1} = 41\%$, $y_{t-24} = 18\%$, $y_{t-168} = 12\%$, $\text{gas_price} = 9\%$. Η μειωμένη βαρύτητα του y_{t-1} σε σχέση με CL υποδηλώνει ότι το μοντέλο δεν εμπιστεύεται πλήρως την πιο πρόσφατη πρόβλεψη (η οποία περιέχει σφάλμα).
- **XGB-SS-Dense-OL:** Με τα dense lags (lags 4-23), οι ενδοημερήσιες τιμές αποκτούν συλλογική βαρύτητα 25%, αντικατοπτρίζοντας ότι η ενδοημερήσια δυναμική αξιοποιείται περισσότερο.

MIMO / Direct

Στα MIMO/Direct μοντέλα, η δομή της σημαντικότητας αλλάζει ριζικά:

- **LGBM-Direct-Dense:** Ανάδυση αιολικής (wind_gen_lag1), ηλιακής (solar_gen_lag1) και gas_price ως top-4 χαρακτηριστικά. Η εξάρτηση από y_{t-1} πέφτει στο 15-20%, αφού το μοντέλο δεν έχει πρόσβαση σε ενδιάμεσες TF τιμές.
- **RF-MIMO-two-stage:** Κυριαρχεί το $y_{\text{roll}24}$ (rolling mean 24h) με 51,6%. Η κυριαρχία αυτή υποδηλώνει ότι το RF αξιοποιεί κυρίως το επίπεδο τιμής της προηγούμενης ημέρας για να «σταθεροποιήσει» τις προβλέψεις σε ένα εύλογο εύρος.

6.3 Αποτελέσματα — Ηλεκτρικό Φορτίο



Σχήμα 6.2. Top-15 χαρακτηριστικά για τα μοντέλα φορτίου ανά αλγόριθμο και στρατηγική.

Το ηλεκτρικό φορτίο παρουσιάζει διαφορετικό προφίλ feature importance σε σχέση με την τιμή:

- **Μικρότερη συγκέντρωση** στο y_{t-1} : για LGBM-CL φορτίου, $y_{t-1} = 45\%$ (έναντι 88% για τιμή), με σημαντική παρουσία $y_{t-24} = 20\%$, $y_{t-168} = 8\%$ και $hour_of_day = 6\%$. Αυτό αντικατοπτρίζει τη σαφή ημερήσια εποχικότητα του φορτίου.
- **Ημερολογιακά χαρακτηριστικά** πιο σημαντικά: *hour*, *day_of_week*, *is_holiday* εμφανίζονται σε top-10 για όλους τους αλγόριθμους φορτίου — αναμενόμενο λόγω εργασιακών κύκλων.
- **Θερμοκρασιακή επίδραση**: Λόγω απουσίας θερμοκρασιακών δεδομένων στο dataset, η έμμεση επίδρασή της αποτυπώνεται μέσω των rolling means (y_{roll24} , $y_{roll168}$) που λειτουργούν ως proxy.

6.4 Σύγκριση Κατά Στρατηγική

Rolling statistics: y_roll24 , $y_roll168$. Έμμεση αποτύπωση επιπέδου τιμής· σημαντικά για RF.

Κύριο εύρημα: καθώς μεταβαίνουμε από TF $\rightarrow$ Recursive $\rightarrow$ MIMO, η εξάρτηση από lagged values μειώνεται (70% $\rightarrow$ 60% $\rightarrow$ 40%), ενώ η βαρύτητα market/exogenous και calendar αυξάνεται αντίστοιχα. Αυτό υποδηλώνει ότι στην MIMO στρατηγική τα μοντέλα αξιοποιούν σε μεγαλύτερο βαθμό τη δομή της αγοράς και τους εξωγενείς παράγοντες, έναντι της αυτόματης αναδρομής.

6.6 Συμπεράσματα Κεφαλαίου

Η ανάλυση feature importance αποκαλύπτει τρεις βασικές κανονικότητες:

1. **Η στρατηγική καθορίζει τη σημαντικότητα:** Το ίδιο χαρακτηριστικό (y_{t-1}) έχει ριζικά διαφορετική βαρύτητα ανάλογα με τη στρατηγική (88% στο TF vs 15% στο MIMO), γεγονός που υποδηλώνει ότι τα μοντέλα «μαθαίνουν» να αξιοποιούν διαφορετικές ιδιότητες των δεδομένων.
2. **Dense lags ανεβάζουν τη βαρύτητα ενδοημερήσιων χαρακτηριστικών:** Τα lags 4–23 προσθέτουν μια νέα κατηγορία πληροφορίας που ο αλγόριθμος αξιοποιεί σημαντικά, εξηγώντας τη βελτίωση απόδοσης MIMO.
3. **Φορτίο vs τιμή:** Το φορτίο εμφανίζει πιο ισόρροπη κατανομή σημαντικότητας με ισχυρότερη παρουσία ημερολογιακών χαρακτηριστικών, αντανakλώντας την πιο ντετερμινιστική εποχική συμπεριφορά του έναντι της τιμής.

Κεφάλαιο 7

Στατιστικοί Έλεγχοι Σύγκρισης Μοντέλων

Η αξιολόγηση βάσει μέσης απόλυτης τιμής σφάλματος (MAE) δεν διακρίνει εάν οι διαφορές επίδοσης μεταξύ δύο μοντέλων είναι στατιστικά σημαντικές ή απλώς τυχαία αποτελέσματα συγκεκριμένης περιόδου δοκιμής. Στο κεφάλαιο αυτό εφαρμόζεται ο έλεγχος Diebold-Mariano με τη διόρθωση Harvey-Leybourne-Newbold για πλήρη ζευγαρωτή σύγκριση 18 μοντέλων ανά εργασία.

7.1 Ο Έλεγχος Diebold-Mariano

Έστω $e_{i,t}$ και $e_{j,t}$ τα σφάλματα πρόβλεψης δύο μοντέλων i και j σε χρόνο t . Ορίζουμε τη διαφορά απωλειών:

$$d_t = L(e_{i,t}) - L(e_{j,t}), \quad L(e) = |e| \quad (7.1)$$

Ο έλεγχος DM [31] εξετάζει την υπόθεση:

$$H_0 : \mathbb{E}[d_t] = 0 \quad (\text{ισοδύναμη πρόβλεψη}) \quad (7.2)$$

Η στατιστική δοκιμής είναι:

$$DM = \frac{\bar{d}}{\sqrt{\hat{V}(\bar{d})/T}} \quad (7.3)$$

όπου $\bar{d} = T^{-1} \sum_t d_t$ και $\hat{V}(\bar{d})$ εκτιμάται μέσω long-run variance (Newey-West HAC estimator με $h - 1$ lags για h -step-ahead πρόβλεψη).

Πρόσημο σύμβασης: $DM(i, j) > 0$ σημαίνει ότι το μοντέλο i έχει χαμηλότερα σφάλματα (καλύτερο) από το j . $DM(i, j) < 0$ σημαίνει ότι το j είναι καλύτερο.

7.2 Διόρθωση Harvey-Leybourne-Newbold

Ο κλασικός DM έλεγχος υπολογίζει μια t -στατιστική που ακολουθεί κανονική κατανομή για μεγάλα T . Σε μικρά δείγματα, υπάρχει τάση απόρριψης H_0 συχνότερα από το ονομαστικό επίπεδο σημαντικότητας. Η διόρθωση Harvey-Leybourne-Newbold (HLN) [32] προσαρμόζει τη στατιστική:

$$DM^* = \left[\frac{T + 1 - 2h + T^{-1}h(h-1)}{T} \right]^{1/2} \cdot DM \quad (7.4)$$

και συγκρίνει το αποτέλεσμα με t_{T-1} κατανομή. Στην παρούσα εφαρμογή ($T = 2160$, $h = 1$ για CL ή $h = 24$ για MIMO), η HLN διόρθωση είναι μικρή αλλά εφαρμόζεται για ακρίβεια.

7.3 Πειραματική Διάταξη

Πίνακας 7.1. Μοντέλα που συμμετέχουν στους DM ελέγχους (Q1 2026, $T = 2160$ ώρες).


Κωδικός	Περιγραφή	Στρατηγική
MR-TF-Ens	Ensemble TF Best3 (MR)	Walk-Forward TF
MR-TF-LGBM	LGBM Teacher-Forcing (MR)	Walk-Forward TF
MR-TF-XGB	XGB Teacher-Forcing (MR)	Walk-Forward TF
MR-TF-RF	RF Teacher-Forcing (MR)	Walk-Forward TF
MR-Rec-XGB-SS	XGB Recursive + SS (MR)	Walk-Forward Rec
CL-Ens	Ensemble TF Best3 (static)	Teacher-Forcing
CL-LGBM	LGBM static CL	Teacher-Forcing
CL-XGB	XGB static CL	Teacher-Forcing
OL-LGBM-DO	LGBM Daily Optuna (static)	Recursive
OL-XGB-SS-D	XGB SS Dense (static)	Recursive + SS
MIMO-Ens	Ensemble MIMO Best3 (static)	MIMO H=24
MIMO-LGBM	LGBM Direct Dense (static)	MIMO H=24
MIMO-XGB	XGB MIMO Dense (static)	MIMO H=24
MIMO-RF	RF two-stage Dense (static)	MIMO H=24
MR-MIMO-Ens	Ensemble MIMO Best3 (MR)	Walk-Forward MIMO
MR-MIMO-LGBM	LGBM Direct Dense (MR)	Walk-Forward MIMO
Naive-1	Naive ημέρας (persistence)	Baseline
Seasonal	Εποχικό Profile	Baseline

Ο πίνακας αποτελείται από $18 \times 17/2 = 153$ ζεύγη. Ο έλεγχος εφαρμόζεται αμφί-πλευρα (two-sided) σε επίπεδο σημαντικότητας $\alpha = 0,05$ και $\alpha = 0,10$. Τα p -values υπολογίζονται από την t_{T-1} κατανομή με την HLN Eq. (7.4).


7.4 Αποτελέσματα — Τιμή DAM

Τα αποτελέσματα για την τιμή DAM (Figs. 7.1 and 7.2) αναδεικνύουν ξεκάθαρη ιεράρχηση:

1. **MR-TF-Ens** (Ensemble Walk-Forward TF): **νικά στατιστικά σημαντικά όλα τα υπόλοιπα 17 μοντέλα** ($p < 0,05$), επιβεβαιώνοντας ότι η Monthly Retraining είναι στατιστικά ανώτερη στρατηγική για Q1 2026.
2. **Ομάδα Walk-Forward TF** (MR-TF-LGBM, MR-TF-XGB): Νικούν 15–17 μοντέλα, με μικρές εσωτερικές διαφορές μεταξύ τους (μη σημαντικές).
3. **Static CL** (CL-Ens, CL-LGBM): Νικούν 10–12 μοντέλα, υπερέχοντας των Recursive και MIMO static αλλά υποχωρώντας έναντι Walk-Forward.
4. **Recursive/OL static**: 6–9 νίκες· ανταγωνιστικά με static CL σε μεμονωμένες συγκρίσεις.



Σχήμα 7.1. Χάρτης θερμότητας DM ελέγχου για τιμή DAM (Q1 2026). Κάθε κελί (i, j) χρωματίζεται σκούρο μπλε αν το μοντέλο i είναι στατιστικά σημαντικά καλύτερο από το j ($p < 0,05$), ανοιχτό μπλε για $p < 0,10$, λευκό για μη σημαντική διαφορά.




Σχήμα 7.2. Αριθμός στατιστικά σημαντικών «νικών» ($p < 0,05$) ανά μοντέλο και στρατηγική για την τιμή DAM.

5. **MIMO static**: 3–6 νίκες· χαμηλότερη κατάταξη, κυρίως πάνω από baselines.

6. **Naive-1, Seasonal Profile**: 0–2 νίκες· οριακά καλύτερα μόνο έναντι SVR που κατέρρευσε σε Q1 2026.

Σημαντική παρατήρηση: Οι εσωτερικές διαφορές εντός της ομάδας Walk-Forward TF (LGBM vs XGB vs RF) δεν είναι στατιστικά σημαντικές, υποδηλώνοντας ότι όλοι οι αλγόριθμοι ωφελούνται εξίσου από τη μηνιαία επανεκπαίδευση. Αντίστοιχα, εντός της ομάδας static CL, LGBM και XGB δεν διαφέρουν σημαντικά.


7.5 Αποτελέσματα — Ηλεκτρικό Φορτίο



Σχήμα 7.3. Χάρτης θερμότητας DM ελέγχου για ηλεκτρικό φορτίο (Q1 2026).

Για το ηλεκτρικό φορτίο (Figs. 7.3 and 7.4), η εικόνα διαφέρει ουσιαστικά:

1. **CL-Ens** (static Ensemble Best3): Κορυφαίο μοντέλο με **16 νίκες** (έναντι 17 του MR-TF για τιμή). Η μηνιαία επανεκπαίδευση δεν αποδίδει τόσο εντυπωσιακά πλεονέκτημα για το φορτίο.
2. **MR-TF-Ens**: 14–15 νίκες· στατιστικά ισοδύναμο με CL-Ens ($p = 0,12$ για ζεύγος CL-Ens vs MR-TF-Ens). Η Walk-Forward MR βελτιώνει αλλά η διαφορά δεν αγγίζει συχνά το κατώφλι $p < 0,05$.



Σχήμα 7.4. Αριθμός στατιστικά σημαντικών «νικών» ανά μοντέλο για το φορτίο.

3. **MR-Rec-XGB-SS:** 13–14 νίκες, σχεδόν ισοδύναμο με MR-TF-Ens για φορτίο. Αυτό επιβεβαιώνει το εύρημα ότι το αναδρομικό σφάλμα για φορτίο είναι μικρό λόγω ομαλής δυναμικής.
4. **MIMO static:** Σαφώς χαμηλότερη κατάταξη (4–7 νίκες)· η MIMO αδυνατεί να ανταγωνιστεί TF/CL για φορτίο λόγω μη πρόσβασης στα πραγματικά πρόσφατα δεδομένα.

Βασικό συμπέρασμα σύγκρισης φορτίου vs τιμής: Για *τιμή*, η Walk-Forward MR είναι αδιαμφισβήτητα η καλύτερη στρατηγική (ξεπερνά τα πάντα με $p < 0,05$). Για *φορτίο*, η CL και η Walk-Forward MR είναι στατιστικά αδιάκριτες· η ομαλή δυναμική του φορτίου σημαίνει ότι η μηνιαία επανεκπαίδευση δεν προσφέρει τόσο σαφές στατιστικό πλεονέκτημα.

7.6 Συμπεράσματα Κεφαλαίου

Ο DM test με HLN διόρθωση επιβεβαιώνει, πέραν της απλής σύγκρισης MAE, τα ακόλουθα στατιστικά σημαντικά ευρήματα:

- Η Walk-Forward Monthly Retraining (TF) είναι στατιστικά ανώτερη όλων των εναλλακτικών για **τιμή** ($\alpha = 0,05$).
- Για **φορτίο**, η Walk-Forward MR και το static CL Ensemble είναι στατιστικά ισοδύναμα· επιλέγεται το απλούστερο (static CL) αν η επιχειρησιακή πολυπλοκότητα είναι παράγοντας.
- Εντός κάθε στρατηγικής, οι διαφορές LGBM/XGB/RF δεν είναι συστηματικά σημαντικές· το ensemble αποδεικνύεται συνεπώς η πλέον ασφαλής επιλογή.
- MIMO στρατηγικές είναι σαφώς κατώτερες CL/TF για αμφότερες τις εργασίες, στατιστικά επιβεβαιωμένα.

Κεφάλαιο 8

Σύστημα Οπτικοποίησης Αποτελεσμάτων

Για την αποτελεσματική παρουσίαση και εξερεύνηση των αποτελεσμάτων αναπτύχθηκε ένα διαδραστικό σύστημα οπτικοποίησης (*dashboard*) με βάση HTML5/JavaScript/Chart.js. Το σύστημα λειτουργεί ως αυτόνομο αρχείο, χωρίς απαίτηση web server ή προγραμματιστικών εργαλείων, και είναι άμεσα αναπαραγώγιμο.

8.1 Αρχιτεκτονική

Τεχνολογίες

- **HTML5 + Vanilla JavaScript:** Το κύριο αρχείο `dashboard.html` (2500 γραμμές κώδικα) δεν απαιτεί npm, webpack ή άλλα build tools.
- **Chart.js 4.x:** Βιβλιοθήκη JavaScript για διαδραστικά γραμμικά διαγράμματα, φορτωμένη μέσω CDN.
- **JSON data files:** 14 αρχεία δεδομένων (ένα ανά task × strategy × horizon) φορτώνονται δυναμικά μέσω `fetch()`.
- **Python http.server:** Απαιτείται μόνο για να εξυπηρετηθούν τα JSON αρχεία λόγω CORS policy· εκκινείται με `python -m http.server 8000`.

Δομή Δεδομένων (JSON Schema)

Κάθε JSON αρχείο ακολουθεί ενιαίο σχήμα:

```
{
  "strategy": "cl" | "ol" | "mimo" | "direct",
  "task":      "price" | "load",
  "dates":     ["2025-12-01 00:00", ...], // 744 timestamps
  "actual":    [110.2, 98.7, ...],        //
  "series": {
    "LightGBM": [...],
    "XGBoost":  [...],
    "Ensemble-Best3": [...],
    "Naive-1":  [...],
    ...
  },
  "metrics": [
    { "Model": "LightGBM", "Type": "ml",
      "MAE": 10.334, "RMSE": 16.236, "sMAPE": 11.178},
  ]
}
```

```

    ...
  ]
}
```

8.2 Στοιχεία Διεπαφής Χρήστη

Επιλογή Task και Στρατηγικής

- **Task toggle [PRICE / LOAD]:** Εναλλαγή μεταξύ τιμής DAM (€/MWh) και ηλεκτρικού φορτίου (MW).
- **Strategy buttons [CL | OL | MIMO | Direct]:** Επιλογή στρατηγικής· κάθε κουμπί φορτώνει το αντίστοιχο JSON.
- **Horizon sub-toggle [H=24 | H=168]:** Εμφανίζεται για OL, MIMO και Direct· επιλέγει daily (24h) ή weekly (168h) chunks.

Φιλτράρισμα και Ζουμ Χρονικής Περιόδου

- **Date range inputs:** Τα πεδία «Από» / «Έως» επιτρέπουν ζουμ σε υπό-περίοδο (π.χ. μία εβδομάδα Χριστουγέννων).
- **Δυναμική επαναυπολογιστική μετρικών:** Μετά την εφαρμογή του date range, υπολογίζονται εκ νέου MAE/RMSE/sMAPE *μόνο για την επιλεγμένη περίοδο*· ο υπό-τιτλος αλλάζει σε «Metrics : {from} → {to}».

Φιλτράρισμα ανά Algorithm Family

Το κουμπί **[Best] Best** ενεργοποιεί τη λογική *best-per-family*: για κάθε αλγόριθμο (LGBM, XGB, RF, SVR, MLP) εμφανίζεται μόνο η καλύτερη παραλλαγή για την τρέχουσα στρατηγική. Αυτό αποφεύγει τον «σωρό» πολλαπλών γραμμών του ίδιου αλγόριθμου και εστιάζει στη σύγκριση *μεταξύ* αλγόριθμων.

Χρωματική Κωδικοποίηση

Κάθε αλγόριθμος / τύπος μοντέλου έχει σταθερό χρώμα σε όλες τις στρατηγικές:

Πίνακας 8.1. Χρωματική κωδικοποίηση dashboard.

Μοντέλο	Χρώμα	Hex
LightGBM	Sky blue	#38bdf8
XGBoost	Orange	#f97316
Random Forest	Green	#22c55e
MLP	Purple	#a855f7
SVR	Red	#ef4444
Ensemble Best3	Gold	#eab308
Ensemble All	Amber	#fbbf24
Actual	White/Light	#e5e7eb
Naive-1	Gray dashed	#9ca3af
Naive-24	Gray dashed	#6b7280
Seasonal Profile	Pink dashed	#ec4899

8.3 Χαρτογράφηση Αρχείων JSON

Πίνακας 8.2. Χαρτογράφηση στρατηγικής/εργασίας σε αρχεία JSON.

Task	Strategy	Horizon	Αρχείο
price	cl	—	...price_cl_monthly.json
price	ol	h24	...price_openloop_h24_monthly.json
price	ol	h168	...price_openloop_h168_monthly.json
price	mimo	h24	...price_mimo_h24_monthly.json
price	direct	h24	...price_direct_h24_monthly.json
load	cl	—	...load_cl_monthly.json
load	ol	h24	...load_openloop_h24_monthly.json
...	...	...	...

Συνολικά 14 JSON αρχεία (7 ανά task) φορτώνονται δυναμικά ανάλογα με την επιλογή του χρήστη. Το μέγεθος κάθε αρχείου κυμαίνεται στα 200–500 KB.

8.4 Οδηγίες Χρήσης

Για εκκίνηση του dashboard:

```
# A          project (epf_greece_starter/)
conda run -n epf python -m http.server 8000
# A          browser: http://localhost:8000/dashboard.html
```

Τυπική ροή χρήσης:

1. Επιλέξτε εργασία (PRICE ή LOAD).
2. Επιλέξτε στρατηγική (CL / OL / MIMO / Direct).
3. Για OL/MIMO/Direct, επιλέξτε ορίζοντα (H=24 ή H=168).
4. Πατήστε [Best] Best για εμφάνιση μόνο του καλύτερου ανά οικογένεια.
5. Χρησιμοποιήστε Date Range για εστίαση σε υπό-περίοδο.
6. Ο πίνακας μετρικών ανανεώνεται αυτόματα.

Κεφάλαιο 9

Συμπεράσματα

Στο κεφάλαιο αυτό συνοψίζονται τα κύρια ευρήματα της εργασίας, συζητούνται οι περιορισμοί και προτείνονται κατευθύνσεις για μελλοντική έρευνα.

9.1 Σύνοψη Κύριων Ευρημάτων

Η παρούσα εργασία διερεύνησε συστηματικά τέσσερις στρατηγικές βραχυπρόθεσμης πρόβλεψης (Teacher-Forcing, Recursive/Open-Loop, MIMO και Walk-Forward Monthly Retraining) για την τιμή DAM και το ηλεκτρικό φορτίο στην ελληνική αγορά, εφαρμόζοντας πέντε αλγόριθμους ML σε τρεις χρονικές περιόδους αξιολόγησης.

ΕΕ1: Ποια στρατηγική είναι καλύτερη;

Τιμή DAM: Η Walk-Forward Monthly Retraining (TF) αναδεικνύεται ξεκάθαρα η βέλτιστη στρατηγική για μακροχρόνιες περιόδους:

- Q1 2026: MR Ensemble-TF-Best3 = 10.491 €/MWh vs static CL Ensemble = 14.478 €/MWh (**-27,7%**)
- Η υπεροχή επιβεβαιώνεται στατιστικά σημαντικά για όλα τα ζεύγη (DM test, $p < 0,05$).

Φορτίο: Η MR-TF και το static CL Ensemble είναι στατιστικά αδιάκριτα (DM test, $p = 0,12$). Πρακτικά ωστόσο, η MR-TF δίνει MAE 67,7 MW vs 96,8 MW (-30%) — σημαντικό πρακτικά, αν και όχι πάντα στατιστικά σημαντικό.

ΕΕ2: Πώς αλλάζει η κατάταξη με τον ορίζοντα;

- **Βραχυχρόνια (1 εβδομάδα):** CL/TF = 9–11 €/MWh, OL = 15–16 €/MWh, MIMO = 25–26 €/MWh. Το CL κυριαρχεί σαφώς.
- **Μακροχρόνια (3 μήνες):** CL MAE αυξάνει σε 14,5 €/MWh λόγω distributional shift. Η MR «κλειδώνει» MAE $\square$ 10–11 €/MWh/μήνα με μηνιαία επαναδιαμόρφωση. Για Q4 2025 (υψηλή μεταβλητότητα Οκτ./Νοε.), ακόμα και το Naive-1 (19.5 €/MWh) νικά τα weekly OL μοντέλα.
- **OL daily (H=24) vs weekly (H=168):** H=24 chunks μειώνει OL MAE κατά 16,7% για Δεκέμβριο 2025 (14,5 vs 17,4 €/MWh), εξαλείφοντας error accumulation 7 ημερών.

EE3: Στατιστική σημαντικότητα διαφορών;

Ο DM test επιβεβαιώνει:

- Walk-Forward TF > όλα (τιμή, $p < 0,05$)
- CL $\square$ Walk-Forward TF για φορτίο (μη σημαντική διαφορά)
- Εντός-στρατηγικής LGBM $\square$ XGB $\square$ RF (μη σημαντικές διαφορές)
- MIMO < CL/TF για αμφότερες τις εργασίες ($p < 0,05$)

EE4: Ποια χαρακτηριστικά αξιοποιούν τα μοντέλα;

- **TF:** Κυριαρχεί y_{t-1} (88% για LGBM) — αυτό-αναδρομική δυναμική.
- **Recursive:** Μικρότερη εξάρτηση από y_{t-1} (41%), αυξημένη βαρύτητα y_{t-24} , y_{t-168} .
- **MIMO:** Ανάδυση εξωγενών (gas_price, αιολική παραγωγή); αναγκαία στροφή λόγω μη πρόσβασης σε πραγματικές ενδιάμεσες τιμές.
- **Dense lags (MIMO):** Αύξηση συλλογικής βαρύτητας lags 4–23, οδηγώντας σε βελτίωση MLP −22%, XGB −7,9%, LGBM −6,5%.

EE5: Αντισταθμίζει η MR το distributional shift;

Ναι, και εντυπωσιακά. Το σημαντικότερο εύρημα της εργασίας:

Πίνακας 9.1. Σύγκριση στρατηγικών Q1 2026 — κύρια αποτελέσματα.

Στρατηγική	Τιμή (€/MWh)	Φορτίο (MW)
Walk-Forward MR (TF Ensemble)	10,491	67,729
Static CL (TF Ensemble)	14,478	96,751
Static OL — best single (H=24)	20,094	102,961
MIMO — best ensemble	20,896	217,088
Naive-1 (baseline)	15,433	267,151

Η μηνιαία επανεκπαίδευση αντισταθμίζει πλήρως τη μεταβολή κατανομής (Φεβρουάριος 2026: μέση τιμή 78 €/MWh έναντι 110 €/MWh Ιανουαρίου): το TF-LGBM-MR επιτυγχάνει MAE 11,7 €/MWh Φεβρουαρίου, έναντι 15,9 €/MWh της static CL.

9.2 Ειδικά Ευρήματα

Dense lags paradox. Τα dense lags (4–23) βελτιώνουν MIMO (χωρίς recursion → καθαρές ιστορικές τιμές) αλλά *βλάπτουν* το Recursive OL (+2,8% LGBM). Αιτία: στο OL, οι dense lags είναι αυτο-αναφορικές προβλέψεις με συσσωρευμένο σφάλμα. Το Scheduled Sampling αντισταθμίζει μερικά αυτό το πρόβλημα (XGB-SS-Dense βελτιώνεται +1,4–1,5%).

SVR κατάρρευση. Το SVR αποτυγχάνει εντυπωσιακά για Q1 2026 (τιμή: 40,8 €/MWh, φορτίο: 600 MW). Αιτία: η βαθμονόμηση του πυρήνα RBF (trained on 2017–Nov2025) δεν γενικεύεται στη νέα κατανομή Ιανουαρίου–Φεβρουαρίου 2026 (volatile, low-price regime). Το SVR είναι ευαίσθητο στη μεταβολή κατανομής λόγω μη-παραμετρικής φύσης.

Ensemble ανθεκτικότητα. Το Ensemble-Best3 (1/MAE weights) αποδεικνύεται σταθερά ανθεκτικό: για φορτίο MR, Ensemble-TF-Best3 = 67,7 MW vs TF-LGBM = 69,4 MW, TF-XGB = 72,9 MW. Ακόμα και όταν ένα μοντέλο (RF ή MLP) αποδίδει άσχημα σε συγκεκριμένο μήνα, το ensemble περιορίζει τη ζημιά λόγω χαμηλής βαρύτητας.

Scheduled Sampling για φορτίο. Για φορτίο, το Scheduled Sampling (Rec-XGB-SS-DO) επιτυγχάνει 70,6 MW — σχεδόν ισοδύναμο με TF-Ensemble (67,7 MW). Αυτό αποδεικνύει ότι για σήματα με ομαλή δυναμική (φορτίο), η Recursive στρατηγική + SS μπορεί να ανταγωνιστεί την oracle TF.

9.3 Περιορισμοί

1. **Συνθετικές τιμές φυσικού αερίου:** Για την περίοδο Νοέμβριος 2025 – Φεβρουάριος 2026, οι τιμές TTF gas υπολογίστηκαν με γραμμική παρεμβολή από σημεία αγκύρωσης. Ο πραγματικός TTF Ιανουαρίου 2026 κυμάνθηκε σε 42–50 €/MWh, ενώ οι συνθετικές τιμές εκτιμούσαν 39 €/MWh. Αυτό εισάγει θόρυβο χαρακτηριστικών, επηρεάζοντας κυρίως τα μοντέλα τιμής Ιανουαρίου–Φεβρουαρίου 2026.
2. **Subsampling SVR:** Το SVR εκπαιδεύτηκε σε μόνο 5.000 δείγματα (7 μήνες δεδομένων, από συνολικά 80.000) λόγω υπολογιστικού κόστους $O(n^2)$ – $O(n^3)$. Τα αποτελέσματα SVR δεν είναι αντιπροσωπευτικά.
3. **Απουσία θερμοκρασιακών δεδομένων:** Η θερμοκρασία αποτελεί κρίσιμο χαρακτηριστικό για ELF. Η παρούσα εργασία αντιμετωπίζει αυτό μέσω rolling averages και ημερολογιακών χαρακτηριστικών ως proxy, αλλά η άμεση ενσωμάτωση θερμοκρασιακής πρόγνωσης αναμένεται να βελτιώσει την ακρίβεια φορτίου.
4. **Μέγεθος δοκιμαστικής περιόδου:** Η αξιολόγηση σε 3 μήνες Q1 2026 παρέχει εύλογο μέγεθος δείγματος ($T = 2160$) αλλά αντιστοιχεί σε ένα μόνο τρίμηνο. Η γενίκευση αποτελεσμάτων σε ολόκληρο έτος ή σε διαφορετικές εποχές παραμένει υποθετική.
5. **Αθροιστική συγχώνευση γεννήτριας δεδομένων:** Η μετατροπή 15-λεπτων αναγνώσεων παραγωγής σε ωριαία χρησιμοποιεί SUM αντί MEAN, αποτελώντας γνωστό τεχνικό παρατηρούμενο. Δεδομένου ότι η κλίμακα παραμένει σταθερή μεταξύ εκπαίδευσης και δοκιμής, η επίδραση στην ακρίβεια πρόβλεψης είναι μηδενική.

9.4 Μελλοντική Έρευνα

1. **Θερμοκρασιακά δεδομένα:** Ενσωμάτωση ωριαίων μετεωρολογικών προβλέψεων από ECMWF/GFS (θερμοκρασία, ηλιοφάνεια, ταχύτητα ανέμου) ως χαρακτηριστικά — αναμένεται σημαντική βελτίωση ιδιαίτερα για ELF.
2. **Βαθιά Μάθηση (LSTM/Transformer):** Δοκιμή αρχιτεκτονικών ακολουθιών (seq2seq LSTM, Temporal Fusion Transformer [33]) που διαχειρίζονται εγγενώς αναδρομικές δομές, πιθανώς υπερεκδίδοντας τα τρέχοντα MIMO/Recursive ML μοντέλα.
3. **Online Learning:** Αντί μηνιαίας επανεκπαίδευσης, διερεύνηση αλγόριθμων online/incremental learning (π.χ. gradient boosting με νέα δεδομένα κάθε ημέρα) που προσαρμόζονται συνεχώς χωρίς πλήρη επανεκπαίδευση.

4. **Πιθανοτική Πρόβλεψη:** Επέκταση σε probabilistic forecasting (prediction intervals, quantile regression) για παροχή εκτιμήσεων αβεβαιότητας — κρίσιμης αξίας για εμπόρους ενέργειας.
5. **Two-Stage Load→Price:** Αν και η τρέχουσα εργασία έδειξε αμελητέα επίδραση (load_fc δεν είναι κρίσιμο χαρακτηριστικό τιμής), η διερεύνηση σε περιόδους υψηλής αβεβαιότητας φορτίου μπορεί να αναδείξει διαφορετική εικόνα.
6. **Γενίκευση σε άλλες αγορές:** Επέκταση της μεθοδολογίας σε άλλες ευρωπαϊκές αγορές (Βουλγαρία, Ρουμανία, Σερβία) που εμφανίζουν παρόμοια χαρακτηριστικά (υψηλή διείσδυση ΑΠΕ, διασυνδέσεις, ευμετάβλητες τιμές).

9.5 Κλείσιμο

Η εργασία αυτή καταδεικνύει ότι η *επιλογή στρατηγικής πρόβλεψης* έχει εξίσου ή και μεγαλύτερη σημασία από την επιλογή αλγόριθμου ML: η Walk-Forward Monthly Retraining βελτιώνει κατά 28–30% έναντι static training, ανεξαρτήτως αλγόριθμου. Η ορθή μεθοδολογική αντιμετώπιση — αποφυγή data leakage, πλήρης out-of-sample αξιολόγηση, στατιστικοί έλεγχοι — αποτελεί τη βάση αξιόπιστης σύγκρισης στη βιβλιογραφία EPF/ELF.

Τα αποτελέσματα έχουν άμεση πρακτική σημασία για τους συμμετέχοντες στην ελληνική αγορά ηλεκτρισμού: αναλυτές ρίσκου, εμπόρους ενέργειας και Διαχειριστή Συστήματος Μεταφοράς που αντιμετωπίζουν τις ίδιες προκλήσεις μεταβλητότητας και distributional shift.

Βιβλιογραφία

- [1] R. Weron, "Electricity price forecasting: A review of the state-of-the-art with a look into the future", *International Journal of Forecasting*, τόμ. 30, αρθμ. 4, σσ. 1030–1081, 2014. DOI: 10.1016/j.ijforecast.2014.08.008
- [2] European Commission. "Commission regulation (eu) 2015/1222 establishing a guideline on capacity allocation and congestion management", διεύθυν.: <https://eur-lex.europa.eu/eli/reg/2015/1222/oj/eng>
- [3] J. Lago, G. Marcjasz, B. De Schutter και R. Weron, "Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark", *Applied Energy*, τόμ. 293, σ. 116983, 2021. DOI: 10.1016/j.apenergy.2021.116983
- [4] T. Hong, P. Pinson, S. Fan, H. Zareipour, A. Troccoli και R. J. Hyndman, "Probabilistic energy forecasting: Global energy forecasting competition 2014 and beyond", *International Journal of Forecasting*, τόμ. 32, αρθμ. 3, σσ. 896–913, 2016. DOI: 10.1016/j.ijforecast.2016.02.001
- [5] NEMO Committee. "Single day-ahead coupling (sdac)", διεύθυν.: <https://www.nemo-committee.eu/sdac>
- [6] IPTO (ADMIE). "Balancing market", διεύθυν.: <https://www.admie.gr/en/market/general/balancing-market>
- [7] Υπουργείο Περιβάλλοντος και Ενέργειας. "Νέο κεφάλαιο ανοίγει στην αγορά ενέργειας με την εκκίνηση του Target Model την 1η Νοεμβρίου", διεύθυν.: <https://ypen.gov.gr/neo-kefalaio-anoigei-stin-agera-energ/>
- [8] Ι. Κανούσης, "Βραχυπρόθεσμη Πρόβλεψη Τιμών Ηλεκτρικής Ενέργειας στην Ελληνική Αγορά με Μεθόδους Μηχανικής Μάθησης", Μεταπτυχική διπλ. εργασ., Πολυτεχνική Σχολή, Πανεπιστήμιο Πατρών, 2025.
- [9] Δ. Μαγκλαράς, "Βραχυπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου με Μεθόδους Μηχανικής Μάθησης: Εφαρμογή στην Ελληνική Αγορά", Μεταπτυχική διπλ. εργασ., Πολυτεχνική Σχολή, Πανεπιστήμιο Πατρών, 2022.
- [10] G. Gross και F. D. Galiana, "Short-term load forecasting", *Proceedings of the IEEE*, τόμ. 75, αρθμ. 12, σσ. 1558–1573, 1987. DOI: 10.1109/PROC.1987.13927
- [11] G. E. P. Box, G. M. Jenkins, G. C. Reinsel και G. M. Ljung, *Time Series Analysis: Forecasting and Control*, 5th. John Wiley & Sons, 2015.
- [12] L. Breiman, "Random forests", *Machine Learning*, τόμ. 45, αρθμ. 1, σσ. 5–32, 2001. DOI: 10.1023/A:1010933404324
- [13] T. Chen και C. Guestrin, "XGBoost: A scalable tree boosting system", στο *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, σσ. 785–794. DOI: 10.1145/2939672.2939785
- [14] G. Ke κ.ά., "LightGBM: A highly efficient gradient boosting decision tree", στο *Advances in Neural Information Processing Systems*, τόμ. 30, 2017.

- [15] A.J. Smola και B. Schölkopf, "A tutorial on support vector regression", *Statistics and Computing*, τόμ. 14, αρθμ. 3, σσ. 199–222, 2004. DOI: 10.1023/B:STCO.0000035301.49549.88
- [16] I. Goodfellow, Y. Bengio και A. Courville, *Deep Learning*. MIT Press, 2016. διεύθυν.: <http://www.deeplearningbook.org>
- [17] S. Hochreiter και J. Schmidhuber, "Long short-term memory", *Neural Computation*, τόμ. 9, αρθμ. 8, σσ. 1735–1780, 1997. DOI: 10.1162/neco.1997.9.8.1735
- [18] A. Vaswani κ.ά., "Attention is all you need", στο *Advances in Neural Information Processing Systems*, τόμ. 30, 2017.
- [19] H. Zhou κ.ά., "Informer: Beyond efficient transformer for long sequence time-series forecasting", στο *Proceedings of the AAAI Conference on Artificial Intelligence*, τόμ. 35, 2021, σσ. 11 106–11 115. DOI: 10.1609/aaai.v35i12.17325
- [20] A. Zeng, M. Chen, L. Zhang και Q. Xu, "Are transformers effective for time series forecasting?", *Proceedings of the AAAI Conference on Artificial Intelligence*, τόμ. 37, σσ. 11 121–11 128, 2023. DOI: 10.1609/aaai.v37i9.26317
- [21] G. Bontempi, S. B. Taieb και Y.-A. Le Borgne, "Machine learning strategies for time series forecasting", στο *Business Intelligence*, 2012, σσ. 62–77. DOI: 10.1007/978-3-642-36318-4_3
- [22] S. B. Taieb, G. Bontempi, A. F. Atiya και A. Sorjamaa, "A review and comparison of strategies for multi-step ahead time series forecasting based on the NN5 forecasting competition", *Expert Systems with Applications*, τόμ. 39, αρθμ. 8, σσ. 7067–7083, 2012. DOI: 10.1016/j.eswa.2012.01.039
- [23] S. Bengio, O. Vinyals, N. Jaitly και N. Shazeer, "Scheduled sampling for sequence prediction with recurrent neural networks", στο *Advances in Neural Information Processing Systems*, τόμ. 28, 2015.
- [24] F. X. Diebold, "Comparing predictive accuracy, twenty years later: A personal perspective on the use and abuse of Diebold-Mariano tests", *Journal of Business & Economic Statistics*, τόμ. 33, αρθμ. 1, σσ. 1–9, 2015. DOI: 10.1080/07350015.2014.983236
- [25] G. Marcjasz, B. Uniejewski και R. Weron, "On the importance of the long-term seasonal component in day-ahead electricity price forecasting", *Energy Economics*, τόμ. 79, σσ. 227–234, 2019. DOI: 10.1016/j.eneco.2018.05.032
- [26] B. Uniejewski, G. Marcjasz και R. Weron, "On the importance of the long-term seasonal component in day-ahead electricity price forecasting with NARX neural networks", *International Journal of Forecasting*, τόμ. 35, αρθμ. 4, σσ. 1520–1532, 2019. DOI: 10.1016/j.ijforecast.2019.02.001
- [27] ENTSO-E. "ENTSO-E transparency platform", διεύθυν.: <https://transparency.entsoe.eu>
- [28] ENTSO-E Transparency Platform Knowledge Base. "Actual total load and day-ahead total load forecast per bidding zone", διεύθυν.: <https://transparencyplatform.zendesk.com/hc/en-us/articles/16647979768084>
- [29] S. Kaufman, S. Rosset, C. Perlich και O. Stitelman, "Leakage in data mining: Formulation, detection, and avoidance", *ACM Transactions on Knowledge Discovery from Data*, τόμ. 6, αρθμ. 4, σσ. 1–21, 2012. DOI: 10.1145/2382577.2382579
- [30] T. Akiba, S. Sano, T. Yanase, T. Ohta και M. Koyama, "Optuna: A next-generation hyperparameter optimization framework", στο *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2019, σσ. 2623–2631. DOI: 10.1145/3292500.3330701

- [31] F. X. Diebold και R. S. Mariano, "Comparing predictive accuracy", *Journal of Business & Economic Statistics*, τόμ. 13, αρθμ. 3, σσ. 253–263, 1995. doi: 10.1080/07350015.1995.10524599
- [32] D. Harvey, S. Leybourne και P. Newbold, "Testing the equality of prediction mean squared errors", *International Journal of Forecasting*, τόμ. 13, αρθμ. 2, σσ. 281–291, 1997. doi: 10.1016/S0169-2070(96)00719-4
- [33] B. Lim, S. Ö. Arık, N. Loeff και T. Pfister, "Temporal fusion transformers for interpretable multi-horizon time series forecasting", στο *International Journal of Forecasting*, τόμ. 37, 2021, σσ. 1748–1764. doi: 10.1016/j.ijforecast.2021.03.012