



Διπλωματική Εργασία

του φοιτητή του Τμήματος Ηλεκτρολόγων Μηχανικών και
Τεχνολογίας Υπολογιστών της Πολυτεχνικής Σχολής του

Πανεπιστημίου Πατρών

Μαγκλάρα Αριστείδη

Αριθμός Μητρώου: 8115

**Βραχυπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου
Αξιοποιώντας Τεχνικές Μηχανικής και Βαθιάς Μάθησης**

Αριθμός Διπλωματικής Εργασίας:

Πάτρα, Σεπτέμβριος 2018

Πανεπιστήμιο Πατρών, Τμήμα ΗΜΤΥ

Αριστείδης Μαγκλάρας

© 2018 – Με την επιφύλαξη παντός δικαιώματος

ΠΙΣΤΟΠΟΙΗΣΗ

Πιστοποιείται ότι η Διπλωματική Εργασία με θέμα:

**“Βραχυπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου
Αξιοποιώντας Τεχνικές Μηχανικής και Βαθιάς Μάθησης”**

του φοιτητή του Τμήματος Ηλεκτρολόγων Μηχανικών και
Τεχνολογίας Υπολογιστών της Πολυτεχνικής Σχολής του

Πανεπιστημίου Πατρών

Μαγκλάρα Αριστείδη

Αριθμός Μητρώου: 8115

Παρουσιάστηκε δημόσια και εξετάστηκε στο Τμήμα
Ηλεκτρολόγων Μηχανικών και Τεχνολογίας Υπολογιστών
στις 26/09/2018

Επιβλέπων: Χούσος Ευθύμιος

Συνεξεταστής: Μπίρμπας Μιχαήλ

Διευθυντής Τομέα: Χούσος Ευθύμιος

Θα ήθελα να αφιερώσω αυτήν την διπλωματική εργασία στην οικογένεια μου για την στήριξη τους όλα τα χρόνια των σπουδών και όχι μόνο...

Ευχαριστίες

Θα ήθελα να ευχαριστήσω θερμά τον κ.Χούσο διότι ήταν πάντα δίπλα μου όποτε τον χρειάστηκα όχι μόνο κατά την διάρκεια εκπόνησης της διπλωματικής εργασίας αλλά καθ' όλη την διάρκεια των σπουδών μου, τον Νίκο τον Ανδριόπουλο για την όμορφη και αποδοτική συνεργασία μας, τον Ιορδάνη τον Ξανθόπουλο για την πολύτιμη βοήθεια του και όλους τους ανθρώπους που γνώρισα αυτά τα χρόνια και με έκαναν να νοιώσω μέλος μίας οικογένειας μακριά από το σπίτι μου!

Επίσης να ευχαριστήσω την ΔΙΕΥΘΥΝΣΗ ΠΕΡΙΦΕΡΕΙΑΣ ΚΕΝΤΡΙΚΗΣ ΕΛΛΑΔΑΣ (ΔΠΚΕ) του ΔΕΔΔΗΕ για την παροχή των δεδομένων που χρησιμοποιήθηκαν στην παρούσα εργασία

Περίληψη

Το ενεργειακό δίκτυο είναι απαραίτητο να αφομοιώσει τις αλλαγές που προέρχονται από τους νέους κανονισμούς, την νέα δομή της αγοράς και κυρίως από τις τρέχουσες και μελλοντικές εξελίξεις των ΤΕΠ(Τεχνολογίες Επικοινωνίας και Πληροφορίας). Σχετικές προσπάθειες, υπογραμμίζουν την ανάγκη μετάλλαξης του παρόντος ενεργειακού δικτύου σε ένα βιώσιμο, αυτόνομο, φιλικό προς το περιβάλλον (χαμηλών εκπομπών άνθρακα) έξυπνο δίκτυο, ανεξάρτητο από τις κεντρικές και συχνά απαρχαιωμένες υποδομές παραγωγής ενέργειας μέσω άνθρακα και πετρελαίου. Στην πορεία για αυτήν τη φιλόδοξη κατεύθυνση θα πρέπει να αντιμετωπιστούν αρκετά ανοικτά ακόμα ζητήματα, και ένα από αυτά είναι η ακριβής και έγκυρη πρόβλεψη του ηλεκτρικού φορτίου μέσω της οποίας επιδιώκεται η εξισορρόπηση παραγωγής και ζήτησης και κατ' επέκταση η μέγιστη εκμετάλλευση των Ανανεώσιμων Πηγών Ενέργειας (ΑΠΕ). Στην παρούσα διπλωματική επιδιώκεται η πρόβλεψη του ηλεκτρικού φορτίου αξιοποιώντας την τεχνητή νοημοσύνη και συγκεκριμένα την μηχανική και βαθιά μάθηση που αποτελούν το State of the Art στους αλγορίθμους πρόβλεψης. Μετά την εκτενή αναφορά στην βιβλιογραφία και στην θεωρία της πρόβλεψης των χρονοσειρών ακολουθεί η ανάπτυξη τεσσάρων αλγορίθμων μηχανικής και βαθιάς μάθησης και στην συνέχεια με αυτούς επιχειρείται η πρόβλεψη του ηλεκτρικού φορτίου πέντε διαφορετικών γραμμών ισχύος του συστήματος διανομής ηλεκτρικής ενέργειας. Καταλήγοντας τα αποτελέσματα αυτής της πρόβλεψης παρουσιάζονται αναλύονται και εξάγονται σημαντικά συμπεράσματα για την συνολική αντιμετώπιση του προβλήματος.

Λέξεις κλειδιά: τεχνητή νοημοσύνη, μηχανική μάθηση, βαθιά μάθηση, χρονοσειρές, πρόβλεψη ηλεκτρικού φορτίου, νευρωνικά δίκτυα

Περιεχόμενα

1	Εισαγωγή	1
1.1	Γενικά	1
1.2	Συνοπτική Παρουσίαση της Εργασίας	2
2	Εισαγωγή στα Έξυπνα Δίκτυα Ηλεκτρικής Ενέργειας	4
2.1	Ιστορική Ανασκόπηση Συστημάτων Ηλεκτρικής Ενέργειας	4
2.2	Σύγχρονα Ηλεκτρικά Δίκτυα	5
2.2.1	Τοπολογία ΣΗΕ	5
2.2.2	Συστήματα και Εξοπλισμός Παρακολούθησης Δικτύου	7
2.2.3	Οι Αδυναμίες του Υπάρχοντος Ηλεκτρικού Δικτύου	10
2.3	Το Έξυπνο Ηλεκτρικό Δίκτυο - Smart Grid	12
2.3.1	Ορισμός του Έξυπνου Δικτύου	12
2.3.2	Στόχοι και Προκλήσεις	14
2.3.3	Πλαίσιο και Χαρακτηριστικά των Έξυπνων Δικτύων	17
2.3.4	Η Αρχιτεκτονική ενός Έξυπνου Δικτύου	19
2.3.5	Τα Θεμέλια Στοιχεία του Έξυπνου Δικτύου	21
3	Πρόβλεψη Ηλεκτρικού Φορτίου-Ανασκόπηση της Βιβλιογραφίας	27
3.1	Η Σημασία της Πρόβλεψης του Ηλεκτρικού Φορτίου	27
3.2	Κατηγοριοποίηση με Βάση τον Ορίζοντα Πρόβλεψης	30

3.2.1	Πολύ Βραχυπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου (Very Short Term Load Forecasting)	30
3.2.2	Βραχυπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου (Short Term Load Forecasting)	31
3.2.3	Μεσοπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου (Medium Term Load Forecasting)	32
3.2.4	Μακροπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου (Long Term Load Forecasting)	32
3.3	Στατιστικά Χαρακτηριστικά Χρονοσειρών Ηλεκτρικού Φορτίου	33
3.3.1	Στασιμότητα (Stationarity)	34
3.3.2	Γραμμικότητα (Linearity)	35
3.3.3	Αυτοσυσχέτιση (Autocorellation)	36
3.4	Στρατηγικές Πρόβλεψης Ηλεκτρικού Φορτίου	37
3.4.1	Αναδρομική στρατηγική (recursive)	38
3.4.2	Άμεση στρατηγική (direct)	40
3.4.3	Στρατηγική πολλαπλών εισόδων και εξόδων (Multiple Input Multiple Output (MIMO))	40
3.4.4	Υβριδική μέθοδος αυτοσυσχέτισης (Hybrid Autocorellation Method(HAM))	41
3.5	Αλγόριθμοι Πρόβλεψης	43
3.5.1	Αναλυτικά Μοντέλα Πρόβλεψης	43
3.5.2	Μοντέλα μηχανικής-βαθιάς μάθησης	44
3.6	Μέτρα Απόδοσης	51
3.6.1	Μέσο Απόλυτο Σφάλμα (MAE)	51
3.6.2	Ρίζα Μέσου Τετραγωνικού Σφάλματος (RMSE)	52
3.6.3	Σύγκριση	52
4	Υλοποίηση	54
4.1	Tensorflow	54
4.1.1	Γενικά	54
4.1.2	Πλεονεκτήματα Tensorflow	55

4.1.3	Υλοποίηση και εκπαίδευση μοντέλων αξιοποιώντας το Keras	56
4.2	Δεδομένα Εισόδου	59
4.2.1	Γραμμή Μέσης Τάσης του Ελληνικού Δικτύου Διανομής Ηλεκτρικής Ενέργειας	59
4.2.2	Open Source Δεδομένα Γραμμών Μέσης Τάσης Trento-Italy	61
4.2.3	Κώδικας φόρτωσης των δεδομένων	62
4.3	Προεπεξεργασία	63
4.4	Χωρισμός του dataset σε train και test	64
4.5	Στατιστική ανάλυση Δεδομένων	66
4.5.1	Γραμμικότητα - Linearity	66
4.5.2	Στασιμότητα - Stationarity	67
4.5.3	Αυτοσυσχέτιση - Autocorellation	70
4.6	Μοντέλο Long Short Term Memory(LSTM)	72
4.7	Μοντέλο Multi Layer Perceptron (MLP)	74
4.8	Μοντέλο Convolution Neural Network (CNN)	75
4.9	Μοντέλο Artificial Neural Network (ANN)	77
5	Παρουσίαση Αποτελεσμάτων και Ερμηνεία	78
5.1	Αταλάντη	78
5.2	Δομοκός	85
5.3	Μακρυχώρι	90
5.4	Άμφισσα	93
5.5	Trento	99
6	Συμπεράσματα και Προτάσεις για Περαιτέρω Έρευνα	105

Κατάλογος Γραφημάτων

2.1	Σταθμός Pearl Street	5
2.2	Control Room συστήματος SCADA	9
2.3	Έξυπνο Δίκτυο vs Δίκτυο Ηλεκτρισμού [15]	14
2.4	Στόχοι ενός Έξυπνου Δικτύου [22]	16
2.5	Χαρακτηριστικά και λύσεις	19
2.6	Μοντέλο του Smart Grid από την NIST [25]	21
2.7	Κεντρική και Κατακεντρωμένη Παραγωγή [26]	22
2.8	Παράδειγμα αυτόματης Απόκρισης Ζήτησης [28]	23
2.9	Σύστημα οικιακής αποθήκευσης ενέργειας Sunrun Tesla [29]	24
2.10	Αλληλεπίδραση ηλεκτρικού οχήματος με έξυπνο δίκτυο [31]	26
3.1	Κατηγοριοποίηση με βάση τον ορίζοντα πρόβλεψης [32]	30
3.2	Επισκόπηση της πολύ βραχυπρόθεσμης πρόβλεψης φορτίου για online εφαρμογή	31
3.3	Γραμμική χρονοσειρά [24]	36
3.4	Μη γραμμική χρονοσειρά ηλεκτρικού φορτίου [;]	36
3.5	Παράδειγμα αρχιτεκτονικής του MLP, μια εφαρμογή σε πρόβλεψη της ταχύτητας του αέρα [49]	47
3.6	Παράδειγμα αρχιτεκτονικής του CNN, [50]	48
3.7	Αρχιτεκτονική του RNN [52]	48
3.8	Αρχιτεκτονική του LSTM [52]	49
4.1	Αριστερά το TimeStamp και δεξιά η τιμή του ηλεκτρι- κού φορτίου σε Ampere	60
4.2	Αριστερά το TimeStamp και δεξιά η τιμή του ηλεκτρι- κού φορτίου σε Ampere	62

4.3	Συνάρτηση μορφοποίησης dataset	63
4.4	Φόρτωση dataset	63
4.5	Κανονικοποίηση του dataset με MinMaxScaler	64
4.6	Κώδικας για χωρισμό του dataset σε train και test . . .	65
4.7	Ο κώδικας για το Augmented Dickey-Fuller test	69
4.8	Ο κώδικας για το έλεγχο των στατιστικών μέτρων . .	69
4.9	Ο κώδικας για την υλοποίηση του LSTM μοντέλου . .	72
4.10	Δομή LSTM block	73
4.11	Κώδικας Υλοποίησης MLP	74
4.12	Κώδικας Υλοποίησης CNN	75
4.13	Κώδικας Υλοποίησης ann	77
5.1	Διάγραμμα αυτοσυσχέτισης για τις επόμενες 48 πα- ρατηρήσεις	79
5.2	Διάγραμμα αυτοσυσχέτισης της τιμής t με την αντί- στοιχη $t + 48$ δηλαδή την ίδια ώρα της επόμενης ημέρας	79
5.3	Διάγραμμα κατανομής	80
5.4	Αποτελέσματα augmented dickey test	80
5.5	Διάγραμμα CNN	81
5.6	Διάγραμμα LSTM	81
5.7	Διάγραμμα MLP	82
5.8	Διάγραμμα ANN	82
5.9	Μεγεθυμένο διάγραμμα LSTM	83
5.10	Διάγραμμα αυτοσυσχέτισης για τις επόμενες 48 πα- ρατηρήσεις	85
5.11	Διάγραμμα αυτοσυσχέτισης της τιμής t με την αντί- στοιχη $t + 48$ δηλαδή την ίδια ώρα της επόμενης ημέρας	86
5.12	Διάγραμμα κατανομής	86
5.13	Αποτελέσματα augmented dickey test	87
5.14	Διάγραμμα CNN	87
5.15	Διάγραμμα LSTM	88
5.16	Διάγραμμα MLP	88
5.17	Διάγραμμα ANN	89

5.18 Μεγεθυμένο διάγραμμα LSTM	90
5.19 Διάγραμμα αυτοσυσχέτισης για τις επόμενες 48 παρατηρήσεις	91
5.20 Διάγραμμα αυτοσυσχέτισης της τιμής t με την αντίστοιχη $t + 48$ δηλαδή την ίδια ώρα της επόμενης ημέρας	91
5.21 Διάγραμμα κατανομής	92
5.22 Αποτελέσματα augmented dickey test	92
5.23 Διάγραμμα CNN	93
5.24 Διάγραμμα LSTM	93
5.25 Διάγραμμα αυτοσυσχέτισης για τις επόμενες 48 παρατηρήσεις	94
5.26 Διάγραμμα αυτοσυσχέτισης της τιμής t με την αντίστοιχη $t + 48$ δηλαδή την ίδια ώρα της επόμενης ημέρας	94
5.27 Διάγραμμα κατανομής	95
5.28 Αποτελέσματα augmented dickey test	95
5.29 Διάγραμμα CNN	96
5.30 Διάγραμμα LSTM	96
5.31 Διάγραμμα MLP	97
5.32 Διάγραμμα ANN	97
5.33 Μεγεθυμένο διάγραμμα LSTM	98
5.34 Διάγραμμα αυτοσυσχέτισης για τις επόμενες 48 παρατηρήσεις	99
5.35 Διάγραμμα αυτοσυσχέτισης της τιμής t με την αντίστοιχη $t + 144$ δηλαδή την ίδια ώρα της επόμενης ημέρας	100
5.36 Διάγραμμα κατανομής	101
5.37 Αποτελέσματα augmented dickey test	101
5.38 Διάγραμμα CNN	102
5.39 Διάγραμμα LSTM	102
5.40 Διάγραμμα MLP	103
5.41 Διάγραμμα ANN	103

Κατάλογος Πινάκων

5.1	Μετρα απόδοσης RMSE και MAE όλων των μοντέλων για το dataset της Αταλάντης	83
5.2	Μετρα απόδοσης RMSE και MAE όλων των μοντέλων για το dataset της Αταλάντης	89
5.3	Μετρα απόδοσης RMSE και MAE όλων των μοντέλων για το dataset του Μακρυχωρίου	92
5.4	Μετρα απόδοσης RMSE και MAE όλων των μοντέλων για το dataset της Άμφισσας	98
5.5	Μετρα απόδοσης RMSE και MAE όλων των μοντέλων για το dataset της περιοχής Trento	104
6.1	Συγκεντρωτικός πίνακας αποτελεσμάτων	106

Κεφάλαιο 1

Εισαγωγή

1.1 Γενικά

Το σύγχρονο ενεργειακό δίκτυο είναι απαραίτητο να αφομοιώσει τις αλλαγές που προέρχονται από τους νέους κανονισμούς, την νέα δομή της αγοράς ενέργειας και κυρίως από τις τρέχουσες και μελλοντικές εξελίξεις των Τεχνολογιών Επικοινωνίας και Πληροφορίας (ΤΕΠ). Σχετικές προσπάθειες, υπογραμμίζουν την ανάγκη μετάλλαξης του παρόντος ενεργειακού δικτύου σε ένα βιώσιμο, αυτόνομο, φιλικό προς το περιβάλλον (χαμηλών εκπομπών άνθρακα) τοπικό δίκτυο, ανεξάρτητο από τις κεντρικές και συχνά απαρχαιωμένες υποδομές παραγωγής ενέργειας μέσω άνθρακα και πετρελαίου. Είναι σαφές ότι η έγκυρη και ακριβής πρόβλεψη του ηλεκτρικού φορτίου είναι ζωτικής σημασίας για την επίτευξη των νέων αυτών στόχων που θέτουν τα έξυπνα δίκτυα. Με εργαλείο την πρόβλεψη, οι πάροχοι μπορούν να μοντελοποιήσουν και να προβλέψουν με ακρίβεια το ηλεκτρικό φορτίο με σκοπό την εξισορρόπηση παραγωγής και ζήτησης, την μείωση του κόστους παραγωγής και την υλοποίηση των διαφόρων στρατηγικών τιμολόγησης και απόκρισης ζήτησης καθώς και την βέλτιστη εκμετάλλευση των ανανεώσιμων πηγών ενέργειας.

Ωστόσο, με την πρόσφατη ενσωμάτωση των συστημάτων έξυπνων δικτύων στα σημερινά συστήματα ισχύος και την αυξανόμενη διείσδυση της κατανεμημένης παραγωγής, η διαδικασία για ακριβή και έγκυρη πρόβλεψη ηλεκτρικού φορτίου γίνεται όλο και πιο πολύπλοκη, απαιτώντας πιο αποτελεσματικές τεχνικές. Σύμμαχος σε αυτήν την προσπάθεια είναι η ραγδαία ανάπτυξη των τεχνικών τεχνητής νοημοσύνης και συγκεκριμένα της μηχανικής μάθησης οι οποίες έχουν υπερισχύσει των συμβατικών γραμμικών μεθόδων, επιτυγχάνοντας αποτελέσματα πολύ μεγαλύτερης ακρίβειας.

Έτσι, στην συγκεκριμένη διπλωματική εργασία εξετάζεται το πρόβλημα της πρόβλεψης ηλεκτρικού φορτίου γραμμής ισχύος, αξιοποιώντας αλγορίθμους μηχανικής και βαθιάς μάθησης (machine-deep learning).

1.2 Συνοπτική Παρουσίαση της Εργασίας

Στο δεύτερο κεφάλαιο επιχειρείται μία εισαγωγική μελέτη που αφορά στις βασικές έννοιες και χαρακτηριστικά ενός Έξυπνου Δικτύου, ενώ στο τρίτο κεφάλαιο “**Πρόβλεψη Ηλεκτρικού Φορτίου-Ανασκόπηση της βιβλιογραφίας**” καλύπτονται βασικές έννοιες της θεωρίας της πρόβλεψης χρονοσειρών με ιδιαίτερη έμφαση στην πρόβλεψη ηλεκτρικού φορτίου και τα ιδιαίτερα χαρακτηριστικά της, ενώ παρουσιάζονται και αναλύονται τα σημαντικότερα μοντέλα πρόβλεψης χρονοσειρών. Στην συνέχεια στο τέταρτο κεφάλαιο “**Υλοποίηση**” παρουσιάζεται αναλυτικά η διαδικασία υλοποίησης του πειράματος. Στο έκτο “**Παρουσίαση Αποτελεσμάτων και Ερμηνεία**” παρουσιάζονται λεπτομερώς τα αποτελέσματα του πειράματος και δίνεται μια ερμηνεία αυτών. Κλείνοντας στο έκτο κεφάλαιο “**Συμπεράσματα και Προτάσεις για Περαιτέρω Έρευνα**” εξάγουμε συνολικά συμπεράσματα


από το αποτέλεσμα του πειράματος και αναπτύσσονται σκέψεις και ιδέες που μπορούν να συνεισφέρουν στην μελλοντική συνέχιση του πειράματος .

Κεφάλαιο 2

Εισαγωγή στα Έξυπνα Δίκτυα Ηλεκτρικής Ενέργειας

2.1 Ιστορική Ανασκόπηση Συστημάτων Ηλεκτρικής Ενέργειας

Η βασική ανθρώπινη ανάγκη και εν συνεχεία απαίτηση για ασφαλές, αποδοτικό και οικονομικό φως αποτέλεσε την κινητήριου δύναμη που οδήγησε στην ανάπτυξη μίας από τις μεγαλύτερες διαχρονικά βιομηχανίες, την βιομηχανία του ηλεκτρικού ρεύματος. Η αρχή αυτού που ονομάζουμε σήμερα Σύστημα Ηλεκτρικής Ενέργειας (ΣΗΕ) οφείλεται στην εφευρετική δεινότητα του Thomas Eddison, ο οποίος δημιούργησε και έθεσε σε λειτουργία το 1882 τον ιστορικό σταθμό της Pearl Street που τροφοδοτούσε με ηλεκτρικό ρεύμα το μεγαλύτερο μέρος του νοτίου Manhattan. Ο πρώτος αυτός σταθμός παραγωγής ηλεκτρικής ενέργειας αποτελούταν από μια ατμομηχανή που κινούσε μία γεννήτρια συνεχούς ρεύματος και τροφοδοτούσε με ηλεκτρική ενέργεια 59 καταναλωτές σε μία ακτίνα περίπου 1,5 χμ [1]. Στην συνέχεια, η ανάπτυξη των πολυφασικών συστημάτων από τον Nikola Tesla σε συνδυασμό με τις πρωτοποριακές για την εποχή



Γράφημα 2.1: Σταθμός Pearl Street

εφευρέσεις του όσον αφορά τους κινητήρες εναλλασσομένου, τις γεννήτριες, τους μετασχηματιστές και τα συστήματα μεταφοράς έθεσαν τα θεμέλια για την ανάπτυξη των σημερινών συστημάτων ηλεκτρικής ενέργειας.

Με την πάροδο των ετών η βιομηχανία παραγωγής ηλεκτρικής ενέργειας εξαπλωνόταν ραγδαία. Οι τεχνολογικές πρόοδοι που επιτυγχάνονταν στη σχεδίαση των διαφόρων συνιστωσών των ενεργειακών συστημάτων ενσωματώνονταν σε κάθε νέα συνιστώσα που εγκαθίσταται, με αποτέλεσμα γρήγορη αναβάθμιση του εξοπλισμού. Έτσι καταλήγουμε στα σύγχρονα ΣΗΕ που αποτελούν ένα πολύπλοκο δίκτυο ηλεκτρισμού το οποίο πρέπει να λειτουργεί κατά τέτοιο τρόπο ώστε να είναι ασφαλές, αξιόπιστο, φιλικό προς το περιβάλλον και να παρέχει ηλεκτρική ενέργεια καλής ποιότητας στην χαμηλότερη κατά το δυνατόν τιμή [2].

2.2 Σύγχρονα Ηλεκτρικά Δίκτυα

2.2.1 Τοπολογία ΣΗΕ

Ένα σύγχρονο ηλεκτρικό δίκτυο καθιστά εφικτή την παραγωγή, μεταφορά και διανομή ηλεκτρικής ενέργειας από τον σταθμό παρα-

γωγής στον καταναλωτή. Τα κύρια στοιχεία που αποτελούν ένα τυπικό δίκτυο ηλεκτρισμού είναι: ηλεκτροπαραγωγοί σταθμοί (power plants), υποσταθμοί μεταφοράς ανύψωσης τάσης (step-up transmission substations), υποσταθμοί μεταφοράς υψηλής τάσης (power plants) και υποβιβασμού της σε μέση τάση (step-down transmission substations), υποσταθμοί διανομής μέσης τάσης και υποβιβασμού σε χαμηλή τάση (distribution substations) και γραμμές διανομής υψηλής, μέσης και χαμηλής τάσης (transmission and distribution lines) [1]. Η ενέργεια η οποία παράγεται στους ηλεκτροπαραγωγούς σταθμούς προέρχεται από ανανεώσιμες ή μη, πηγές ενέργειας. Οι ανανεώσιμες πηγές ενέργειας κατατάσσονται συνήθως σε δύο κατηγορίες: τις μεταβλητές (ηλιακή, αιολική ενέργεια) και τις μη μεταβλητές πηγές ενέργειας (υδροηλεκτρική, βιομάζα, γεωθερμική ενέργεια). Οι μη ανανεώσιμες (και μη μεταβλητές) πηγές ενέργειας αφορούν συνήθως στα ορυκτά καύσιμα (κάρβουνο, πετρέλαιο, φυσικό αέριο) ή την πυρηνική ενέργεια.

Όπως και να παράγεται όμως η ενέργεια στους ηλεκτροπαραγωγούς σταθμούς, το επόμενο βήμα είναι το ίδιο και έχει να κάνει με τη μεταφορά της μέσω μετασχηματιστών σε υψηλές τάσεις, πριν από την εισαγωγή της στο δίκτυο μεταφοράς, ώστε να ελαχιστοποιηθούν οι απώλειες λόγω του φαινομένου του Joule [1]. Μέσω των γραμμών μεταφοράς υψηλής τάσης η ενέργεια αυτή φτάνει σε υποσταθμούς μεταφοράς η οποίοι μετασχηματίζουν την υψηλή τάση σε μέση τάση για να συνεχίσει να μεταφέρεται μέσω των γραμμών μεταφοράς προς τους υποσταθμούς διανομής οι οποίοι μετασχηματίζοντας τη μέση τάση σε χαμηλή, παραδίδουν την ενέργεια σε γραμμές διανομής χαμηλής τάσης οι οποίες συνδέονται στο τέλος στους πελάτες χαμηλής τάσης. Οι υποσταθμοί μεταφοράς ηλεκτρικής ενέργειας βέβαια πέρα από το ρόλο που διαδραματίζουν για το μετασχηματισμό τάσης σχεδιάζονται στις πλείστες των περιπτώσεων με τρόπο τέτοιο

που να εξασφαλίζονται διασυνδέσεις εναλλακτικής τροφοδοσίας από υφιστάμενους υποσταθμούς, σε περιπτώσεις κατά τις οποίες ένας υποσταθμός δε μπορεί να χρησιμοποιηθεί για κάποιο λόγο (π.χ. εργασίες συντήρησης), πράγμα που αυξάνει την αξιοπιστία του δικτύου μεταφοράς ηλεκτρικής ενέργειας. Παράλληλα, μέσα στους υποσταθμούς μεταφοράς εντοπίζονται μεταξύ άλλων διακόπτες κυκλωμάτων (circuit breakers) οι οποίοι αξιοποιούνται για αποσύνδεση από το σύστημα μεταφοράς (για απομόνωση των εγκαταστάσεων ή/και των μηχανημάτων), αλλά και μονάδες συλλογής δεδομένων του υποσταθμού για αποστολή τους σε ένα κέντρο ελέγχου ενέργειας.

2.2.2 Συστήματα και Εξοπλισμός Παρακολούθησης Δικτύου

Ουσιαστικής σημασίας για την ομαλή λειτουργία του ΣΗΕ, είναι η ύπαρξη των κατάλληλων συστημάτων και εξοπλισμού προκειμένου να επιτυγχάνεται η διαρκής παρακολούθηση του δικτύου για την όσο το δυνατό πιο άμεση αποκατάσταση παροχής ηλεκτρικής ενέργειας μετά από περιστατικά διακοπής και την όσο το δυνατό πιο ακριβή πρόβλεψη της ζήτησης για ισοζυγισμό της παραγωγής. Το βασικό σύστημα πίσω από αυτή τη διαδικασία σήμερα είναι γνωστό σαν Σύστημα Εποπτικού Ελέγχου και Συλλογής Πληροφοριών (Supervisory Control and Data Acquisition system (SCADA)). Ο έλεγχος εποπτείας και η συλλογή δεδομένων (SCADA) είναι μια αρχιτεκτονική συστήματος ελέγχου που χρησιμοποιεί υπολογιστές, δικτυακές επικοινωνίες δεδομένων και γραφικές διεπαφές χρήστη για διαχείριση εποπτικών διαδικασιών υψηλού επιπέδου, αλλά χρησιμοποιεί άλλες περιφερειακές συσκευές, όπως προγραμματιζόμενους λογικούς ελεγκτές και διακριτούς ελεγκτές PID, εγκαταστάσεις ή μηχανήματα επεξεργασίας. Οι διεπαφές χρήστη που επιτρέπουν την παρακολούθηση και την έκ-

δοση εντολών διεργασίας, όπως οι αλλαγές σημείων ρύθμισης του ελεγκτή, διεκπεραιώνονται μέσω του συστήματος υπολογιστή (SCADA). Ωστόσο, οι υπολογισμοί λογικού ελέγχου σε πραγματικό χρόνο ή υπολογισμοί ελέγχου πραγματοποιούνται από δικτυωμένα δομοστοιχεία τα οποία συνδέονται με τους αισθητήρες πεδίου και τους ενεργοποιητές [4].

Ένα τέτοιο σύστημα εκτελεί στην πραγματικότητα 4 βασικές λειτουργίες : συλλογή, επεξεργασία και παρουσίαση δεδομένων και έλεγχο του συστήματος. Η συλλογή δεδομένων από ολόκληρο το δίκτυο μεταφοράς καθίσταται δυνατή μέσω εξοπλισμού ο οποίος περιλαμβάνει αισθητήρες και τηλετεματικό εξοπλισμό (Remote Terminal Units (RTUs)) ο οποίος μετατρέπει τα σήματα των αισθητήρων σε ψηφιακή πληροφορία, την οποία μεταφέρει στο σύστημα επεξεργασίας δεδομένων μέσω τηλεπικοινωνιακών διασυνδέσεων. Η επεξεργασία γίνεται από ένα σύνολο συστημάτων μεγάλης υπολογιστικής ισχύος τα οποία παρουσιάζουν την πληροφορία που προέκυψε από τα δεδομένα σε μια μορφή που αποκτά νόημα για τους τεχνικούς που είναι υπεύθυνοι για την παρακολούθηση του δικτύου μέσω της διεπαφής (Human Machine Interface (HMI)) που διαθέτει κάθε σύστημα SCADA. Η διεπαφή αυτή, παρουσιάζει σε κατανοητή μορφή την πληροφορία που αφορά στην κατάσταση του δικτύου, δίνοντας ουσιαστικά τη δυνατότητα στον ελεγκτή της να έχει άμεση πληροφόρηση για ό,τι αφορά στο δίκτυο, τη θέση των διακοπών , τη φόρτιση των γραμμών, τα επίπεδα τάσης, τα επίπεδα παραγωγής από όλες τις μονάδες, την κατάσταση του εξοπλισμού, τη θερμοκρασία εντός των υποσταθμών κτλ. Μέσω αυτής καθίσταται δυνατός ο εντοπισμός προβληματικών καταστάσεων οι οποίες απειλούν την ομαλή λειτουργία του ηλεκτρικού δικτύου, και οι οποίες ταξινομούνται από το σύστημα βάσει της επικινδυνότητας τους με τις πιο σοβαρές να αξιολογούνται ως ύψιστης

προτεραιότητας, πράγμα το οποίο συμβάλλει στην όσο το δυνατό πιο άμεση ανταπόκριση. Τα συστήματα αυτά παρέχουν επιπρόσθετα και τη δυνατότητα ελέγχου και τηλεχειρισμού του εξοπλισμού που βρίσκεται στους υποσταθμούς, πράγμα το οποίο σε πολλές περιπτώσεις έχει ως αποτέλεσμα την αποκατάσταση μιας βλάβης χωρίς να χρειαστεί φυσική παρουσία τεχνικού στον υποσταθμό που αντιμετωπίσε το πρόβλημα.



Γράφημα 2.2: Control Room συστήματος SCADA

Ένα ολοκληρωμένο σύστημα SCADA συνεργάζεται πάντα με ένα Σύστημα Διαχείρισης Ενέργειας (Energy Management System (EMS)). Το EMS αποτελείται στην πραγματικότητα από ένα σύνολο εφαρμογών οι οποίες έχουν ως στόχο τους τη βελτιστοποίηση της διαδικασίας παραγωγής και μεταφοράς, ώστε να είναι όσο το δυνατό πιο αποδοτική, ασφαλής και οικονομική. Ένα σύστημα EMS είναι υπεύθυνο για την πρόβλεψη διακύμανσης ζήτησης ηλεκτρικής ενέργειας για την επόμενη μέρα, πρόβλεψη η οποία γίνεται εφικτή βάσει ενός ιστορικού ζήτησης ηλεκτρικής ενέργειας σε μέρες συγκρίσιμες με την αυριανή (π.χ. μέρες με τις ίδιες καιρικές συνθήκες, την ίδια εποχή, στις ίδιες ώρες). Μετά την πρόβλεψη, το σύστημα οφείλει να προχωρήσει στην εισήγηση του καλύτερου τρόπου αξιοποίησης των μονάδων παραγωγής, βάσει της πρόβλεψης ζήτησης και βάσει της πιο συμφέρουσας οικονομικά λύσης. Παράλληλα, η δυνατότητα προσομοίωσης της κατάστασης του δικτύου σε περίπτωση αποσύνδεσης εξοπλισμού προκειμένου να λαμβάνονται μέτρα πριν από προγραμματισμένες ε-

νέργειες, εμπίπτει επίσης στις δυνατότητες ενός EMS [3].

2.2.3 Οι Αδυναμίες του Υπάρχοντος Ηλεκτρικού Δικτύου

Κάπως έτσι η ηλεκτρική ενέργεια παράγεται και φτάνει στα σπίτια μας. Με μια διαδικασία η οποία ελάχιστα άλλαξε μέσα στα τελευταία 100 χρόνια. Η εξέλιξη της τεχνολογίας έχει φέρει προφανώς την αυτοματοποίηση στην παραγωγή της ηλεκτρικής ενέργειας και στα συστήματα ελέγχου της, ωστόσο σε καμία περίπτωση δε μπορούμε να πούμε ότι έφερε την επανάσταση στον τομέα αυτό, όπως έχει κάνει σε τόσους άλλους τομείς της βιομηχανίας. Καθώς όμως τα χρόνια περνούν οι απαιτήσεις μας αλλάζουν, πράγμα το οποίο απαιτεί και τα συστήματά μας να μπορούν να συμβαδίζουν και να ανταποκρίνονται σε αυτές. Συνεπώς έχουμε πλέον αρχίσει να αντιλαμβανόμαστε τις αδυναμίες του παρόντος ηλεκτρικού δικτύου.

Προφανώς, ένα δίκτυο το οποίο λειτουργεί βασισμένο σε μεγάλους κεντρικούς ηλεκτροπαραγωγούς σταθμούς, που βρίσκονται σε στρατηγικά σημεία και συνδεδεμένους με συστήματα μεταφοράς υψηλής τάσης για να στηρίζουν την ηλεκτροδότηση μεγάλων περιοχών, στηρίζεται στη διακίνηση ενός τεράστιου όγκου πληροφορίας από και προς τα κέντρα παραγωγής. Αυτό έχει ως αποτέλεσμα η πληροφορία αυτή να φτάνει πολλές φορές με καθυστερήσεις στον προορισμό (high data latency), γεγονός το οποίο στερεί τη δυνατότητα στο σύστημα να διενεργεί έλεγχο σε πραγματικό χρόνο.

Την ίδια στιγμή, μια άλλη αδυναμία του τρέχοντος δικτύου ηλεκτροδότησης έγκειται στη μονόπλευρη φύση της επικοινωνίας και διανομής ενέργειας, η οποία ορίζει πως ενέργεια μεταφέρεται μόνο από τον ηλεκτροπαραγωγό σταθμό στο δίκτυο και κατά συνέπεια στον πελάτη, χωρίς ο πελάτης να μπορεί να συμβάλει στη βελτίω-

ση της αποδοτικότητας του δικτύου εισάγοντας σε αυτό δικές του πηγές ενέργειας (ηλιακή ενέργεια, αιολική ενέργεια από ιδιόκτητες εγκαταστάσεις). Αυτή η αδυναμία του τρέχοντος ηλεκτρικού δικτύου να ενσωματώσει με επιτυχία τις εναλλακτικές πηγές ενέργειας (οι οποίες εξαρτώνται από τοπικές και καιρικές συνθήκες) στο δίκτυο, με τρόπο που να μην επηρεάζεται η αξιοπιστία του συστήματος (η οποία τώρα εξασφαλίζεται από την επεξεργασία των μη ανανεώσιμων μη μεταβλητών πηγών ενέργειας οι οποίες εγγυημένα θα δώσουν το ζητούμενο ποσοστό ηλεκτρικής ενέργειας), έχει παράλληλα και σημαντικές επιπτώσεις στο περιβάλλον, η ρύπανση του οποίου αποτελεί ένα σημαντικό πρόβλημα σήμερα.

Πέραν όλων αυτών βέβαια, άλλο ένα σημαντικό μειονέκτημα του τρέχοντος ηλεκτρικού δικτύου έχει να κάνει με την αδυναμία να αποθηκεύσουμε την ηλεκτρική ενέργεια με εύκολο τρόπο, γεγονός το οποίο οδηγεί στην επιτακτική ανάγκη έγκυρης και ακριβούς πρόβλεψης ώστε το δίκτυο να ανταποκριθεί με επιτυχία στις απαιτήσεις της επόμενης ημέρας. Παρά τις προσπάθειες για εξασφάλιση όσο το δυνατό μεγαλύτερης ακρίβειας σε αυτές τις προβλέψεις, η ζήτηση δε μπορεί ποτέ να προβλεφθεί με απόλυτη επιτυχία. Αυτό έχει πολύ συχνά ως αποτέλεσμα είτε την παραγωγή περισσότερης ενέργειας από όση πραγματικά θα χρειαστεί, με αποτέλεσμα η επιπλέον αυτή ενέργεια να μη χρησιμοποιείται πουθενά (αλλά το κόστος της παραγωγής της να επιβαρύνει τον πελάτη), είτε τη διακοπή ρεύματος (rolling blackouts) λόγω μιας κακής εκτίμησης η οποία είχε ως αποτέλεσμα την παραγωγή λιγότερης ενέργειας από αυτή που πραγματικά ζητήθηκε την επόμενη μέρα. Όλα αυτά έρχονται φυσικά να επιβαρυνθούν και από το γεγονός ότι το τρέχον σύστημα χρειάζεται τη φυσική παρέμβαση ενός χειριστή προκειμένου να μπορέσει να επανέλθει σε κατάσταση λειτουργίας κατόπιν οποιασδήποτε βλάβης.

Καταλήγοντας, είναι αδιαμφισβήτητο ότι βιώνουμε μια εποχή συνεχών αλλαγών στο τοπίο της ενέργειας. Πολλές εξ' αυτών απορρέουν από το σημαντικό κόστος (τόσο οικονομικό όσο και περιβαλλοντικό) που συνεπάγονται οι αυξημένοι ρύποι, από την αύξηση της διείσδυσης του φυσικού αερίου και την ανταγωνιστική πλέον παρουσία των ΑΠΕ. Τα παραπάνω, σε συνδυασμό με τις εξελίξεις στον τομέα των Τεχνολογιών Επικοινωνίας και Πληροφορίας (ΤΕΠ) οδηγούν στην επιτακτική ανάγκη μετάλλαξης του υπάρχοντος ενεργειακού δικτύου σε ένα αξιόπιστο, βιώσιμο, αυτόνομο, φιλικό προς το περιβάλλον αποκεντρωμένο τοπικό δίκτυο στα πρότυπα ενός μικροδικτύου ή μιας ενεργειακής κοινότητας. Κάπως έτσι γεννήθηκε η ιδέα του Smart Grid.

2.3 Το Έξυπνο Ηλεκτρικό Δίκτυο - Smart Grid


2.3.1 Ορισμός του Έξυπνου Δικτύου

Το γεγονός ότι δεν υπάρχει ένας μοναδικός ορισμός για το Έξυπνο Δίκτυο δεν αποτελεί σε καμία περίπτωση έκπληξη. Ο καθορισμός του έξυπνου δικτύου με έναν συνοπτικό τρόπο δεν είναι εύκολος δεδομένου ότι η έννοια είναι σχετικά νέα και καθώς επίσης πολλά και διαφορετικά στοιχεία μπορούν να δομήσουν ένα έξυπνο δίκτυο. Στην βιβλιογραφία μπορεί να συναντήσει κανείς πολλούς ορισμούς για το 'Έξυπνο Δίκτυο'. Σύμφωνα με το Electric Power Research Institute (EPRI), το Έξυπνο Δίκτυο παρουσιάζεται ως «μία ευφυής υποδομή παροχής ηλεκτρικής ενέργειας η οποία υποστηρίζεται από τις τελευταίες τεχνολογίες στον τομέα της επικοινωνίας, των υπολογιστών και της ηλεκτρονικής, προκειμένου να ανταποκριθεί στις μελλοντικές απαιτήσεις της κοινωνίας σε ηλεκτρική ενέργεια». Σε μια άλλη εκδοχή, το Γραφείο Μεταφοράς και Διανομής Ενέργειας του Department of Energy (DoE) των ΗΠΑ, ορίζει το Έξυπνο Δίκτυο ως τη λύση που «θα εξα-

σφαλίσει την αξιοπιστία, την ασφάλεια και την αποδοτικότητα του ηλεκτρικού συστήματος μέσω ανταλλαγής πληροφοριών, κατανεμημένης παραγωγής και αποθήκευσης της ενέργειας». Η Ευρωπαϊκή Επιτροπή, μέσω του COM(2011) 202 "Smart Grids: from innovation to deployment" [11] παρουσιάζει το Έξυπνο Δίκτυο ως «ένα εξελιγμένο ηλεκτρικό δίκτυο, του οποίου αναπόσπαστο κομμάτι είναι η αμφίδρομη επικοινωνία μεταξύ παραγωγού και καταναλωτή και τα ευφυή συστήματα μέτρησης και παρακολούθησης της λειτουργίας του». Ενώ το European Commission Task Force for Smart Grid [12] ορίζει το Έξυπνο Δίκτυο ως «ένα ηλεκτρικό δίκτυο το οποίο με αποδοτικό τρόπο μπορεί να ενσωματώσει τη συμπεριφορά και τις δράσεις όλων των παραγόντων που βρίσκονται συνδεδεμένοι σε αυτό παραγωγοί, καταναλωτές ή και καταναλωτές που παράγουν ενέργεια ώστε να διασφαλίσει ένα οικονομικά αποδοτικό, βιώσιμο σύστημα ενέργειας με χαμηλές απώλειες και υψηλής ποιότητας υπηρεσία, σε ένα ασφαλές και αξιόπιστο δίκτυο». Σύμφωνα με την IEEE [14] "το Έξυπνο Δίκτυο έρχεται να περιγράψει ένα σύστημα ηλεκτρικής ενέργειας επόμενης γενιάς που χαρακτηρίζεται από την αυξημένη χρήση των επικοινωνιών και των τεχνολογιών της πληροφορίας κατά την παραγωγή, την παράδοση και κατανάλωση ηλεκτρικής ενέργειας".

Από τους πιο πάνω ορισμούς μπορεί κανείς να καταλάβει πως ένα Έξυπνο Δίκτυο δεν είναι τίποτα άλλο παρά η μετεξέλιξη του τρέχοντος ηλεκτρικού δικτύου σε ένα δίκτυο στο οποίο η τεχνολογία της πληροφορίας θα έχει τον πρώτιστο ρόλο [10]. Στην ουσία, με την τεχνολογία της πληροφορίας θα καθίσταται πλέον δυνατός ο απομακρυσμένος έλεγχος όλων των σταδίων από την παραγωγή στην κατανάλωση, η αμφίδρομη επικοινωνία μεταξύ παραγωγής και κατανάλωσης (δίνοντας την ευκαιρία στον καταναλωτή να μετέχει και στην παραγωγή ως prosumer), η εξασφάλιση βιωσιμότητας (sustainabi-

lity) και ποιότητας υπηρεσιών, η κατανεμημένη (distributed) παραγωγή ηλεκτρικής ενέργειας, η επεξεργασία της πληροφορίας σε τοπικό επίπεδο (χωρίς να απαιτείται αποστολή της σε ένα κεντρικό σημείο), η αποθήκευσή της παραγόμενης ενέργειας και η έξυπνη μέτρηση της κατανάλωσης της.



Γράφημα 2.3: Έξυπνο Δίκτυο vs Δίκτυο Ηλεκτρισμού [15]

2.3.2 Στόχοι και Προκλήσεις

Όπως προαναφέρθηκε ένα τόσο πολύπλοκο σύστημα, όπως το έξυπνο δίκτυο εκτός του ότι είναι πολύ δύσκολο να οριστεί μονοσήμαντα, είναι επίσης πολύ δύσκολο να αποδώσει κανείς ξεκάθαρα ποιοι είναι οι στόχοι και οι προκλήσεις που το χαρακτηρίζουν. Υπάρχουν διάφορες αναφορές, τόσο από την ακαδημαϊκή κοινότητα όσο και από την βιομηχανία, σε προοπτικές και στόχους των Έξυπνων Δικτύων. Ωστόσο θα μπορούσε κάποιος να ισχυριστεί ότι σε κάθε περίπτω-

ση οι στόχοι-προσδοκίες των έξυπνων δικτύων αναπτύσσονται γύρω από 4 βασικούς πυλώνες:

1. Περιβαλλοντικές προκλήσεις.
2. Ανάγκες αγοράς/καταναλωτών.
3. Προκλήσεις υποδομής.
4. Καινοτόμες τεχνολογίες.


Συγκεκριμένα, σύμφωνα με το DoE [16] ένα Έξυπνο Δίκτυο πρέπει να στοχεύει στην:

- Βελτιστοποίηση της αξιοποίησης των περιουσιακών στοιχείων και την λειτουργική αποδοτικότητα τους.
- Παροχή και αξιοποίηση όλων των επιλογών παραγωγής και αποθήκευσης ενέργειας.
- Αντιμετώπιση διαταραχών μέσω αυτοματοποιημένης πρόληψης, περιορισμού και αποκατάστασης.
- Ανθεκτική λειτουργία ενάντια στις φυσικές και κυβερνοεπιθέσεις και φυσικές καταστροφές.
- Ενθάρρυνση της ενεργού συμμετοχής των καταναλωτών.
- Παροχή νέων προϊόντων, υπηρεσιών και αγορών.

Σύμφωνα με την Ευρωπαϊκή Ένωση [17] ένα έξυπνο δίκτυο πρέπει να είναι:

- Ευέλικτο: Να ικανοποιεί τις ανάγκες των πελατών, να ανταποκρίνεται στις αλλαγές και στις προκλήσεις που πρέπει να αντιμετωπιστούν.

- Προσβάσιμο: Παροχή σύνδεσης σε όλο το δίκτυο ιδίως για ανανεώσιμες πηγές ενέργειας και υψηλής απόδοσης τοπικές (καταναεμημένες) παραγωγές με μηδενικές ή χαμηλές εκπομπές άνθρακα.
- Παροχή ποιότητας ενέργειας για το εύρος των αναγκών σε ψηφιακή οικονομία.
- Αξιοπίστο: Διασφάλιση και βελτίωση της ασφάλειας και της ποιότητας της παροχής, σε αρμονία με τις απαιτήσεις της ψηφιακής-τεχνολογικής εξέλιξης και με αντοχή σε κινδύνους και αβεβαιότητες.
- Ανθεκτική λειτουργία ενάντια στις φυσικές και κυβερνοεπιθέσεις και φυσικές καταστροφές.
- Οικονομικό: Προσφορά της καλύτερης ποιότητας με το χαμηλότερο δυνατόν κόστος μέσω της καινοτομίας, της αποτελεσματικής διαχείρισης της ενέργειας και του ανταγωνισμού.



Γράφημα 2.4: Στόχοι ενός Έξυπνου Δικτύου [22]

Αντίστοιχοι στόχοι έχουν τεθεί και από την βιομηχανία από εταιρείες κολοσσούς και πρωτοπόρους στην έρευνα όσον αφορά τα

έξυπνα δίκτυα όπως η EDF [19], η ABB [18], η Siemens [20].

Συνοψίζοντας τους παραπάνω ορισμούς αλλά και αυτούς που αναφέρονται στην βιβλιογραφία θα καταλήγαμε ότι τα βασικά ευρήματα και στην πραγματικότητα οι τελικοί στόχοι που προκύπτουν [13] αφορούν στα εξής:

- Η ενίσχυση της υποδομής του συστήματος ενέργειας (αισθητήρες, επικοινωνίες, υπολογιστικές εγκαταστάσεις κ.κλπ.)
- Δημιουργία νέων επιχειρηματικών ευκαιριών.
- Μείωση των εκπομπών ρύπων.
- Βελτιστοποίηση του συστήματος ηλεκτρικής ενέργειας.
- Βιώσιμη ανάπτυξη των αναδυόμενων τεχνολογιών.
- Διαχείριση περιουσιακών στοιχείων και έλεγχος κόστους.
- Πιο ανταγωνιστική αγορά ηλεκτρικής ενέργειας με ανοικτή πρόσβαση.

2.3.3 Πλαίσιο και Χαρακτηριστικά των Έξυπνων Δικτύων

Για να ικανοποιηθούν οι προσδοκίες και να εκπληρωθούν οι στόχοι που έθεσε η κοινότητα για τα Έξυπνα Δίκτυα πρέπει να υπάρξει ένας καινοτόμος σχεδιασμός τόσο των εφαρμογών όσο και των υποδομών του νέου δικτύου, ώστε να αποδοθούν σε αυτό χαρακτηριστικά που θα συμβάλλουν στην φιλόδοξη αυτή μετάβαση προς το Έξυπνο Δίκτυο. Πιο συγκεκριμένα απαραίτητα κρίνονται :

1. **Εισαγωγή της τεχνολογίας της πληροφορίας, των τηλεπικοινωνιακών υποδομών και σύγχρονων αισθητήρων σε μεγάλη κλί-**

μακα τόσο για τις online όσο και για τις offline υπηρεσίες ώστε να διευκολύνεται η λειτουργία και η διαχείριση του ηλεκτρικού δικτύου:

Οι καινοτομίες του έξυπνου δικτύου θα αξιοποιήσουν και θα επεκτείνουν τη χρήση της τεχνολογίας των υπολογιστών και των επικοινωνιών. Θα συνεισφέρουν στην ανάπτυξη της νέας τεχνολογίας των έξυπνων αισθητήρων, των συστημάτων διαχείρισης βάσεων δεδομένων, των δυνατοτήτων επεξεργασίας δεδομένων. Μέσω της δικτύωσης των ηλεκτρονικών υπολογιστών στον κυβερνοχώρο και της οριστικοποίησης δεδομένων θα προσφερθούν νέα εργαλεία για τους διαχειριστές και πελάτες του Έξυπνου Δικτύου.

2. Η ενσωμάτωση νέων εφαρμογών συστημάτων παρακολούθησης, ελέγχου και ασφαλείας:


Το έξυπνο Δίκτυο θα βελτιώσει τις τεχνολογίες παρακολούθησης, του ελέγχου και της προστασίας. Αυτή η πρόοδος θα ενισχύσει την προσπάθεια ενσωμάτωσης των καθαρών ανανεώσιμων πηγών ενέργειας και της κατανεμημένης παραγωγής, θα προσφέρει πληθώρα επιλογών στους καταναλωτές και στους διαχειριστές του δικτύου και γενικότερα θα συμβάλλει στην ενίσχυση της αξιοπιστίας, της ασφάλειας και της λειτουργικότητας του δικτύου.

3. Θέσπιση πρωτοκόλλων και ειδικών ρυθμίσεων που θα εξασφαλίζουν την οικονομική διαύγεια και δικαιοσύνη για όλους του συμμετέχοντες του δικτύου και φυσικά για τις αγορές ενέργειας:

Βασική και αδιαπραγμάτευτη αρχή του Έξυπνου Δικτύου είναι ότι οι πελάτες θα πληρώνουν για τις υπηρεσίες που χρησιμοποιούν και θα πληρώνονται για αυτές που προσφέρουν. Ωστόσο, η κύρια αλλαγή για το έξυπνο δίκτυο θα είναι να αναγνωρίσει ότι οι πελάτες μπορούν επίσης να παρέχουν υπηρεσίες στο

δίκτυο μέσω της απόκρισης ζήτησης. Η ενσωμάτωση προϊόντων απόκρισης ζήτησης και το δέλεαρ του οικονομικού οφέλους από την συμμετοχή των πελατών σε αυτή θα οδηγήσει σε νέες δυνατότητες το δίκτυο.

Στο γράφημα 2.5 φαίνεται πως μέσω συγκεκριμένων χαρακτηριστικών και λύσεων επιτυγχάνουμε τους στόχους [21].



Γράφημα 2.5: Χαρακτηριστικά και λύσεις

2.3.4 Η Αρχιτεκτονική ενός Έξυπνου Δικτύου


Υπάρχει πληθώρα τρόπων με τους οποίους μπορεί κανείς να περιγράψει ένα Έξυπνο Δίκτυο. Ένας τρόπος ο οποίος αξιοποιείται συχνά στη βιβλιογραφία [25] αφορά στην απεικόνιση του Έξυπνου Δικτύου ως ενός συνόλου από οντότητες οι οποίες επικοινωνούν μεταξύ τους. Ο τρόπος αυτός όπως προτάθηκε για πρώτη φορά από τον οργανισμό NIST, προσφέρει μια αφαιρετική απεικόνιση του Έξυπνου Δικτύου σε υψηλό επίπεδο, χωρίζοντάς το σε επτά συνεργαζόμενους τομείς-δίκτυα κάθε ένα από τα οποία περιλαμβάνει μια ή περισσότερες οντότητες - συσκευές, συστήματα ή προγράμματα (όπως π.χ. smart meters, συστήματα SCADA κτλ..) τα οποία ανταλλάσσουν πλη-

ροφορίες και λαμβάνουν αποφάσεις για την εξασφάλιση της εύρυθμης λειτουργίας του. Οι επτά τομείς στους οποίους μπορούμε να χωρίσουμε ένα Έξυπνο Δίκτυο είναι οι Πελάτες, οι Αγορές, οι Πάροχοι Υπηρεσιών, οι Λειτουργίες, η Παραγωγή, η Μεταφορά και η Διανομή [3]. Ακολουθεί μια περιγραφή των οντοτήτων τις οποίες περιλαμβάνει κάθε τομέας του μοντέλου όπως προκύπτει από το [25]:

- **Πελάτες :** Τομέας που περιλαμβάνει τόσο τους καταναλωτές όσο και τις συσκευές που αυτοί διαθέτουν για να παράγουν, να αποθηκεύουν και να διαχειρίζονται την ενέργεια. Τυπικά αναφερόμαστε σε τρεις τύπους πελατών. Πελάτες του δικτύου με σκοπό την οικιακή χρήση ηλεκτρισμού, πελάτες με σκοπό την εμπορική χρήση και πελάτες με σκοπό τη βιομηχανική χρήση.
- **Αγορές :** Τομέας που περιλαμβάνει τους λειτουργούς και τους συμμετέχοντες στην αγορά ενέργειας.
- **Πάροχοι Υπηρεσιών :** Τομέας που αφορά στους οργανισμούς οι οποίοι προσφέρουν υπηρεσίες παροχής ηλεκτρικής ενέργειας σε πελάτες αλλά και παρόχους άλλων υπηρεσιών.
- **Λειτουργίες :** Τομέας που έχει να κάνει με τους διαχειριστές της διακίνησης ηλεκτρικής ενέργειας μεταξύ δικτύων.
- **Παραγωγή :** Τομέας που περιλαμβάνει το σύνολο των γεννητριών και ηλεκτροπαραγωγών σταθμών που παράγουν ενέργεια σε μεγάλες ποσότητες και τις μονάδες αποθήκευσης ενέργειας για διάθεση σε κατοπινό στάδιο.
- **Μεταφορά :** Τομέας που αναφέρεται στην υποδομή για μεταφορά ηλεκτρικής ενέργειας σε μακρινές αποστάσεις. Ενδεχομένως

να περιλαμβάνει μέσα για την αποθήκευση ή παραγωγή ενέργειας κατά τόπους.

- **Διανομή :** Τομέας που έχει να κάνει με την υποδομή που υπάρχει για διανομή ηλεκτρικής ενέργειας από και προς πελάτες, ο οποίος ενδεχομένως να περιλαμβάνει και την αποθήκευση ενέργειας ή την παραγωγή της .



Γράφημα 2.6: Μοντέλο του Smart Grid από την NIST [25]

2.3.5 Τα Θεμέλια Στοιχεία του Έξυπνου Δικτύου

Κατανεμημένη παραγωγή

Τα ηλεκτρικά δίκτυα γίνονται σταδιακά πιο έξυπνα και παράλληλα η χρήση της κατανεμημένης παραγωγής αυξάνεται. Με τον όρο “Κατανεμημένη Παραγωγή” ορίζεται ως η παραγωγή ενέργειας μικρής κλίμακας, άμεσα συνδεδεμένη στο δίκτυο διανομής, με τιμές που κατά κανόνα κυμαίνονται από 1kW μέχρι 100MW. Είναι μία σχετικά καινούρια τάση στην αγορά ηλεκτρικής ενέργειας και στην βιομηχανία ηλεκτρισμού. Τα έξυπνα δίκτυα διανομής θα έχουν ενεργητικό ρόλο και θα πρέπει να εξασφαλίζουν αμφίδρομη ροή ισχύος. Τα Ευρωπαϊκά συστήματα ηλεκτρικής ενέργειας λειτουργούν πλέον σε ένα πλαίσιο μοντέλου αγοράς στο οποίο οι μονάδες παραγωγής διανέμονται σύμφωνα με τις απαιτήσεις της κάθε αγοράς και το κέντρο

ελέγχου του δικτύου αναλαμβάνει ένα γενικό ρόλο εποπτείας. Μια μεγάλη ποσότητα ηλεκτρισμού που παράγεται από μεγάλους συμβατικούς σταθμούς παραγωγής θα προέρχεται από την Κατανεμημένη Παραγωγή και τις Ανανεώσιμες Πηγές Ενέργειας (ΑΠΕ). Παράλληλα είναι δυνατό να χρειασθεί η ύπαρξη εφεδρείας σε περίπτωση ελλειπών παραγωγής από ανανεώσιμες πηγές, ενώ η ανάγκη για έγκυρη πρόβλεψη του ηλεκτρικού φορτίου είναι απαραίτητη για την πλήρη και ασφαλή εκμετάλλευση της Κατανεμημένης Παραγωγής. Οι αλλαγές και υψηλές προδιαγραφές λειτουργίας που απαιτούνται από το ηλεκτρικό δίκτυο για να αποδώσει και να αξιοποιηθεί η Κατανεμημένη Παραγωγή οδηγούν στο έξυπνο δίκτυο.




Γράφημα 2.7: Κεντρική και Κατανεμημένη Παραγωγή [26]

Διαχείριση φορτίου - Απόκριση ζήτησης

Η απόκριση ζήτησης (Demand Responce) είναι μια επέμβαση στην κατανάλωση ρεύματος ενός πελάτη ηλεκτρικού εξοπλισμού με σκοπό την εξισορρόπηση παραγωγής και ζήτησης ηλεκτρικής ισχύος [27]. Η ηλεκτρική ενέργεια δεν μπορεί να αποθηκευτεί εύκολα, επομένως οι επιχειρήσεις κοινής ωφέλειας είναι υποχρεωμένες να εξισορροπούν τη ζήτηση και την παραγωγή, περιορίζοντας το ρυθμό παραγωγής

των σταθμών ηλεκτροπαραγωγής τους, παίρνοντας μονάδες παραγωγής σε λειτουργία ή εκτός γραμμής ή εισάγοντας ενέργεια από άλλες επιχειρήσεις κοινής ωφέλειας. Υπάρχουν όρια σε ό, τι μπορεί να επιτευχθεί στην πλευρά της προσφοράς, επειδή ορισμένες μονάδες παραγωγής μπορούν να πάρουν πολύ χρόνο για να φτάσουν σε πλήρη ισχύ, ορισμένες μονάδες μπορεί να είναι πολύ δαπανηρές για να λειτουργούν και η ζήτηση μπορεί κατά καιρούς να είναι μεγαλύτερη από την ικανότητα όλων τις διαθέσιμες μονάδες παραγωγής ηλεκτρικής ενέργειας. Η απόκριση ζήτησης επιδιώκει να προσαρμόσει τη ζήτηση ενέργειας αντί να ρυθμίσει την παροχή.



Γράφημα 2.8: Παράδειγμα αυτόματης Απόκρισης Ζήτησης [28]

Αποθήκευση ενέργειας

Το έξυπνο δίκτυο προσφέρει πολλά πλεονεκτήματα σε σχέση με το παραδοσιακό δίκτυο όσων αφορά την ενεργό αλληλεπίδραση με τους καταναλωτές, ωστόσο η εξάρτησή του από την κατανεμημένη παραγωγή και τις ανανεώσιμες πηγές ενέργειας, καθιστά την αποθή-


κευση ενέργειας βασικό στοιχείο για την επιτυχή λειτουργία του. Οι τεχνολογίες αποθήκευσης ενέργειας εμπίπτουν σε πέντε κατηγορίες: μηχανικές, ηλεκτροχημικές, χημικές, ηλεκτρικές και θερμικές, και με πιο υποσχόμενη εφαρμογή να είναι οι μπαταρίες (χημική). Η πολύ γρήγορη απόκριση και η δυνατότητα κατανεμημένης αποθήκευσης είναι τα βασικά πλεονεκτήματα έναντι των παραδοσιακών τεχνικών. Επιπλέον οι μπαταρίες μπορούν να βρίσκονται τόσο από την μεριά του καταναλωτή όσο και από την μεριά του διανομέα ή παραγωγού ηλεκτρικής ενέργειας. Οι δυνατότητες αποθήκευσης ενέργειας αυξάνονται ως αποτέλεσμα της διείσδυσης των ανανεώσιμων πηγών ενέργειας, της ωριμότητας των τεχνολογιών και της εμπορικής διαθεσιμότητας σε ανταγωνιστικές τιμές, της ευαισθητοποίησης όσον αφορά τα οφέλη και την αξία και την αύξηση της υποστήριξης από τις ρυθμιστικές αρχές, αλλά παρ' όλα αυτά δεν βρίσκονται ακόμα σε ικανοποιητικό επίπεδο ώστε να είναι εφικτή η πλήρης εκμετάλλευσή τους.



Γράφημα 2.9: Σύστημα οικιακής αποθήκευσης ενέργειας Sunrun Tesla [29]

Ηλεκτρικά οχήματα

Τα ηλεκτρικά οχήματα είναι ένα πολύ σημαντικό στοιχείο για το έξυπνο δίκτυο καθώς η μπαταρία που διαθέτουν λειτουργεί ως έμμεση κατανεμημένη εφαρμογή αποθήκευσης ενέργειας. Τα ηλεκτρικά οχήματα με μπαταρία διαθέτουν ένα επαναφορτιζόμενο σύστημα αποθήκευσης ενέργειας και έναν ηλεκτρικό κινητήρα (συνεχούς ή εναλλασσόμενου ρεύματος, ανάλογα με την τεχνολογία). Η μπαταρία φορτίζεται είτε συνδέοντας το αυτοκίνητο σε μια κοινή πρίζα, είτε σε κάποιο εξοπλισμό παροχής ηλεκτρικών οχημάτων. Το επίπεδο της τάσης που φορτίζεται η μπαταρία, και επομένως η ταχύτητα της φόρτισης, εξαρτάται από το πρότυπο που υλοποιείται. Τα ηλεκτρικά οχήματα αποτελούν ιδιαίτερες περιπτώσεις επειδή έχουν δυνατότητα μετακίνησης αλλά και στοχαστικά πρότυπα τοποθεσίας, γεγονός που κάνει τη διαθεσιμότητα και αξιοπιστία στοχαστική, ο κύριος σκοπός τους δεν είναι η παροχή υπηρεσιών και τέλος το καθένα ξεχωριστά έχει πολύ μικρότερη χωρητικότητα από αυτή που απαιτείται από τις εταιρείες ηλεκτρισμού για την παροχή αυτών των υπηρεσιών. Έτσι δημιουργούν προκλήσεις για την ενσωμάτωσή τους με αυτό το ρόλο στο δίκτυο.[30]



Γράφημα 2.10: Αλληλεπίδραση ηλεκτρικού οχήματος με έξυπνο δίκτυο [31]

Κεφάλαιο 3

Πρόβλεψη Ηλεκτρικού Φορτίου-Ανασκόπηση της Βιβλιογραφίας

3.1 Η Σημασία της Πρόβλεψης του Ηλεκτρικού Φορτίου

Η πρόβλεψη αποτελεί ένα πρόβλημα το οποίο βρίσκει εφαρμογή σχεδόν σε όλες τις βιομηχανίες του κόσμου. Οι αεροπορικές εταιρείες προσπαθούν να προβλέψουν τον αριθμό των επιβατών για να προγραμματίσουν πτήσεις, οι ζυθοποιίες προβλέπουν την κατανάλωση μπίρας για τον προγραμματισμό της παραγωγής. Οι έμποροι λιανικής πώλησης προβλέπουν τη ζήτηση των ειδών μόδας για να αποφασίσουν ποια έκπτωση θα προσφέρουν στους πελάτες. Οι χρηματιστές προβλέπουν τις τιμές των μετοχών για να επενδύσουν με μεγαλύτερη ασφάλεια τα χρήματά τους και των πελατών τους. Είναι φανερό λοιπόν ότι η πρόβλεψη είναι βασικό συστατικό για τις περισσότερες δραστηριότητες των ανθρώπων και φυσικά η ηλεκτρική βιομηχανία δεν αποτελεί εξαίρεση σε αυτό!


Οι ηλεκτρικές επιχειρήσεις κοινής ωφέλειας, είναι υπεύθυνες για την λειτουργία του ηλεκτρικού δικτύου, το οποίο είναι γνωστό ως το πιο μεγάλο και πολύπλοκο σύστημα στη γη, και την τροφοδότηση με ηλεκτρικό ρεύμα πάνω από 5 δισεκατομμυρίων ανθρώπων ανά την υφήλιο[7]. Όταν κάποιος πατάει τον διακόπτη θεωρεί δεδομένο ότι το φως θα ανάψει. Ωστόσο, η διαδικασία από την παραγωγή ενέργειας μέχρι και την τροφοδοσία των λαμπτήρων και άλλων ηλεκτρικών συσκευών δεν είναι τόσο απλή. Ενώ πολλές άλλες βιομηχανίες έχουν κάποια μορφή αποθέματος για την αποθήκευση και την απομάκρυνση των προϊόντων και των υπηρεσιών τους, στην περίπτωση της παραγωγής ηλεκτρικής ενέργειας δεν υπάρχει αυτό το προτέρημα καθώς τουλάχιστον με την σημερινή τεχνολογία, η μαζική αποθήκευση ενέργειας δεν είναι εφικτή. Ως αποτέλεσμα, η ηλεκτρική ενέργεια πρέπει να παράγεται και να παραδίδεται μόλις καταναλωθεί. Με άλλα λόγια, οι επιχειρήσεις κοινής ωφέλειας πρέπει να εξισορροπήσουν την προσφορά και ζήτηση κάθε στιγμή.

Η πρόβλεψη φορτίου, που αφορά κυρίως στην πρόβλεψη της ζήτησης ηλεκτρικής ενέργειας και της ενέργειας, χρησιμοποιείται σε όλα τα τμήματα της βιομηχανίας ηλεκτρικής ενέργειας, συμπεριλαμβανομένης της παραγωγής, της μεταφοράς, της διανομής καθώς και του λιανικού εμπορίου ενέργειας με την απελευθέρωση των αγορών όπως προαναφέρθηκε. Με εργαλείο την πρόβλεψη, οι πάροχοι υπηρεσιών του δικτύου μπορούν να μοντελοποιήσουν και να προβλέψουν με ακρίβεια το ηλεκτρικό φορτίο με σκοπό την εξισορρόπηση παραγωγής και ζήτησης, την μείωση του κόστους παραγωγής και την υλοποίηση των διαφόρων στρατηγικών τιμολόγησης και απόκρισης ζήτησης. Η πρόβλεψη είναι πολύ σημαντική επίσης για τον σχεδιασμό και την υποστήριξη της λήψης αποφάσεων που αφορούν σε αγορά και εγκατάσταση νέου εξοπλισμού και υποδομών ώστε να ικανοποιηθούν οι

μελλοντικές απαιτήσεις σε ενέργεια των καταναλωτών με ένα υψηλό μάλιστα επίπεδο ποιότητας και αξιοπιστίας. Λόγω του θεμελιώδους ρόλου της πρόβλεψης φορτίου στις επιχειρήσεις κοινής ωφέλειας, οι ανακριβείς προβλέψεις φορτίου ενδέχεται να έχουν ως αποτέλεσμα την οικονομική επιβάρυνση ή ακόμη και την πτώχευση μιας εταιρείας κοινής ωφέλειας. Ενώ η πρόβλεψη φορτίου παρέχει μια βασική συνεισφορά στις λειτουργίες και τον προγραμματισμό των συστημάτων ισχύος, οι ανακριβείς προβλέψεις φορτίου μπορούν να οδηγήσουν σε αποτυχίες εξοπλισμού ή ακόμα και σε black out [6]. Επίσης, σε επίπεδο μικροδικτύου η ακριβής πρόβλεψη της καμπύλης φορτίου είναι σημαντική για τον σχεδιασμό της οικονομικής στρατηγικής της επόμενης μέρας, τον χρονοπρογραμματισμό των ευέλικτων φορτίων και την βελτιστοποίηση του μείγματος παραγωγής, που οδηγούν στην ευελιξία και αυτονομία του μικροδικτύου [8]. Επιπροσθέτως, με την ανάπτυξη του χρηματιστηρίου ενέργειας και των πλειοδοτικών αγορών απαιτείται μεγάλη ακρίβεια στη πρόβλεψη καθώς αυτή μπορεί να οδηγήσει είτε σε οικονομικό όφελος είτε σε ζημιά με ενδεχόμενη αστοχία στην πρόβλεψη[9] .

3.2 Κατηγοριοποίηση με Βάση τον Ορίζοντα Πρόβλεψης

Όπως φαίνεται στο Γράφημα 3.1, η πρόβλεψη του ηλεκτρικού φορτίου, με γνώμονα την διάρκεια του ορίζοντα πρόβλεψης, χωρίζεται σε τέσσερις κατηγορίες: 1) very short term, 2) short term, 3) medium term και 4) long term forecasting. Όπως είναι προφανές για κάθε κατηγορία υπάρχουν και ενδείκνυνται οι αντίστοιχοι αλγόριθμοι και εφαρμογές. Στην συνέχεια του κεφαλαίου γίνεται μια εκτενέστερη αναφορά για κάθε κατηγορία ξεχωριστά.




Γράφημα 3.1: Κατηγοριοποίηση με βάση τον ορίζοντα πρόβλεψης [32]

3.2.1 Πολύ Βραχυπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου (Very Short Term Load Forecasting)

Όταν αναφερόμαστε σε πολύ βραχυπρόθεσμη πρόβλεψη ηλεκτρικού φορτίου (Very Short Term Load Forecasting (VSTLF)) μιλάμε για μία πρόβλεψη με ορίζοντα από μερικά λεπτά έως και μία ώρα. Όπως λοιπόν είναι αναμενόμενο, η χρησιμότητα αυτού του είδους πρόβλεψης έγκειται σε real time εφαρμογές, όπως για παράδειγμα η λειτουργία και η συντήρηση, η διάγνωση σφαλμάτων και η αυτοθεραπεία (self-healing) και γενικότερα η πιο ασφαλής και εύρωστη λειτουργία του

ηλεκτρικού δικτύου. Σε συνδυασμό με το SCADA σύστημα ή και online συστήματα παρακολούθησης και τηλεχειρισμών μπορούν να αποφευχθούν προβλήματα που προκύπτουν και να υπάρχει μια πιο ομαλή λειτουργία του ηλεκτρικού δικτύου, όπως φαίνεται στο Γράφημα 3.2 [33].



Γράφημα 3.2: Επισκόπηση της πολύ βραχυπρόθεσμης πρόβλεψης φορτίου για online εφαρμογή

3.2.2 Βραχυπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου (Short Term Load Forecasting)

Αντίστοιχα η βραχυπρόθεσμη πρόβλεψη ηλεκτρικού φορτίου (Short Term Load Forecasting (STLF)) έχει έναν ορίζοντα πρόβλεψης από μία ώρα έως και μερικές εβδομάδες. Οι εφαρμογές εδώ αφορούν περισσότερο στον σχεδιασμό του συστήματος διανομής και μεταφοράς, στην χάραξη στρατηγικής όσων αφορά την προμήθεια ενέργειας αλλά και σε εφαρμογές που αγγίζουν τον καταναλωτή όπως απόκριση ζήτησης και έλεγχος της αποθήκευσης ενέργειας. Μία ακριβής τεχνική STLF μπορεί να μετριάσει το λειτουργικό κόστος, να κρατήσει αποτελεσματικές τις αγορές ενέργειας και να βοηθήσει στην καλύτερη κατανόηση της δυναμικής του συστήματος. Αντίθετα, μια λανθασμένη πρόβλεψη μπορεί να προκαλέσει είτε σε υπερεκτίμηση φορτίου, η οποία οδηγεί

σε υπερβολική προσφορά και αποθεματικό ενέργειας και κατά συνέπεια, περισσότερες δαπάνες και απορρύθμιση της αγοράς ενέργειας είτε σε υπερεκτίμηση της παραγωγής ή οποία μπορεί να οδηγήσει και σε διακοπή της λειτουργίας του δικτύου [33]!

3.2.3 Μεσοπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου (Medium Term Load Forecasting)

Η μεσοπρόθεσμη πρόβλεψη ηλεκτρικού φορτίου ή Medium Term Load Forecasting (MTLF), δηλαδή με ορίζοντα πρόβλεψης από δύο εβδομάδες έως και 3 χρόνια, αποτελεί ουσιαστικό εργαλείο για τα σημερινά συστήματα ισχύος, κυρίως στις χώρες των οποίων τα συστήματα ισχύος λειτουργούν σε απελευθερωμένο περιβάλλον. Αυτή η πρόβλεψη φορτίου έχει πολλές εφαρμογές οικονομικού σχεδιασμού, όπως προγραμματισμό συντήρησης, μεσοπρόθεσμο υδροθερμικό συντονισμό, αξιολόγηση της επάρκειας, διαχείριση περιορισμένων ενεργειακών μονάδων, διαπραγμάτευση προθεσμιακών συμβάσεων και ανάπτυξη στρατηγικών προμηθειών καυσίμων με αποτελεσματικό κόστος [34].

3.2.4 Μακροπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου (Long Term Load Forecasting)

Ο σχεδιασμός του συστήματος ενέργειας ξεκινά με μια πρόβλεψη των απαιτήσεων φορτίου. Η μακροπρόθεσμη πρόβλεψη φορτίου ή Long Term Load Forecasting (LTLF) καλύπτει συνήθως τους ορίζοντες προβλέψεων τριών έως δέκα ετών, και μερικές φορές μέχρι και αρκετές δεκαετίες. Παρέχει εβδομαδιαίες και μηνιαίες προβλέψεις για τα φορτία αιχμής και κοιλάδας που είναι σημαντικά για την επέκταση και τον σχεδιασμό συστημάτων παραγωγής, μεταφοράς και διανομής

[35].

3.3 Στατιστικά Χαρακτηριστικά Χρονοσειρών Ηλεκτρικού Φορτίου

Τα στατιστικά χαρακτηριστικά της εκάστοτε χρονοσειράς που θέλουμε να μελετήσουμε παίζουν καθοριστικό ρόλο στην επιλογή του μοντέλου πρόβλεψης που θα χρησιμοποιήσουμε. Παρόλο που θα μπορούσε κάποιος να ισχυριστεί ότι η προσέγγιση των μοντέλων μηχανικής μάθησης είναι ανεξάρτητη και δεν επηρεάζεται από αυτά, η αλήθεια είναι η προσεκτική ερμηνεία και εις βάθος μελέτη των στατιστικών αυτών χαρακτηριστικών μπορεί να συνδράμει στην βελτίωση και καλύτερη αξιοποίηση των μοντέλων που θα χρησιμοποιηθούν αλλά επίσης και να βοηθήσει στην κατάλληλη επιλογή μοντέλων μηχανικής μάθησης.

Το πρόβλημα στην ανάλυση χρονοσειρών, όπως και του ηλεκτρικού φορτίου είναι να εκτιμήσουμε το σύστημα που παράγει τη χρονοσειρά και να κάνουμε προβλέψεις μελλοντικών τιμών του μεγέθους που παρατηρούμε. Η πρώτη υπόθεση που θα πρέπει να απορρίψουμε για να έχει νόημα η ανάλυση της χρονοσειράς είναι ότι η μεταβολή των τιμών του μεγέθους που παρατηρούμε είναι εντελώς τυχαία, δηλαδή το σύστημα που παρατηρούμε είναι λευκός θόρυβος. Αν οι παρατηρήσεις της χρονοσειράς δεν είναι ανεξάρτητες, η πληροφορία που υπάρχει στη χρονοσειρά μπορεί να δίνεται με διαφορετικές μορφές και τα κυριότερα χαρακτηριστικά που θα πρέπει να μελετήσουμε πριν προχωρήσουμε να προσαρμόσουμε κάποιο μοντέλο στη χρονοσειρά είναι η Στασιμότητα (Stationarity), η Γραμμικότητα (Linearity) και η Συσχέτιση (Autocorellation).

3.3.1 Στασιμότητα (Stationarity)

Μία χρονοσειρά είναι στάσιμη όταν οι στατιστικές της ιδιότητες, όπως ο μέσος όρος, η διακύμανση, η αυτοσυσχέτιση κ.κλπ., είναι όλες σταθερές με την πάροδο του χρόνου. Ορισμένες μέθοδοι στατιστικής πρόβλεψης βασίζονται στην υπόθεση ότι οι χρονοσειρές μπορούν να καταστούν σχεδόν στάσιμες (μέσω της χρήσης μαθηματικών μετασχηματισμών). Μια στάσιμη σειρά είναι σχετικά εύκολη στην πρόβλεψη: απλώς προβλέπεται ότι οι στατιστικές της ιδιότητες θα είναι οι ίδιες στο μέλλον όπως στο παρελθόν! Οι προβλέψεις για την στάσιμη σειρά μπορούν στη συνέχεια να "μετατραπούν", αντιστρέφοντας όποιους μαθηματικούς μετασχηματισμούς χρησιμοποιήθηκαν στο παρελθόν, για να λάβουν προβλέψεις για την αρχική σειρά. Έτσι, η εύρεση της ακολουθίας των μετασχηματισμών που απαιτούνται για τη στασιμότητα μιας χρονοσειράς συχνά παρέχει σημαντικές ενδείξεις στην αναζήτηση ενός κατάλληλου μοντέλου πρόβλεψης. Οι περισσότερες επιχειρηματικές και οικονομικές χρονοσειρές απέχουν πολύ από την στασιμότητα όταν εκφράζονται στις αρχικές μονάδες μέτρησης. Εάν η σειρά έχει μια σταθερή μακρόχρονη τάση και τείνει να επανέλθει σε αυτή μετά από μια διαταραχή, μπορεί να είναι δυνατή η σταθεροποίησή της. Μια τέτοια σειρά λέγεται ότι είναι τάση-στάσιμη (trend-stationary). Ωστόσο, μερικές φορές για να μετατρέψουμε τη σειρά στάσιμη μπορεί να είναι απαραίτητο να μετατραπεί σε μια σειρά από διαστήματα περιόδου σε περίοδο και/ή εποχής σε σεζόν. Εάν ο μέσος όρος, η διακύμανση και οι αυτοσυσχετίσεις της αρχικής σειράς δεν είναι σταθεροί στο χρόνο, ακόμα και μετά την απομάκρυνση, ίσως οι στατιστικές των αλλαγών στη σειρά μεταξύ περιόδων ή μεταξύ εποχών θα είναι σταθερές. Μια τέτοια σειρά λέγεται ότι είναι διαφορικά-στάσιμη (difference-stationary). Μερικές φορές μπορεί να είναι δύσκολο να διακρίνουμε τη διαφορά ανάμεσα σε μια σειρά που είναι

στάσιμη και μια διαφορικά-στάσιμη και μπορεί να χρησιμοποιηθεί μια αποκαλούμενη δοκιμή μοναδιαίας ρίζας (unit root test) για να πάρουμε μια πιο οριστική απάντηση [36].

3.3.2 Γραμμικότητα (Linearity)

Μία χρονοσειρά είναι γραμμική όταν οι μεταβλητές του συστήματος (ορατές και μη) αλληλεπιδρούν γραμμικά. Στην αντίθετη περίπτωση η χρονοσειρά είναι μη γραμμική. Για τη χρονοσειρά αυτό σημαίνει πως για ένα γραμμικό σύστημα ορίζουμε την εξέλιξη της χρονοσειράς ως γραμμικό συνδυασμό των προηγούμενων παρατηρήσεων της χρονοσειράς, ενώ για ένα μη-γραμμικό σύστημα μπορούμε να ορίσουμε την εξέλιξη της χρονοσειράς με μεγαλύτερη ακρίβεια αν θεωρήσουμε και τη συνδυασμένη επίδραση των προηγούμενων παρατηρήσεων σε διαφορετικές χρονικές στιγμές ή τις ίδιες. Μία χρονοσειρά δηλαδή είναι γραμμική εάν ισχύει η παρακάτω εξίσωση:


$$X_t = \sum_{k=-\infty}^{\infty} \beta_k Z_{t-k}$$

,όπου η σειρά Z_t είναι ανεξάρτητη, με μέση τιμή μηδέν και διακύμανση $\sigma^2 > 0$ [37] . Πολλές φορές η οπτικοποίηση των δεδομένων μπορεί να μας φανερώσει αμέσως την ύπαρξη η μη γραμμικότητας σε μία χρονοσειρά όπως φαίνεται στο Γράφημα 3.3


Ομοίως στο Γράφημα 3.4 η μη γραμμική συμπεριφορά είναι προφανής

Είναι προφανές ότι για μία γραμμική χρονοσειρά είναι εύκολο να γίνει πρόβλεψη με μεγάλη ακρίβεια ακόμα και από απλά στατιστικά μοντέλα πρόβλεψης.

3.3 Στατιστικά Χαρακτηριστικά Χρονοσειρών Ηλεκτρικού Φορτίου 36



Γράφημα 3.3: Γραμμική χρονοσειρά [24]



Γράφημα 3.4: Μη γραμμική χρονοσειρά ηλεκτρικού φορτίου [;]

3.3.3 Αυτοσυσχέτιση (Autocorellation)

Η αυτοσυσχέτιση είναι χαρακτηριστικό των δεδομένων στα οποία η συσχέτιση μεταξύ των τιμών των ίδιων μεταβλητών βασίζεται σε συναφή αντικείμενα. Παραβιάζει την υπόθεση της ανεξαρτησίας των περιπτώσεων, η οποία αποτελεί τη βάση για τα περισσότερα συμβατικά μοντέλα. Γενικά υπάρχει σε αυτούς τους τύπους συνόλων δεδομένων στις οποίες τα δεδομένα, αντί να επιλέγονται τυχαία, προέρχονται από την ίδια πηγή. Σε δεδομένα χρονοσειρών, η αυτοσυσχέτιση ορίζεται ως η καθυστερημένη συσχέτιση μιας δεδομένης

σειράς, δηλαδή είναι η σχέση της τιμής μία δεδομένη χρονική στιγμή με μία αντίστοιχη τιμή του παρελθόντος. Η αυτοσυσχέτιση είναι καθυστερημένη συσχέτιση και καθυστερείται από ορισμένο αριθμό μονάδων χρόνου. Η σειριακή αυτοσυσχέτιση είναι αυτή που καθορίζει τη συσχέτιση υστέρησης μεταξύ των δύο σειρών σε δεδομένα χρονοσειρών.

Η παρουσία αυτοσυσχέτισης είναι γενικά απροσδόκητη. Εμφανίζεται κυρίως εξαιτίας εξαρτήσεων εντός των δεδομένων, αλλά η παρουσία της είναι ένα ισχυρό κίνητρο για περαιτέρω έρευνα και μπορεί να οδηγήσει σε σημαντικά συμπεράσματα όσων αφορά την φύση των δεδομένων [38]. Η ύπαρξη ειδικά αυτοσυσχέτισης σε προβλήματα πρόβλεψης αποτελεί ένα ισχυρό εργαλείο που συμβάλλει στην βελτιστοποίηση των αλγορίθμων και στην μείωση του χρόνου και των υπολογιστικών πόρων που χρησιμοποιούνται.

3.4 Στρατηγικές Πρόβλεψης Ηλεκτρικού Φορτίου

Η πρόβλεψη πολλαπλών βημάτων (multi-step forecasting) εξακολουθεί να αποτελεί μια ανοιχτή πρόκληση στην πρόβλεψη χρονοσειρών, παρά την μεγάλη πρόοδο που έχει συντελεστεί στον τομέα. Η πρόβλεψη χρονοσειρών είναι ένα αυξανόμενο πεδίο ενδιαφέροντος παίζοντας ένα σημαντικό ρόλο σε όλους σχεδόν τους τομείς της επιστήμης και της μηχανικής, όπως η οικονομία, η μετεωρολογία και οι τηλεπικοινωνίες. Σε αντίθεση με τις προβλέψεις ενός βήματος μπροστά, η πρόβλεψη πολλαπλών βημάτων παρουσιάζει μεγαλύτερες δυσκολίες [43] καθώς πρέπει να αντιμετωπίσει διάφορες πρόσθετες επιπλοκές, όπως η συσσώρευση σφαλμάτων, η μειωμένη ακρίβεια και η αυξημένη αβεβαιότητα [44]. Η πρόβλεψη χρονοσειρών πολλαπλών βημάτων

συνίσταται στην πρόβλεψη των επόμενων H τιμών $(y_{N+1}, \dots, y_{N+H})$ μίας χρονοσειράς αποτελούμενης από N παρατηρήσεις $(y_1, \dots, y_N)$ όπου η $H > 1$ υποδηλώνει τον ορίζοντα πρόβλεψης.

Υπάρχουν τρεις στρατηγικές που χρησιμοποιούνται ευρέως για την πρόβλεψη πολλαπλών βημάτων για χρονοσειρές, η αναδρομική (recursive), η άμεση (direct) και η πολλαπλών εισόδων και εξόδων (Multiple Input Multiple Output (MIMO)).

3.4.1 Αναδρομική στρατηγική (recursive)

Η παλαιότερη και πιο διαισθητική στρατηγική πρόβλεψης είναι η αναδρομική (recursive) (που ονομάζεται επίσης ελεγχόμενη ή πολλαπλών σταδίων) στρατηγική [45]. Σε αυτή τη στρατηγική, ένα ενιαίο το μοντέλο f εκπαιδεύεται για να πραγματοποιήσει μια πρόβλεψη ενός βήματος, δηλ.

$$y_{t+1} = f(y_t, \dots, y_{t-d+1}) + w, \text{ με το } t \in (d, \dots, N-1)$$

Κατά την πρόβλεψη των H βημάτων, αρχικά προβλέπουμε το πρώτο βήμα εφαρμόζοντας το μοντέλο. Στη συνέχεια, χρησιμοποιούμε την τιμή που μόλις προβλέψαμε ως μέρος των μεταβλητών εισόδου για την πρόβλεψη του επόμενου βήματος (χρησιμοποιώντας το ίδιο μονόπλευρο μοντέλο). Συνεχίζουμε με αυτόν τον τρόπο μέχρι να προβλέψουμε ολόκληρο τον ορίζοντα. Έστω $\hat{f}$ το εκπαιδευμένο μοντέλο για ένα βήμα μπροστά. Τότε οι προβλέψεις είναι:

$$\hat{y}_{N+h} = \begin{cases} \hat{f}(y_N, \dots, y_{N-d+1}) & \text{if } h = 1, \\ \hat{f}(\hat{y}_{N+h-1}, \dots, \hat{y}_{N+1}, y_N, \dots, y_{N-d+h}) & \text{if } h \in \{2, \dots, d\}, \\ \hat{f}(\hat{y}_{N+h-1}, \dots, \hat{y}_{N+h-d}) & \text{if } h \in \{d+1, \dots, H\}. \end{cases}$$

Ανάλογα με τον θόρυβο που υπάρχει στις χρονοσειρές και τον ορίζοντα πρόβλεψης, η αναδρομική στρατηγική μπορεί να υποφέρει από χαμηλές επιδόσεις σε προβλέψεις πολλαπλών βημάτων. Πράγματι,

αυτό είναι ιδιαίτερα εμφανές εάν ο ορίζοντας πρόβλεψης H υπερβαίνει την ενσωμάτωση διάσταση d , καθώς σε κάποιο σημείο όλες οι είσοδοι είναι προβλεπόμενες τιμές αντί των πραγματικών παρατηρήσεων. Η αναδρομική στρατηγική είναι ευαίσθητη στη μεταφορά των σφαλμάτων καθώς σφάλματα που υπάρχουν στις ενδιάμεσες προβλέψεις θα προωθηθούν για τον προσδιορισμό των επόμενων προβλέψεων. Παρά τους περιορισμούς αυτούς, η αναδρομική στρατηγική χρησιμοποιείται επιτυχώς για να προβλέψει πολλές πραγματικές χρονοσειρές χρησιμοποιώντας διαφορετικά μοντέλα μηχανικής μάθησης, όπως τα επαναλαμβανόμενα νευρωνικά δίκτυα (Recurrent Neural Nets) και οι πλησιέστεροι γείτονες (Nearest Neighbors).

3.4.2 Άμεση στρατηγική (direct)

Η άμεση στρατηγική (επίσης αποκαλούμενη ανεξάρτητη) αποτελείται από ανεξάρτητες προβλέψεις για κάθε ορίζοντα ξεχωριστά. Με άλλα λόγια f_H μοντέλα διενεργούν H προβλέψεις για κάθε ορίζοντα δηλαδή:

$$y_{t+h} = f_h(y_t, \dots, y_{t-d+1}) + w, \text{ με το } t \in (d, \dots, N-H) \text{ και } h \in (1, \dots, H)$$

Οι προβλέψεις προκύπτουν ως εξής:

$$\hat{f}_{N+h} = \hat{f}_h(y_t, \dots, y_{t-d+1}) + w$$

Αυτό σημαίνει ότι η άμεση στρατηγική δεν χρησιμοποιεί καμία προσέγγιση για τον υπολογισμό των προβλέψεων, δεν επηρεάζεται έτσι λοιπόν από την συσσώρευση σφαλμάτων. Ωστόσο, τα H μοντέλα είναι εκπαιδευμένα ανεξάρτητα προκαλώντας μια υπό όρους ανεξαρτησία στις προβλέψεις H . Αυτό επηρεάζει την ακρίβεια της πρόβλεψης καθώς αποτρέπει την εξέταση σύνθετων εξαρτήσεων μεταξύ των μεταβλητών. Επίσης, αυτή η στρατηγική απαιτεί μεγάλη υπολογιστική ισχύ δεδομένου ότι υπάρχουν τόσα πολλά μοντέλα για να εκπαιδευτούν, όσο το μέγεθος του ορίζοντα πρόβλεψης.

3.4.3 Στρατηγική πολλαπλών εισόδων και εξόδων (Multiple Input Multiple Output (MIMO))

Η εισαγωγή της στρατηγικής πολλαπλών εισόδων και εξόδων (Multi-Input Multi-Output (MIMO)) έχει κίνητρο την ανάγκη αποφυγής της μοντελοποίησης της χαρτογράφησης μιας εξόδου, η οποία παραμελεί την ύπαρξη στοχαστικών εξαρτήσεων μεταξύ των μελλοντικών τιμών και επομένως επηρεάζει την προβλεπόμενη ακρίβεια. Σε αυτήν την στρατηγική εκπαιδεύεται ένα μόνο μοντέλο F με την χρονοσειρά $(y_1, \dots, y_N)$, όπου $y_{t+h} = F(y_t, \dots, y_{t-d+1}) + w$, με το $t \in (d, \dots, N-H)$

και το $F: R^d \rightarrow R^h$ να είναι είναι μια διανυσματική συνάρτηση, και το w είναι ένα διάνυσμα θορύβου. Η πρόβλεψη λοιπόν έρχεται σε ένα μόνο βήμα από το μοντέλο $\hat{F}$, όπου $\hat{y}_{t+h} = \hat{F}(y_n, \dots, y_{N-d+1}) + w$

Το σκεπτικό της στρατηγικής είναι να διατηρηθεί, η στοχαστική εξάρτηση μεταξύ των προβλεπόμενων τιμών που χαρακτηρίζουν τη χρονοσειρά. Αυτή η στρατηγική αποφεύγει την ανεξαρτησία των υποθέσεων της άμεσης στρατηγικής καθώς και της συσσώρευσης των σφαλμάτων. Μέχρι τώρα, αυτή η στρατηγική έχει εφαρμοστεί επιτυχώς σε αρκετά προβλήματα πραγματικού κόσμου. Ωστόσο, η ανάγκη διατήρησης των στοχαστικών εξαρτήσεων χρησιμοποιώντας ένα μοντέλο έχει ένα μειονέκτημα καθώς περιορίζει όλους τους ορίζοντες να προβλεφθούν με την ίδια δομή μοντέλου. Αυτός ο περιορισμός θα μπορούσε να μειώσει την ευελιξία της προσέγγισης πρόβλεψης.

3.4.4 Υβριδική μέθοδος αυτοσυσχέτισης (Hybrid Autocorrelation Method(HAM))

Όπως αναφέρθηκε προηγουμένως, όλες οι στρατηγικές πολλαπλών βημάτων παρουσιάζουν ένα σφάλμα σχετικά με την ακρίβεια της πρόβλεψης, που εξαρτάται από το μέγεθος του ορίζοντα πρόβλεψης. Όσο μεγαλύτερο ορίζοντα πρόβλεψης έχουμε, τόσο μεγαλύτερο το σφάλμα. Κατά συνέπεια, η μικρότερη ακρίβεια είναι αναπόφευκτη όταν θέλουμε να προβλέψουμε πολλά βήματα μπροστά. Για να αντιμετωπιστεί αυτό το πρόβλημα, αναπτύχθηκε μία νέα υβριδική στρατηγική που αξιοποιεί την αυτοσυσχέτιση των τιμών της χρονοσειράς και οδηγεί σε απόδοση πλησιέστερη στις μεθόδους πρόβλεψης ενός βήματος. Η υβριδική μέθοδος αυτοσυσχέτισης καταφέρνει να ελαττώσει τον ορίζοντα πρόβλεψης έτσι ώστε να προσεγγίσει μία uni-step μέθοδο.

Πιο συγκεκριμένα εκπαιδεύεται ένα μοντέλο f με την χρονοσειρά

$(y_1, \dots, y_N)$ και έστω ότι η τιμή y_t είναι αυτοσυσχετιζόμενη με την τιμή y_{t-a} . Τότε ως είσοδο στο μοντέλο πρόβλεψης δεν θα έχουμε την y_{t-1} όπως συνηθίζεται στην πρόβλεψη χρονοσειρών, αλλά την y_{t-a} . Όπως είναι προφανές σε κάθε χρονοσειρά η y_t εξαρτάται από την προηγούμενη τιμή y_{t-1} , αλλά φυσικά δεν μπορούμε να χρησιμοποιούμε την αμέσως προηγούμενη τιμή για ορίζοντα πρόβλεψης μεγαλύτερο του 1 γιατί δεν την έχουμε. Έτσι εφαρμόζοντας στατιστικά τεστ αυτοσυσχέτισης προσπαθούμε να βρούμε την αμέσως επόμενη πιο αυτοσυσχετιζόμενη τιμή y_{t-a} και βασίζουμε εκεί την εκπαίδευση του μοντέλου. Με αυτόν τον τρόπο κάνουμε πρόβλεψη πολλαπλών βημάτων, δεν υποφέρουμε από μεταφορά σφάλματος, διότι σαν είσοδο έχουμε μόνο πραγματικές τιμές και παράλληλα λαμβάνονται υπόψιν και οι στοχαστικές εξαρτήσεις μεταξύ των τιμών. Έτσι όσο ο ορίζοντας πρόβλεψης H είναι μικρότερος του a τότε όλες οι προβλέψεις είναι ενός βήματος, ενώ όταν ο H είναι μεγαλύτερος του a τότε το βήμα αυξάνεται αλλά παραμένει πολύ μικρότερο απ' ό τι με τις προαναφερθείσες μεθόδους.

Ας υποθέσουμε ότι θέλουμε να προβλέψουμε τις επόμενες 24 ώρες μιας χρονοσειράς και το δεδομένο χρονικό βήμα είναι $t = 30$ λεπτά. Προφανώς, ο ορίζοντας πρόβλεψης είναι $H = 24 * 2 = 48$, οπότε στόχος μας είναι να προβλέψουμε 48 βήματα εμπρός. Η τιμή $t + 1$ εξαρτάται από το t , αλλά η τιμή με την αμέσως μεγαλύτερη αυτοσυσχέτιση είναι η $t-47$, που αντιστοιχεί στην τιμή την ίδια ώρα την προηγούμενη ημέρα. Ως εκ τούτου, αν θέλουμε να προβλέψουμε το φορτίο στις 14:00, οι πιο σχετικές και αποφασιστικές τιμές είναι εκείνες που αντιστοιχούν στις 14:00 την προηγούμενη ημέρα. Με αυτόν τον τρόπο κατορθώσαμε να προβλέψουμε μόνο μία τιμή μπροστά. Η διαδικασία επαναλαμβάνεται για τις υπόλοιπες περιόδους. Στο τέλος, θα έχουμε 48 νέα σημεία, όπως και σε πολλά βήματα μπροστά

πρόβλεψη, εφαρμόζοντας όμως ένα μονόπλευρο πρότυπο πρόβλεψης. Ως εκ τούτου, ο ορίζοντας πρόβλεψης περιορίζεται από 48 σε 1. Παρόλα αυτά, εάν θέλουμε να προβλέψουμε τις επόμενες 48 ώρες, δηλαδή $48 * 2 = 96$ βήματα μπροστά, δεν μπορούμε να πραγματοποιήσουμε την πρόβλεψη σε ένα βήμα, αλλά σε δύο που είναι ακόμα καλύτερη από 96. Επιπλέον, όσο μικρότερο είναι το χρονικό βήμα η πρόβλεψη παίρνει αντίστοιχα μεγαλύτερο περιθώριο βελτίωσης. Συνοπτικά, η προτεινόμενη μεθοδολογία μειώνει σημαντικά το σφάλμα προβλέψεων μειώνοντας τον ορίζοντα πρόβλεψης. Πράγματι, η βελτίωση που επιτυγχάνεται είναι υψηλότερη όσο το χρονικό βήμα των χρονοσειρών μειώνεται και αντίστοιχα ο ορίζοντας πρόβλεψης αυξάνεται περαιτέρω.

3.5 Αλγόριθμοι Πρόβλεψης

Στην βιβλιογραφία, οι μέθοδοι πρόβλεψης χρονοσειρών χωρίζονται σε δύο κατηγορίες, τα αναλυτικά μοντέλα και τα μοντέλα τεχνητής νοημοσύνης.

3.5.1 Αναλυτικά Μοντέλα Πρόβλεψης

Μία γενική κατηγορία μεθόδων αποτελούν τα στατιστικά μοντέλα πρόβλεψης τα οποία περιλαμβάνουν τα Autoregressive (AR), Moving Average (MA), Autoregressive Integrated Moving Average (ARIMA) μοντέλα και διάφορες παραλλαγές τους. Για την ακρίβεια τα ARIMA Models είναι μία από τις πιο δημοφιλείς και ευρέως χρησιμοποιούμενες μεθόδους πρόβλεψης μονοδιάστατων χρονοσειρών. Ωστόσο, αυτές οι μέθοδοι λειτουργούν αποτελεσματικά υποθέτοντας ότι η παρατηρούμενη χρονοσειρά και η αντίστοιχη προβλεπόμενη θα χαρακτηρίζονται από γραμμική εξάρτηση και στασιμότητα, γεγονός που τις καθιστά

στις περισσότερες περιπτώσεις αδύναμες και μη αποδοτικές για χρονοσειρές με χαρακτηριστικά διαφορετικά από τα παραπάνω, όπως και οι χρονοσειρές ηλεκτρικού φορτίου. Έχει γίνει πολύ δουλειά ώστε να ξεπεραστεί αυτό το πρόβλημα και να επεκταθούν τα στατιστικά μοντέλα σε μη γραμμικά προβλήματα όπως η ανάπτυξη του μοντέλου Autoregressive Conditional Heteroscedastic (GARCH), αλλά παρ'όλα αυτά τα στατιστικά μοντέλα εξακολουθούν και παραμένουν μη ελκυστικά για μη στατικά και μη γραμμικά δεδομένα [5].

3.5.2 Μοντέλα μηχανικής-βαθιάς μάθησης

Τα τελευταία χρόνια τα τεχνητά νευρικά δίκτυα (ANN) κέρδισαν μεγάλο προβάδισμα για την πρόβλεψη των χρονοσειρών. Ανεξαρτηता της φύσης μαύρου κουτιού τους και την αρχική δυσπιστία και αβεβαιότητα λόγω αυτού του γεγονότος, σήμερα τα ANN έχουν επικρατήσει έναντι των παραδοσιακών τεχνικών πρόβλεψης. Συγκεκριμένα, τα μοντέλα βαθιάς μάθησης, που είναι μια υποκατηγορία των ANN όπως ο Multilayer Perceptron (MLP), το Convolution Neural Networks (CNN) αλλά και ρηχά μοντέλα μηχανικής μάθησης όπως το Long Short Term Memory neural network (LSTM) έχουν επιτύχει εξαιρετικά αποτελέσματα και εκπληκτικές επιδόσεις τόσο σε προβλήματα επιβλεπόμενης και μη επιβλεπόμενης μάθησης. Το MLP και το CNN είναι δύο μοντέλα με υψηλές επιδόσεις που μπορούν να επιτύχουν State of the Art αποτελέσματα σε πολλά διαφορετικά προβλήματα. Και οι δύο αλγόριθμοι ανήκουν στα μοντέλα νευρωνικών δικτύων προσοτροφodότησης (feed-forward). Η ανεξαρτησία μεταξύ δεδομένων εκπαίδευσης και αξιολόγησης είναι ο κύριος λόγος για τον οποίο και τα δύο προαναφερθέντα μοντέλα δείχνουν αξιοσημείωτη ακρίβεια. Παρ'όλα αυτά, η ακρίβεια είναι ευαίσθητη από αυτήν την εξάρτηση και η απόδοση των αλγορίθμων επηρεάζεται λόγω της ανικανότητάς τους να εκμε-

ταλλεύονται αυτήν τη σχέση μεταξύ των δεδομένων εκπαίδευσης και αξιολόγησης. Το γεγονός αυτό μπορεί να οδηγεί σε χαμηλότερη απόδοση που είναι συγκρίσιμη με τα απλά ANN, ειδικά σε περιπτώσεις χρονοσειρών όπου οι σχέσεις δεδομένων και οι εξαρτήσεις είναι ισχυρές.


Δεδομένου ότι οι εφαρμογές γίνονται όλο και πιο περίπλοκες, ένας μόνος νευρώνας δεν θα ήταν σε θέση να εκτελέσει αυτές τις πολύ απαιτητικές λειτουργίες. Ως εκ τούτου, οι αλγόριθμοι βαθιάς μάθησης χρησιμοποιούνται ευρέως. Βαθιά μάθηση είναι ένα σύνολο αλγορίθμων μηχανικής μάθησης, που χρησιμοποιούν μοντέλα που αποτελούνται από πολλαπλούς μη γραμμικούς μετασχηματισμούς, ανακαλύπτουν πρότυπα στα δεδομένα και λαμβάνουν αποφάσεις με βάση αυτά τα πρότυπα. Είναι μέρος μιας ευρείας οικογένειας μεθόδων μηχανικής μάθησης. Ένας αλγόριθμος θεωρείται βαθύς εάν τα δεδομένα εισόδου περνούν μέσω ενός στρώματος μη γραμμικών ή γραμμικών μετασχηματισμών πριν οδηγηθούν στην έξοδο. Πιο απλά ένα μοντέλο που αποτελείται από περισσότερα των τριών στρωμάτων (συμπεριλαμβανομένων της εισόδου και εξόδου) θεωρείται μοντέλο βαθιάς μάθησης. Η βαθιά μάθηση αφαιρεί τη χειροκίνητη αναγνώριση χαρακτηριστικών στα δεδομένα και, αντ' αυτού, βασίζεται σε οποιαδήποτε εκπαιδευτική διαδικασία απασχολεί προκειμένου να ανακαλυφθούν τα χρήσιμα μοτίβα της εισόδου. Αυτό κάνει την κατάρτιση δικτύου πιο εύκολη και ταχύτερη, και μπορεί να αποφέρει καλύτερο αποτέλεσμα.

Στην συγκεκριμένη διπλωματική χρησιμοποιήσαμε και συγκρίναμε την απόδοση τεσσάρων διαφορετικών μοντέλων νευρωνικών δικτύων στο πρόβλημα της πρόβλεψης της χρονοσειράς του ηλεκτρικού φορτίου. Συγκεκριμένα πρόκειται για τρία μοντέλα βαθιάς μάθησης, τα Convolution Neural Nets (CNN), Multilayer Perceptron (MLP) και το Long Short Term Memory (LSTM) καθώς και ένα απλό μοντέλο νευρω-

νικού δικτύου Artificial Neural Network (ANN)

Multilayer Perceptron (MLP)


Ο MLP χαρακτηρίζεται από πολλά στρώματα κόμβων εισόδου συνδεδεμένων με την μορφή γράφου μεταξύ των στρώσεων εισόδου και εξόδου. Στο απλούστερο δίκτυο θα έχουμε ένα στρώμα εισόδου, ένα κρυφό στρώμα και ένα στρώμα εξόδου. Κάθε στρώμα έχει πολλαπλούς νευρώνες και όλοι οι νευρώνες ενός στρώματος συνδέονται με όλους τους νευρώνες του επόμενου στρώματος. Αυτά τα δίκτυα είναι πλήρως συνδεδεμένα δίκτυα. Ένας MLP είναι ένα προσοτροφοδούμενο (feedforward) τεχνητό νευρωνικό δίκτυο που παράγει ένα σύνολο από εξόδους από ένα σύνολο εισόδων. Ένας MLP χρησιμοποιεί τον αλγόριθμο ανάστροφης τροφοδότησης (back propagation), ο οποίος στηρίζεται στον κανόνα διόρθωσης σφάλματος. Δεδομένου ότι υπάρχουν πολλά στρώματα νευρώνων, ο MLP μπορεί να αντιμετωπιστεί ως αλγόριθμος βαθιάς μάθησης. Ο MLP χρησιμοποιείται ευρέως για την επίλυση προβλημάτων που απαιτούν εποπτευόμενη μάθηση καθώς και για ερευνητικούς σκοπούς στην υπολογιστική νευροεπιστήμη και σε άλλες εφαρμογές παράλληλης και κατανεμημένης επεξεργασίας. Ορισμένες από τις εφαρμογές περιλαμβάνουν αναγνώριση ομιλίας, αναγνώριση εικόνας και μηχανική μετάφραση [48]



Γράφημα 3.5: Παράδειγμα αρχιτεκτονικής του MLP, μια εφαρμογή σε πρόβλεψη της ταχύτητας του αέρα [49]

Convolution Neural Network (CNN)


Ένα συνελικτικό νευρωνικό δίκτυο Convolution Neural Network (CNN) είναι ένας ειδικός τύπος τεχνητού νευρωνικού δικτύου που χρησιμοποιεί perceptrons για επιβλεπόμενη μάθηση και ανάλυση δεδομένων. Τα CNN έχουν εφαρμοστεί κυρίως στην επεξεργασία εικόνων, επεξεργασία φυσικής γλώσσας και άλλα είδη γνωστικών καθηκόντων. Ένα συνελικτικό νευρωνικό δίκτυο είναι επίσης γνωστό ως ConvNet. Όπως και άλλα είδη τεχνητών νευρωνικών δικτύων έχει ένα στρώμα εισόδου, ένα στρώμα εξόδου και διάφορα κρυμμένα στρώματα. Μερικά από αυτά τα στρώματα είναι συνελικτικά, χρησιμοποιώντας ένα μαθηματικό μοντέλο για τη μετάδοση των αποτελεσμάτων στα επόμενα επίπεδα. Αυτή η διαδικασία αντιγράφει μερικές από τις ενέργειες στον ανθρώπινο οπτικό φλοιό. Τα CNN αποτελούν ένα θεμελιώδες παράδειγμα βαθιάς μάθησης, τα μοντέλα των οποίων ωθούν τις ανάπτυξη του τομέα της τεχνητής νοημοσύνης προσφέροντας συστήματα που προσομοιώνουν διαφορετικούς τύπους της βιολογικής ανθρώπινης εγκεφαλικής δραστηριότητας [47].



Γράφημα 3.6: Παράδειγμα αρχιτεκτονικής του CNN, [50]

Long Short Term Memory (LSTM)

Τα Long Short Term Memory (LSTM) είναι μία υποκατηγορία των Recurrent Neural Networks (RNN). Τα RNN νευρωνικά δίκτυα σχεδιάστηκαν για να αντιμετωπίσουν το ζήτημα των διαδοχικών δεδομένων χρονοσειρών. Το RNN επιτρέπει την αμφίδρομη μεταφορά σημάτων με την εισαγωγή βρόχων και εσωτερικών συνδέσεων, ένα χαρακτηριστικό που τα καθιστά ικανά για ανίχνευση και αξιοποίηση μακροπρόθεσμων ή βραχυπρόθεσμων εξαρτήσεων μεταξύ των δεδομένων.




Γράφημα 3.7: Αρχιτεκτονική του RNN [52]

Τα μοντέλα LSTM ανήκουν στην κατηγορία των RNN και μάλιστα αποτελούν τα πιο προηγμένα μοντέλα RNNs. Το 1997 οι Hochreiter και Schmidhuber [51] εισήγαγαν τα LSTM, των οποίων το κύριο χαρακτηριστικό είναι η ικανότητα ανάκλησης πληροφοριών για μεγά-

λα χρονικά διαστήματα, καλύτερη από οποιαδήποτε άλλη συμβατική RNN υλοποίηση.

Τα LSTM έχουν διαφορές όσον αφορά την αρχιτεκτονική τους σε σύγκριση με τυπικές εκδόσεις RNN. Το κοινό χαρακτηριστικό τους είναι οι επαναλαμβανόμενες λειτουργίες με τη μορφή μιας αλυσίδας του νευρωνικού δικτύου. Στα πρότυπα RNNs, αυτό το επαναλαμβανόμενο στοιχείο είναι μια πολύ απλή δομή, όπως μία μονή στρώση tanh. Παρόλο που τα LSTM έχουν αυτή τη μορφή αλυσίδας, η επαναλαμβανόμενη λειτουργία έχει μια διαφορετική και πιο πολύπλοκη δομή, όπου αντί έχοντας ένα μόνο στρώμα νευρωνικού δικτύου, χρησιμοποιούνται τέσσερις, αλληλεπιδρώντας με έναν πολύ ιδιαίτερο τρόπο, όπως φαίνεται στο Γράφημα 3.8.



Γράφημα 3.8: Αρχιτεκτονική του LSTM [52]

Η βασική ιδέα για τα LSTMs είναι η κατάσταση του κυττάρου C_t , η οριζόντια γραμμή που διέρχεται από την κορυφή του όπως φαίνεται στο Γράφημα 3.8. Το LSTM έχει τη δυνατότητα να αφαιρέσει ή να προσθέσει πληροφορίες στην κατάσταση κυττάρου. Η ροή πληροφοριών ρυθμίζεται από τις πύλες, που είναι ένας τρόπος να αφήσουμε προαιρετικά την πληροφορία να περάσει. Ένα LSTM έχει τρεις από αυτές τις πύλες, για να προστατεύει και να ελέγχει την κατάσταση του κυττάρου. Το πρώτο βήμα είναι να αποφασιστεί ποιες από τις πληροφορίες δεν χρειάζονται. Η απόφαση αυτή γίνεται

από ένα στρώμα σιγμοειδούς που ονομάζεται forget layer. Αυτό εξετάζει τις h_{t-1} και x_t , και εξάγει έναν αριθμό μεταξύ 0 και 1 για κάθε αριθμό στην κυτταρική κατάσταση C_t . Το "1" σημαίνει ότι λαμβάνουμε υπόψιν ολόκληρη την πληροφορία ενώ το "0" ότι δεν την λαμβάνουμε καθόλου υπόψιν. Το επόμενο βήμα είναι να αποφασίσουμε ποιες νέες πληροφορίες είναι απαραίτητες ώστε να αποθηκευτούν στην κατάσταση του κυττάρου. Στην αρχή, ένα στρώμα σιγμοειδούς που ονομάζεται input gate layer αποφασίζει ποιες τιμές θα ενημερωθούν. Στην συνέχεια, ένα στρώμα tanh δημιουργεί ένα διάνυσμα νέων υποψήφιων τιμών, C_t , που μπορούν να προστεθούν στην κατάσταση. Στο επόμενο βήμα, ένας συνδυασμός από αυτές τις δύο χρησιμοποιείται για να δημιουργήσει μια ενημέρωση για την κατάσταση. Η παλιά κατάσταση πολλαπλασιάζεται με το f_t , ξεχνώντας τα πράγματα που αποφάσισε να μην λάβει υπόψιν νωρίτερα και έπειτα το i_t και C_t προστίθενται. Αυτές είναι οι νέες υποψήφιες τιμές, κλιμακούμενες από τον συντελεστή που αποφασίστηκε να ενημερώνεται κάθε τιμή κατάστασης. Τέλος, η έξοδος θα προκύψει από την κατάσταση των κυττάρων, αλλά θα είναι μια φιλτραρισμένη έκδοση. Πρώτον, ένα σιγμοειδές στρώμα εκτελείται το οποίο αποφασίζει ποια μέρη της κατάστασης κυττάρου θα φύγουν στην έξοδο. Στη συνέχεια, η κατάσταση κυψέλης κυττάρου περνά μέσω μίας tanh (για να πιέσει τις τιμές να είναι μεταξύ 0 και 1) και έπειτα πολλαπλασιάζεται στην έξοδο της σιγμοειδούς πύλης, έτσι ώστε μόνο το απαραίτητο μέρος να φτάσει στην έξοδο.

Το LSTM ξεπερνά τα υπόλοιπα μοντέλα όταν το μοντέλο πρέπει να μάθει και να αξιοποιήσει μακροπρόθεσμες εξαρτήσεις.

3.6 Μέτρα Απόδοσης

Η σωστή επιλογή των μέτρων απόδοσης που θα χρησιμοποιήσουμε για να αξιολογήσουμε τα μοντέλα πρόβλεψης είναι πολύ σημαντική. Αφενός, βασιζόμενοι σε αυτά τα αποτελέσματα θα επιλέξουμε το τελικό μοντέλο πρόβλεψης και αφετέρου μέσω της επιλογής συγκεκριμένων μετρικών επιλέγουμε σε ποιο συγκεκριμένα χαρακτηριστικά της πρόβλεψης θα εστιάσουμε και ποια θα επηρεάσουν περισσότερο την τελική επιλογή. Είναι σημαντικό να αναφέρουμε ότι για διαφορετικά προβλήματα μπορεί να είναι κατάλληλα διαφορετικά μέτρα απόδοσης. Το μέσο απόλυτο σφάλμα (Mean Absolute Error, MAE) και το σφάλμα μέσης τετραγωνικής ρίζας (Root Mean Squared Error, RMSE) είναι δύο από τις πιο κοινά και πλέον αξιόπιστα μέτρα απόδοσης που χρησιμοποιούνται για τη μέτρηση της ακρίβειας συνεχών μεταβλητών, όπως είναι και το ηλεκτρικό φορτίο.

3.6.1 Μέσο Απόλυτο Σφάλμα (MAE)

Μέσο Απόλυτο Σφάλμα (MAE) : Το MAE μετρά το μέσο μέγεθος των σφαλμάτων σε ένα σύνολο προβλέψεων, χωρίς να λαμβάνει υπόψη την κατεύθυνσή τους. Είναι ο μέσος όρος του δείγματος δοκιμής των απόλυτων διαφορών μεταξύ πρόβλεψης και πραγματικής παρατήρησης όπου όλες οι μεμονωμένες διαφορές έχουν το ίδιο βάρος:

$$MAE = (1/n) \sum_{j=1}^n |y_j - y'_j|$$

Αν δεν ληφθεί η απόλυτη τιμή (τα πρόσημα των σφαλμάτων δεν καταργούνται), το μέσο σφάλμα γίνεται το Σφάλμα Μέσης Εκτίμησης (ΣΜΕ) και συνήθως προορίζεται για τη μέτρηση της μέσης απόκλισης του μοντέλου. Το ΣΜΕ μπορεί να μεταφέρει χρήσιμες πληροφορίες,

αλλά πρέπει να ερμηνεύεται προσεκτικά επειδή τα θετικά και αρνητικά σφάλματα θα αλληλοαναιρεθούν.

3.6.2 Ρίζα Μέσου Τετραγωνικού Σφάλματος (RMSE)

Ρίζα μέσου τετραγωνικού σφάλματος (PMSE): Το PMSE είναι ένας τετραγωνικός κανόνας βαθμολόγησης που επίσης μετρά το μέσο μέγεθος του σφάλματος. Είναι η τετραγωνική ρίζα του μέσου όρου τετραγωνικών διαφορών μεταξύ πρόβλεψης και πραγματικής παρατήρησης.

$$RMSE = \sqrt{(1/n) \sum_{j=1}^n (y_j - y'_j)^2}$$

3.6.3 Σύγκριση

Τόσο το MAE όσο και το RMSE εκφράζουν μέσο σφάλμα πρόβλεψης μοντέλου σε μονάδες της εξεταζόμενης μεταβλητής. Δηλαδή αν η χρονοσειρά που μελετάμε είναι σε Ampere, τότε και η τιμή των RMSE και MAE, θα είναι σε Ampere, γεγονός που είναι πολύ βολικό για να λάβουμε μια άμεση εκτίμηση της επιτυχίας ή όχι του μοντέλου. Και οι δύο μετρήσεις μπορούν να κυμαίνονται από 0 έως ∞ και είναι αδιάφορες στην κατεύθυνση των σφαλμάτων. Είναι αρνητικά προσανατολισμένα αποτελέσματα, πράγμα που σημαίνει ότι οι χαμηλότερες τιμές είναι καλύτερες.

Η λήψη της τετραγωνικής ρίζας των μέσων τετραγωνικών σφαλμάτων έχει μερικές ενδιαφέρουσες επιπτώσεις για το RMSE. Δεδομένου ότι τα σφάλματα τετραγωνίζονται προτού καταμετρηθούν, ο RMSE δίνει ένα σχετικά μεγάλο βάρος σε μεγάλα σφάλματα. Αυτό σημαίνει ότι το RMSE είναι πιο χρήσιμο όταν μεγάλα σφάλματα είναι ιδιαίτε-

ρα ανεπιθύμητα. Προφανώς ένα μεγάλο σφάλμα στην πρόβλεψη της τιμής του ηλεκτρικού ρεύματος μπορεί να προκαλέσει όπως προαναφέρθηκε μεγάλα προβλήματα και γι αυτό δεν είναι επιθυμητή, έτσι το RMSE είναι ένα κατάλληλο μέτρο απόδοσης για το πρόβλημα της πρόβλεψης ηλεκτρικού φορτίου.

Κεφάλαιο 4

Υλοποίηση

4.1 Tensorflow

Για την υλοποίηση και την εκπαίδευση των αλγορίθμων πρόβλεψης αξιοποιήθηκε η βιβλιοθήκη Tensorflow και συγκεκριμένα το High Level API Keras. Το Tensorflow αποτελεί μία πολύ δημοφιλή λύση για πολλές εφαρμογές τεχνητής νοημοσύνης, τόσο για classification όσο και για regression προβλήματα.

4.1.1 Γενικά

Το Tensorflow είναι μια βιβλιοθήκη λογισμικού ανοικτού κώδικα για αριθμητικούς υπολογισμούς υψηλής απόδοσης. Η ευέλικτη αρχιτεκτονική της επιτρέπει την εύκολη ανάπτυξη υπολογισμών σε διάφορες πλατφόρμες (CPUs, GPUs, TPUs) και από επιτραπέζιους υπολογιστές σε συστοιχίες εξυπηρετητών σε κινητές συσκευές και συσκευές αιχμής. Αρχικά αναπτύχθηκε από ερευνητές και μηχανικούς της ομάδας Google Brain στο πλαίσιο του οργανισμού AI της Google και έρχεται με ισχυρή υποστήριξη για μηχανική μάθηση και βαθιά μάθηση και ο ευέλικτος πυρήνας αριθμητικών υπολογισμών που προσφέρει χρησιμοποιείται σε πολλούς άλλους επιστημονικούς τομείς επίσης [39].

4.1.2 Πλεονεκτήματα Tensorflow

Πριν από το TensorFlow υπήρχαν πολλές βιβλιοθήκες Machine Learning που προσέφεραν μεγάλη λειτουργικότητα για αρκετές μεθόδους και ήταν καλά τεκμηριωμένες όπως τα Theano, Caffe και Torch . Ωστόσο ποτέ δεν υπήρχε μια συλλογή όλων των βιβλιοθηκών, τόσο ολοκληρωμένη με σχεδόν απεριόριστες δυνατότητες, συνεχώς υποστηριζόμενες και παράλογα ευανάγνωστη και εύχρηστη.

Εκτός αυτού, αφού προγραμματίσουμε κάτι με το TensorFlow, μπορούμε να το εκτελέσουμε οπουδήποτε και είναι ιδιαίτερα εύκολο να το μεταφέρουμε στην πλατφόρμα cloud της Google. Με αυτόν τον τρόπο μάλιστα η Google σχεδιάζει να στρέψει την αγορά του cloud computing μακριά από το Amazon, βοηθώντας τις εταιρείες να κάνουν χρήση της μηχανικής μάθησης με το TensorFlow και φαίνεται να το πετυχαίνει καθώς έχει ήδη υιοθετηθεί από διάφορους γίγαντες όπως η Airbus, το Twitter, η IBM και άλλοι, κυρίως λόγω της εξαιρετικά ευέλικτης αρχιτεκτονικής του συστήματος!

Συνεπώς καταλήγουμε ότι η ευκολία στην χρήση, η διαλειτουργικότητα και η ολοκληρωμένη προσέγγιση αποτελούν τα πλεονεκτήματα του Tensorflow , που οδήγησαν τόσο εμάς όσο και εκατομμύρια προγραμματιστές να το προτιμήσουμε έναντι των προηγούμενων βιβλιοθηκών Machine Learning.

4.1.3 Υλοποίηση και εκπαίδευση μοντέλων αξιοποιώντας το Keras

Το Tensorflow μπορεί να χρησιμοποιηθεί είτε παίρνοντας έτοιμα μοντέλα νευρωνικών δικτύων και απλώς εφαρμόζοντας τα στο πρόβλημα, είτε να χρησιμοποιηθούν συγκεκριμένες δομικές μονάδες σαν βάση και με τις κατάλληλες τροποποιήσεις να καταλήξουμε σε ένα custom μοντέλο που ταιριάζει καλύτερα στα δεδομένα του προβλήματος που καλούμαστε να λύσουμε. Κατά τον δεύτερο τρόπο αξιοποιήθηκε στην παρούσα διπλωματική. Συγκεκριμένα χρησιμοποιήθηκε το High level Keras API, το οποίο παρέχει τις δομικές μονάδες για τη δημιουργία και την εκπαίδευση μοντέλων βαθιάς μάθησης και περιλαμβάνει υποστήριξη για λειτουργίες που σχετίζονται με το TensorFlow, όπως η eager execution, tf.data pipelines, και Estimators. Το tf.keras καθιστά το TensorFlow ευκολότερο στη χρήση χωρίς να θυσιάζει την ευελιξία και την απόδοση.

Για να χρησιμοποιήσουμε το Keras, πρέπει να κάνουμε import το tf.keras ως μέρος του Tensorflow setup, όπως φαίνεται παρακάτω: Στη

```
import tensorflow as tf
from tensorflow import keras
```

συνέχεια τα πράγματα είναι επίσης απλά και μπορούμε να αρχίσουμε να αναπτύσσουμε το μοντέλο μας αξιοποιώντας τις παροχές του Keras. Στο Keras, συγκεντρώνετε στρώσεις layers για να φτιάξουμε μοντέλα. Ένα μοντέλο είναι (συνήθως) ένα γράφημα των στρώσεων. Στο επόμενο παράδειγμα σχηματίζουμε έναν από τους πιο ευρέως χρησιμοποιούμενους τύπους μοντέλων, το Sequential το οποίο αποτελείται από διαδοχικά layers.

Όπως φαίνεται στον παρακάτω κώδικά, αρχικά ορίζουμε τον τύ-

```
model = keras.Sequential()  
# Adds a densely-connected layer with 64 units to the model:  
model.add(keras.layers.Dense(64, activation='relu'))  
# Add another:  
model.add(keras.layers.Dense(64, activation='relu'))  
# Add a softmax layer with 10 output units:  
model.add(keras.layers.Dense(10, activation='softmax'))
```

πο του μοντέλου (στο παράδειγμά μας **model** **keras.Sequential()**) και στην συνέχεια προσθέτουμε στρώσεις επιλέγοντας τους νευρώνες εξόδου για κάθε στρώση αλλά και την συνάρτηση ενεργοποίησης κάθε στρώσης (**model.add(keras.layers.Dense(64,activation='relu'))**).

Υπάρχουν διάφορα διαθέσιμα `tf.keras.layers` με κάποιες κοινές παραμέτρους του κατασκευαστή:

- **activation**: Ορίζει τη συνάρτηση ενεργοποίησης για το στρώμα. Αυτή η παράμετρος καθορίζεται από το όνομα μιας ενσωματωμένης συνάρτησης ή ως αντικείμενο με δυνατότητα υποβολής. Από προεπιλογή, δεν εφαρμόζεται καμία ενεργοποίηση.
- **kernel_regularizer and bias_regularizer**: Οι εντολές που κανονικοποιούνται τα βάρη του στρώματος (`kernel`) και `bias`), όπως L1 ή L2. Από προεπιλογή, δεν εφαρμόζεται κανονικοποίηση.
- **kernel_initializer and bias_initializer**: Οι εντολές αρχικοποίησης που δημιουργούν τα βάρη του στρώματος (`kernel`) και `bias`). Αυτή η παράμετρος είναι ένα όνομα ή ένα αντικείμενο με δυνατότητα υποβολής. Η προεπιλεγμένη ρύθμιση είναι "Glorot uniform".

Αφού λοιπόν κατά τον παραπάνω τρόπο σχεδιάζουμε το μοντέλο στη συνέχεια θα διαμορφώσουμε την διαδικασία της εκπαίδευσης χρησιμοποιώντας την μέθοδο `compile`.

Η εντολή `tf.keras.Model.compile` παίρνει τρεις σημαντικές παραμέτρους:


```
model.compile(optimizer=tf.train.AdamOptimizer(0.001),  
              loss='categorical_crossentropy',  
              metrics=['accuracy'])
```

- **optimizer**: Καθορίζει τη διαδικασία εκπαίδευσης. Ορίζεται από το module `tf.train` και επιλέγουμε την εκάστοτε διαδικασία βελτιστοποίησης, όπως το `AdamOptimizer`, το `RMSPropOptimizer` ή το `GradientDescentOptimizer`.
- **loss**: Η συνάρτηση που θέλουμε να ελαχιστοποιήσουμε μέσω της βελτιστοποίησης. Κοινές επιλογές περιλαμβάνουν το μέσο τετραγωνικό σφάλμα (`mse`), `categorical_crossentropy` και `binary_crossentropy`.
- **metrics**: Χρησιμοποιείται για την παρακολούθηση της εκπαίδευσης. Αυτά είναι ονόματα συμβολοσειρών και καλούνται από την `tf.keras.metrics`.

```
# Configure a model for mean-squared error regression.  
model.compile(optimizer=tf.train.AdamOptimizer(0.01),  
              loss='mse',          # mean squared error  
              metrics=['mae'])    # mean absolute error  
  
# Configure a model for categorical classification.  
model.compile(optimizer=tf.train.RMSPropOptimizer(0.01),  
              loss=keras.losses.categorical_crossentropy,  
              metrics=[keras.metrics.categorical_accuracy])
```

Στη συνέχεια, το μοντέλο προσαρμόζεται στα δεδομένα με την μέθοδο `fit`: Η `tf.keras.Model.fit` δέχεται τρεις παραμέτρους:

```
model.fit(data, labels, epochs=10, batch_size=32)
```

- **epochs**: Η εκπαίδευση είναι δομημένη σε `epochs`. Μια `epoch` είναι μια επανάληψη σε ολόκληρο το σύνολο των δεδομένων εισόδου.

- **batch_size**: Όταν περνάμε δεδομένα, το μοντέλο μοιράζει τα δεδομένα σε μικρότερες παρτίδες και επαναλαμβάνεται πάνω από αυτές τις κατά τη διάρκεια της εκπαίδευσης. Αυτός ο ακέραιος προσδιορίζει το μέγεθος κάθε παρτίδας. Έχετε υπόψη ότι η τελευταία παρτίδα μπορεί να είναι μικρότερη εάν ο συνολικός αριθμός δειγμάτων δεν διαιρείται με το μέγεθος της παρτίδας.
- **validation_data**: Όταν ορίζεται ένα μοντέλο, θέλουμε να αξιολογήσουμε την απόδοσή του σε ορισμένα δεδομένα επικύρωσης. Αν περάσουμε αυτό το όρισμα - μια πλειάδα εισόδων και ετικετών - επιτρέπει στο μοντέλο να εμφανίζει τις απώλειες και τις μετρήσεις σε κατάσταση συμπερασμάτων για τα περασμένα δεδομένα, στο τέλος κάθε epoch.

Καταλήγοντας, όπως φαίνεται παραπάνω αξιοποιώντας την βιβλιοθήκη Tensorflow υλοποιήσαμε ένα Sequential μοντέλο, το εκπαιδεύσαμε και προσαρμόσαμε τα δεδομένα εισόδου που θέλουμε να προβλέψουμε με πολύ εύκολο τρόπο.

4.2 Δεδομένα Εισόδου

4.2.1 Γραμμή Μέσης Τάσης του Ελληνικού Δικτύου Διανομής Ηλεκτρικής Ενέργειας

Η πρόβλεψη φορτίου εφαρμόστηκε σε 4 διαφορετικά datasets, με κάθε ένα από αυτά να αντιστοιχεί σε μία γραμμή μέσης τάσης του Ελληνικού δικτύου διανομής. Πρόκειται για δεδομένα που αποτελούνται από δύο στήλες, με την πρώτη να είναι το Timestamp και η δεύτερη η τιμή του ηλεκτρικού φορτίου της γραμμής σε Ampere, την οποία και θέλουμε να προβλέψουμε για τις επόμενες 24 ώρες. Τα δεδομένα απομαστεύονται μέσω ενός συστήματος SCADA και αποθη-

κεύονται σε έναν SQL server όπου από εκεί στην συνέχεια γίνεται εξαγωγή σε ένα αρχείο excel. Για να χρησιμοποιήσουμε τα δεδομένα στο συγκεκριμένο πρόβλημα μετατρέψαμε το excel αρχείο σε csv. Στο γράφημα 4.1 φαίνονται ενδεικτικά μερικές γραμμές από το αρχείο. Κατά μέσον όρο κάθε dataset αποτελείται από 5000 μετρήσεις που

	A	B
1	S TimeStamp	MeasurementValue
2	1/12/2015 8:30	90
3	1/12/2015 9:00	70.6
4	1/12/2015 9:30	71.4
5	1/12/2015 10:00	75.6
6	1/12/2015 10:30	74.2
7	1/12/2015 11:00	74.8
8	1/12/2015 11:30	79.2
9	1/12/2015 12:00	77.4
10	1/12/2015 12:30	76.6
11	1/12/2015 13:00	79.8
12	1/12/2015 13:30	81.2
13	1/12/2015 14:00	82.6
14	1/12/2015 14:30	81.8
15	1/12/2015 15:00	90.4
16	1/12/2015 15:30	95.6
17	1/12/2015 16:00	92.2
18	1/12/2015 16:30	91.4
19	1/12/2015 17:00	85
20	1/12/2015 17:30	87
21	1/12/2015 18:00	101.8
22	1/12/2015 18:30	101
23	1/12/2015 19:00	103.4
24	1/12/2015 19:30	105.6
25	1/12/2015 20:00	108.8
26	1/12/2015 20:30	103
27	1/12/2015 21:00	104.2
28	1/12/2015 21:30	100.4
29	1/12/2015 22:00	93.8
30	1/12/2015 22:30	89.8
31	1/12/2015 23:00	85.8
32	1/12/2015 23:30	80.2
33	1/13/2015	72.2

Γράφημα 4.1: Αριστερά το TimeStamp και δεξιά η τιμή του ηλεκτρικού φορτίου σε Ampere

αντιστοιχούν σε ένα διάστημα 5 μηνών. Όπως φαίνεται οι μετρήσεις έρχονται ανά 30 λεπτά, το οποίο και αποτελεί το βήμα ή timestep της χρονοσειράς. Συνεπώς χρειάζεται να προβλέψουμε $24 \times 2 = 48$ νέ-

ες τιμές που αντιστοιχούν στην επόμενη μέρα, δηλαδή με ορίζοντα πρόβλεψης 48.

4.2.2 Open Source Δεδομένα Γραμμών Μέσης Τάσης Trento-Italy

Εκτός από τα δεδομένα προερχόμενα από τον ΔΕΔΔΗΕ, χρησιμοποιήθηκαν δεδομένα open source από την περιοχή Trento της Ιταλίας, μέσω του dandelion.eu. Χρησιμοποιώντας επιπλέον δεδομένα από μία πολύ διαφορετική περιοχή και με πολύ διαφορετικά χαρακτηριστικά ενισχύεται η στιβαρότητα και η αξιοπιστία των μοντέλων που αναπτύχθηκαν. Η δομή των δεδομένων είναι ίδια ακριβώς με τα ελληνικά με την μόνη αλλά ουσιώδη διαφορά ότι αυτά έρχονται ανά δέκα λεπτά. Συνεπώς η πρόβλεψη για την επόμενη μέρα αντιστοιχεί σε έναν ορίζοντα πρόβλεψης $24 \cdot 6 = 144$, γεγονός που δυσκολεύει το πρόβλημα. Ενδεικτικά παρουσιάζονται μερικές γραμμές από το προαναφερθέν dataset στο γράφημα 4.2 Παρατηρούμε ότι τα συγκεκριμένα δεδομένα παρουσιάζουν πολύ μικρότερη διακύμανση από τα ελληνικά δεδομένα, ενώ μία επιπλέον διαφορά είναι ότι έχουμε περίπου 1100 μετρήσεις που αντιστοιχούν σε διάστημα 2,5 μηνών. Όπως θα δούμε στην συνέχεια η απόδοση της πρόβλεψης δεν επηρεάστηκε σε ανησυχητικό βαθμό από αυτές τις διαφορές.

	A	B
1	DATE	
2	2013-11-01 00:00	37.439999
3	2013-11-01 00:10	37.439999
4	2013-11-01 00:20	36
5	2013-11-01 00:30	35.279999
6	2013-11-01 00:40	35.279999
7	2013-11-01 00:50	34.199997
8	2013-11-01 01:00	35.279999
9	2013-11-01 01:10	34.199997
10	2013-11-01 01:20	33.119999
11	2013-11-01 01:30	34.739998
12	2013-11-01 01:40	32.939999
13	2013-11-01 01:50	32.399998
14	2013-11-01 02:00	32.399998
15	2013-11-01 02:10	32.399998
16	2013-11-01 02:20	31.859999
17	2013-11-01 02:30	32.399998
18	2013-11-01 02:40	31.319998
19	2013-11-01 02:50	30.959999
20	2013-11-01 03:00	32.219997
21	2013-11-01 03:10	32.399998
22	2013-11-01 03:20	32.399998
23	2013-11-01 03:30	32.399998
24	2013-11-01 03:40	31.319998

Γράφημα 4.2: Αριστερά το TimeStamp και δεξιά η τιμή του ηλεκτρικού φορτίου σε Ampere

4.2.3 Κώδικας φόρτωσης των δεδομένων

Αρχικά δημιουργούμε την συνάρτηση `create_dataset`, που φαίνεται στο Γράφημα 4.3 με την οποία ορίζουμε την μορφή του dataset, για να το αξιοποιήσουμε στον κώδικα. Στην συγκεκριμένη περίπτωση δημιουργούμε δύο στήλες με την μία να έχει την τιμή την χρονική στιγμή t και την δεύτερη να έχει την τιμή την στιγμή $t - 46$, όπως ορίζεται από την μεταβλητή `look_back`. Εφόσον θέλουμε να προβλέψουμε την τιμή για την χρονική στιγμή $t + 1$ χρειαζόμαστε σύμφωνα με την μέθοδο πρόβλεψης που περιγράφεται στο κεφάλαιο 3 την αντίστοιχη τιμή της προηγούμενης ημέρας και αφού έχουμε 48 πα-

```
# convert an array of values into a dataset matrix
def create_dataset(dataset, look_back=46):
    dataX, dataY = [], []
    for i in range(len(dataset)-look_back-46):
        a = dataset[i:(i+look_back), 46]
        dataX.append(a)
        dataY.append(dataset[i + look_back, 0])
    return numpy.array(dataX), numpy.array(dataY)
```

Γράφημα 4.3: Συνάρτηση μορφοποίησης dataset

ρατηρήσεις ανά ημέρα για τα datasets του Ελληνικού Δικτύου αυτή είναι η $t - 46$ (λόγω του ότι η αρίθμηση των πινάκων ξεκινά από το 0). Αντίστοιχα, για τα open-source δεδομένα, όπου έχουμε μετρήσεις ανά δέκα λεπτά, δηλαδή 144 παρατηρήσεις την ημέρα, η αντίστοιχη μεταβλητή look_back είναι 142.

Ωστόσο ακόμα δεν έχουμε 'φορτώσει' το dataset, απλά έχουμε ορίσει το πως θα το διαβάσει το πρόγραμμα όταν το φορτώσουμε. Στο Γράφημα 4.4 παρουσιάζεται ο κώδικας με τον οποίο φορτώνουμε το dataset, αξιοποιώντας την read_csv της βιβλιοθήκης pandas.

```
# load the dataset
dataframe = read_csv('/home/aris/data/lamia/makrixori.csv', usecols=[0, 46])
X = dataframe.values

dataset = dataframe.values
dataset = dataset.astype('float32')
```

Γράφημα 4.4: Φόρτωση dataset

4.3 Προεπεξεργασία

Αφού έχουμε φορτώσει το dataset τώρα μένει το βήμα της προεπεξεργασίας των δεδομένων. Για να εφαρμόσουμε στην συνέχεια τους αλγορίθμους πρόβλεψης πρέπει πρώτα να κανονικοποιήσουμε το dataset, δηλαδή να αντιστοιχήσουμε τις τιμές τους στο διάστημα $[0,1]$.

Η κανονικοποίηση είναι ένα απαραίτητο βήμα για μία έγκυ-

ρη και ασφαλή πρόβλεψη, αλλά και γενικότερα για εφαρμογές που χρησιμοποιούν εξωτερικά προερχόμενα datasets. Ο κύριος στόχος της κανονικοποίησης των δεδομένων είναι η διασφάλιση της ποιότητας των δεδομένων προτού τροφοδοτηθεί σε οποιονδήποτε αλγόριθμο εκμάθησης. Υπάρχουν πολλοί τύποι κανονικοποίησης δεδομένων. Η κανονικοποίηση μπορεί να χρησιμοποιηθεί για την κλιμάκωση των δεδομένων στην ίδια περιοχή τιμών για κάθε λειτουργία εισαγωγής ώστε να ελαχιστοποιηθεί το bias μέσα στο νευρωνικό δίκτυο. Η κανονικοποίηση των δεδομένων μπορεί επίσης να επιταχύνει το χρόνο εκπαίδευσης ξεκινώντας τη διαδικασία εκπαίδευσης για κάθε χαρακτηριστικό μέσα στην ίδια κλίμακα. Είναι ιδιαίτερα χρήσιμη για εφαρμογές μοντελοποίησης όπου οι είσοδοι είναι γενικά σε πολύ διαφορετικές κλίμακες. Διαφορετικές τεχνικές μπορούν να χρησιμοποιούν διαφορετικούς κανόνες όπως min-max, Z-score, δεκαδική κλίμακα, μέση κανονικοποίηση και ούτω καθεξής.

Σε αυτήν την υλοποίηση επιλέξαμε τον min-max κανόνα. Σε αυτήν την τεχνική οι είσοδοι δεδομένων χαρτογραφούνται σε μια προκαθορισμένη περιοχή εύρος $[0, 1]$ (ή $[-1, 1]$) [40]. Για να κανονικοποιήσουμε τα δεδομένα αξιοποιούμε την βιβλιοθήκη Scit-learn και συγκεκριμένα τον MinMaxScaler, όπως φαίνεται στο Γράφημα 4.4

```
# normalize the dataset
scaler = MinMaxScaler(feature_range=(0, 1))
dataset = scaler.fit_transform(dataset)
```

Γράφημα 4.5: Κανονικοποίηση του dataset με MinMaxScaler

4.4 Χωρισμός του dataset σε train και test

Στην συνέχεια εφόσον έχουμε προηγουμένως φορτώσει και κανονικοποιήσει το dataset, πρέπει να το χωρίσουμε σε δύο μέρη, το train

dataset και το test dataset. Συνήθως επικρατεί ο κανόνας του 75% - 25% αντίστοιχα για train και test.

```
# split into train and test sets
```

```
train_size = int(len(dataset) * percentage-48)
test_size = len(dataset) - train_size
train, test = dataset[0:train_size,:], dataset[train_size:len(dataset),:]
# reshape into X=t and Y=t+1
look_back = 46
trainX, trainY = create_dataset(train, look_back)
testX, testY = create_dataset(test, look_back)
# reshape input to be [samples, time steps, features]
trainX = numpy.reshape(trainX, (trainX.shape[0], trainX.shape[1], 1))
testX = numpy.reshape(testX, (testX.shape[0], testX.shape[1], 1))
```

Γράφημα 4.6: Κώδικας για χωρισμό του dataset σε train και test

Αφού το χωρίσαμε στην αρχή του κώδικα που φαίνεται στο Γράφημα 4,6, στην συνέχεια χρησιμοποιώντας την `create_dataset` φέρνουμε τα δύο datasets στην μορφή που θέλουμε για να μπορέσουμε να εφαρμόσουμε την τεχνική πρόβλεψης που περιγράφουμε στο Κεφάλαιο 3. Επιπλέον με την `numpy.reshape` της βιβλιοθήκης `numpy` διαμορφώνουμε πάλι τα νέα `trainX` και `trainY` για να εφαρμόσουμε στην συνέχεια τα μοντέλα πρόβλεψης.

4.5 Στατιστική ανάλυση Δεδομένων

Όπως αναλύθηκε στο Κεφάλαιο 3 η στατιστική ανάλυση των δεδομένων πριν από εφαρμογή πρόβλεψης είναι πολύ σημαντική. Έτσι στην συνέχεια θα εφαρμόσουμε κάποια στατιστικά τεστ ώστε να καταλήξουμε σε ασφαλή συμπεράσματα για τα προαναφερθέντα στατιστικά στοιχεία που μας ενδιαφέρουν, την γραμμικότητα, την στασιμότητα και την αυτοσυσχέτιση των δεδομένων. Χρησιμοποιούμε τις βιβλιοθήκες `pandas` και `statsmodel`, με την βοήθεια των οποίων ο κώδικας εφαρμογής των τεστ είναι πάρα πολύ απλός και κατανοητός. Επίσης χάριν ευκολίας και για να είναι πιο ευανάγνωστος ο κώδικας για να φορτώσουμε το dataset των στατιστικών τεστ χρησιμοποιήσαμε την `Series` της βιβλιοθήκης `pandas`

```
series = Series.from_csv('/home/aris/data/lamia/domokos.csv', header=0)
```

4.5.1 Γραμμικότητα - Linearity

Αποτελεί την πιο εύκολη περίπτωση καθώς απλώς με ένα `plot` των δεδομένων μπορούμε αμέσως να διακρίνουμε την ύπαρξη ή μη γραμμικότητας. Με την `series.values` διαβάζουμε τις μετρήσεις και στην συνέχεια με την `pyplot` της βιβλιοθήκης `matplotlib` σχεδιάζουμε την χρονοσειρά.

```
x = series.values  
pyplot.plot(x)  
pyplot.show()
```

4.5.2 Στασιμότητα - Stationarity

Οι χρονοσειρές είναι στάσιμες εάν δεν έχουν εποχιακές τάσεις ή επιδράσεις, ενώ στις μη στάσιμες χρονοσειρές τα στατιστικά μεγέθη όπως πχ ο μέσος όρος και η διακύμανση αλλάζουν με τον χρόνο. Υπάρχουν τρεις τρόποι να ελέγξουμε την στασιμότητα ή μη των δεδομένων:

- **Οπτικοποίηση:** Η πιο απλή λύση, καθώς οπτικοποιώντας τις παρατηρήσεις μπορούμε να ανιχνεύσουμε την ύπαρξη ή μη εποχιακών τάσεων και επιδράσεων και γενικότερα επαναλαμβανόμενων με τον χρόνο χαρακτηριστικών.
- **Στατιστικά Μέτρα:** Ελέγχοντας τα στατιστικά μέτρα για διάφορες περιόδους μπορούμε να αποφανθούμε για στασιμότητα ή μη των δεδομένων εφόσον είναι σχεδόν ίδια ή μεταβάλλονται για διαφορετικές περιόδους.
- **Στατιστικά Τεστ:** Τα στατιστικά τεστ κάνουν ισχυρές υποθέσεις σχετικά με τα δεδομένα. Μπορούν να χρησιμοποιηθούν μόνο για να ενημερώσουν το βαθμό στον οποίο μια μηδενική υπόθεση μπορεί να απορριφθεί ή να μην απορριφθεί. Το αποτέλεσμα πρέπει να ερμηνευθεί για ένα δεδομένο πρόβλημα για να έχει νόημα. Παρόλα αυτά, μπορούν να δώσουν έναν γρήγορο έλεγχο και επιβεβαιωτικά στοιχεία ότι η χρονοσειρά είναι στάσιμη ή μη στάσιμη. Το πιο γνωστό τεστ είναι το Augmented Dickey-Fuller test που είναι ένας τύπος στατιστικού τεστ που ονομάζεται τεστ μοναδιαίας ρίζας και αυτό χρησιμοποιήθηκε στην παρούσα υλοποίηση.

Augmented Dickey-Fuller test

Υπάρχουν αρκετά τεστ μοναδιαίας ρίζας και το Augmented Dickey-Fuller είναι ένα από τα πιο ευρέως χρησιμοποιούμενα. Χρησιμοποιεί ένα αυτορυθμιζόμενο μοντέλο και βελτιστοποιεί ένα κριτήριο πληροφορίας σε πολλαπλές διαφορετικές τιμές καθυστέρησης. Η μηδενική υπόθεση της δοκιμής είναι ότι οι χρονοσειρές μπορούν να αναπαρασταθούν από μια μοναδιαία ρίζα που δεν είναι στάσιμη (έχει κάποια δομή που εξαρτάται από το χρόνο). Η εναλλακτική υπόθεση (απόρριψη της μηδενικής υπόθεσης) είναι ότι οι χρονοσειρές είναι στάσιμες. τον χρόνο [41].

- **Μηδενική Υπόθεση(H_0):** Εάν αποτύχει να απορριφθεί, προτείνεται ότι η χρονοσειρά έχει μια μοναδιαία ρίζα, που σημαίνει ότι είναι μη στάσιμη. Έχει κάποια δομή που εξαρτάται από το χρόνο.
- **Εναλλακτική Υπόθεση(H_1):** Η μηδενική υπόθεση απορρίπτεται. Υποδηλώνει ότι η χρονοσειρά δεν έχει μοναδιαία ρίζα, που σημαίνει ότι είναι στάσιμη. Δεν έχει δομή εξαρτώμενη από το χρόνο.

Ερμηνεύουμε αυτό το αποτέλεσμα χρησιμοποιώντας την τιμή p από τη δοκιμή. Μια τιμή p κάτω από ένα όριο (όπως 5% ή 1%) υποδηλώνει ότι απορρίπτουμε την μηδενική υπόθεση (στάσιμη), διαφορετικά μια τιμή p πάνω από το όριο υποδηλώνει ότι αποτυγχάνουμε να απορρίψουμε την μηδενική υπόθεση (μη στάσιμη).

- **$p\text{-value} > 0.05$:** Αποτυχία απόρριψης της μηδενικής υπόθεσης (H_0), τα δεδομένα έχουν μοναδιαία ρίζα και δεν είναι στάσιμα.
- **$p\text{-value} < 0.05$:** Απόρριψη της μηδενικής υπόθεσης (H_0), τα δεδομένα δεν έχουν μοναδιαία ρίζα και είναι στάσιμα.

Στο Γράφημα 4.7 παρουσιάζεται ο κώδικας για το τεστ, χρησιμοποιώντας πάλι την βιβλιοθήκη statsmodel και συγκεκριμένα την εντολή adfuller.

```
X = series.values
pyplot.plot(X)
pyplot.show()
result = adfuller(X)
print('ADF Statistic: %f' % result[0])
print('p-value: %f' % result[1])
print('Critical Values:')
for key, value in result[4].items():
    print('\t%s: %.3f' % (key, value))
```

Γράφημα 4.7: Ο κώδικας για το Augmented Dickey-Fuller test

Στατιστικά Μέτρα

Επιπλέον θα ενισχύσουμε το αποτέλεσμα του τεστ εφαρμόζοντας και έναν έλεγχο στα στατιστικά μέτρα του dataset. Έτσι στην συνέχεια χωρίζουμε το dataset σε δύο ίσα μέρη και ελέγχουμε για κάθε ένα ξεχωριστά τον μέσο όρο και την διακύμανση. Εάν είναι παρόμοια και τα δύο μεγέθη για κάθε μέρος τότε η χρονοσειρά είναι στάσιμη, ειδάλλως μη στάσιμη. Στο Γράφημα 4.8 παρουσιάζεται το κομμάτι κώδικα [41]

```
split = len(X) / 2
X1, X2 = X[0:split], X[split:]
mean1, mean2 = X1.mean(), X2.mean()
var1, var2 = X1.var(), X2.var()
print('mean1=%f, mean2=%f' % (mean1, mean2))
print('variance1=%f, variance2=%f' % (var1, var2))
```

Γράφημα 4.8: Ο κώδικας για το έλεγχο των στατιστικών μέτρων

Οπτικός Έλεγχος

Στη συνέχεια μένει μόνο να ελέγξουμε και μέσω της οπτικοποίησης εάν το dataset είναι στάσιμο ή όχι. Επειδή εξετάζουμε το μέσο όρο και την διακύμανση, υποθέτουμε ότι τα δεδομένα συμμορφώνονται με μια Gaussian και μπορούμε επίσης να το ελέγξουμε γρήγορα αυτό με ιστόγραμμα των παρατηρήσεών μας [41].

```
series.hist()  
pyplot.show()
```

4.5.3 Αυτοσυσχέτιση - Autocorellation

Υπάρχει ένας γρήγορος, οπτικός έλεγχος που μπορούμε να κάνουμε για να δούμε εάν υπάρχει μια αυτοσυσχέτιση στο σύνολο δεδομένων της σειράς χρονοσειρών μας. Μπορούμε να σχεδιάσουμε την παρατήρηση στο προηγούμενο βήμα ($t - 1$) με την παρατήρηση στο επόμενο βήμα ($t + 1$) ως διάγραμμα σκέδασης. Αυτό θα μπορούσε να γίνει αρχικά δημιουργώντας μια έκδοση καθυστερήσεων του συνόλου δεδομένων χρονοσειρών και χρησιμοποιώντας μια ενσωματωμένη λειτουργία γραφικών σκέδασης στη βιβλιοθήκη Pandas. Αλλά υπάρχει ένας ευκολότερος τρόπος. Το Pandas παρέχει μια ενσωματωμένη εντολή για να γίνει αυτό ακριβώς, που ονομάζεται `lag_plot()` [42].

```
lag_plot(series)  
pyplot.show()
```

```
lag_plot(series)  
pyplot.show()
```

Μπορούμε να σχεδιάσουμε τον συντελεστή συσχέτισης για κάθε μεταβλητή καθυστέρησης. Αυτό μπορεί πολύ γρήγορα να δώσει

μια ιδέα για το ποιες μεταβλητές καθυστέρησης μπορεί να είναι καλοί υποψήφιοι για χρήση σε ένα προγνωστικό μοντέλο και πώς η σχέση μεταξύ της παρατήρησης και των ιστορικών αξιών της αλλάζει με την πάροδο του χρόνου. Θα μπορούσαμε να υπολογίσουμε με μη αυτόματο τρόπο τις τιμές συσχετισμού για κάθε μεταβλητή καθυστέρησης και να σχεδιάσουμε το αποτέλεσμα. Ευτυχώς, το Pandas προσφέρει το `autocorrelation_plot()`. Το γράφημα παρέχει τον αριθμό καθυστέρησης κατά μήκος του άξονα ξ και την τιμή συντελεστή συσχέτισης μεταξύ -1 και 1 στον άξονα ψ . Περιλαμβάνει επίσης σταθερές και διακεκομμένες γραμμές που υποδηλώνουν το διάστημα εμπιστοσύνης 95% και 99% για τις τιμές συσχετισμού. Οι τιμές συσχέτισης πάνω από αυτές τις γραμμές είναι πιο σημαντικές από εκείνες κάτω από τη γραμμή, παρέχοντας ένα όριο ή αποκοπή για την επιλογή πιο σχετικών τιμών καθυστέρησης.

```
autocorrelation_plot(series)
pyplot.show()
```

Η βιβλιοθήκη `statsmodels` παρέχει επίσης μια έκδοση του σχεδίου στη συνάρτηση `plot_acf()` ως γραφική παράσταση γραμμής.

```
plot_acf(series, lags=47)
pyplot.show()
```

Εδώ επιλέγουμε 47 για να ελέγξουμε την προηγούμενη μέρα.

4.6 Μοντέλο Long Short Term Memory(LSTM)

Το LSTM νευρωνικό δίκτυο είναι ένα machine learning learning μοντέλο και υλοποιήθηκε αξιοποιώντας το Keras API όπως προαναφέρθηκε. Στο Γράφημα 4.9 παρουσιάζεται ο κώδικας για την υλοποίησή του, ο οποίος αναλύεται στην συνέχεια.


```
model = Sequential()
model.add(LSTM(4, input_shape=(1, look_back)))
model.add(Dense(1))
model.compile(loss='mean_squared_error', optimizer='adam')

model.fit(trainX, trainY, epochs=10, batch_size=1, verbose=2)
```

Γράφημα 4.9: Ο κώδικας για την υλοποίηση του LSTM μοντέλου

Καταρχάς, ορίζουμε ότι το μοντέλο ανήκει στην κατηγορία Sequential στην πρώτη γραμμή και στην συνέχεια με την εντολή **model.add(LSTM(4,input_shape(1,look_back)))**, ορίζουμε την δομή του LSTM, η οποία είναι να αποτελείται από 4 νευρώνες, μονοδιάστατης εισόδου, με είσοδο το look_back που ορίσαμε προηγουμένως, στην προκειμένη περίπτωση την τιμή 48 παρατηρήσεις πριν. Στην συνέχεια με την εντολή **model.add(Dense(1))** ορίζουμε την έξοδο του νευρωνικού δικτύου για αυτό και το Dense=1, καθώς στην έξοδο θα έχω μία τιμή ηλεκτρικού φορτίου, δηλαδή μονοδιάστατη έξοδο, επομένως ένας νευρώνας εξόδου.

Στο Γράφημα 4.10 αναπαρίσταται το LSTM block που κατασκευάσαμε. Η $H(t+1)$ είναι η έξοδος την χρονική στιγμή $t+1$, δηλαδή η πρόβλεψη ένα βήμα μπροστά και βλέπουμε ότι παίρνει σαν είσοδο την $Q(t-48)$, δηλαδή την παρατήρηση 48 βήματα πίσω, δηλαδή την τιμή του ηλεκτρικού φορτίου την ίδια ακριβώς ώρα 24 ώρες πριν. Ομοίως για τις επόμενες 47 προβλέψεις μέχρι να έχουμε όλο το επόμενο 24ωρο.



Γράφημα 4.10: Δομή LSTM block

Στην συνέχεια με την εντολή `model.compile(loss='mean_squared_error',optimizer='adam')` ορίζουμε την συνάρτηση "adam" με την οποία θέλουμε να βελτιστοποιήσουμε το mean_squared_error κατά την εκπαίδευση του μοντέλου.

Καταλήγοντας επιλέγουμε να εκπαιδεύσουμε το μοντέλο με αριθμό epochs ίσο με 10 και με batch_size=1 με την εντολή `model.fit(trainX, trainY, epochs=10, batch_size=1, verbose=2)`. Η επιλογή των αριθμών αυτών δεν γίνεται στην τύχη αλλά προηγείται μία διαδικασία βελτιστοποίησης συνυπολογιζομένου και του χρόνου που διαρκεί η εκπαίδευση εκτός του αποτελέσματος.

4.7 Μοντέλο Multi Layer Perceptron (MLP)

Ο MLP είναι ένα deep learning μοντέλο, αρκετά απλό ωστόσο αποτελεσματικό σε πολλά προβλήματα. Στο Γράφημα 4.11 παρουσιάζεται ο κώδικας της υλοποίησης.

```
model = Sequential()  
model.add(Flatten(input_shape=trainX.shape[1:]))  
model.add(Dense(256, activation='relu'))  
model.add(Dense(1, activation='sigmoid'))  
model.add(Dense(1, activation='linear'))  
model.add(Dense(1, activation='sigmoid'))  
model.add(Dense(1, activation='linear'))  
  
model.compile(loss='mean_squared_error', optimizer='adam')  
model.fit(trainX, trainY, epochs=10, batch_size=1, verbose=2)
```

Γράφημα 4.11: Κώδικας Υλοποίησης MLP

Ομοίως με προηγουμένως έχουμε στην αρχή τον ορισμό του τύπου μοντέλου ως Sequential, ενώ στην συνέχεια έρχεται η εντολή **model.add(Flatten(input_shape=trainX.shape[1:]))** η οποία έρχεται συνήθως πριν από την Dense όταν έχουμε περισσότερους του ενός νευρώνες για να μετατρέπει την είσοδο σε μονοδιάστατο στην προκειμένη περίπτωση πίνακα. Στην συνέχεια προσθέτουμε 5 layers (4+1 έξοδος) για κάθε ένα με την αντίστοιχη συνάρτηση ενεργοποίησης. Μπορούμε να επιλέξουμε διαφορετικές συναρτήσεις ενεργοποίησης ανάλογα με το ποια έχει καλύτερα αποτελέσματα. Το μοντέλο εκπαιδεύτηκε με epochs=10, batch_size=1, verbose=2 όπως όλα.

4.8 Μοντέλο Convolution Neural Network (CNN)

Το CNN είναι ένα αρκετά περίπλοκο μοντέλο. Στον Γράφημα 4.12 παρουσιάζεται ο κώδικας υλοποίησής του.

```
# create and fit the CNN network
```

```
nb_filter = 1
filter_length = 1
start_time = time.time()
```

```
model = Sequential()
model.add(Convolution1D(nb_filter=nb_filter,
                        filter_length=filter_length, border_mode='valid',
                        | activation='relu', input_shape=trainX.shape[1:]))
model.add(MaxPooling1D(pool_length=1))
model.add(Flatten(input_shape=trainX.shape[1:]))
```

```
# We add a vanilla hidden layer:
```

```
model.add(Dense(hidden_dims))
model.add(Dropout(0.5))
model.add(Activation('relu'))
```

```
# We project onto a single unit output layer, and squash it with a sigmoid
```

```
model.add(Dense(1))
model.add(Activation('linear'))
```

```
model.compile(loss='mean_squared_error', optimizer='rmsprop')
```

```
model.fit(trainX, trainY, epochs=10, batch_size=1, verbose=2)
```

Γράφημα 4.12: Κώδικας Υλοποίησης CNN

Στο πρώτο μέρος του κώδικα ορίζονται 2 μεταβλητές. Το `nb_filter=1`, το `filter_length=1` που σημαίνει ότι θέλουμε ένα φίλτρο διάστασης 1, καθώς η είσοδος και η έξοδος είναι μονοδιάστατες. Αν για παράδειγμα είχαμε ένα πρόβλημα classification εικόνων, που είναι και η πιο γνωστή εφαρμογή των CNN θα χρειαζόμασταν `filter_length` όσα pixels ήταν η εικόνα!

Στην συνέχεια, ορίζουμε το μοντέλο ως τύπου `Sequential` και με την `model.add(Convolution1D(nb_filter=nb_filter, filter_length=filter_length,`

`border_mode='valid', activation='relu', input_shape=trainX.shape[1:])` ορίζουμε ένα μονοδιάστατο Convolution μοντέλο με τις μεταβλητές που ορίσαμε στην αρχή και με συνάρτηση ενεργοποίησης relu.

Τα Convolution δίκτυα μπορούν να περιλαμβάνουν στρώματα συγκέντρωσης, τα οποία συνδυάζουν τις εξόδους των συστοιχιών νευρώνων σε μία στρώση σε έναν μόνο νευρώνα στο επόμενο στρώμα. Για παράδειγμα, η μέγιστη συγκέντρωση χρησιμοποιεί τη μέγιστη τιμή από κάθε ένα από ένα σύμπλεγμα νευρώνων στο προηγούμενο επίπεδο. Έτσι με την `model.add(MaxPooling1D(pool_length=1))` επιλέγουμε ένα μονοδιάστατο στρώμα με μία είσοδο (`pool_length=1`) και στην συνέχεια με την Flatten ομαλοποιούμε την είσοδο.

Εν συνεχεία προσθέτουμε άλλο ένα layer με 256 νευρώνες (`hidden_dims`) και προσθέτουμε την Dropout. Η Dropout είναι μια τεχνική όπου τυχαία επιλεγμένοι νευρώνες αγνοούνται κατά τη διάρκεια της εκπαίδευσης. Το αποτέλεσμα είναι ότι το δίκτυο γίνεται λιγότερο ευαίσθητο στα συγκεκριμένα βάρη των νευρώνων. Αυτό με τη σειρά του έχει ως αποτέλεσμα ένα δίκτυο που είναι ικανό για καλύτερη γενίκευση και είναι λιγότερο πιθανό να υπερκεράσει τα δεδομένα εκπαίδευσης. Ωστόσο η Dropout δεν έχει πάντα θετική επίδραση στα δίκτυα. Ειδικά αν το μέγεθος του dataset εκπαίδευσης δεν είναι μεγάλο και εκτός αυτού αν ο χρόνος εκπαίδευσης δεν είναι αρκετός, συνήθως χειροτερεύει την επίδοση, γι αυτό και στα προηγούμενα μοντέλα δεν χρησιμοποιήθηκε η Dropout. Η επιλογή ή όχι της Dropout γίνεται με δοκιμή. Το layer ενεργοποιείται με την 'relu'

Στην συνέχεια προσθέτουμε άλλο ένα layer κατά τα γνωστά, και κάνουμε compile το μοντέλο με συνάρτηση βελτιστοποίησης την 'rmsprop'. Το μοντέλο εκπαιδεύεται κατά τα γνωστά με 10 epochs και `batch_size=1`.

4.9 Μοντέλο Artificial Neural Network (ANN)

Για το τέλος έχει υλοποιηθεί και ένα απλό (ANN), ένας Perceptron. Η υλοποίηση είναι πολύ απλή και παρουσιάζεται στο Γράφημα 4.13

```
model = Sequential()  
model.add(Flatten(input_shape=trainX.shape[1:]))  
model.add(Dense(256, activation='relu'))  
model.add(Dense(1, activation='sigmoid'))  
model.compile(loss='mean_squared_error', optimizer='adam')  
model.fit(trainX, trainY, epochs=10, batch_size=1, verbose=2)
```

Γράφημα 4.13: Κώδικας Υλοποίησης ann

Το μοντέλο αποτελείται από 3 layers συμπεριλαμβανομένης εισόδου και εξόδου, χρησιμοποιεί ως συνάρτηση βελτιστοποίησης την 'adam' και εκπαιδεύεται με 10 epochs και batch_size=1.


Κεφάλαιο 5

Παρουσίαση Αποτελεσμάτων και Ερμηνεία

Στο παρόν κεφάλαιο θα παρουσιαστούν τα αποτελέσματα της πρόβλεψης. Συγκεκριμένα όπως προαναφέρθηκε εφαρμόστηκαν τέσσερα διαφορετικά μοντέλα σε πέντε διαφορετικά σετ δεδομένων. Έτσι, αρχικά παρουσιάζεται το αποτέλεσμα της στατιστικής ανάλυσης των δεδομένων, έπειτα τα διαγράμματα των προβλέψεων, και τέλος ο συγκεντρωτικός πίνακας των μέτρων απόδοσης για κάθε σετ δεδομένων ξεχωριστά.


5.1 Αταλάντη

Στο Γράφημα 5.1 παρατηρούμε ότι από τις επόμενες 49 παρατηρήσεις υψηλότερη αυτοσυσχέτιση δηλαδή κοντά στο 1 έχει η 48η όπως σωστά υποθέσαμε, ενώ στο Γράφημα 5.2 έχει σχεδιαστεί η τιμή της χρονικής στιγμής t με την τιμή την χρονική στιγμή $t + 48$ που είναι η ίδια τιμή την επόμενη μέρα. Όσο πιο πολύ κοντά στην $y = x$ βρίσκονται οι κουκκίδες τόσο μεγαλύτερη η αυτοσυσχέτιση. Όπως φαίνεται στο Γράφημα 5.2 υπάρχει υποψία αυτοσυσχέτισης καθώς παρόλο που κάποιες τιμές αποκλίνουν από την $y = x$, ο κύριος όγκος




Γράφημα 5.1: Διάγραμμα αυτοσυσχέτισης για τις επόμενες 48 παρατηρήσεις

των παρατηρήσεων κινείται πάνω σε αυτήν την ευθεία.



Γράφημα 5.2: Διάγραμμα αυτοσυσχέτισης της τιμής t με την αντίστοιχη $t + 48$ δηλαδή την ίδια ώρα της επόμενης ημέρας




Γράφημα 5.3: Διάγραμμα κατανομής

```
ADF Statistic: -18.824354
p-value: 0.000000
Critical Values:
    5%: -2.862
    1%: -3.432
    10%: -2.567
mean1=31.549306, mean2=27.925694
variance1=96.773402, variance2=93.791086
```


Γράφημα 5.4: Αποτελέσματα augmented dickey test

Στο Γράφημα 5.3 παρατηρούμε ότι η κατανομή των δεδομένων προσεγγίζει την κανονική κατανομή σε πολύ μεγάλο βαθμό γεγονός που επαληθεύουν τα αποτελέσματα του augmented dickey test που φαίνονται στο Γράφημα 5.4 καθώς όσο πιο αρνητική η ADF Statistic τόσο πιο στατικό το dataset. Μάλιστα μπορούμε να αποφανθούμε με περισσότερο του 99% σιγουριά (λόγω του ότι η τιμή για 1% είναι -3,432) για την στασιμότητα των δεδομένων. Επίσης βλέπουμε ότι χωρίζοντας το σετ σε δύο ίσα μέρη ο μέσο όρος και η διακύμανση παραμένουν ίδιες. Άρα έχουμε ένα στατικό dataset.


Στην συνέχεια παρουσιάζονται τα διαγράμματα των προβλέψεων, με πράσινο μέρος των δεδομένων εκπαίδευσης, με μπλε τα αληθινά δεδομένα και με κόκκινο τα δεδομένα αξιολόγησης.




Γράφημα 5.5: Διάγραμμα CNN



Γράφημα 5.6: Διάγραμμα LSTM



Γράφημα 5.7: Διάγραμμα MLP




Γράφημα 5.8: Διάγραμμα ANN

Στον ΠΙΝΑΚΑ 5.1 παρουσιάζονται τα αποτελέσματα των προβλέψεων. Όπως βλέπουμε το LSTM ξεπέρασε όλα τα υπόλοιπα πετυχαίνοντας της καλύτερη επίδοση. Δεύτερο καλύτερο μοντέλο εδώ έρχεται ο MLP ενώ η έκπληξη παρατηρείται στην τρίτη θέση όπου το απλά νευρωνικό δίκτυο “κερδίζει” το CNN. Αυτό το αποτέλεσμα μπορεί να μοιάζει περίεργο όμως όπως προαναφέρθηκε στο 3ο Κεφάλαιο είναι πολλές φορές αναμενόμενο σε datasets με υψηλή συσχέτιση και εξαρτήσεις μεταξύ των δεδομένων, όπως το συγκεκριμένο.

ΠΙΝΑΚΑΣ 5.1. Μετρα απόδοσης *RMSE* και *MAE* όλων των μοντέλων για το *dataset* της Αταλάντης

	Αταλάντη	
	RMSE	MAE
LSTM	3.17	2.38
ANN	4.09	3.32
CNN	4.14	3.32
MLP	3.18	2.37




Γράφημα 5.9: Μεγεθυμένο διάγραμμα LSTM

Μπορούμε να παρατηρήσουμε ότι τόσο το *RMSE* όσο και το *MAE* για όλα τα μοντέλα πρόβλεψης κινήθηκε πολύ χαμηλά γεγονός που επαληθεύει και τεκμηριώνει την επιτυχία όλων των μοντέλων. Η μέγιστη τιμή του συγκεκριμένου σετ είναι λίγο πάνω από 60 και η ελάχιστη λίγο κάτω από 10, δηλαδή ένα εύρος περίπου 50 Ampere και το μέγιστο σφάλμα σε *MAE* είναι 3.32 Ampere ενώ σε *RMSE* είναι 4.14 Ampere. Μάλιστα το 4,14 του *RMSE* δείχνει ότι η πρόβλεψη μας δεν έχει κάνει σφάλματα με μεγάλες αποκλίσεις γεγονός απαραίτητο

αν σκεφτούμε ότι ένα μεγάλο σφάλμα στην πρόβλεψη του ηλεκτρικού φορτίου μπορεί να προκαλέσει πολύ μεγάλα προβλήματα στο δίκτυο. Καταλήγοντας, ακόμα και το χειρότερο μοντέλο ανταπεξήλθε στο δύσκολο πρόβλημα της πρόβλεψης.


5.2 Δομοκός

Στο Γράφημα 5.10 φαίνεται ότι από τις επόμενες 49 παρατηρήσεις υψηλότερη αυτοσυσχέτιση δηλαδή κοντά στο 1 έχει η 48η και γι αυτό επιλέχθηκε να χρησιμοποιηθεί στην στρατηγική πρόβλεψης.




Γράφημα 5.10: Διάγραμμα αυτοσυσχέτισης για τις επόμενες 48 παρατηρήσεις

Στο Γράφημα 5.11 έχει σχεδιαστεί η τιμή της χρονικής στιγμής t με την τιμή την χρονική στιγμή $t + 47$ που είναι η ίδια τιμή την επόμενη μέρα. Όπως φαίνεται στο Γράφημα 5.11 αρκετές τιμές αποκλίνουν από την $y = x$, γεγονός που προϊδεάζει ότι δεν υπάρχει ισχυρή αυτοσυσχέτιση και άρα θα είναι ένα δύσκολο σετ όσων αφορά την πρόβλεψη.



Γράφημα 5.11: Διάγραμμα αυτοσυσχέτισης της τιμής t με την αντίστοιχη $t + 48$ δηλαδή την ίδια ώρα της επόμενης ημέρας



Γράφημα 5.12: Διάγραμμα κατανομής


Στο Γράφημα 5.12 παρατηρούμε ότι η κατανομή των δεδομένων δεν προσεγγίζει την κανονική κατανομή. Ωστόσο αν παρατηρήσουμε τα αποτελέσματα του augmented dickey test που φαίνονται στο Γράφημα 5.13 θα πρέπει να καταλήξουμε ότι η χρονοσειρά είναι στατική καθώς όσο πιο αρνητική η ADF Statistic τόσο πιο στατικό το dataset και εδώ έχουμε $-11,35$. Μάλιστα μπορούμε να αποφανθούμε με περισσότερο του 99% σιγουριά (λόγω του ότι η τιμή για 1% είναι $-3,432$) για την στασιμότητα των δεδομένων. Επίσης βλέπουμε ότι χωρίζοντας το σετ σε δύο ίσα μέρη ο μέσο όρος και η διακύμανση

```
ADF Statistic: -11.351261
p-value: 0.000000
Critical Values:
    5%: -2.862
    1%: -3.432
   10%: -2.567
mean1=15.146631, mean2=17.394474
variance1=328.795835, variance2=377.565829
```


Γράφημα 5.13: Αποτελέσματα augmented dickey test

παραμένουν ίδιες. Άρα έχουμε ένα στατικό dataset.


Στην συνέχεια παρουσιάζονται τα διαγράμματα των προβλέψεων, με πράσινο μέρος των δεδομένων εκπαίδευσης, με μπλε τα αληθινά δεδομένα και με κόκκινο τα δεδομένα αξιολόγησης.



Γράφημα 5.14: Διάγραμμα CNN




Γράφημα 5.15: Διάγραμμα LSTM



Γράφημα 5.16: Διάγραμμα MLP

Στον ΠΙΝΑΚΑ 5.2 παρουσιάζονται τα αποτελέσματα των προβλέψεων. Όπως βλέπουμε το LSTM πάλι έχει την καλύτερη απόδοση. Δεύτερο καλύτερο μοντέλο εδώ έρχεται το CNN ενώ η έκπληξη παρατηρείται στην τρίτη θέση όπου το απλά νευρωνικό δίκτυο υπερσχύει του MLP. ακριβώς το ίδιο είχε παρατηρηθεί και στο σετ της Αταλάντης και πάλι όμως η εξήγηση είχε δοθεί στο 3ο Κεφάλαιο όπου αναφέρεται πως τόσο ο MLP όσο το CNN δεν είναι πολύ καλύτερα ενός απλού ANN σε δεδομένα που παρουσιάζουν μεταξύ τους εξαρτήσεις.




Γράφημα 5.17: Διάγραμμα ANN

ΠΙΝΑΚΑΣ 5.2. Μετρα απόδοσης RMSE και MAE όλων των μοντέλων για το dataset της Αταλάντης

	Δομοκός	
	RMSE	MAE
LSTM	7.09	4.08
ANN	7.73	4.68
CNN	7.36	4.48
MLP	8.27	5.46

Μπορούμε να παρατηρήσουμε ότι το RMSE όσο και το MAE για όλα τα μοντέλα πρόβλεψης κινήθηκαν σε λίγο υψηλότερες τιμές από το πολύ καλό στατιστικά σετ της Αταλάντης αλλά ακόμα και εδώ είναι πολύ ικανοποιητικά αυτά τα αποτελέσματα. Πάλι αν παρατηρήσουμε η μέγιστη τιμή του συγκεκριμένου σετ είναι λίγο πάνω από 70 και η ελάχιστη λίγο κάτω από 10, δηλαδή ένα εύρος περίπου 60 Ampere και το μέγιστο σφάλμα σε MAE είναι 5,46 Ampere ενώ σε RMSE είναι 8,27 Ampere. Η τιμή του RMSE δείχνει ότι η πρόβλεψη μας δεν έχει κάνει σφάλματα με μεγάλες αποκλίσεις.




Γράφημα 5.18: Μεγεθυμένο διάγραμμα LSTM


5.3 Μακρυχώρι

Στο Γράφημα 5.19 φαίνεται ότι από τις επόμενες 49 παρατηρήσεις υψηλότερη αυτοσυσχέτιση δηλαδή κοντά στο 1 έχει η 48η, χαμηλότερα όμως από τα προηγούμενα δύο σετ δεδομένων, γύρω στο 0,5 ενώ στο Γράφημα 5.20 έχει σχεδιαστεί η τιμή της χρονικής στιγμής t με την τιμή την χρονική στιγμή $t + 48$. Από το Γράφημα 5.20 φαίνεται ότι οι τιμές είναι κατά κανόνα πάνω στην $y = x$ αλλά με αρκετές παρεκκλίνοσες επίσης. Συνεπώς καταλήγουμε ότι υπάρχει αυτοσυσχέτιση αλλά όχι τόσο ισχυρή.

Στο Γράφημα 5.21 παρατηρούμε ότι η κατανομή των δεδομένων προσεγγίζει ελάχιστα την κανονική κατανομή. Ωστόσο αν παρατηρήσουμε τα αποτελέσματα του augmented dickey test που φαίνονται στο Γράφημα 5.22 θα πρέπει να καταλήξουμε ότι η χρονοσειρά είναι στατική καθώς όσο πιο αρνητική η ADF Statistic τόσο πιο στατικό




Γράφημα 5.19: Διάγραμμα αυτοσυσχέτισης για τις επόμενες 48 παρατηρήσεις



Γράφημα 5.20: Διάγραμμα αυτοσυσχέτισης της τιμής t με την αντίστοιχη $t + 48$ δηλαδή την ίδια ώρα της επόμενης ημέρας

το dataset και εδώ έχουμε $-4,99$. Επίσης βλέπουμε ότι χωρίζοντας το σετ σε δύο ίσα μέρη ο μέσο όρος και η διακύμανση παραμένουν παρόμοιες.



Γράφημα 5.21: Διάγραμμα κατανομής

```

ADF Statistic: -4.993490
p-value: 0.000023
Critical Values:
    5%: -2.862
    1%: -3.432
    10%: -2.567
mean1=60.607785, mean2=52.188455
variance1=1098.353892, variance2=1009.439140


```

Γράφημα 5.22: Αποτελέσματα augmented dickey test


Στον ΠΙΝΑΚΑ 5.3 παρουσιάζονται τα αποτελέσματα των προβλέψεων. Το LSTM πάλι ξεπερνάει τα υπόλοιπα μοντέλα. Δεύτερο καλύτερο μοντέλο εδώ έρχεται το CNN και στην συνέχεια το MLP. Το ANN έχει την χειρότερη απόδοση από τα τέσσερα. Ομοίως φαίνεται όλα τα μοντέλα να αποδίδουν πολύ καλά και σε αυτό το σετ δεδομένων.

ΠΙΝΑΚΑΣ 5.3. Μετρα απόδοσης *RMSE* και *MAE* όλων των μοντέλων για το *dataset* του Μακρυχωρίου

	Μακρυχώρι	
	RMSE	MAE
LSTM	6.99	4.72
ANN	7.23	5.18
CNN	7.12	5.16
MLP	7.01	4.93




Γράφημα 5.23: Διάγραμμα CNN



Γράφημα 5.24: Διάγραμμα LSTM


5.4 Άμφισσα

Στο Γράφημα 5.25 φαίνεται ότι από τις επόμενες 49 παρατηρήσεις πάλι υψηλότερη αυτοσυσχέτιση δηλαδή κοντά στο 1 με σχεδόν 0,75 έχει η 48η. Πρόκειται για την ισχυρότερη αυτοσυσχέτιση που συναντήσαμε μέχρι στιγμής και μάλιστα παρατηρούμε ότι όχι μόνο η 48η αλλά και οι προηγούμενες έχουν πολύ υψηλό συντελεστή αυτοσυσχέτισης. Είναι λοιπόν ένα καλό σετ για πρόβλεψη.




Γράφημα 5.25: Διάγραμμα αυτοσυσχέτισης για τις επόμενες 48 παρατηρήσεις

Στο Γράφημα 5.26 έχει σχεδιαστεί η τιμή της χρονικής στιγμής t με την τιμή την χρονική στιγμή $t + 48$ που είναι η ίδια τιμή την επόμενη μέρα. Από το Γράφημα 5.2 φαίνεται ότι οι τιμές είναι πάνω στην $y = x$ με λίγες μάλιστα να παρεκκλίνουν αυτής της πορείας. Συνεπώς φαίνεται ότι υπάρχει αυτοσυσχέτιση και μάλιστα ιδιαίτερα ισχυρή.



Γράφημα 5.26: Διάγραμμα αυτοσυσχέτισης της τιμής t με την αντίστοιχη $t + 48$ δηλαδή την ίδια ώρα της επόμενης ημέρας



Γράφημα 5.27: Διάγραμμα κατανομής


```

ADF Statistic: -4.661131
p-value: 0.000099
Critical Values:
    5%: -2.862
    1%: -3.432
    10%: -2.567
mean1=78.489932, mean2=57.744684
variance1=1351.535834, variance2=362.025741
  
```


Γράφημα 5.28: Αποτελέσματα augmented dickey test

Στο Γράφημα 5.27 παρατηρούμε ότι η κατανομή των δεδομένων προσεγγίζει ελάχιστα την κανονική κατανομή. Ωστόσο αν παρατηρήσουμε τα αποτελέσματα του augmented dickey test που φαίνονται στο Γράφημα 5.28 θα πρέπει να καταλήξουμε ότι η χρονοσειρά είναι στατική καθώς όσο πιο αρνητική η ADF Statistic τόσο πιο στατικό το dataset και εδώ έχουμε -4,99. Επίσης βλέπουμε ότι χωρίζοντας το σετ σε δύο ίσα μέρη ο μέσο όρος και η διακύμανση παραμένουν παρόμοιες.


Στην συνέχεια παρουσιάζονται τα διαγράμματα των προβλέψεων, με πράσινο μέρος των δεδομένων εκπαίδευσης, με μπλε τα αληθινά δεδομένα και με κόκκινο τα δεδομένα αξιολόγησης.




Γράφημα 5.29: Διάγραμμα CNN



Γράφημα 5.30: Διάγραμμα LSTM



Γράφημα 5.31: Διάγραμμα MLP




Γράφημα 5.32: Διάγραμμα ANN

Στον ΠΙΝΑΚΑ 5.4 παρουσιάζονται τα αποτελέσματα των προβλέψεων. Το LSTM πάλι ξεπερνάει τα υπόλοιπα μοντέλα. Δεύτερο καλύτερο μοντέλο εδώ έρχεται το CNN και στην συνέχεια το ANN. Το MLP έχει την χειρότερη απόδοση από τα τέσσερα. Σε αυτό το σετ δεδομένων παρατηρούμε μία μεγάλη διαφορά του LSTM μοντέλου από τα υπόλοιπα. Αυτό μπορεί να ερμηνευθεί από το γεγονός ότι η γραμμή Άμφισσα είναι αστική γραμμή και συνεπώς πιο δύσκολη στην πρόβλεψη από τις υπόλοιπες αφού ο ανθρώπινος παράγοντας επηρεάζει περισσότερο την τιμή του φορτίου. Όπως είδαμε από την στατιστική ανάλυση η στασιμότητα του σετ δεν είναι ξεκάθαρη κα-

ΠΙΝΑΚΑΣ 5.4. Μετρα απόδοσης *RMSE* και *MAE* όλων των μοντέλων για το *dataset* της Άμφισσας

	Άμφισσα	
	RMSE	MAE
LSTM	4.15	3.05
ANN	7.03	6.6
CNN	6.58	7.47
MLP	8.61	7.36


θώς τα τεστ έρχονται σε αντιπαράθεση, συνεπώς εύκολα μπορούμε να αποφανθούμε ότι αυτό είναι το πιο δύσκολο από τα τέσσερα προβλήματα. Έτσι το LSTM που στην βιβλιογραφία προτείνεται για να αντιμετωπιστούν προβλήματα προβλέψεις ηλεκτρικού φορτίου εδώ αποδίδει πολύ καλύτερα από τα υπόλοιπα μοντέλα που ενδείκνυνται για διαφορετικές εφαρμογές συνήθως.



Γράφημα 5.33: Μεγεθυμένο διάγραμμα LSTM

5.5 Trento


Το επόμενο σετ δεδομένων, όπως προαναφέρθηκε είναι open-source και προέρχεται από ένα πείραμα στην περιοχή Trento της Ιταλίας. Έχει ένα πολύ σημαντικό μειονέκτημα σε σχέση με τα προηγούμενα σετ και αυτό είναι ότι δεν έχουμε πολλές μετρήσεις, μόνο 1134 δηλαδή κάτι λιγότερο από δέκα ημέρες. Αυτό το γεγονός είναι καθοριστικό για την ακρίβεια της πρόβλεψης καθώς τα μοντέλα δεν μπορούν να εκπαιδευτούν σωστά, αλλά εξετάζοντας το μπορούμε να καταλήξουμε σε ορισμένα χρήσιμα συμπεράσματα και γι αυτό επιλέχθηκε.




Γράφημα 5.34: Διάγραμμα αυτοσυσχέτισης για τις επόμενες 48 παρατηρήσεις

Στο Γράφημα 5.34 φαίνεται ότι από τις επόμενες 150 παρατηρήσεις (που αντιστοιχούν σε μία ημέρα μετά) πάλι υψηλότερη αυτοσυσχέτιση με ελάχιστα περισσότερο από 0,6 έχει η 144η. Έτσι λοιπόν βασιζόμενοι σε αυτήν την παρατήρηση θα δομήσουμε το μοντέλο μας.

Στο Γράφημα 5.35 έχει σχεδιαστεί η τιμή της χρονικής στιγμής t με την τιμή την χρονική στιγμή $t + 144$ που είναι η ίδια τιμή την επόμενη μέρα. Από το Γράφημα 5.35 φαίνεται ότι οι τιμές είναι πάνω στην $y = x$. Συνεπώς φαίνεται ότι υπάρχει αυτοσυσχέτιση.



Γράφημα 5.35: Διάγραμμα αυτοσυσχέτισης της τιμής t με την αντίστοιχη $t + 144$ δηλαδή την ίδια ώρα της επόμενης ημέρας



Γράφημα 5.36: Διάγραμμα κατανομής

```


ADF Statistic: -3.403668
p-value: 0.010834
Critical Values:
  5%: -2.864
  1%: -3.436
 10%: -2.568
mean1=44.580633, mean2=61.430791
variance1=360.055591, variance2=293.697509

```


Γράφημα 5.37: Αποτελέσματα augmented dickey test

Στο Γράφημα 5.36 παρατηρούμε ότι η κατανομή των δεδομένων δεν προσεγγίζει την κανονική κατανομή. Επίσης παρατηρώντας τα αποτελέσματα του augmented dickey test που φαίνονται στο Γράφημα 5.37 θα πρέπει να καταλήξουμε ότι η χρονοσειρά δεν είναι στατική. Επίσης βλέπουμε ότι χωρίζοντας το σετ σε δύο ίσα μέρη ο μέσο όρος και η διακύμανση αλλάζουν. Αυτό είναι πολύ λογικό να συμβαίνει διότι έχουμε δεδομένα μόνο για δέκα ημέρες η οποίες μπορεί να είναι πολύ διαφορετικές μεταξύ τους και να μην μπορούν να δημιουργηθούν συσχετίσεις. Είναι λοιπόν αναμενόμενα τα αποτελέσματα.


Στην συνέχεια παρουσιάζονται τα διαγράμματα των προβλέψεων, με πράσινο μέρος των δεδομένων εκπαίδευσης, με μπλε τα αληθινά δεδομένα και με κόκκινο τα δεδομένα αξιολόγησης.




Γράφημα 5.38: Διάγραμμα CNN



Γράφημα 5.39: Διάγραμμα LSTM



Γράφημα 5.40: Διάγραμμα MLP



Γράφημα 5.41: Διάγραμμα ANN

Στον ΠΙΝΑΚΑ 5.5 παρουσιάζονται τα αποτελέσματα των προβλέψεων. Το LSTM ισοβαθμεί όσων αφορά το RMSE με το CNN στην πρώτη θέση αλλά υστερεί στο MAE. Τρίτο καλύτερο μοντέλο εδώ έρχεται το ANN και στην συνέχεια το MLP έχει την χειρότερη απόδοση από τα τέσσερα. Βλέπουμε ότι τα μοντέλα δεν απέδωσαν πολύ καλά σε αυτό το σετ και επίσης για πρώτη φορά το LSTM δεν υπερισχύει όλων (τουλάχιστον στο MAE). Αυτό το αποτέλεσμα έχει την εξήγηση του και δεν είναι άλλη από το ότι το LSTM δεν μπόρεσε να αξιοποιήσει το πλεονέκτημα του έναντι των υπολοίπων μοντέλων που είναι η εκμετάλλευση των μακροχρόνιων εξαρτήσεων,

ΠΙΝΑΚΑΣ 5.5. Μετρα απόδοσης *RMSE* και *MAE* όλων των μοντέλων για το *dataset* της περιοχής Trento

	Trento	
	RMSE	MAE
LSTM	11.17	9.96
ANN	11.63	9.35
CNN	11.17	8.60
MLP	14.68	13.83

γεγονός λογικό καθώς ενδεχομένως να μην υπάρχουν σε ένα πολύ μικρό διάστημα όπως αυτό των δέκα ημερών! Τα σχετικά μεγάλα (σε σχέση με τα προηγούμενα σετ) σφάλματα οφείλονται ξεκάθαρα στο μικρό σετ δεδομένων.

Κεφάλαιο 6

Συμπεράσματα και Προτάσεις για Περαιτέρω Έρευνα

Όπως φαίνεται από τον συγκεντρωτικό πίνακα αποτελεσμάτων, το LSTM μοντέλο απέδωσε σε όλα τα σετ δεδομένων καλύτερα από τα υπόλοιπα παρά τις όποιες στατιστικές διαφορές, γεγονός που ενισχύει και επιβεβαιώνει την βιβλιογραφία που τα προτείνει ως τον καλύτερο αλγόριθμο για το δύσκολο πρόβλημα της πρόβλεψης του ηλεκτρικού φορτίου. Από την άλλη βλέπουμε ότι και το απλό νευρωνικό δίκτυο είχε μία σταθερή συμπεριφορά ενώ τα CNN και MLP βρίσκονται σε όλα τα σετ ή στην δεύτερη ή στην τρίτη θέση, δηλαδή οι δύο καλύτερες επιδόσεις πάντα έρχονται από Deep learning αλγόριθμους. Στο τελευταίο σετ από το Trento φάνηκε οι αλγόριθμοι να χάνουν την δύναμή τους και αυτό όπως προηγουμένως τονίστηκε οφείλεται στην μη ύπαρξη επαρκούς αριθμού παρατηρήσεων ώστε να “μάθουν” τα μοντέλα. Συνολικά όμως παρατηρούμε ότι οι επιδόσεις όλων των μοντέλων είναι παραπάνω από ικανοποιητικές και φαίνεται ότι οι Deep Learning αλγόριθμοι μπορούν με ευκολία να λύσουν το απαιτητικό πρόβλημα της πρόβλεψης ηλεκτρικού φορτίου.

ΠΙΝΑΚΑΣ 6.1. Συγκεντρωτικός πίνακας αποτελεσμάτων

	Αταλάντη		Άμφισσα		Μακρυχώρι		Δομοκός		Trento	
	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE
LSTM	3.17	2.38	4.15	3.05	6.99	4.72	7.09	4.08	11.17	9.96
ANN	4.09	3.32	7.03	6.6	7.23	5.18	7.73	4.68	11.63	9.35
CNN	4.14	3.32	6.58	7.47	7.12	5.16	7.36	4.48	11.17	8.60
MLP	3.18	2.37	8.61	7.36	7.01	4.93	8.27	5.46	14.68	13.83

Μεγάλο ενδιαφέρον παρουσιάζεται στην συνέχεια η μελέτη της βελτιστοποίησης της διαδικασίας ως προς τον χρόνο. Πολύ συχνά χρειαζόμαστε real time επιδόσεις για να προβλέψουμε την αμέσως επόμενη τιμή για εφαρμογές όπως fault detection ή εκτίμηση της κατάστασης του δικτύου. Σε αυτήν την περίπτωση χρειαζόμαστε περισσότερη υπολογιστική ισχύ ώστε οι αλγόριθμοι να τρέξουν γρηγορότερα σε κλίμακα δευτερολέπτων. Η δυνατότητα μεταφοράς της διαδικασίας στο Cloud μπορεί να είναι μία λύση, καθώς έτσι απαιτείται πολύ μικρότερη τοπική υπολογιστική ισχύς (έναν μικροεπεξεργαστή αρκεί για να συλλέξει απλά τα δεδομένα και να τα στείλει στο Cloud) ενώ μπορεί να αξιοποιηθεί όλη η δύναμη του Cloud για να τρέξουν οι αλγόριθμοι. Μία απλή μετάβαση στη χρήση υπηρεσιών Cloud και συγκεκριμένα των microservices μπορούν να παρέχουν ουσιαστική ευελιξία και να λύσουν το πρόβλημα. Επιπλέον η παραλληλοποίηση των αλγορίθμων, αξιοποιώντας τις δυνατότητες του Tensorflow (Distributed Tensorflow) και των Tensorflow Servers μπορεί να μειώσει αισθητά τον χρόνο της διαδικασίας, και θα έδινε την δυνατότητα να μεταφερθεί η διαδικασία στο Fog στρώμα ενδεχομένως αξιοποιώντας edge computing στοιχεία.

Βιβλιογραφία

- [1] Νικόλαος Βοβός, Γαβριήλ Γιαννακόπουλος, "Εισαγωγή Στα Συστήματα Ηλεκτρικής Ενέργειας", Εκδόσεις Ζήτη, Πανεπιστήμιο Πατρών, Ιούλιος 2008.
- [2] Olle I. Elgerd, Electric Energy Systems an Introduction, 2nd edition, 1982
- [3] Ζαππής Σωκράτης, "Εξυπνα Δίκτυα Ενέργειας", Διπλωματική Εργασία, Τμήματος Ηλεκτρολόγων Μηχανικών και Τεχνολογίας Υπολογιστών της Πολυτεχνικής Σχολής του Πανεπιστημίου Πατρών, Πάτρα, Μάιος 2015.
- [4] <https://en.wikipedia.org/wiki/SCADA>
- [5] Kasim Zor, Oguzhan Timur, Ahmet Teke, "A State-of-the-Art Review of Artificial Intelligence Techniques for Short-Term Electric Load Forecasting",

Department of Electrical and Electronics Engineering Adana Science and Technology University Adana, Turkey
- [6] Tao Hong, "Load Forecasting Case Study", University of North Carolina at Charlotte and Mohammad Shahidehpour, Illinois Institute of Technology For EISPC and NARUC Funded by the U.S. Department of Energy

- [7] Giuliano Andrea Pagani and Marco Aiello "The Power Grid as a Complex Network: a Survey" Distributed Systems Group Johann Bernoulli Institute for Mathematics and Computer Science University of Groningen Groningen, The Netherlands, 21 Mar 2012
- [8] Hristiyan KANCHEV, Di LU, Frédéric COLAS, Vladimir LAZAROV, Bruno FRANCOIS - Energy management and operational planning of a microgrid with a PV-based active generator for Smart Grid Applications - 2011
- [9] Vishnuteja Nanduri, Student Member, IEEE, and Tapas K. Das, Member, IEEE-IEEE TRANSACTIONS ON POWER SYSTEMS, VOL. 22, NO. 1, FEBRUARY 2007, A Reinforcement Learning Model to Assess Market Power Under Auction-Based Energy Pricing- 2011
- [10] <https://www.techopedia.com/definition/692/smart-grid>
- [11] COM(2011)202 - Smart Grids: from innovation to deployment
- [12] <https://ec.europa.eu/energy/en/topics/markets-and-consumers/smart-grids-and-meters/smart-grids-task-force>
- [13] Shabanzadeh, Morteza and Parsa Moghaddam, Mohsen. (2013). What is the Smart Grid? Definitions, Perspectives, and Ultimate Goals. Power System Conference. 10.13140/2.1.2826.7525.
- [14] <http://smartgrid.ieee.org/ieee-smart-grid>
- [15] https://www.elp.com/articles/powergrid_international/print/volume-17/issue-11/features/the-role-communications-smart-grid.html
- [16] Dan Ton, " DOE's Perspectives on Smart Grid Technology, Challenges, and Research Opportunities", November 19, 2009

- [17] European Technology Platform SmartGrids: Vision and Strategy for Europe'As Electricity Networks of the Future?, Directorate-General for Research Sustainable Energy Systems, 2006
- [18] <http://www.abb.com/cawp/db0003db002698/e41499e00a67ceebc12579ba002e1a92.aspx>
- [19] <http://www.edf.org/energy/smart-grid>
- [20]] <http://w3.usa.siemens.com/smartgrid/us/en/pages/smart-grid.aspx>
- [21] Mladen Kezunovic, Vijay Vittal, Sakis Meliopoulos, and Tim Mount, "The Big Picture", 2012
- [22] Ahsan RazaKhana, Anzar Mahmooda, Awais Safdara, Zafar A. Khanb Naveed, Ahmed Khan, "Load forecasting, dynamic pricing and DSM in smart grid: A review, Renewable and Sustainable Energy Reviews Volume 54, February 2016, Pages 1311-1322
- [23] <http://people.duke.edu/~rnau/411trend.htm>
- [24] https://en.wikipedia.org/wiki/Duck_curve
- [25] U.S. Department of Commerce, "NIST Special Publication 1108 NIST Framework and Roadmap for Smart Grid Interoperability Standards, Release 1.0", 2010.
- [26] <http://highwestenergy.com/distributed-generation>
- [27] https://en.wikipedia.org/wiki/Demand_response
- [28] <https://energy-solution.com/project/automated-demand-response/>
- [29] Big batteries for every home and business: Energy storage to double this year
- [30] Λεονάρδος Παντίσκας, "Εξυπνα Ενεργειακά Δίκτυα: Διαχείριση και Εφαρμογές"

- [31] <https://cleantechnica.com/2013/12/04/cadillac-elr-will-smart-grid-ready>
- [32] Kas?m Zor O?uzhan Timur, Ahmet Teke A State-of-the-Art Review of Artificial Intelligence Techniques for Short-Term Electric Load Forecasting
- [33] Marlon Capuno, Jung-Su Kim, and Hwachang Song, Very Short-Term Load Forecasting Using Hybrid Algebraic Prediction and Support Vector Regression, Mathematical Problems in Engineering Volume 2017, Article ID 8298531
- [34] NimaAmjadyFarshidKeynia, Mid-term load forecasting of power systems by a new prediction method, Energy Conversion and Management Volume 49, Issue 10, October 2008, Pages 2678-2687
- [35] Hossein Daneshi, Mohammad Shahidehpour, Azim Lotfjou Choobbari, Long-term load forecasting in electricity market, 2008 IEEE International Conference on Electro/Information Technology
- [36] <https://people.duke.edu/~rnau/411diff.htm>
- [37] Arthur Berg, Timothy McMurry?, Dimitris N. Politis, Testing time series linearity: traditional and bootstrap methods
- [38] <http://www.statisticssolutions.com/autocorrelation/>
- [39] <https://www.tensorflow.org/>
- [40] S. C. Nayak, B. B. Misra and H. S. Behera, Impact of Data Normalization on Stock Index Forecasting, Mathematical Problems in Engineering, International Journal of Computer Information Systems and Industrial Management Applications. ISSN 2150-7988 Volume 6 (2014) pp. 257 - 269

- [41] <https://machinelearningmastery.com/time-series-data-stationary-python/>
- [42] <https://machinelearningmastery.com/autoregression-models-time-series-forecasting-python/>
- [43] Tiao, G. C., Tsay, R. S. (1994). Some advances in non-linear and adaptive modelling in time-series. *Journal of Forecasting*, 13(2), 109-131
- [44] Sorjamaa, A., Hao, J., Reyhani, N., Ji, Y., Lendasse, A. (2007). Methodology for longterm prediction of time series. *Neurocomputing*, 70(16-18), 2861-2869
- [45] Cheng, H., Tan, P.-N., Gao, J., Scripps, J. (2006). Multistep-ahead time series prediction. In W. K. Ng, M. Kitsuregawa, J. Li, K. Chang (Eds.), *PAKDD. Lecture notes in computer science* (Vol. 3918, pp. 765-774). Springer. ISBN: 3-540-33206-5.
- [46] Hamzacebi, C., Akay, D., Kutay, F. (2009). Comparison of direct and iterative artificial neural network forecast approaches in multi-periodic time series forecasting. *Expert Systems with Applications*, 36(2, Part 2), 3839-3844. ISSN: 0957-4174.
- [47] Andriopoulos Nikolaos, Magklaras Aristeidis, Daskalaki Sophia, Valouxis Christos, Birbas Michael, Housos Efthymios, Birbas Alex, A Cloud Based Electric Load Forecasting Tool Exploiting Novel Machine Learning Algorithms
- [48] Σπύρος Τζαφέστας, Υπολογιστική Νομοσύνη
- [49] Hassen Bouzgou, Advanced Methods for the Processing and Analysis of Multidimensional Signals: Application to Wind Speed
- [50] Saleh Albelwi and Ausif Mahmood, A Framework for Designing the Architectures of Deep Convolutional Neural Networks

- [51] Sepp Hochreiter and Jurgen Schmidhuber, Long Short Term Memory, Neural Computation 9 (8):1735-1780,1997 2011
- [52] <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>