



UNIVERSITY OF PATRAS
DEPARTMENT OF ELECTRICAL AND COMPUTER
ENGINEERING

DIVISION OF ELECTRONICS AND COMPUTERS
MICROELECTRONIC CIRCUITS LABORATORY

ELECTRICITY PRICE AND LOAD FORECASTING IN THE GREEK DAY-AHEAD MARKET WITH MACHINE LEARNING METHODS

DIPLOMA THESIS

ANGELOS SOLOMOS

SUPERVISOR: ALEXIOS BIRBAS

PATRAS – JULY, 2026

University of Patras, Department of Electrical and Computer Engineering.

Angelos Solomos

© 2026 – All rights reserved

The whole work is an original work, produced by Angelos Solomos, and does not violate the rights of third parties in any way. If the work contains material which has not been produced by him/her, this is clearly visible and is explicitly mentioned in the text of the work as a product of a third party, noting in a similarly clear way his/her identification data, while at the same time confirming that in case of using original graphics representations, images, graphs, etc., has obtained the unrestricted permission of the copyright holder for the inclusion and subsequent publication of this material.

CERTIFICATION

It is certified that the Diploma Thesis titled

ELECTRICITY PRICE AND LOAD FORECASTING IN THE GREEK DAY-AHEAD MARKET WITH MACHINE LEARNING METHODS

of the Department of Electrical and Computer Engineering student

ANGELOS SOLOMOS

Registration Number: 1079665

was presented publicly at the Department of Electrical and Computer
Engineering on

01/07/2026

and was examined by the following examining committee:

Alexios Birbas, Professor, ECE
Sofia Daskalaki, Assistant Professor, ECE
Michael Birbas, Associate Professor, ECE

The Supervisor

Alexios Birbas
Professor, ECE

The Director of the Division

Georgios Theodoridis
Associate Professor, ECE



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ
ΤΜΗΜΑ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ
ΤΕΧΝΟΛΟΓΙΑΣ ΥΠΟΛΟΓΙΣΤΩΝ

ΤΟΜΕΑΣ ΗΛΕΚΤΡΟΝΙΚΗΣ ΚΑΙ ΥΠΟΛΟΓΙΣΤΩΝ
ΕΡΓΑΣΤΗΡΙΟ ΜΙΚΡΟΗΛΕΚΤΡΟΝΙΚΩΝ ΚΥΚΛΩΜΑΤΩΝ

ΠΡΟΒΛΕΨΗ ΤΙΜΗΣ ΚΑΙ ΦΟΡΤΙΟΥ ΗΛΕΚΤΡΙΚΗΣ ΕΝΕΡΓΕΙΑΣ ΣΤΗΝ
ΕΛΛΗΝΙΚΗ ΑΓΟΡΑ ΕΠΟΜΕΝΗΣ ΗΜΕΡΑΣ ΜΕ ΜΕΘΟΔΟΥΣ
ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ
ΑΓΓΕΛΟΣ ΣΟΛΩΜΟΣ

ΕΠΙΒΛΕΠΩΝ: ΑΛΕΞΙΟΣ ΜΠΙΡΜΠΑΣ

ΠΑΤΡΑ - ΙΟΥΛΙΟΣ 2026

Πανεπιστήμιο Πατρών, Τμήμα Ηλεκτρολόγων Μηχανικών και Τεχνολογίας Υπολογιστών.

Άγγελος Σολωμός

© 2026 – Με την επιφύλαξη παντός δικαιώματος

Το σύνολο της εργασίας αποτελεί πρωτότυπο έργο, παραχθέν από τον Άγγελο Σολωμό, και δεν παραβιάζει δικαιώματα τρίτων καθ' οιονδήποτε τρόπο. Αν η εργασία περιέχει υλικό, το οποίο δεν έχει παραχθεί από τον/την ίδιο/α, αυτό είναι ευδιάκριτο και αναφέρεται ρητώς εντός του κειμένου της εργασίας ως προϊόν εργασίας τρίτου, σημειώνοντας με παρομοίως σαφή τρόπο τα στοιχεία ταυτοποίησής του, ενώ παράλληλα βεβαιώνει πως στην περίπτωση χρήσης αυτούσιων γραφικών αναπαραστάσεων, εικόνων, γραφημάτων κ.λπ., έχει λάβει τη χωρίς περιορισμούς άδεια του κατόχου των πνευματικών δικαιωμάτων για την συμπερίληψη και επακόλουθη δημοσίευση του υλικού αυτού.

ΠΙΣΤΟΠΟΙΗΣΗ

Πιστοποιείται ότι η Διπλωματική Εργασία με τίτλο

ΠΡΟΒΛΕΨΗ ΤΙΜΗΣ ΚΑΙ ΦΟΡΤΙΟΥ ΗΛΕΚΤΡΙΚΗΣ ΕΝΕΡΓΕΙΑΣ ΣΤΗΝ ΕΛΛΗΝΙΚΗ ΑΓΟΡΑ ΕΠΟΜΕΝΗΣ ΗΜΕΡΑΣ ΜΕ ΜΕΘΟΔΟΥΣ ΜΗΧΑΝΙΚΗΣ ΜΑΘΗΣΗΣ

του φοιτητή του Τμήματος Ηλεκτρολόγων Μηχανικών και
Τεχνολογίας Υπολογιστών

ΑΓΓΕΛΟΣ ΣΟΛΩΜΟΣ

Αριθμός Μητρώου: 1079665

Παρουσιάστηκε δημόσια στο Τμήμα Ηλεκτρολόγων Μηχανικών και
Τεχνολογίας Υπολογιστών στις

01/07/2026

και εξετάστηκε από την ακόλουθη εξεταστική επιτροπή:

Αλέξιος Μπίρμπας, Καθηγητής, ΤΗΜ&ΤΥ
Σοφία Δασκαλάκη, Επίκουρη Καθηγήτρια, ΤΗΜ&ΤΥ
Μιχαήλ Μπίρμπας, Αναπληρωτής Καθηγητής, ΤΗΜ&ΤΥ

Ο Επιβλέπων

Ο Διευθυντής του Τομέα

Αλέξιος Μπίρμπας
Καθηγητής, ΤΗΜ&ΤΥ

Γεώργιος Θεοδωρίδης
Αναπληρωτής Καθηγητής, ΤΗΜ&ΤΥ

ΕΥΧΑΡΙΣΤΙΕΣ

Θα ήθελα να ευχαριστήσω θερμά τον επιβλέποντα καθηγητή μου, κ. Αλέξιο Μπίρμπα, για την καθοδήγηση, την εμπιστοσύνη και την ουσιαστική υποστήριξή του καθ' όλη τη διάρκεια εκπόνησης της παρούσας διπλωματικής εργασίας.

Ιδιαίτερα ευγνώμων είμαι στον Νίκο Ανδριόπουλο για την πολύτιμη βοήθειά του και για την προθυμία του να βρίσκεται δίπλα μου σε κάθε δυσκολία που προέκυπτε. Η συμβολή του υπήρξε καθοριστική για την ολοκλήρωση της παρούσας εργασίας.

Σημαντικό στήριγμα σε όλη αυτή την πορεία υπήρξε η οικογένειά μου, την οποία ευχαριστώ για τη συνεχή στήριξη, την υπομονή και την ενθάρρυνσή της σε όλη τη διάρκεια των σπουδών μου.

Τέλος, ένα μεγάλο ευχαριστώ στους φίλους μου, στους συμφοιτητές μου και στα παιδιά με τα οποία μοιράστηκα τη στρατιωτική μου θητεία, για το κουράγιο και τη συμπαράσταση που μου έδειξαν, ο καθένας με τον δικό του τρόπο, σε δύσκολες και απαιτητικές περιόδους.

ΠΕΡΙΛΗΨΗ

Πρόβλεψη Τιμής και Φορτίου Ηλεκτρικής Ενέργειας στην Ελληνική Αγορά Επόμενης Ημέρας με Μεθόδους Μηχανικής Μάθησης

Η παρούσα διπλωματική εργασία εξετάζει τη βραχυπρόθεσμη πρόβλεψη τιμών της Αγοράς Επόμενης Ημέρας και ηλεκτρικού φορτίου στο ελληνικό σύστημα ηλεκτρικής ενέργειας με χρήση μεθόδων μηχανικής μάθησης. Στόχος είναι η συστηματική αξιολόγηση διαφορετικών στρατηγικών πρόβλεψης για ορίζοντα 24 ωρών και η διερεύνηση της συμπεριφοράς τους σε περιόδους αυξημένης μεταβλητότητας και μεταβολής κατανομής.

Για τον σκοπό αυτό κατασκευάζεται ενιαίο σύνολο δεδομένων από δημόσια διαθέσιμες πηγές, κυρίως την πλατφόρμα ENTSO-E Transparency, εμπλουτισμένο με χρονικές υστερήσεις, ημερολογιακές μεταβλητές και εξωγενείς παράγοντες. Συγκρίνονται τέσσερις στρατηγικές πρόβλεψης, Teacher-Forcing, Recursive, Multi-Input Multi-Output και Direct, σε δύο πλαίσια εκπαίδευσης, στατική εκπαίδευση και μηνιαία walk-forward επανεκπαίδευση. Η αξιολόγηση πραγματοποιείται για πέντε αλγορίθμους, LightGBM, XGBoost, Random Forest, SVR και MLP, με χρήση των δεικτών MAE, RMSE και sMAPE. Επιπλέον, εφαρμόζεται στατιστικός έλεγχος Diebold-Mariano με διόρθωση Harvey-Leybourne-Newbold, ενώ η ανάλυση σημαντικότητας χαρακτηριστικών και ένα διαδραστικό εργαλείο οπτικοποίησης χρησιμοποιούνται για την ερμηνεία και παρουσίαση των αποτελεσμάτων.

Τα αποτελέσματα δείχνουν ότι η μηνιαία walk-forward επανεκπαίδευση αποτελεί κρίσιμο παράγοντα απόδοσης σε εκτεταμένες περιόδους αξιολόγησης. Στο Q1 2026, το καλύτερο retrained LightGBM μοντέλο αναφοράς επιτυγχάνει MAE 10,46 €/MWh στην πρόβλεψη τιμής και 69,4 MW στην πρόβλεψη φορτίου, μειώνοντας το σφάλμα περίπου κατά 28% και 29% αντίστοιχα σε σχέση με τη στατική εκπαίδευση. Τα μοντέλα LightGBM και XGBoost εμφανίζουν την πιο σταθερή συνολική συμπεριφορά, ενώ το SVR παρουσιάζει μειωμένη ανθεκτικότητα σε περιόδους μεταβολής κατανομής. Το Teacher-Forcing λειτουργεί ως ιδεατό μοντέλο αναφοράς, χωρίς να είναι άμεσα εφαρμόσιμο στην πράξη, ενώ η Recursive στρατηγική με walk-forward επανεκπαίδευση αναδεικνύεται ως η πιο κατάλληλη επιλογή για επιχειρησιακή χρήση. Η ανάλυση σημαντικότητας χαρακτηριστικών δείχνει ότι η στρατηγική πρόβλεψης επηρεάζει καθοριστικά το είδος της πληροφορίας που αξιοποιείται από τα μοντέλα.

Συνολικά, η εργασία καταλήγει ότι η αξιόπιστη βραχυπρόθεσμη πρόβλεψη στην ελληνική αγορά δεν εξαρτάται αποκλειστικά από την επιλογή αλγορίθμου, αλλά από τον συνδυασμό κατάλληλης στρατηγικής πρόβλεψης, συστηματικής επανεκπαίδευσης και ερμηνεύσιμης αξιολόγησης χωρίς διαρροή πληροφορίας.

Keywords: electricity price forecasting, load forecasting, Greek Day-Ahead Market, machine learning, forecasting strategies, walk-forward retraining

ABSTRACT

Electricity Price and Load Forecasting in the Greek Day-Ahead Market with Machine Learning Methods

This diploma thesis examines short-term forecasting of Day-Ahead Market prices and electricity load in the Greek power system using machine learning methods. The objective is the systematic evaluation of different forecasting strategies for a 24-hour horizon and the investigation of their behavior during periods of increased volatility and distributional change.

For this purpose, a unified dataset is constructed from publicly available sources, primarily the ENTSO-E Transparency Platform, enriched with time lags, calendar variables and exogenous factors. Four forecasting strategies are compared, Teacher-Forcing, Recursive, Multi-Input Multi-Output and Direct, under two training frameworks, static training and monthly walk-forward retraining. The evaluation is carried out for five algorithms, LightGBM, XGBoost, Random Forest, SVR and MLP, using the MAE, RMSE and sMAPE metrics. In addition, the Diebold-Mariano statistical test with Harvey-Leybourne-Newbold correction is applied, while feature-importance analysis and an interactive visualization tool are used for the interpretation and presentation of the results.

The results show that monthly walk-forward retraining is a critical performance factor over extended evaluation periods. In Q1 2026, the best retrained LightGBM reference model achieves an MAE of 10.46 €/MWh for price forecasting and 69.4 MW for load forecasting, reducing the error by approximately 28% and 29%, respectively, compared with static training. LightGBM and XGBoost exhibit the most stable overall behavior, whereas SVR shows reduced robustness during periods of distributional change. Teacher-Forcing serves as an ideal reference model, without being directly applicable in practice, while the Recursive strategy with walk-forward retraining emerges as the most suitable option for operational use. The feature-importance analysis shows that the forecasting strategy decisively affects the type of information exploited by the models.

Overall, the thesis concludes that reliable short-term forecasting in the Greek electricity market does not depend solely on the choice of algorithm, but on the combination of an appropriate forecasting strategy, systematic retraining and interpretable evaluation without information leakage.

Keywords: electricity price forecasting, load forecasting, Greek Day-Ahead Market, machine learning, forecasting strategies, walk-forward retraining, LightGBM

Περιεχόμενα

Κατάλογος Ακρωνύμων	xiv
1 Εισαγωγή	1
1.1 Ενεργειακή Μετάβαση και Απελευθέρωση Αγορών Ηλεκτρικής Ενέργειας	1
1.2 Ο Ευρωπαϊκός Σχεδιασμός: Το Μοντέλο Στόχος	2
1.3 Η Ελληνική Αγορά Ηλεκτρικής Ενέργειας	3
1.4 Πρόβλεψη Τιμών Ηλεκτρικής Ενέργειας	5
1.5 Πρόβλεψη Ηλεκτρικού Φορτίου	6
1.6 Αλληλεπίδραση Τιμής και Φορτίου	7
1.7 Σκοπός και Ερευνητικά Ερωτήματα	7
1.8 Δομή της Εργασίας	8
2 Βιβλιογραφική Ανασκόπηση	10
2.1 Πρόβλεψη Τιμών Ηλεκτρικής Ενέργειας	10
2.1.1 Εξέλιξη πεδίου και βασικές ανασκοπήσεις	10
2.1.2 Κατηγορίες Μεθόδων Πρόβλεψης	10
2.1.3 Ο ρόλος εποχικής διόρθωσης	11
2.2 Πρόβλεψη Ηλεκτρικού Φορτίου	11
2.2.1 Ιστορική εξέλιξη	11
2.2.2 Κατηγοριοποίηση κατά Ορίζοντα	11
2.2.3 Στατιστικά Χαρακτηριστικά	11
2.3 Μοντέλα Αναφοράς (Naive Baselines)	12
2.4 Αλγόριθμοι Μηχανικής Μάθησης	12
2.4.1 Μέθοδοι Gradient Boosting	12
2.4.2 Support Vector Regression	13
2.4.3 Multi-Layer Perceptron (MLP)	14
2.5 Στρατηγικές Πολυβηματικής Πρόβλεψης	15
2.6 Scheduled Sampling	17
2.7 Walk-Forward Μηνιαία Επανεκπαίδευση	18
2.8 Σύνθεση και Τοποθέτηση της Παρούσας Εργασίας	19

3	Δεδομένα & Χαρακτηριστικά	20
3.1	Πηγές Ακατέργαστων Δεδομένων	20
3.1.1	Τιμές Αγοράς Επόμενης Ημέρας — ENTSO-E DAM	20
3.1.2	Πραγματικό Ηλεκτρικό Φορτίο — ENTSO-E	21
3.1.3	Πραγματική Παραγωγή ανά Τύπο Τεχνολογίας — ENTSO-E	21
3.1.4	Τιμή Φυσικού Αερίου — Dutch TTF Futures (Ημερήσια)	21
3.1.5	Τιμή Δικαιωμάτων CO ₂ — EU ETS Futures (Ημερήσια)	22
3.1.6	Προβλέψεις Παραγωγής Επόμενης Ημέρας — ENTSO-E Extra	22
3.1.7	Μετεωρολογικά Δεδομένα — Open-Meteo API	22
3.1.8	Πρόβλεψη Φορτίου Επόμενης Ημέρας (load_fc)	22
3.2	Κανονικοποίηση Χρονικού Δείκτη	22
3.3	Διοχέτευση Επεξεργασίας Δεδομένων	23
3.4	Μηχανική Χαρακτηριστικών	23
3.4.1	Ημερολογιακά Χαρακτηριστικά	23
3.4.2	Χρονικά Καθυστερημένα Χαρακτηριστικά	23
3.4.3	Κυλιόμενα Στατιστικά	24
3.4.4	Δείκτες Απόντων Τιμών	24
3.4.5	Αντιμετώπιση Διαρροής Δεδομένων	24
3.4.6	Πυκνές Ενδοημερήσιες Υστερήσεις (Dense Intraday Lags) — Μόνο για MIMO/Direct	25
3.4.7	Τελικός Πίνακας Χαρακτηριστικών	25
3.5	Κατασκευή Πίνακα Εκπαίδευσης	27
3.6	Χρονικός Διαχωρισμός Εκπαίδευσης / Αξιολόγησης	27
3.7	Περιγραφική Ανάλυση	27
3.7.1	Χρονοσειρά Τιμής Ηλεκτρικής Ενέργειας	27
3.7.2	Χρονοσειρά Ηλεκτρικού Φορτίου	28
3.7.3	Εποχιακή Εξέλιξη ανά Έτος	29
3.7.4	Ωριαία και Εβδομαδιαία Εποχικότητα	30
3.7.5	Αυτοσυσχέτιση και Επιλογή Υστερήσεων	32
3.7.6	Ενδοημερήσια Εξάρτηση Ημέρας D από D−1	33
3.7.7	Επίδραση Φυσικού Αερίου και Ανανεώσιμων Πηγών	35
3.7.8	Διαχωρισμός Εκπαίδευσης και Αξιολόγησης	36
4	Μεθοδολογία	38
4.1	Αλγόριθμοι Μηχανικής Μάθησης	38
4.1.1	LightGBM	38
4.1.2	XGBoost	38

4.1.3	Random Forest	38
4.1.4	Support Vector Regression	38
4.1.5	Multi-Layer Perceptron	39
4.2	Στρατηγικές Πρόβλεψης Ορίζοντα 24 Ωρών	39
4.2.1	Teacher-Forcing (TF)	40
4.2.2	Recursive (Rec)	40
4.2.3	MIMO (Multi-Input Multi-Output)	40
4.2.4	Direct Multistep	41
4.3	Scheduled Sampling	41
4.4	Βελτιστοποίηση Υπερπαραμέτρων με Optuna	42
4.5	Ensembles	43
4.6	Μετρικές Αξιολόγησης	44
4.7	Βασικές Αναφορές (Baselines)	44
5	Εργαλείο Οπτικοποίησης	45
5.1	Συνολική Όψη της Εφαρμογής	45
5.2	Τυπική Ροή Χρήσης	46
5.3	Σύνοψη	47
6	Αποτελέσματα Αξιολόγησης	50
6.1	Ρύθμιση Πειραμάτων	50
6.2	Στατική Εκπαίδευση: Δεκέμβριος 2025	51
6.2.1	Teacher-Forcing (TF)	52
6.2.2	Recursive (Rec)	53
6.2.3	MIMO και Direct	54
6.2.4	Συνολική Σύνοψη Στατικής Αξιολόγησης	55
6.3	Walk-Forward Μηνιαία Επανεκπαίδευση, Q1 2026	57
6.3.1	Αποτελέσματα Στρατηγικής Teacher-Forcing (TF) Walk-Forward	58
6.3.2	Ανάλυση Μεταβολής Καθεστώτος	59
6.3.3	Αντίκτυπος Επανεκπαίδευσης	60
6.4	Συγκριτική Αξιολόγηση Στρατηγικών Πρόβλεψης	63
6.4.1	Στατιστική Κατανομή και Μεροληψία Σφαλμάτων	64
6.4.2	Χρονικές και Κυκλικές Συνθήκες Πρόβλεψης	65
6.4.3	Ανθεκτικότητα σε Ακραίες Συνθήκες Αιχμής (Spikes)	68
6.5	Στατιστική Επικύρωση των Προβλέψεων (Diebold-Mariano)	72
6.6	Σύγκριση με Σχετικές Εργασίες	73
6.6.1	Μεθοδολογική ευθυγράμμιση με την ελληνική αγορά	73

6.6.2	Αναδρομική πρόβλεψη και η θεωρία συσσώρευσης σφάλματος	74
6.6.3	Επανεκπαίδευση και μεταβολή καθεστώτος	74
6.6.4	Πολυπλοκότητα μοντέλου και αξία των συνδυαστικών μετρικών	75
6.7	Σύνοψη Αποτελεσμάτων και Συμπεράσματα	75
7	Ανάλυση Σημαντικότητας Χαρακτηριστικών	76
7.1	Μεθοδολογικό Πλαίσιο και Μαθηματική Θεμελίωση	76
7.1.1	Πρωτόκολλο Επεξεργασίας και Παραγωγής Αποτελεσμάτων	77
7.2	Teacher-Forcing και Recursive	77
7.3	MIMO και Direct	79
7.4	Συνολική εικόνα ανά στρατηγική	82
7.5	Κατηγοριοποίηση χαρακτηριστικών	83
7.6	Σύνθεση και συμπεράσματα	85
8	Συμπεράσματα	87
8.1	Σύνοψη Κύριων Ευρημάτων	87
8.2	Συνεισφορές της Εργασίας	89
8.3	Περιορισμοί	89
8.4	Μελλοντική Έρευνα	89
8.5	Κλείσιμο	90

Κατάλογος σχημάτων

1.1	Χρονική ακολουθία αγορών ηλεκτρισμού (D-2/D-1/D). Τα μοντέλα ML υποβάλλουν προβλέψεις στον ορίζοντα D-1 πριν την κλεισίδωση της DAM στις 12:00 CET. Η Αγορά Εξισορρόπησης (ΔΕΠ) λειτουργεί σε πραγματικό χρόνο κατά την D.	4
2.1	Σχηματική αναπαράσταση του αλγόριθμου Random Forest: B δέντρα εκπαιδεύονται σε bootstrap δείγματα και η τελική πρόβλεψη προκύπτει ως ο μέσος όρος τους.	13
2.2	Σύγκριση <i>level-wise</i> (XGBoost) και <i>leaf-wise</i> (LightGBM) στρατηγικής ανάπτυξης δέντρου.	14
2.3	Ο «σωλήνας ανοχής» (ε -tube) της SVR. Τα δείγματα εντός του σωλήνα δεν συνεισφέρουν στην αντικειμενική συνάρτηση, μόνο τα δείγματα εκτός (μεταβλητές χαλαρότητας ξ_i, ξ_i^*) τιμωρούνται.	15
2.4	Αρχιτεκτονική MLP με κρυφά στρώματα. Κάθε κόμβος στρώματος l δέχεται τις εξόδους του στρώματος $l - 1$ και εφαρμόζει τον μετασχηματισμό της εξίσωσης 2.8.	16
2.5	Στρατηγικές πολυβηματικής πρόβλεψης. Αριστερά: η γενική ταξινόμηση της βιβλιογραφίας [1], με τις βασικές στρατηγικές (Recursive, Direct, MIMO) και τις υβριδικές παραλλαγές (DirRec, DIRMO). Δεξιά: οι τέσσερις στρατηγικές που αξιολογούνται στην παρούσα εργασία: Teacher-Forcing (TF) , Recursive (Rec) , Direct και MIMO	17
3.1	Διοχέτευση επεξεργασίας δεδομένων πέντε φάσεων: από τις οκτώ ακατέργαστες πηγές (αριστερά) στους δύο τελικούς πίνακες χαρακτηριστικών (δεξιά).	26
3.2	Ωριαία τιμή ηλεκτρικής ενέργειας (€/MWh) στην ελληνική αγορά (Ιαν. 2017 - Μαρ. 2026). Πάνω: ωριαίες τιμές (μπλε) και 30-ήμερος κυλιόμενος μέσος (κόκκινος)· κίτρινη σκίαση για την περίοδο ενεργειακής κρίσης 2021-2022 και πράσινη για τα lockdown COVID-19. Κάτω: μηνιαία κατανομή τιμών (boxplots) για ολόκληρη την περίοδο.	28
3.3	Ωριαίο ηλεκτρικό φορτίο (MW) στην ελληνική αγορά (Ιαν. 2017 - Νοεμ. 2025). Πάνω: ωριαίο φορτίο (πορτοκαλί) και 30-ήμερος κυλιόμενος μέσος (κόκκινος)· πράσινη σκίαση για τα lockdown COVID-19. Κάτω: μηνιαία κατανομή φορτίου (boxplots) για ολόκληρη την περίοδο.	29
3.4	Μηνιαία μέση τιμή ηλεκτρικής ενέργειας (πάνω) και φορτίου (κάτω) ανά έτος (2017-2025). Κάθε γραμμή αντιστοιχεί σε ένα ημερολογιακό έτος· τα έτη 2021-2022 σχεδιάζονται με έντονη γραμμή.	30
3.5	Ενδοημερήσια μοτίβα τιμής ΗΑ. Πάνω: μέσο ωριαίο προφίλ ανά εποχή· κάτω αριστερά: μέσο ωριαίο προφίλ ανά ημέρα εβδομάδας (εργάσιμες μπλε, Σαββατοκύριακο πορτοκαλί)· κάτω δεξιά: θερμικός χάρτης μέσης τιμής (ημέρα εβδομάδας $\times$ ώρα).	31

3.6	Ενδοημερήσια μοτίβα ηλεκτρικού φορτίου, με ίδια διάταξη όπως η τιμή (Σχ. 3.5). Πάνω: προφίλ ανά εποχή· κάτω αριστερά: προφίλ ανά ημέρα εβδομάδας· κάτω δεξιά: θερμικός χάρτης μέσου φορτίου (ημέρα εβδομάδας $\times$ ώρα).	32
3.7	Συνάρτηση αυτοσυσχέτισης (ACF, αριστερά) και μερικής αυτοσυσχέτισης (PACF, δεξιά) της ωριαίας τιμής HA για lags 1-168 ώρες. Οι κατακόρυφες διακεκομμένες γραμμές σημειώνουν τα lag-24, 48 και 168.	33
3.8	Συνάρτηση αυτοσυσχέτισης (ACF, αριστερά) και μερικής αυτοσυσχέτισης (PACF, δεξιά) του ωριαίου ηλεκτρικού φορτίου για lags 1-168 ώρες. Οι κατακόρυφες διακεκομμένες γραμμές σημειώνουν τα lag-24, 48 και 168.	33
3.9	Χάρτης Pearson ενδοημερήσιας συσχέτισης (24×24) μεταξύ ώρας h ημέρας D και ώρας l ημέρας $D - 1$ για την τιμή HA (2017-2025). Οι ισοϋψείς γραμμές σημειώνουν τα $r = 0,7$ και $r = 0,9$	34
3.10	Χάρτης Pearson ενδοημερήσιας συσχέτισης (24×24) μεταξύ ώρας h ημέρας D και ώρας l ημέρας $D - 1$ για το ηλεκτρικό φορτίο (2017-2025). Η κλίμακα χρωμάτων είναι ανεξάρτητη, προσαρμοσμένη στο υψηλότερο εύρος συσχέτισης του φορτίου (πρβλ. Σχ. 3.9).	35
3.11	Αριστερά: διάγραμμα διασποράς ημερήσιας μέσης τιμής HA έναντι τιμής φυσικού αερίου TTF (2017-2025), χρωματισμένο ανά έτος, με προσαρμογή OLS (κόκκινη γραμμή) και αναγραφή της κλίσης της. Δεξιά: χρονοσειρά τιμής HA και τιμής αερίου με διπλό κατακόρυφο άξονα, που αναδεικνύει τη συγχρονισμένη εξέλιξή τους. . . .	36
3.12	Χρονικός διαχωρισμός εκπαίδευσης (Ιαν. 2017 - Νοεμ. 2025) και αξιολόγησης (κόκκινο, Δεκ. 2025 - Φεβ. 2026), για την τιμή (πάνω) και το φορτίο (κάτω).	37
4.1	Πρόγραμμα Scheduled Sampling: η πιθανότητα ε χρήσης προβλεπόμενης τιμής αντί πραγματικής αυξάνει γραμμικά από 0,10 έως 0,40 σε τρία περάσματα εκπαίδευσης, υλοποιώντας τη μετάβαση teacher-forcing $\rightarrow$ autoregressive (βλ. Εξ. 4.7).	42
5.1	Συνολική όψη του dashboard με τις τέσσερις ζώνες: (1) πίνακας ελέγχου, (2) γράφημα χρονοσειράς, (3) πίνακες μετρικών, (4) συγκεντρωτικός πίνακας κατάταξης. . .	46
5.2	Ο πίνακας ελέγχου σε μεγέθυνση.	46
5.3	Τρεις προβολές της εφαρμογής για διαφορετικούς συνδυασμούς εργασίας, στρατηγικής, περιόδου και φίλτρου.	48
5.4	Δύο λειτουργίες λεπτομερούς ανάγνωσης: (α) το tooltip του hover για ένα χρονικό βήμα και (β) ο επιλογέας ημερομηνίας για μια υποπερίοδο.	49
5.5	Πίνακες μετρικών: επάνω οι αυτόνομες κατατάξεις των μοντέλων μηχανικής μάθησης (αριστερά) και των μοντέλων αναφοράς (δεξιά), και κάτω ο ενιαίος συγκεντρωτικός πίνακας όλων των μοντέλων, με επιλογέα ταξινόμησης Sort by.	49
6.1	Στατική εκπαίδευση, Δεκέμβριος 2025: καλύτερο MAE ανά στρατηγική για την τιμή DAM.	56
6.2	Στατική εκπαίδευση, Δεκέμβριος 2025: καλύτερο MAE ανά στρατηγική για το ηλεκτρικό φορτίο.	57
6.3	Μεταβολή καθεστώτος Q1 2026: κυλιόμενος μέσος και κυλιόμενη μεταβλητότητα 30 ημερών του πραγματικού σήματος, Τιμή DAM (€/MWh).	59

6.4	Μεταβολή καθεστώτος Q1 2026: κυλιόμενος μέσος και κυλιόμενη μεταβλητότητα 30 ημερών του πραγματικού σήματος, Ηλεκτρικό φορτίο (MW).	60
6.5	Μηνιαία ανάλυση MAE στην τιμή DAM: Στατική εκπαίδευση έναντι Walk-Forward Monthly Retrain, Q1 2026.	61
6.6	Μηνιαία ανάλυση MAE στο ηλεκτρικό φορτίο: Στατική εκπαίδευση έναντι Walk-Forward Monthly Retrain, Q1 2026.	62
6.7	Συνολική διαφορά επίδοσης (Walk-Forward vs Static) ανά στρατηγική στην τιμή DAM, Q1 2026.	62
6.8	Συνολική διαφορά επίδοσης (Walk-Forward vs Static) ανά στρατηγική στο ηλεκτρικό φορτίο, Q1 2026.	63
6.9	Κατανομή απόλυτων σφαλμάτων πρόβλεψης στην τιμή DAM, Q1 2026.	64
6.10	Κατανομή απόλυτων σφαλμάτων πρόβλεψης στο ηλεκτρικό φορτίο, Q1 2026.	65
6.11	Προφίλ ωριαίας μεροληψίας (Bias) στην τιμή DAM, Q1 2026. Θετικές τιμές υποδηλώνουν υποεκτίμηση και αρνητικές τιμές υπερεκτίμηση.	66
6.12	Προφίλ ωριαίας μεροληψίας (Bias) στο ηλεκτρικό φορτίο, Q1 2026. Θετικές τιμές υποδηλώνουν υποεκτίμηση και αρνητικές τιμές υπερεκτίμηση.	66
6.13	Ωριαίο προφίλ σφάλματος (Hourly MAE) στην τιμή DAM, Q1 2026.	67
6.14	Ωριαίο προφίλ σφάλματος (Hourly MAE) στο ηλεκτρικό φορτίο, Q1 2026.	68
6.15	Χρονική κατανομή και εντοπισμός των ακραίων εξάρσεων (spikes) της τιμής DAM, Q1 2026.	69
6.16	Ποσοστό αστοχίας (Miss Rate) των μοντέλων κατά τις ώρες αιχμής της τιμής DAM.	69
6.17	Χρονική συγκέντρωση των ακραίων εξάρσεων (spikes) του ηλεκτρικού φορτίου, Q1 2026.	70
6.18	Ποσοστό αστοχίας (Miss Rate) των μοντέλων κατά τις ώρες ακραίου ηλεκτρικού φορτίου.	70
6.19	Πραγματική απόκριση των στρατηγικών πρόβλεψης κατά τη διάρκεια ενός επεισοδίου έξαρσης (spike) της τιμής DAM.	71
6.20	Πραγματική απόκριση των στρατηγικών πρόβλεψης κατά τη διάρκεια ενός επεισοδίου αιχμής του ηλεκτρικού φορτίου.	71
6.21	Κατάταξη μοντέλων βάσει στατιστικά σημαντικών νικών DM-HLN ($p < 0,05$) έναντι των υπολοίπων, τιμή DAM, Q1 2026.	72
6.22	Κατάταξη μοντέλων βάσει στατιστικά σημαντικών νικών DM-HLN ($p < 0,05$) έναντι των υπολοίπων, ηλεκτρικό φορτίο, Q1 2026.	73
7.1	Σημαντικότητα ανά μοντέλο: Teacher-Forcing, τιμή	78
7.2	Σημαντικότητα ανά μοντέλο: Recursive, τιμή	78
7.3	Σημαντικότητα ανά μοντέλο: Teacher-Forcing, φορτίο	79
7.4	Σημαντικότητα ανά μοντέλο: Recursive, φορτίο	80
7.5	Σημαντικότητα ανά μοντέλο: MIMO, τιμή	80
7.6	Σημαντικότητα ανά μοντέλο: Direct, τιμή	81
7.7	Σημαντικότητα ανά μοντέλο: MIMO, φορτίο	82

7.8	Σημαντικότητα ανά μοντέλο: Direct, φορτίο	83
7.9	Σημαντικότητα ανά στρατηγική, τιμή	84
7.10	Σημαντικότητα ανά στρατηγική, φορτίο	84

Κατάλογος πινάκων

2.1	Αντιπροσωπευτικές εργασίες EPF/ELF και τοποθέτηση της παρούσας εργασίας. . . .	19
3.1	Πηγές ακατέργαστων δεδομένων.	20
3.2	Σύνολα υστερήσεων ανά σήμα.	24
3.3	Επεξεργασμένα αρχεία Parquet μετά τη φάση 5 του αγωγού.	25
3.4	Ομάδες χαρακτηριστικών, αριθμός μεταβλητών ανά εργασία.	26
4.1	Συγκριτική παρουσίαση των τεσσάρων στρατηγικών πρόβλεψης $H = 24$ ωρών. . .	39
4.2	Εύρη αναζήτησης υπερπαραμέτρων (Optuna) και βέλτιστες τιμές για το καλύτερο μοντέλο κάθε αλγόριθμου (εργασία τιμής, TF/Rec στρατηγική).	42
5.1	Πίνακας αναφοράς χειριστηρίων του dashboard.	47
6.1	Επίδοση μοντέλων αναφοράς (benchmarks) για την τιμή DAM και το ηλεκτρικό φορτίο, μηνιαία αξιολόγηση.	51
6.2	TF, πρόβλεψη τιμής, Δεκέμβριος 2025 (744h).	52
6.3	TF, πρόβλεψη φορτίου, Δεκέμβριος 2025 (744h).	52
6.4	Rec $H = 24$, πρόβλεψη τιμής, Δεκέμβριος 2025 (31 ημερήσια τμήματα).	53
6.5	Rec $H = 24$, πρόβλεψη φορτίου, Δεκέμβριος 2025 (31 ημερήσια τμήματα).	53
6.6	MIMO $H = 24$, πρόβλεψη τιμής, Δεκέμβριος 2025.	54
6.7	MIMO $H = 24$, πρόβλεψη φορτίου, Δεκέμβριος 2025. Το † δηλώνει μοντέλο που εξαιρείται λόγω αστοχίας.	54
6.8	Direct $H = 24$, πρόβλεψη τιμής, Δεκέμβριος 2025.	55
6.9	Direct $H = 24$, πρόβλεψη φορτίου, Δεκέμβριος 2025.	55
6.10	Στατική εκπαίδευση, Δεκέμβριος 2025: καλύτερο μοντέλο ανά στρατηγική για την τιμή DAM.	55
6.11	Στατική εκπαίδευση, Δεκέμβριος 2025: καλύτερο μοντέλο ανά στρατηγική για το ηλεκτρικό φορτίο.	56
6.12	Walk-forward TF, πρόβλεψη τιμής DAM, Q1 2026 (2.160h).	58
6.13	Walk-forward TF, πρόβλεψη ηλεκτρικού φορτίου, Q1 2026 (2.160h).	58
6.14	Walk-forward μηνιαία επανεκπαίδευση, Q1 2026 (2.160h): καλύτερο μοντέλο ανά στρατηγική για τιμή DAM και φορτίο.	61

8.1	Σύγκριση στρατηγικών Q1 2026 στον επιχειρησιακό ορίζοντα $H=24$ (ημερήσια δημοπρασία DAM).	87
-----	--	----

Κατάλογος Ακρωνύμων

ACF Autocorrelation Function
API Application Programming Interface
ARIMA Autoregressive Integrated Moving Average
BZN|GR Bidding Zone Greece
CET Central European Time
CNN Convolutional Neural Network
CO₂ Carbon Dioxide
CSS Cascading Style Sheets
CSV Comma-Separated Values
CV Cross-Validation
DAM Day-Ahead Market
Direct Direct Multistep
DM Diebold-Mariano
ELF Electricity Load Forecasting
ENTSO-E European Network of Transmission System Operators for Electricity
EPF Electricity Price Forecasting
EU ETS European Union Emissions Trading System
EUA European Union Allowance
FDR False Discovery Rate
FWER Family-Wise Error Rate
GARCH Generalized Autoregressive Conditional Heteroskedasticity
GOSS Gradient-based One-Side Sampling
GRU Gated Recurrent Unit
HAC Heteroskedasticity and Autocorrelation Consistent
HEnEx Hellenic Energy Exchange
HLN Harvey-Leybourne-Newbold
HTML HyperText Markup Language
IEA International Energy Agency
IQR Interquartile Range
LightGBM Light Gradient Boosting Machine
LSTM Long Short-Term Memory
LTLF Long-Term Load Forecasting
MAE Mean Absolute Error
MDI Mean Decrease Impurity
MIMO Multi-Input Multi-Output
ML Machine Learning
MLP Multi-Layer Perceptron
MR Monthly Retraining
MSE Mean Squared Error
MTLF Medium-Term Load Forecasting
MW Megawatt
MWh Megawatt-hour
NaN Not a Number

NaT Not a Time
NN Neural Networks
OLS Ordinary Least Squares
PACF Partial Autocorrelation Function
RBF Radial Basis Function
Rec Recursive
ReLU Rectified Linear Unit
RES Renewable Energy Sources
RF Random Forest
RMSE Root Mean Squared Error
RNN Recurrent Neural Network
SARIMA Seasonal Autoregressive Integrated Moving Average
SDAC Single Day-Ahead Coupling
SIDC Single Intraday Coupling
sMAPE symmetric Mean Absolute Percentage Error
SS Scheduled Sampling
STLF Short-Term Load Forecasting
SVM Support Vector Machine
SVR Support Vector Regression
TF Teacher-Forcing
TPE Tree-structured Parzen Estimator
TSO Transmission System Operator
TTF Title Transfer Facility
UTC Coordinated Universal Time
VAR Vector Autoregression
VSTLF Very Short-Term Load Forecasting
WF Walk-Forward
XGB eXtreme Gradient Boosting
ΑΔΜΗΕ Ανεξάρτητος Διαχειριστής Μεταφοράς Ηλεκτρικής Ενέργειας
ΑΠΕ Ανανεώσιμες Πηγές Ενέργειας
ΔΑΠΕΕΠ Διαχειριστής ΑΠΕ και Εγγυήσεων Προέλευσης
ΔΕΗ Δημόσια Επιχείρηση Ηλεκτρισμού
ΔΕΠ Αγορά Εξισορρόπησης
ΕΣΜΗΕ Εθνικό Σύστημα Μεταφοράς Ηλεκτρικής Ενέργειας
ΗΕΠ Ημερήσιος Ενεργειακός Προγραμματισμός
ΡΑΑΕΥ Ρυθμιστική Αρχή Αποβλήτων, Ενέργειας και Υδάτων
ΣΠΕΔ Ενδοημερήσιοι Κύκλοι Αγοράς

1. Εισαγωγή

1.1 Ενεργειακή Μετάβαση και Απελευθέρωση Αγορών Ηλεκτρικής Ενέργειας

Η ηλεκτρική ενέργεια είναι ο κινητήριος άξονας της σύγχρονης κοινωνίας: από τη βιομηχανική παραγωγή και τις μεταφορές ως τις υπηρεσίες υγείας και τις τηλεπικοινωνίες, ελάχιστες πτυχές της ανθρώπινης δραστηριότητας λειτουργούν σήμερα χωρίς αξιόπιστη και οικονομικά προσιτή ηλεκτρική ενέργεια. Παράλληλα, ο ενεργειακός τομέας διέρχεται μια περίοδο αναδιάρθρωσης: η κλιματική κρίση, η ωρίμανση των Ανανεώσιμων Πηγών Ενέργειας (Renewable Energy Sources, RES) και η ψηφιοποίηση της οικονομίας τον μετασχηματίζουν.

Αυτή η μεταμόρφωση συνοψίζεται συχνά με τον όρο *τριπλή μετάβαση* ή *τρία D's*: *Απορρύθμιση* (Deregulation), *Αποανθρακοποίηση* (Decarbonization) και *Αποκέντρωση* (Decentralization) [2]. Οι τρεις αυτές δυνάμεις λειτουργούν ταυτόχρονα και αλληλεπιδρούν, διαμορφώνοντας ένα τοπίο ολοένα και πιο πολύπλοκο για τους συμμετέχοντες στην αγορά ηλεκτρισμού.

Η *Απορρύθμιση* αναφέρεται στη μακρά διαδικασία απομάκρυνσης από τα κλασικά μονοπωλιακά μοντέλα προς αγορές με ελεύθερο ανταγωνισμό. Το παραδοσιακό μοντέλο, που επικρατούσε παγκοσμίως για το μεγαλύτερο μέρος του 20ού αιώνα, βασιζόταν σε κάθετα ολοκληρωμένες επιχειρήσεις που ελέγχαν την παραγωγή, μεταφορά, διανομή και λιανική πώληση ηλεκτρισμού. Αυτό το μοντέλο, αν και εξασφάλιζε σταθερότητα, δεν δημιουργούσε κίνητρα για αποδοτικότητα και καινοτομία.

Η πρώτη μεγάλη ρήξη με αυτό το πρότυπο συνέβη στο Ηνωμένο Βασίλειο το 1990, όταν τέθηκε σε λειτουργία η *England and Wales Electricity Pool* και άρχισε η απελευθέρωση της αγοράς ηλεκτρισμού [2]. Λίγο αργότερα, η Νορβηγία εισήγαγε το μοντέλο της NordPool, μιας ανεξάρτητης χρηματιστηριακής αγοράς που είναι σήμερα πρότυπο αναφοράς για όλη την Ευρώπη. Στον ευρωπαϊκό χώρο, η θεσμική αφετηρία υπήρξε η Οδηγία 1996/92/EK για τους κοινούς κανόνες στην εσωτερική αγορά ηλεκτρισμού, η οποία δρομολόγησε τον σταδιακό διαχωρισμό (unbundling) των δικτύων μεταφοράς από τις παραγωγικές και εμπορικές δραστηριότητες. Η Οδηγία 2003/54/EK επέβαλε αυστηρότερο unbundling και επιτάχυνε το άνοιγμα της αγοράς, ενώ η Οδηγία 2009/72/EK (τρίτο ενεργειακό πακέτο) επέκτεινε τη ρύθμιση και έθεσε τις βάσεις για την ευρωπαϊκή ενοποίηση αγορών [3].

Ένας θεμελιώδης διαχωρισμός στη μορφή των απελευθερωμένων αγορών είναι αυτός μεταξύ *Power Pool* (Αγορά Υποχρεωτικής Κοινοπραξίας) και *Power Exchange* (Χρηματιστήριο Ηλεκτρικής Ενέργειας). Στο μοντέλο Power Exchange, η αγορά λειτουργεί ως χρηματιστήριο: οι συμμετέχοντες υποβάλλουν εθελοντικές προσφορές αγοράς και πώλησης ενέργειας, η τιμή διαμορφώνεται από την ισορροπία προσφοράς-ζήτησης και επιτρέπονται διεθνείς συναλλαγές και παράγωγα χρηματοοικονομικά προϊόντα. Το τελευταίο μοντέλο επικρατεί στις σύγχρονες ευρωπαϊκές αγορές.

Η *Αποανθρακοποίηση* συνιστά τον δεύτερο πυλώνα της μετάβασης και αντανakλά την αποφασιστικότητα των ευρωπαϊκών κυβερνήσεων να μειώσουν τις εκπομπές άνθρακα του ενεργειακού τομέα. Στόχοι όπως το «Fit for 55» της ΕΕ και το πλαίσιο της Συμφωνίας του Παρισιού επιβάλλουν μεγάλη αύξηση του μεριδίου των ΑΠΕ και μείωση των ορυκτών καυσίμων. Οι ΑΠΕ, και ιδίως η ηλιακή και αιολική ενέργεια, χαρακτηρίζονται από μηδενικό οριακό κόστος παραγωγής, αλλά εισάγουν αβεβαιότητα και μεταβλητότητα στο σύστημα λόγω της εξάρτησής τους από τις καιρικές συνθήκες.

Αυτό καθιστά την πρόβλεψη τόσο της παραγωγής όσο και της τιμής ηλεκτρισμού πιο κρίσιμη.

Η *Αποκέντρωση* αφορά τη γεωγραφική και θεσμική κατανομή της παραγωγής ενέργειας: η ανάπτυξη κατανεμημένης παραγωγής (Distributed Generation), τα νέα εργοστάσια ΑΠΕ μικρότερης κλίμακας, τα συστήματα αποθήκευσης και οι «ενεργειακές κοινότητες» μετατρέπουν ένα σύστημα που παλιά ήταν ιεραρχικό και κεντρικό σε ένα δίκτυο ευέλικτων, κατανεμημένων κόμβων. Αυτή η αλλαγή θέτει νέες προκλήσεις στη διαχείριση φορτίου και στη σταθερότητα του δικτύου.

1.2 Ο Ευρωπαϊκός Σχεδιασμός: Το Μοντέλο Στόχος

Απέναντι στις προκλήσεις της μετάβασης, η Ευρωπαϊκή Ένωση ανέπτυξε ένα ολοκληρωμένο ρυθμιστικό πλαίσιο για τις αγορές ηλεκτρισμού, γνωστό ως *Ευρωπαϊκό Μοντέλο Στόχος* (European Target Model). Βασισμένο στις αρχές της φιλελευθεροποίησης, της ενοποίησης αγορών και της αποδοτικής κατανομής πόρων, το Μοντέλο Στόχος ορίζει τέσσερα επίπεδα αγοράς που λειτουργούν σε διαδοχικές χρονικές βαθμίδες: την *Προθεσμιακή Αγορά*, την *Αγορά Επόμενης Ημέρας*, την *Ενδοημερήσια Αγορά* και την *Αγορά Εξισορρόπησης* [4].

Προθεσμιακή Αγορά Η Προθεσμιακή Αγορά (Forward Market) λειτουργεί σε χρονικό ορίζοντα εβδομάδων, μηνών ή ετών πριν από την πραγματική παράδοση της ενέργειας. Ο κεντρικός της σκοπός δεν είναι η φυσική παράδοση ηλεκτρισμού, αλλά η παροχή εργαλείων *αντιστάθμισης κινδύνου* (hedging) στους συμμετέχοντες. Παραγωγοί και καταναλωτές μπορούν να κλειδώσουν τιμές για μελλοντικές περιόδους, προστατεύοντας τον εαυτό τους από την τιμολογιακή αβεβαιότητα.

Αγορά Επόμενης Ημέρας Η Αγορά Επόμενης Ημέρας (Day-Ahead Market (DAM)) είναι ο κεντρικός μηχανισμός του Μοντέλου Στόχος. Κάθε ημέρα, συνήθως μέχρι το μεσημέρι, οι συμμετέχοντες υποβάλλουν προσφορές πώλησης και αγοράς ηλεκτρικής ενέργειας για κάθε μια από τις 24 ώρες της επόμενης ημέρας. Ο αλγόριθμος εκκαθάρισης αγοράς EUPHEMIA επιλύει ταυτόχρονα τις αγορές όλων των συζευγμένων χωρών, κατανέμοντας αποδοτικά τη συνολική προσφορά και ζήτηση και λαμβάνοντας υπόψη τις διαθέσιμες διασυνδέσεις μεταξύ ζωνών ισορροπίας [5]. Η τιμή εκκαθάρισης που προκύπτει για κάθε χώρα και κάθε ώρα, η *Market Clearing Price* ή *Spot Price*, είναι ο βασικός δείκτης τιμής ηλεκτρισμού και το αντικείμενο μελέτης της παρούσας εργασίας.

Η ευρωπαϊκή ζεύξη αγορών επόμενης ημέρας υλοποιείται μέσω του μηχανισμού Single Day-Ahead Coupling (SDAC), που είναι κεντρικός θεσμός του Μοντέλου Στόχος. Μέσω του SDAC, οι εθνικές αγορές επόμενης ημέρας χωρών-μελών της ΕΕ και γειτονικών χωρών εκκαθαρίζονται ταυτόχρονα από έναν κοινό αλγόριθμο, με αποτέλεσμα οι τιμές να συγκλίνουν στον βαθμό που επιτρέπουν οι διασυνδέσεις [4].

Ενδοημερήσια Αγορά Η Ενδοημερήσια Αγορά (Intraday Market) λειτουργεί μετά την εκκαθάριση της αγοράς επόμενης ημέρας και επιτρέπει στους συμμετέχοντες να αναπροσαρμόζουν τις θέσεις τους καθ' όλη τη διάρκεια της ίδιας ημέρας, μέχρι το κλείσιμο των πυλών (gate closure). Αυτό είναι σημαντικό για τη διαχείριση αποκλίσεων που προκύπτουν από αλλαγές στη διαθεσιμότητα μονάδων παραγωγής, διορθωμένες προβλέψεις για παραγωγή ΑΠΕ ή απρόσμενες διακυμάνσεις φορτίου. Η ευρωπαϊκή ζεύξη ενδοημερήσιων αγορών υλοποιείται μέσω του Single Intraday Coupling (SIDC) [4].

Αγορά Εξισορρόπησης Η Αγορά Εξισορρόπησης (Balancing Market) λειτουργεί σε πραγματικό χρόνο και είναι αποκλειστικά στην αρμοδιότητα του Διαχειριστή Συστήματος Μεταφοράς (Transmission System Operator (TSO)). Στόχος της είναι η διατήρηση της ισορροπίας μεταξύ

παραγωγής και κατανάλωσης: αν κάποια μονάδα παραγωγής βγει εκτός λειτουργίας απρόσμενα ή το φορτίο αποκλίνει από την πρόβλεψη, ο διαχειριστής επεμβαίνει χρησιμοποιώντας εφεδρικές μονάδες ισορρόπησης [6].

1.3 Η Ελληνική Αγορά Ηλεκτρικής Ενέργειας

Η ελληνική αγορά ηλεκτρικής ενέργειας πέρασε τις τελευταίες τρεις δεκαετίες από δομικές μεταρρυθμίσεις που άλλαξαν τον τρόπο λειτουργίας της. Η μετάβαση από ένα σύστημα πλήρους κρατικής ιδιοκτησίας, με τη Δημόσια Επιχείρηση Ηλεκτρισμού (ΔΕΗ) στον κεντρικό ρόλο, σε ένα χρηματιστηριακό μοντέλο ενταγμένο στο ευρωπαϊκό πλαίσιο απαίτησε σημαντικές θεσμικές και επιχειρησιακές αλλαγές

Θεσμικό Πλαίσιο: ΡΑΑΕΥ Η Ρυθμιστική Αρχή Αποβλήτων, Ενέργειας και Υδάτων (ΡΑΑΕΥ) είναι η ανεξάρτητη ρυθμιστική αρχή της ελληνικής αγοράς ηλεκτρικής ενέργειας και φυσικού αερίου [7]. Ο βασικός ρόλος της είναι να εξασφαλίζει τον αποτελεσματικό ανταγωνισμό στην αγορά ενέργειας, να προστατεύει τα συμφέροντα των καταναλωτών, να εγκρίνει τιμολόγια πρόσβασης στα δίκτυα και να εποπτεύει τη συμμόρφωση με τους κανόνες λειτουργίας.

Διαχείριση Συστήματος Μεταφοράς: ΑΔΜΗΕ Ο Ανεξάρτητος Διαχειριστής Μεταφοράς Ηλεκτρικής Ενέργειας (ΑΔΜΗΕ) είναι ο Διαχειριστής του Ελληνικού Συστήματος Μεταφοράς Ηλεκτρικής Ενέργειας. Ιδρύθηκε το 2012 στο πλαίσιο της υποχρεωτικής απόσχισης δικτύων μεταφοράς από παραγωγικές δραστηριότητες που επέβαλε το τρίτο ευρωπαϊκό ενεργειακό πακέτο [6]. Ο ΑΔΜΗΕ είναι υπεύθυνος για τη λειτουργία, συντήρηση και ανάπτυξη του Εθνικού Συστήματος Μεταφοράς Ηλεκτρικής Ενέργειας (ΕΣΜΗΕ), εκτελώντας τις αρμοδιότητές του σε θέματα ισορρόπησης του συστήματος, διαχείρισης συμφόρησης διασυνδέσεων, παρακολούθησης της επάρκειας παραγωγής και δημοσίευσης προβλέψεων φορτίου και ΑΠΕ για την επόμενη ημέρα. Η εκτίμηση φορτίου που δημοσιεύει ο ΑΔΜΗΕ κάθε πρωί, πριν από την υποβολή προσφορών στην αγορά επόμενης ημέρας, είναι σημαντικό δεδομένο εισόδου για τα μοντέλα τιμής: μια πληροφορία που είναι τυπικά διαθέσιμη πριν από τις αποφάσεις αγοράς και δεν δημιουργεί πρόβλημα διαρροής δεδομένων.


Λειτουργία Αγοράς: ΔΑΠΕΕΠ και ΗEnEx Ο Διαχειριστής ΑΠΕ και Εγγυήσεων Προέλευσης (ΔΑΠΕΕΠ) ήταν ο φορέας διαχείρισης της ελληνικής αγοράς ηλεκτρισμού για πολλά χρόνια, λειτουργώντας κυρίως ως εκκαθαριστής του Ημερήσιου Ενεργειακού Προγραμματισμού (ΗΕΠ) στο παλαιότερο μοντέλο αγοράς Pool. Με τη μεταρρύθμιση του 2020 και τη μετάβαση στο Μοντέλο Στόχος, οι αρμοδιότητες αναδιαρθρώθηκαν και δημιουργήθηκε η Hellenic Energy Exchange (HEEnEx).

Το Ελληνικό Χρηματιστήριο Ενέργειας HEEnEx ιδρύθηκε το 2017 και ξεκίνησε την πλήρη εμπορική λειτουργία του τον Νοέμβριο του 2020, οπότε και η Ελλάδα εντάχθηκε στον μηχανισμό ζεύξης αγορών επόμενης ημέρας SDAC [5]. Αυτή η ένταξη υπήρξε καθοριστική για την πορεία της ελληνικής αγοράς ηλεκτρισμού: από εκείνη τη στιγμή, η ελληνική τιμή εκκαθάρισης καθορίζεται μέσω του ευρωπαϊκού αλγορίθμου EURHEMIA, μαζί με τις υπόλοιπες ευρωπαϊκές αγορές που συμμετέχουν στο SDAC.

Η Αγορά Επόμενης Ημέρας στην Ελλάδα Στο σύγχρονο ελληνικό μοντέλο, η διαδικασία επόμενης ημέρας ακολουθεί τυποποιημένη διαδρομή: κάθε ημέρα πριν τις 12:00 (κεντρικής ευρωπαϊκής ώρας), όλοι οι εγγεγραμμένοι συμμετέχοντες (παραγωγοί, προμηθευτές και έμποροι) υποβάλλουν στη HEEnEx προσφορές πώλησης και αγοράς ηλεκτρισμού για κάθε ώρα της επόμενης ημέρας. Ο αλγόριθμος EURHEMIA συνδυάζει τις προσφορές από όλες τις συζευγμένες αγορές, λαμβάνει

υπόψη τις μεταφορικές ικανότητες των διασυνδέσεων και βρίσκει την τιμή εκκαθάρισης (Market Clearing Price) για κάθε ζώνη ισορροπίας και κάθε ώρα [5].

Το Σχήμα 1.1 παρουσιάζει τη χρονική ακολουθία των αγορών ηλεκτρισμού. Οι κύριες δραστηριότητες κατανέμονται σε τρεις ημερολογιακές ημέρες: την D-2 (δύο ημέρες πριν την παράδοση), τη D-1 (ημέρα υποβολής προσφορών) και την D (ημέρα παράδοσης). Κατά την D-1, πριν τις 12:00 CET, υποβάλλονται οι προσφορές στη HEEx, ο αλγόριθμος EURHEMIA εκτελεί την εκκαθάριση (13:00 CET), και τα αποτελέσματα δημοσιεύονται. Κατά την D, τρεις ενδοημερήσιοι κύκλοι (ΣΠΕΔ 1, 2, 3) επιτρέπουν τη διόρθωση θέσεων, ενώ η Αγορά Εξισορρόπησης (ΔΕΠ) λειτουργεί σε πραγματικό χρόνο.



Σχήμα 1.1. Χρονική ακολουθία αγορών ηλεκτρισμού (D-2/D-1/D). Τα μοντέλα ML υποβάλλουν προβλέψεις στον ορίζοντα D-1 πριν την κλεισίδωση της DAM στις 12:00 CET. Η Αγορά Εξισορρόπησης (ΔΕΠ) λειτουργεί σε πραγματικό χρόνο κατά την D.

Χαρακτηριστικά της Ελληνικής Αγοράς Η ελληνική αγορά εμφανίζει ορισμένα ιδιαίτερα χαρακτηριστικά που την καθιστούν ενδιαφέρουσα ως αντικείμενο μελέτης.

Πρώτον, η *διείσδυση ΑΠΕ* βρίσκεται σε συνεχή ανάπτυξη. Η ηλιακή ακτινοβολία στην Ελλάδα είναι από τις υψηλότερες στην Ευρώπη, και η εγκατεστημένη ισχύς φωτοβολταϊκών και αιολικών πάρκων συνεχίζει να αυξάνεται. Σε πολλές ώρες κατά τη θερινή περίοδο, οι ΑΠΕ καλύπτουν πάνω από το 70-80% της ζήτησης, πιέζοντας τις τιμές χαμηλά μέσω του *merit order effect*: η φθηνή παραγωγή ΑΠΕ εκτοπίζει τις ακριβότερες θερμικές μονάδες από τη στοίβα παραγωγής.

Δεύτερον, ο *ρόλος του φυσικού αερίου* είναι κεντρικός. Οι μονάδες παραγωγής με φυσικό αέριο συνιστούν συχνά τη *μεθοριακή μονάδα* που καθορίζει την τελική τιμή εκκαθάρισης, ιδιαίτερα τις ώρες αιχμής. Αυτό σημαίνει ότι οι διεθνείς τιμές φυσικού αερίου (ιδίως το TTF ολλανδικό benchmark) ασκούν ισχυρή επίδραση στις ελληνικές τιμές ηλεκτρισμού. Η ενεργειακή κρίση του 2021-2022, κατά την οποία οι τιμές TTF εκτοξεύθηκαν λόγω της μειωμένης ρωσικής παροχής φυσικού αερίου, είναι χαρακτηριστικό παράδειγμα αυτής της εξάρτησης.

Τρίτον, οι *διεθνείς διασυνδέσεις* παίζουν καθοριστικό ρόλο. Η Ελλάδα διαθέτει διασυνδέσεις με τη Βουλγαρία (μεγαλύτερη ισχύς), τη Βόρεια Μακεδονία, την Αλβανία, την Τουρκία, μέσω της Κρήτης και νέων καλωδίων, με πρόσθετες ζώνες. Η χρησιμοποίηση αυτών των διασυνδέσεων καθορίζεται αυτόματα από τον αλγόριθμο EURHEMIA, με αποτέλεσμα η ελληνική τιμή να επηρεάζεται έντονα από τις συνθήκες στις γειτονικές αγορές.

Τέταρτον, η *εποχικότητα* έχει ιδιαίτερα χαρακτηριστικά στην Ελλάδα. Λόγω κλίματος, η θερινή περίοδος χαρακτηρίζεται από υψηλή ζήτηση ψύξης και ταυτόχρονα υψηλή παραγωγή ηλιακής ενέργειας: δύο αντίρροπες δυνάμεις που δημιουργούν ενδιαφέροντα πρότυπα στην τιμή. Στην περίοδο αξιολόγησης της παρούσας εργασίας, Q1 2026 (κυλιόμενο τρίμηνο Δεκέμβριος 2025 - Φεβρουάριος 2026, και όχι το ημερολογιακό Α' τρίμηνο), ο συνδυασμός υψηλής ζήτησης θέρμανσης, μειωμένης υδροηλεκτρικής ισχύος και αυξημένων τιμών καυσίμων οδήγησε σε έντονη μεταβλητότητα, με

μέσες τιμές που κυμάνθηκαν μεταξύ 78 €/MWh (Φεβρουάριος 2026) και 110 €/MWh (Δεκέμβριος 2025 - Ιανουάριος 2026).

1.4 Πρόβλεψη Τιμών Ηλεκτρικής Ενέργειας

Η Σημασία της Πρόβλεψης Τιμής Η πρόβλεψη τιμών ηλεκτρικής ενέργειας (Electricity Price Forecasting, EPF) είναι ένας από τους πιο κρίσιμους τομείς ανάλυσης σε απελευθερωμένες αγορές ηλεκτρισμού. Το πεδίο αυτό ξεκίνησε να αναπτύσσεται στην τελευταία δεκαετία του 20ού αιώνα, παράλληλα με τις πρώτες απελευθερώσεις αγορών, και έκτοτε έχει εξελιχθεί σε ένα ζωτικό κλάδο τόσο στην ακαδημαϊκή έρευνα όσο και στην εμπορική πρακτική.

Οι συμμετέχοντες στην αγορά αντιμετωπίζουν ημερησίως αποφάσεις που εξαρτώνται από την εκτίμηση της μελλοντικής τιμής. Οι *παραγωγοί* χρησιμοποιούν προβλέψεις τιμής για να βελτιστοποιήσουν τις προσφορές τους στην αγορά επόμενης ημέρας: μια ακριβής πρόβλεψη επιτρέπει τη μεγιστοποίηση του περιθωρίου κέρδους, καθορίζοντας έτσι τη στρατηγική και κατ' επέκταση την τοποθέτηση για μελλοντικές θέσεις. Οι *προμηθευτές* και *έμποροι* χρησιμοποιούν τις προβλέψεις για να σχεδιάσουν αγορές ενέργειας, να αντισταθμίσουν κίνδυνο μέσω της Προθεσμιακής Αγοράς και να διαχειριστούν χαρτοφυλάκια παραγωγής και κατανάλωσης. Οι *μεγάλοι βιομηχανικοί καταναλωτές* εκμεταλλεύονται τις προβλέψεις για να μεταθέσουν ενεργοβόρες διεργασίες στις φθηνότερες ώρες, μειώνοντας το ενεργειακό τους κόστος.

Ιδιαίτερα Χαρακτηριστικά των Τιμών Ηλεκτρισμού Ο Weron [2] στην εκτενή ανασκόπηση του κατατάσσει το EPF ανάμεσα στα δυσκολότερα προβλήματα πρόβλεψης χρονοσειρών, εντοπίζοντας μια σειρά χαρακτηριστικών που το διαφοροποιούν σε σχέση με άλλες χρηματοοικονομικές ή ενεργειακές χρονοσειρές:

Πολλαπλή εποχικότητα: Οι τιμές ηλεκτρισμού εμφανίζουν ταυτόχρονα ημερήσια, εβδομαδιαία και ετήσια μοτίβα. Σε ημερήσιο επίπεδο, παρατηρείται τυπική διπλή αιχμή (double peak) κατά τις πρωινές και βραδινές ώρες αιχμής, ενώ τις νυχτερινές ώρες εμφανίζονται χαμηλές τιμές. Σε εβδομαδιαίο επίπεδο, οι τιμές των Σαββατοκύριακων τείνουν να είναι χαμηλότερες λόγω μειωμένης βιομηχανικής κατανάλωσης. Σε ετήσιο επίπεδο, η εποχιακή δομή επηρεάζεται από τη θερμοκρασία και τη διαθεσιμότητα υδροηλεκτρικής ενέργειας.

Ακραίες τιμές (Price Spikes): Μια από τις πιο χαρακτηριστικές ιδιότητες των τιμών ηλεκτρισμού είναι η εμφάνιση απότομων αιχμών, όπου η τιμή μπορεί να πολλαπλασιαστεί σε μερικές ώρες και στη συνέχεια να επιστρέψει γρήγορα σε κανονικά επίπεδα. Τα spikes οφείλονται συνήθως σε ταυτόχρονη εμφάνιση υψηλής ζήτησης, χαμηλής παραγωγής ΑΠΕ και περιορισμένης διαθεσιμότητας θερμικών μονάδων [2].

Μη στασιμότητα: Αντίθετα με πολλές χρηματοοικονομικές χρονοσειρές, οι τιμές ηλεκτρισμού δεν συμπεριφέρονται σταθερά στατιστικά διαχρονικά. Αλλαγές στη σύνθεση της παραγωγής, στο κόστος καυσίμων, στη ζήτηση ή στις δομές της αγοράς αλλάζουν τα στατιστικά χαρακτηριστικά της σειράς, τονίζοντας τη σημασία προσαρμοστικών προσεγγίσεων.

Μεταβλητή συσχέτιση τιμής-φορτίου: Η τιμή συσχετίζεται γενικά θετικά με το φορτίο, αλλά η σχέση αυτή δεν είναι σταθερή και εξαρτάται από τη σύνθεση της παραγωγής. Σε υψηλές διεισδύσεις ΑΠΕ, το φορτίο μπορεί να αυξάνεται ενώ η τιμή παραμένει χαμηλή ή μειώνεται, λόγω της αυξημένης παραγωγής από ΑΠΕ [2].

Παράγοντες που Επηρεάζουν την Τιμή Ηλεκτρισμού Οι παράγοντες που διαμορφώνουν την τιμή ηλεκτρισμού στην αγορά επόμενης ημέρας μπορούν να ταξινομηθούν σε τρεις βασικές κατηγορίες [2, 8].

Από την πλευρά της *προσφοράς*, ο πιο άμεσος καθοριστής της τιμής είναι η *στοίβα παραγωγής* (merit order stack): η αλληλουχία μονάδων παραγωγής ταξινομημένων κατά αυξανόμενο οριακό κόστος. Η τελική τιμή καθορίζεται από το οριακό κόστος της τελευταίας μονάδας που απαιτείται για να καλυφθεί η ζήτηση.

Εκτός από τη σύνθεση της παραγωγής, κρίσιμο ρόλο παίζει η *κόστος καυσίμων*. Οι τιμές φυσικού αερίου (TTF), οι τιμές λιθάνθρακα (API2) και οι τιμές δικαιωμάτων εκπομπής CO₂ (EU ETS) μεταφράζονται άμεσα στα οριακά κόστη παραγωγής και επηρεάζουν ισχυρά την τιμή εκκαθάρισης.

Από την πλευρά της *ζήτησης*, το *ηλεκτρικό φορτίο* είναι ο πιο άμεσος οδηγός της τιμής: υψηλή κατανάλωση σημαίνει ότι ακριβότερες μονάδες καλούνται να καλύψουν τη ζήτηση, ανεβάζοντας τη μεθοριακή τιμή εκκαθάρισης.

1.5 Πρόβλεψη Ηλεκτρικού Φορτίου

Η Σημασία της Πρόβλεψης Φορτίου Η πρόβλεψη ηλεκτρικού φορτίου (Electricity Load Forecasting, ELF) είναι ένας από τους παλαιότερους και πιο καλά μελετημένους τομείς στη διαχείριση ηλεκτρικών συστημάτων. Από τις πρώτες σημαντικές εργασίες των Gross και Galiana [9] στα τέλη της δεκαετίας του '80, ο τομέας έχει συσσωρεύσει δεκαετίες εμπειρίας και μια πλούσια βιβλιογραφία. Παρόλα αυτά, παραμένει ενεργό πεδίο έρευνας λόγω της συνεχούς εξέλιξης των απαιτήσεων του συστήματος.

Η ακριβής πρόβλεψη φορτίου εξυπηρετεί πολλαπλές λειτουργικές ανάγκες [10]. Πρώτον, είναι απαραίτητο δεδομένο εισόδου για τον *βραχυπρόθεσμο προγραμματισμό μονάδων* (Unit Commitment). Δεύτερον, χρησιμοποιείται για τον *οικονομικό προγραμματισμό*: τη βέλτιστη κατανομή ισχύος μεταξύ μονάδων και τον σχεδιασμό αγορών και πωλήσεων στις αγορές επόμενης ημέρας. Τρίτον, η ακριβής πρόβλεψη φορτίου είναι απαραίτητη για τη *διαχείριση αποθεμάτων ισχύος* (Spinning and Non-Spinning Reserves).

Κατηγοριοποίηση κατά Ορίζοντα Πρόβλεψης Ένας από τους πιο ευρέως αποδεκτούς τρόπους ταξινόμησης των προβλημάτων πρόβλεψης φορτίου είναι ο χρονικός ορίζοντας [10]:

Η *Πολύ Βραχυπρόθεσμη Πρόβλεψη Φορτίου* (Very Short-Term Load Forecasting (VSTLF), έως 1 ώρα) καλύπτει ορίζοντα από μερικά δευτερόλεπτα έως μία ώρα και χρησιμοποιείται κυρίως με αυτόματη ρύθμιση παραγωγής.

Η *Βραχυπρόθεσμη Πρόβλεψη Φορτίου* (Short-Term Load Forecasting (STLF), 1 ώρα έως 2 εβδομάδες) συνιστά τον κρίσιμότερο ορίζοντα για τις αγορές ηλεκτρισμού, καλύπτοντας τόσο τα 24-48h για τον σχεδιασμό της αγοράς επόμενης ημέρας όσο και τον βραχυπρόθεσμο προγραμματισμό (Unit Commitment). Η εφαρμογή που εξετάζεται στην παρούσα εργασία εμπίπτει ακριβώς σε αυτή την κατηγορία.

Η *Μεσοπρόθεσμη Πρόβλεψη Φορτίου* (Medium-Term Load Forecasting (MTLF), 2 εβδομάδες έως 3 χρόνια) χρησιμοποιείται κυρίως για τον σχεδιασμό συστημάτων συντήρησης, αγορών καυσίμων και δυναμικότητας.

Η *Μακροπρόθεσμη Πρόβλεψη Φορτίου* (Long-Term Load Forecasting (LTLF), πάνω από 3 χρόνια) καλύπτει ορίζοντα για αποφάσεις δομής: σχεδιασμός νέων σταθμών παραγωγής, επεκτάσεις δικτύου μεταφοράς και ενεργειακός σχεδιασμός σε επίπεδο κράτους.

Παράγοντες που Επηρεάζουν το Φορτίο Σε σχέση με τους παράγοντες που επηρεάζουν τη ζήτηση ηλεκτρισμού, η βασικότερη κατηγορία είναι τα *μετεωρολογικά δεδομένα*, και ειδικότερα η θερμοκρασία αέρα. Η σχέση μεταξύ φορτίου και θερμοκρασίας είναι μη γραμμική (U-shaped): χαμηλές

Θερμοκρασίες αυξάνουν τη ζήτηση λόγω θέρμανσης, ενώ υψηλές θερμοκρασίες οδηγούν επίσης σε υψηλό φορτίο λόγω ψύξης.

Τα *ημερολογιακά χαρακτηριστικά* (ώρα ημέρας, ημέρα εβδομάδας, αργίες, εποχή, ημέρα μήνα) εξηγούν από μόνα τους ένα μεγάλο μέρος της διακύμανσης του φορτίου. Η εργάσιμη ημέρα έχει διαφορετικό ημερήσιο προφίλ από την Κυριακή, και μια αργία μπορεί να μεταβάλλει τη ζήτηση συγκριτικά με μια τυπική ίδιας ημέρας εβδομάδας.

1.6 Αλληλεπίδραση Τιμής και Φορτίου

Τιμή ηλεκτρισμού και ηλεκτρικό φορτίο δεν είναι ανεξάρτητα μεγέθη, αλλά συνδέονται μέσω πολύπλευρων αλληλεξαρτήσεων που λειτουργούν και στις δύο κατευθύνσεις, αν και με διαφορετική ένταση και χρονική κλίμακα.

Στην πιο άμεση κατεύθυνση, το *φορτίο επηρεάζει την τιμή μέσω του merit order*. Σε μια αγορά που λειτουργεί με βάση την οικονομική στοίβα παραγωγής, κάθε πρόσθετη μονάδα ζήτησης ικανοποιείται από ακριβότερες μονάδες παραγωγής, ανεβάζοντας τη μεθοριακή τιμή εκκαθάρισης. Γι' αυτόν τον λόγο, η εκτίμηση φορτίου που δημοσιεύει ο ΑΔΜΗΕ κάθε πρωί μπαίνει σχεδόν πάντα ως βασικό χαρακτηριστικό εισόδου σε μοντέλα τιμής και χρησιμοποιείται ευρέως στη βιβλιογραφία του EPF.

Η αντίστροφη κατεύθυνση (*επίδραση τιμής στο φορτίο*) λειτουργεί μέσω του λεγόμενου *demand response*: η δυνατότητα των καταναλωτών να ανταποκριθούν σε σήματα τιμής μετατοπίζοντας τη ζήτησή τους χρονικά. Μεγάλοι βιομηχανικοί καταναλωτές με ευέλικτες παραγωγικές διεργασίες (π.χ. αλουμινοβιομηχανίες, αλυκές, ψυγεία) μπορούν να μειώσουν τη ζήτηση κατά τις ώρες αιχμής. Ωστόσο, στον βραχυπρόθεσμο ορίζοντα που εξετάζεται στην παρούσα εργασία, αυτή η επίδραση παραμένει σχετικά αδύναμη.

Η *κοινή μοντελοποίηση* τιμής και φορτίου ανοίγει ενδιαφέρουσες ερευνητικές δυνατότητες. Η λεγόμενη προσέγγιση *two-stage* (δύο βημάτων) εκτιμά πρώτα το φορτίο και στη συνέχεια χρησιμοποιεί αυτή την εκτίμηση ως είσοδο στο μοντέλο τιμής [8]. Στην παρούσα εργασία, εξετάζεται εμπειρικά η επίδραση της αντικατάστασης της επίσημης πρόβλεψης φορτίου (ΑΔΜΗΕ) από αυτόνομα εκπαιδευμένα μοντέλα φορτίου μηχανικής μάθησης, ώστε να αξιολογηθεί αν και κατά πόσο αυτή βελτιώνει την ακρίβεια πρόβλεψης τιμής.

Από μεθοδολογική σκοπιά, η παράλληλη αντιμετώπιση τιμής και φορτίου σε κοινό πλαίσιο αξιολόγησης εξυπηρετεί πολλαπλούς σκοπούς. Επιτρέπει την άμεση σύγκριση αλγόριθμων, στρατηγικών πρόβλεψης και μεθόδων βελτιστοποίησης σε δύο προβλήματα με διαφορετικά χαρακτηριστικά: η τιμή, με την υψηλή μεταβλητότητα και τα spikes, και το φορτίο, με τη σταθερή εποχικότητά του, αντιπροσωπεύουν δύο διαφορετικές κατηγορίες προβλημάτων. Έτσι, τα συμπεράσματα της σύγκρισης επισημαίνουν τα εγγενή χαρακτηριστικά κάθε μεθόδου σε δύο προβλήματα με διαφορετική δυναμική.

1.7 Σκοπός και Ερευνητικά Ερωτήματα

Σκοπός της εργασίας είναι η αξιολόγηση και σύγκριση προσεγγίσεων βραχυπρόθεσμης πρόβλεψης για την τιμή και το ηλεκτρικό φορτίο στην ελληνική Αγορά Επόμενης Ημέρας (DAM). Η πρόβλεψη γίνεται αποκλειστικά με πληροφορία που είναι διαθέσιμη στις ρεαλιστικές συνθήκες λειτουργίας της αγοράς, σύμφωνα με το ισχύον πλαίσιο δηλαδή έως το "κλείσιμο της πύλης" (D-1, 12:00 CET). Η σύγκριση αναπτύσσεται σε τρεις άξονες: τη στρατηγική πρόβλεψης (Teacher-Forcing, Recursive, MIMO, Direct), τον αλγόριθμο μηχανικής μάθησης και το πλαίσιο εκπαίδευσης (στατική έναντι μηνιαίας walk-forward επανεκπαίδευσης). Παράλληλα, εξετάζεται και η συμπεριφορά των μεγεθών (τιμή και φορτίο), καθώς και οι διαφορές τους ως προς τη δυσκολία πρόβλεψης. Η αξιολόγηση

γίνεται σε δύο περιόδους: πρώτα σε έναν σταθερό μήνα αναφοράς (Δεκέμβριος 2025), όπου συγκρίνεται η δομική συμπεριφορά των στρατηγικών υπό ελεγχόμενες συνθήκες. Έπειτα στο τρίμηνο Q1 2026 (Δεκέμβριος 2025-Φεβρουάριος 2026), περίοδο έντονης μεταβλητότητας και μεταβολής καθεστώτος, όπου δοκιμάζεται η ανθεκτικότητά τους, καθώς και ο βαθμός στον οποίο απαιτούν συχνή επανεκπαίδευση για να διατηρήσουν την απόδοσή τους. Πέρα από την κατάταξη, η εργασία εξετάζει τον ρόλο των δεδομένων και της επεξεργασίας τους στην επίδοση κάθε στρατηγικής και κάθε αλγόριθμου, ερμηνεύοντας μέσω της ανάλυσης σημαντικότητας χαρακτηριστικών σε ποια πληροφορία στηρίζεται κάθε προσέγγιση.

Με βάση τον σκοπό που τέθηκε, η εργασία οργανώνεται γύρω από πέντε ερευνητικά ερωτήματα, τα οποία διατρέχουν τη μεθοδολογία και απαντώνται συγκεντρωτικά στο Κεφάλαιο 8:

- EE1.** Ποια στρατηγική (Recursive, MIMO, Direct), ποιος αλγόριθμος και ποιο πλαίσιο εκπαίδευσης (στατικό ή walk-forward) δίνουν την ακριβέστερη πρακτικά εφαρμόσιμη πρόβλεψη τιμής DAM και φορτίου, σε σύγκριση με το ιδεατό Teacher-Forcing και τα μοντέλα αναφοράς;
- EE2.** Ποιες βασικές διαφορές εμφανίζουν τα δύο σήματα, τιμή και φορτίο, στη μοντελοποίηση και την πρόγνυσή τους, υπό κοινή και παράλληλη αρχιτεκτονική και αξιολόγηση;
- EE3.** Πώς μεταβάλλεται η ακρίβεια των προβλέψεων ανά προβλεπόμενο μέγεθος, στρατηγική και αλγόριθμο σε περιόδους έντονης μεταβλητότητας και αλλαγής καθεστώτος;
- EE4.** Πώς τεκμηριώνονται οι παραπάνω συγκρίσεις σε ποιοτικό, ποσοτικό και στατιστικό επίπεδο;
- EE5.** Τι αντίκτυπο έχουν τα δεδομένα και ο τρόπος επεξεργασίας τους στην επίδοση κάθε στρατηγικής, και τι αναδεικνύει η ανάλυση σημαντικότητας χαρακτηριστικών ανά στρατηγική και ανά αλγόριθμο;

Τιμή και φορτίο μοντελοποιούνται παράλληλα, με κοινή αρχιτεκτονική, ίδιο σύνολο χαρακτηριστικών και ίδιο πλαίσιο αξιολόγησης, ώστε τα αποτελέσματά τους να είναι άμεσα συγκρίσιμα. Οι συνεισφορές που προκύπτουν από τη διερεύνηση αυτή συνοψίζονται στο Κεφάλαιο 8.

1.8 Δομή της Εργασίας

Η εργασία οργανώνεται σε οκτώ κεφάλαια, δομημένα ώστε να οδηγούν τον αναγνώστη βήμα προς βήμα από το θεωρητικό πλαίσιο στη μεθοδολογία, τα αποτελέσματα και τα συμπεράσματα.

Το παρόν **Κεφάλαιο 1** παρουσίασε το ευρύτερο πλαίσιο της εργασίας: την ευρωπαϊκή ενεργειακή μετάβαση, τη δομή και τη λειτουργία της ελληνικής αγοράς ηλεκτρισμού, τα βασικά χαρακτηριστικά των προβλημάτων πρόβλεψης τιμής και φορτίου, καθώς και τον σκοπό και τους άξονες διερεύνησης της εργασίας.

Το **Κεφάλαιο 2** τοποθετεί την εργασία στο ευρύτερο ερευνητικό πλαίσιο μέσα από βιβλιογραφική ανασκόπηση. Εξετάζεται η εξέλιξη των αλγόριθμων Machine Learning (ML) για EPF και ELF, οι στρατηγικές πολυβήματης πρόβλεψης, η χρήση τεχνικών Scheduled Sampling και η πρακτική της walk-forward αξιολόγησης στη σχετική βιβλιογραφία.

Τα **Κεφάλαια 3 και 4** συνιστούν τον κορμό της μεθοδολογίας. Το Κεφάλαιο 3 περιγράφει τις πηγές δεδομένων, τη διαδικασία συλλογής, τον καθαρισμό, τη μηχανική χαρακτηριστικών (feature engineering) και τα μέτρα αποφυγής διαρροής δεδομένων. Το Κεφάλαιο 4 παρουσιάζει αναλυτικά τους πέντε αλγόριθμους μηχανικής μάθησης, τις τέσσερις στρατηγικές πρόβλεψης, τη βελτιστοποίηση υπερπαραμέτρων με Optuna και το πλαίσιο walk-forward μηνιαίας επανεκπαίδευσης.

Το **Κεφάλαιο 5** παρουσιάζει το διαδραστικό εργαλείο οπτικοποίησης (dashboard) που αναπτύχθηκε για την εξερεύνηση και σύγκριση όλων των μοντέλων, στρατηγικών και χρονικών περιόδων αξιολόγησης.

Τα **Κεφάλαια 6 και 7** συνιστούν τον πυρήνα της πειραματικής ανάλυσης. Το Κεφάλαιο 6 παρουσιάζει τα αριθμητικά αποτελέσματα για τιμή και φορτίο, τόσο για τη στατική αξιολόγηση σε Δεκέμβριο 2025 όσο και για την walk-forward περίοδο Q1 2026, ανά στρατηγική και αλγόριθμο, μαζί με ποιοτική ανάλυση των σφαλμάτων (χρονική δομή, κατανομή, μεροληψία) και τη στατιστική επικύρωση των κατατάξεων μέσω του ελέγχου Diebold-Mariano. Το Κεφάλαιο 7 αναλύει τη σημαντικότητα των χαρακτηριστικών ανά στρατηγική, εξηγώντας σε ποιες μεταβλητές στηρίζεται κάθε μοντέλο.

Η εργασία ολοκληρώνεται με το **Κεφάλαιο 8**, το οποίο αποτιμά κατά πόσο επιτεύχθηκε ο σκοπός της εργασίας, συνοψίζει τα κύρια ευρήματα και τις συνεισφορές, οριοθετεί τους περιορισμούς της προσέγγισης και προτείνει κατευθύνσεις για μελλοντική έρευνα.

2. Βιβλιογραφική Ανασκόπηση

2.1 Πρόβλεψη Τιμών Ηλεκτρικής Ενέργειας

2.1.1 Εξέλιξη πεδίου και βασικές ανασκοπήσεις

Η βραχυπρόθεσμη πρόβλεψη τιμών ηλεκτρικής ενέργειας (*Electricity Price Forecasting*, EPF) είναι ένα από τα πιο απαιτητικά προβλήματα χρονοσειρών [2]. Ο Weron [2] παρουσιάζει εκτεταμένη ανασκόπηση, τονίζοντας ότι οι αγορές ηλεκτρισμού παρουσιάζουν δύσκολη δυναμική: απότομες αιχμές (*spikes*), ισχυρή εποχικότητα (ωριαία, ημερήσια, εβδομαδιαία) και μη σταθερή διακύμανση. Οργανώνει τις μεθόδους σε πέντε κατηγορίες: multi-agent, fundamental, reduced-form, statistical και computational intelligence, τεκμηριώνοντας ότι οι στατιστικές και υπολογιστικές προσεγγίσεις κυριαρχούν στη βραχυπρόθεσμη πρόβλεψη.

Οι Lago et al. [8] επικεντρώνονται σε αλγόριθμους τελευταίας γενιάς και προτείνουν ένα ανοιχτό σημείο αναφοράς (benchmark) για αντικειμενική σύγκριση μεθόδων στην αγορά Nord Pool. Ο Kanousis [11] εφαρμόζει ένα σύνολο μεθόδων ML στην ελληνική αγορά επόμενης ημέρας (*Day-Ahead Market*), επιτυγχάνοντας σημαντική βελτίωση έναντι στατιστικών μοντέλων αναφοράς. Ο Κοντράρος [12] εξετάζει τεχνικές ensemble για ελληνικά δεδομένα, αναδεικνύοντας τη σημασία της επιλογής χαρακτηριστικών στα αποτελέσματα πρόβλεψης.

2.1.2 Κατηγορίες Μεθόδων Πρόβλεψης

Τα μοντέλα EPF διακρίνονται σε τέσσερις ευρείες κατηγορίες. Τα *στατιστικά μοντέλα* (ARIMA, GARCH, VAR) κυριαρχούσαν στη βιβλιογραφία έως τα μέσα του 2010. Τα *μοντέλα μηχανικής μάθησης* (Gradient Boosting Machines, SVR, MLP) συχνά υπερτερούν των στατιστικών μοντέλων σε σύγχρονες αγορές, κατά κύριο λόγο λόγω της ικανότητάς τους να ενσωματώνουν πολλαπλές εξωγενείς μεταβλητές χωρίς ισχυρές παραδοχές κατανομής. Τα *μοντέλα βαθιάς μάθησης* (LSTM, Transformer) επιτυγχάνουν ισχυρά αποτελέσματα σε παγκόσμιες αγορές υψηλής ρευστότητας [13--15]. Ειδικότερα, το *Temporal Fusion Transformer* [15] συνδυάζει μηχανισμούς attention (προσοχής, που σταθμίζουν δυναμικά τη βαρύτητα διαφορετικών χρονικών βημάτων) με temporal self-attention, επιτρέποντας ερμηνεύσιμη μοντελοποίηση πολλαπλών χρονικών οριζόντων. Ωστόσο, οι Zeng et al. [16] υποστηρίζουν ότι απλά γραμμικά μοντέλα συχνά ξεπερνούν τους Transformers σε χρονοσειρές περιορισμένου μήκους, όπως η ωριαία EPF ($T \approx 80.000$ δείγματα). Για την ελληνική αγορά ειδικότερα, οι μέθοδοι ML (Gradient Boosting) παραμένουν ανταγωνιστικές λόγω περιορισμένου μεγέθους δεδομένων και υψηλής μεταβλητότητας που δεν ευνοεί την πλήρη αξιοποίηση deep learning. Τέλος, τα *υβριδικά/ensemble μοντέλα* συνδυάζουν προβλέψεις πολλαπλών αλγόριθμων με τεχνικές σταθμισμένης συγχώνευσης, συχνά επιτυγχάνοντας καλύτερη γενίκευση από κάθε μεμονωμένο μοντέλο [17, 18].

2.1.3 Ο ρόλος εποχικής διόρθωσης

Η εποχική αποσύνθεση πριν από την εφαρμογή ML έχει αναδειχθεί ως χρήσιμη προεπεξεργασία για την EPF. Οι Uniejewski et al. [19] δείχνουν ότι η διόρθωση βάσει της μακροπρόθεσμης (ετήσιας) εποχικής συνιστώσας (LTSC) μειώνει σημαντικά το MAE σε ευρωπαϊκές αγορές. Οι Marcjasz et al. [20] επεκτείνουν αυτή την ιδέα σε τεχνικές ειδικές ανά ώρα, τεκμηριώνοντας σημαντικές βελτιώσεις σε δείκτες ακρίβειας. Στην παρούσα εργασία, οι εποχικές ιδιότητες ενσωματώνονται απευθείας ως χαρακτηριστικά υστέρησης και κυκλικές κωδικοποιήσεις χρόνου (lag features / cyclic encodings) αντί ρητής αποσύνθεσης, ακολουθώντας τη βέλτιστη πρακτική που περιγράφεται στον Lago et al. [8].

2.2 Πρόβλεψη Ηλεκτρικού Φορτίου

2.2.1 Ιστορική εξέλιξη

Η πρόβλεψη ηλεκτρικού φορτίου (*Electricity Load Forecasting*, ELF) έχει μακρύτερη ιστορία από την EPF. Οι Gross και Galiana [9] τεκμηριώνουν τις πρώτες συστηματικές προσεγγίσεις ήδη από τη δεκαετία του 1980, βασισμένες κυρίως σε παλινδρόμηση και εκθετική εξομάλυνση. Ο Μαγκκλάρς [21] εξετάζει τις σύγχρονες τεχνικές ML για το ελληνικό δίκτυο, τονίζοντας τη σημασία των μετεωρολογικών χαρακτηριστικών.

2.2.2 Κατηγοριοποίηση κατά Ορίζοντα

Η βιβλιογραφία διακρίνει τέσσερις κατηγορίες ανάλογα με τον ορίζοντα πρόβλεψης:

- **VSTLF** (*Very Short-Term Load Forecasting*): μερικά λεπτά έως μία ώρα, κρίσιμο για τον έλεγχο ισορροπίας σε πραγματικό χρόνο.
- **STLF** (*Short-Term Load Forecasting*): μία ώρα έως δύο εβδομάδες, ο ορίζοντας της παρούσας εργασίας ($H = 24h$).
- **MTLF** (*Medium-Term Load Forecasting*): δύο εβδομάδες έως τρία χρόνια, σχεδιασμός συντήρησης δικτύου.
- **LTLF** (*Long-Term Load Forecasting*): πάνω από τρία χρόνια, επενδυτικές αποφάσεις υποδομής.

2.2.3 Στατιστικά Χαρακτηριστικά

Το ηλεκτρικό φορτίο παρουσιάζει τρία διακριτά στατιστικά χαρακτηριστικά. Πρώτον, ισχυρή *εποχικότητα*: ημερήσιο μοτίβο (υψηλά φορτία εργάσιμες ώρες), εβδομαδιαίο μοτίβο (χαμηλά Σαββατοκύριακα) και ετήσιο μοτίβο (αιχμές χειμώνα/καλοκαιριού λόγω θέρμανσης/ψύξης). Δεύτερον, ισχυρή *αυτοσυσχέτιση* στις υστερήσεις $t - 1$ (1 ώρα, η προηγούμενη ώρα), $t - 24$ (η ίδια ώρα χθες) και $t - 168$ (η ίδια ώρα την ίδια εργάσιμη/μη-εργάσιμη μέρα την προηγούμενη εβδομάδα). Τρίτον, *μη γραμμικότητα* λόγω ακραίων κλιματικών συνθηκών (θερμοκρασία, υγρασία), ειδικών ημερών (εορτές, απεργίες) και απότομων αλλαγών συμπεριφοράς του καταναλωτή.

Αυτά τα χαρακτηριστικά καθιστούν τα μοντέλα ML κατάλληλα, καθώς μπορούν να συλλάβουν μη γραμμικές αλληλεπιδράσεις μεταξύ πολλαπλών χαρακτηριστικών χωρίς ρητή μοντελοποίηση.

2.3 Μοντέλα Αναφοράς (Naive Baselines)

Πριν από κάθε αλγόριθμο μηχανικής μάθησης, η βιβλιογραφία πρόβλεψης χρονοσειρών ορίζει ένα σύνολο αφελών μοντέλων αναφοράς (naive baselines): μεθόδους εμμονής (persistence) χωρίς εκπαίδευση, που θέτουν το ελάχιστο όριο επίδοσης το οποίο οφείλει να υπερβεί κάθε μη τετριμμένο μοντέλο [8]. Στην εργασία χρησιμοποιούνται τέσσερα: το **Naive-1** (τιμή προηγούμενης ώρας), το **Naive-24** (ίδια ώρα προηγούμενης ημέρας), το **Naive-168** (ίδια ώρα προηγούμενης εβδομάδας) και το **Seasonal Profile** (μέσος όρος ανά ώρα και ημέρα εβδομάδας του συνόλου εκπαίδευσης). Τα τρία πρώτα είναι η άμεση λειτουργική έκφραση της αυτοσυσχέτισης που περιγράφηκε παραπάνω (υστερήσεις $t - 1, t - 24, t - 168$). Η επιλογή του κατάλληλου baseline εξαρτάται από το σύνολο πληροφορίας κάθε στρατηγικής: το Naive-1 για τις μονοβηματικές προσεγγίσεις, το Naive-24 για τις στρατηγικές μίας αφετηρίας (MIMO/Direct), ζήτημα στο οποίο επανερχόμαστε στην Ενότητα 2.5. Οι τυπικοί ορισμοί δίνονται στο Κεφάλαιο 4.

2.4 Αλγόριθμοι Μηχανικής Μάθησης

2.4.1 Μέθοδοι Gradient Boosting

Random Forest. Ο αλγόριθμος Random Forest [22] εκπαιδεύει B ανεξάρτητα δέντρα απόφασης, το καθένα σε bootstrap δείγμα του συνόλου εκπαίδευσης, και συνδυάζει τις προβλέψεις τους με αριθμητικό μέσο:

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (2.1)$$

Η διάσπαση κάθε κόμβου επιλέγεται ώστε να μεγιστοποιεί τη μείωση της διακύμανσης (*variance reduction*):

$$IV = \frac{1}{N} \sum_{i \in I_L} (y_i - \bar{y}_L)^2 + \frac{1}{N} \sum_{i \in I_R} (y_i - \bar{y}_R)^2 \quad (2.2)$$

όπου I_L, I_R τα δείγματα αριστερού/δεξιού κόμβου και $\bar{y}_L, \bar{y}_R$ οι αντίστοιχοι μέσοι όροι.

Ως μέθοδος *ομαδικής μάθησης* (*ensemble learning*), το Random Forest ακολουθεί την τεχνική *bagging* (Bootstrap Aggregating): αντί να εμπιστεύεται ένα μόνο δέντρο, συνδυάζει πολλά ανεξάρτητα και λειτουργεί σαν επιτροπή εκτιμητών, όπου ο μέσος όρος πολλών κρίσεων είναι πιο σταθερός και αξιόπιστος από μία μεμονωμένη.


Η τυχαία επιλογή υποσυνόλου χαρακτηριστικών σε κάθε κόμβο μειώνει τη διακύμανση χωρίς αντίστοιχη αύξηση του σφάλματος μεροληψίας. Η μέθοδος είναι ιδιαίτερα ανθεκτική σε ακραίες τιμές (outliers) και σε υπερπροσαρμογή (*overfitting*) [22].

XGBoost. Ο αλγόριθμος XGBoost (*Extreme Gradient Boosting*) [23] κατασκευάζει δέντρα σειριακά, με κάθε νέο δέντρο να μαθαίνει τα κατάλοιπα του προηγούμενου. Η αντικειμενική συνάρτηση εκπαίδευσης περιλαμβάνει ρητό όρο κανονικοποίησης:

$$\mathcal{L} = \sum_i \ell(y_i, \hat{y}_i) + \sum_k \Omega(f_k) \quad (2.3)$$

όπου ℓ είναι η συνάρτηση απώλειας (π.χ. τετραγωνικό σφάλμα) και $\Omega(f_k) = \gamma T_k + \frac{1}{2} \lambda \|w_k\|^2$ ελέγχει την πολυπλοκότητα κάθε δέντρου f_k μέσω του αριθμού φύλλων T_k και των βαρών w_k . Η πρόβλεψη ενημερώνεται προσθετικά, $\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i)$, και η αντικειμενική συνάρτηση στο

Random Forest — bagging ensemble for regression



Σχήμα 2.1. Σχηματική αναπαράσταση του αλγόριθμου Random Forest: B δέντρα εκπαιδεύονται σε bootstrap δείγματα και η τελική πρόβλεψη προκύπτει ως ο μέσος όρος τους.

βήμα t προσεγγίζεται με ανάπτυγμα Taylor δεύτερης τάξης:

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^N \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (2.4)$$

όπου g_i και h_i είναι η πρώτη και η δεύτερη παράγωγος της απώλειας ως προς την πρόβλεψη, T ο αριθμός φύλλων και w_j τα βάρη τους. Ο αλγόριθμος χρησιμοποιεί *level-wise* ανάπτυξη δέντρου, δηλαδή διαχωρίζει όλους τους κόμβους του ίδιου επιπέδου πριν προχωρήσει στο επόμενο.

LightGBM. Ο αλγόριθμος LightGBM [24] βελτιώνει τον XGBoost με δύο καινοτομίες. Πρώτον, η *leaf-wise* ανάπτυξη δέντρου επιλέγει πάντα το φύλλο με τη μεγαλύτερη μείωση απώλειας, ανεξαρτήτως επιπέδου, επιτρέποντας ασύμμετρα δέντρα που συχνά καλύπτουν καλύτερα τις μη-γραμμικές σχέσεις. Δεύτερον, η τεχνική *Gradient-based One-Side Sampling* (GOSS) εστιάζει την εκπαίδευση στα δείγματα με μεγαλύτερα gradients, μειώνοντας τον χρόνο υπολογισμού χωρίς ουσιαστική απώλεια ακρίβειας. Το κέρδος ενός υποψήφιου σημείου διαχωρισμού υπολογίζεται από τα αθροίσματα των gradients (G) και Hessians (H) στον αριστερό και δεξιό κόμβο:


$$\text{Gain} = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] \quad (2.5)$$

όπου λ είναι ο συντελεστής κανονικοποίησης L_2 . Για απώλεια L_2 (objective="regression"), ισχύει $g_i = \hat{y}_i - y_i$ και $h_i = 1$.

2.4.2 Support Vector Regression

Η *Support Vector Regression* (SVR) [25] επιδιώκει να βρει μια συνάρτηση $f(x)$ που αποκλίνει από τις πραγματικές τιμές y_i κατά το πολύ ε , ελαχιστοποιώντας παράλληλα την πολυπλοκότητα του μοντέλου:

$$\min_{w, b, \xi, \xi^*} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \quad (2.6)$$



Σχήμα 2.2. Σύγκριση *level-wise* (XGBoost) και *leaf-wise* (LightGBM) στρατηγικής ανάπτυξης δέντρου.

υπό τους περιορισμούς $y_i - \langle w, x_i \rangle - b \leq \varepsilon + \xi_i$ και $\langle w, x_i \rangle + b - y_i \leq \varepsilon + \xi_i^*$, με $\xi_i, \xi_i^* \geq 0$. Η παράμετρος C ελέγχει την ισορροπία μεταξύ απλότητας μοντέλου και ανοχής σε σφάλμα, ενώ η ε ορίζει τον «σωλήνα ανοχής» εντός του οποίου τα σφάλματα αγνοούνται. Η ζώνη αυτή ορίζεται μέσω της ε -insensitive συνάρτησης απώλειας, $L_\varepsilon(y_i, \hat{y}_i) = \max(0, |y_i - \hat{y}_i| - \varepsilon)$.

Η χρήση πυρήνα RBF δίνει τη δυνατότητα στο μοντέλο να συλλάβει μη-γραμμικές σχέσεις μέσω της απεικόνισης σε υψηλοδιάστατο χώρο χαρακτηριστικών.

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (2.7)$$


2.4.3 Multi-Layer Perceptron (MLP)

Το *Multi-Layer Perceptron* (MLP) [26] υπολογίζει τη διέξοδο του μέσω διαδοχικών μετασχηματισμών γραμμικής προβολής και μη-γραμμικής ενεργοποίησης:

$$h^{(l)} = \sigma(W^{(l)}h^{(l-1)} + b^{(l)}) \quad (2.8)$$

όπου $W^{(l)}$ και $b^{(l)}$ είναι τα βάρη και τα όρια (*biases*) του στρώματος l , και σ είναι η συνάρτηση ενεργοποίησης (ReLU στη συγκεκριμένη υλοποίηση). Η ReLU ορίζεται ως $\sigma(x) = \max(0, x)$, αποτρέποντας το πρόβλημα της εξαφάνισης κλίσης (*vanishing gradient*). Η εκπαίδευση γίνεται με τον αλγόριθμο Adam, ο οποίος συνδυάζει προσαρμοστικό βήμα εκμάθησης με ορμή δεύτερης τάξης. Κατά την εκπαίδευση χρησιμοποιούνται επιπλέον δύο τεχνικές κανονικοποίησης: το *dropout*, που απενεργοποιεί τυχαία ένα ποσοστό νευρώνων σε κάθε επανάληψη ώστε το δίκτυο να μη στηρίζεται υπερβολικά σε μεμονωμένους νευρώνες (περιορισμός υπερπροσαρμογής), και η *batch normalization*, που κανονικοποιεί τις ενεργοποιήσεις κάθε mini-batch, σταθεροποιώντας και επιταχύνοντας την εκπαίδευση.

Τα *LSTM* (*Long Short-Term Memory*) [27] είναι επανατροφοδοτούμενη επέκταση των MLP με ενσωματωμένους μηχανισμούς «πύλης» για τη διαχείριση μακροπρόθεσμης εξάρτησης. Στην παρούσα εργασία, τα LSTM δεν χρησιμοποιήθηκαν στο τελικό σύνολο μοντέλων, καθώς τα δεδομένα ωριαίας ανάλυσης και η ρητή συμπερίληψη lag χαρακτηριστικών ήδη παρέχουν τη χρονική πληροφορία που αποσκοπεί να εκμεταλλευτεί το LSTM. Αντίστοιχα, οι αρχιτεκτονικές Transformer [28] έχουν



Σχήμα 2.3. Ο «σωλήνας ανοχής» (ε -tube) της SVR. Τα δείγματα εντός του σωλήνα δεν συνεισφέρουν στην αντικειμενική συνάρτηση, μόνο τα δείγματα εκτός (μεταβλητές χαλαρότητας ξ_i, ξ_i^*) τιμωρούνται.

επιδείξει ισχυρές επιδόσεις σε προβλήματα ακολουθιών, αλλά απαιτούν μεγαλύτερα σύνολα δεδομένων από αυτά που διαθέτει η ελληνική αγορά κατά την περίοδο μελέτης. Επιπλέον, πρόσφατη έρευνα [16] αμφισβητεί την υπεροχή τους έναντι απλούστερων μοντέλων σε χρονοσειρές περιορισμένου μήκους.

2.5 Στρατηγικές Πολυβηματικής Πρόβλεψης

Η πρόβλεψη σε ορίζοντα $H > 1$ βημάτων υλοποιείται με τέσσερις στρατηγικές [1, 29].


Teacher-Forcing (TF). Στη στρατηγική Teacher-Forcing (TF), το μοντέλο τροφοδοτείται με τις *πραγματικές* υστερήσεις (lags) σε κάθε βήμα πρόβλεψης. Έχει νόημα μόνο σε συνθήκες αξιολόγησης ή σε σενάρια όπου οι πραγματικές τιμές είναι διαθέσιμες (π.χ. ενδοημερήσια αγορά, online ενημέρωση μοντέλου). Παρέχει το άνω φράγμα επίδοσης (oracle).

Recursive (Rec). Η αναδρομική στρατηγική εκπαιδεύει ένα μοντέλο μονού βήματος και χρησιμοποιεί επαναληπτικά τις *προβλέψεις* ως εισόδους για τα επόμενα βήματα:

$$\hat{y}_{t+h} = f(\hat{y}_{t+h-1}, \dots, \hat{y}_{t+1}, y_t, y_{t-1}, \dots) \quad (2.9)$$

Η μέθοδος είναι απλή στην υλοποίηση αλλά υπόκειται σε συσσώρευση σφάλματος (*error accumulation*) για μεγάλους ορίζοντες.

Multilayer Perceptron — feedforward architecture



Σχήμα 2.4. Αρχιτεκτονική MLP με κρυφά στρώματα. Κάθε κόμβος στρώματος l δέχεται τις εξόδους του στρώματος $l - 1$ και εφαρμόζει τον μετασχηματισμό της εξίσωσης 2.8.

MIMO. Η στρατηγική *Multiple-Input Multiple-Output* (MIMO) εκπαιδεύει ένα μοντέλο που παράγει ολόκληρο το διάνυσμα πρόβλεψης ταυτόχρονα:

$$(\hat{y}_{t+1}, \dots, \hat{y}_{t+H}) = f(x_t) \quad (2.10)$$


Δεν υπάρχει συσσώρευση σφάλματος, αλλά η κοινή εκπαίδευση για όλα τα βήματα μπορεί να οδηγήσει σε μειωμένη ακρίβεια για τα πρώτα βήματα του ορίζοντα σε σχέση με μεθόδους εξειδικευμένες ανά βήμα.

Direct. Η άμεση στρατηγική εκπαιδεύει H ανεξάρτητα μοντέλα, ένα για κάθε βήμα h του ορίζοντα:

$$\hat{y}_{t+h} = f_h(x_t), \quad h = 1, \dots, H \quad (2.11)$$

Κάθε μοντέλο f_h βελτιστοποιείται αποκλειστικά για το συγκεκριμένο βήμα πρόβλεψης, εξαλείφοντας τη συσσώρευση σφάλματος. Το κόστος είναι H -πλάσιος χρόνος εκπαίδευσης.

Στην παρούσα εργασία αξιολογούνται τέσσερις στρατηγικές για τις ελληνικές αγορές τιμής και φορτίου, με ορίζοντα $H = 24$ ώρες (ημερήσιος κύκλος DAM). Η στρατηγική TF δεν εμφανίζεται ρητά στο σχήμα της βιβλιογραφίας γιατί θεωρείται ειδική περίπτωση της Recursive που χρησιμοποιεί *πραγματικές* υστερήσεις αντί προβλέψεων κατά την αξιολόγηση.



Σχήμα 2.5. Στρατηγικές πολυβηματικής πρόβλεψης. **Αριστερά:** η γενική ταξινόμηση της βιβλιογραφίας [1], με τις βασικές στρατηγικές (Recursive, Direct, MIMO) και τις υβριδικές παραλλαγές (DirRec, DIRM). **Δεξιά:** οι τέσσερις στρατηγικές που αξιολογούνται στην παρούσα εργασία: **Teacher-Forcing (TF)**, **Recursive (Rec)**, **Direct** και **MIMO**.

Δικαιοσύνη σύγκρισης και το «κόστος του ορίζοντα». Οι τέσσερις στρατηγικές δεν διαθέτουν το ίδιο σύνολο πληροφορίας τη στιγμή της πρόβλεψης, γεγονός που καθιστά παραπλανητική την άμεση αντιπαραβολή των απόλυτων σφαλμάτων τους. Το Teacher-Forcing «βλέπει» την πραγματική τιμή της αμέσως προηγούμενης ώρας σε κάθε βήμα, ενώ τα MIMO και Direct προβλέπουν ολόκληρο το 24ωρο από μία και μόνη αφετηρία (το τέλος της προηγούμενης ημέρας), χωρίς πρόσβαση σε ενδοημερήσιες πραγματικές τιμές. Αυτή η ασυμμετρία (το «κόστος του ορίζοντα») σημαίνει ότι ένα σφάλμα MIMO δεν είναι άμεσα συγκρίσιμο με ένα σφάλμα TF. Η *δίκαιη* αναφορά για τις στρατηγικές μίας αφετηρίας (MIMO/Direct) είναι το **Naive-24**, η τιμή της ίδιας ώρας την προηγούμενη ημέρα, που μοιράζεται ακριβώς το ίδιο σύνολο πληροφορίας. Ένα μοντέλο MIMO αποδεικνύει προστιθέμενη αξία όταν ξεπερνά το Naive-24, και όχι όταν συγκρίνεται με το oracle TF. Η παρούσα εργασία υιοθετεί αυτή την αρχή κατά την ερμηνεία των αποτελεσμάτων (Κεφάλαιο 6).

2.6 Scheduled Sampling

Η τεχνική Scheduled Sampling (SS) προτάθηκε αρχικά για αναδρομικά νευρωνικά δίκτυα [30] ως ενδιάμεση λύση μεταξύ Teacher-Forcing (εκπαίδευση) και Recursive (συμπέρασμα). Το πρόβλημα που αντιμετωπίζει είναι η *έκθεση σε μεροληψία (exposure bias)*: κατά την εκπαίδευση το μοντέλο βλέπει πάντα τις πραγματικές προηγούμενες τιμές, ενώ κατά την εκτέλεση τροφοδοτείται με τις δικές του προβλέψεις. Έτσι τα πρώιμα σφάλματα συσσωρεύονται και η ακολουθία αποκλίνει σταδιακά [30]. Ως στρατηγική *σταδιακής μάθησης (curriculum learning)*, η μέθοδος μεταβαίνει ομαλά από την πλήρως καθοδηγούμενη εκπαίδευση με πραγματικές τιμές προς ένα σχήμα που στηρίζεται κυρίως στις παραγόμενες τιμές του ίδιου του μοντέλου. Κατά τη διάρκεια εκπαίδευσης, κάθε εισερχόμενη υστέρηση επιλέγεται τυχαία:

$$x_t = \begin{cases} y_{t-1} & \text{με πιθανότητα } \varepsilon_t \\ \hat{y}_{t-1} & \text{με πιθανότητα } 1 - \varepsilon_t \end{cases} \quad (2.12)$$

Η παράμετρος ε_t μειώνεται μονότονα κατά την εκπαίδευση (*annealing*): ξεκινά από $\varepsilon_0 = 1$ (καθαρό Teacher-Forcing) και φτάνει στο $\varepsilon_T \approx 0$ (πλήρης αναδρομική πρόβλεψη). Στην αρχική διατύπωση,

το πρόγραμμα μείωσης του ε μπορεί να είναι γραμμικό, εκθετικό ή αντίστροφης σιγμοειδούς μορφής [30]. Έτσι το μοντέλο εκπαιδεύεται στις συνθήκες που θα συναντήσει κατά την εκτέλεση και γίνεται ανθεκτικό (*robust*) απέναντι στα σφάλματα που συσσωρεύει κατά την αναδρομική πρόβλεψη.

Στην παρούσα εργασία, το Scheduled Sampling επεκτείνεται στους αλγόριθμους Gradient Boosting (LightGBM, XGBoost, Random Forest), ακολουθώντας ανάλογη λογική: κατά την εκπαίδευση, τα αναδρομικά χαρακτηριστικά υστέρησης αντικαθίστανται με προβλέψεις του ίδιου του μοντέλου με πιθανότητα ε_t . Εδώ το ε δηλώνει την πιθανότητα να αντικατασταθεί μια πραγματική υστέρηση από την αντίστοιχη πρόβλεψη του μοντέλου (*sampling probability*), δηλαδή αντίστροφα από την αρχική διατύπωση όπου το ε ήταν η πιθανότητα χρήσης της πραγματικής τιμής. Ακολουθώντας γραμμικό πρόγραμμα, η ε_t αυξάνεται από 0,10 σε 0,40 στις τρεις επαναλήψεις (*SS iterations*), ισορροπώντας τη διόρθωση προς αναδρομικές συνθήκες με τη διατήρηση σήματος από τις πραγματικές τιμές.

2.7 Walk-Forward Μηνιαία Επανεκπαίδευση

Η στατική εκπαίδευση ενός μοντέλου σε σταθερό παράθυρο ιστορικών δεδομένων αδυνατεί να προσαρμοστεί σε αλλαγές καθεστώτος (*regime shifts*) της αγοράς. Στην ελληνική αγορά, η τιμή ηλεκτρισμού παρουσίασε ακραία μεταβλητότητα κατά την περίοδο 2021–2022 (ενεργειακή κρίση) και σταθεροποίηση το 2024–2025, με αποτέλεσμα ένα μοντέλο που εκπαιδεύτηκε σε ολόκληρη αυτή την περίοδο να αποτυγχάνει να αντικατοπτρίσει τις τρέχουσες συνθήκες.

Η *Walk-Forward Μηνιαία Επανεκπαίδευση* λύνει αυτό το πρόβλημα με ένα επεκτεινόμενο παράθυρο δεδομένων: πριν από κάθε μήνα δοκιμής m , το μοντέλο επανεκπαιδεύεται σε όλα τα διαθέσιμα ιστορικά δεδομένα έως και το τέλος του προηγούμενου μήνα:

$$\mathcal{D}_m = \{(x_t, y_t) : t \leq T_m\}, \quad T_{m+1} = T_m + \Delta \quad (2.13)$$

όπου Δ είναι ο αριθμός των ωρών ενός μήνα (συνήθως 720–744 ώρες) και T_m ο χρόνος τερματισμού εκπαίδευσης για τον μήνα m . Σε κάθε κύκλο, το μοντέλο ενσωματώνει τα πιο πρόσφατα μοτίβα χωρίς να «ξεχνά» την ιστορική πληροφορία. Η προσέγγιση διαφέρει από το rolling window, όπου τα πιο παλαιά δεδομένα αφαιρούνται ενώ εδώ το σύνολο εκπαίδευσης διαρκώς αυξάνεται.

Η επανεκπαίδευση ενσωματώνει άμεσα στο μοντέλο τις πρόσφατες μεταβολές στα μοτίβα τιμής και φορτίου, μειώνοντας σημαντικά το σφάλμα σε περιόδους αλλαγής καθεστώτος. Στο πλαίσιο της παρούσας εργασίας, η Walk-Forward Μηνιαία Επανεκπαίδευση αξιολογείται για τρεις μήνες (Δεκέμβριος 2025, Ιανουάριος 2026, Φεβρουάριος 2026) και συγκρίνεται με τα αντίστοιχα στατικά μοντέλα, καταγράφοντας βελτίωση έως 30% στο MAE.

2.8 Σύνθεση και Τοποθέτηση της Παρούσας Εργασίας

Ο Πίνακας 2.1 συνοψίζει αντιπροσωπευτικές εργασίες πρόβλεψης τιμής [Electricity Price Forecasting (EPF)] και φορτίου [Electricity Load Forecasting (ELF)], με την περιοχή μελέτης, τους αλγόριθμους, τον ορίζοντα και τη στρατηγική πρόβλεψης κάθε εργασίας, και τοποθετεί την παρούσα εργασία ως προς αυτές (τελευταία γραμμή). Η ποσοτική αντιπαραβολή των ευρημάτων αναπτύσσεται στο Κεφάλαιο 6. Κάθε αριθμητική σύγκριση MAE μεταξύ εργασιών είναι ενδεικτική και όχι αυστηρή, καθώς οι μελέτες διαφέρουν ως προς την περίοδο δοκιμής, την αγορά, το σύνολο χαρακτηριστικών και τον ορισμό σφάλματος.

Συγγραφέας (Έτος)	Στόχος	Περιοχή (Dataset)	Μέθοδοι	Ορίζοντας	Στρατηγική
Kontraros (2023) [12]	Τιμή	Ελλάδα (EXE)	Ridge, Lasso, Random Forest, LSTM, Quantile Regression Forest	Day-Ahead (24h)	Ντετερμινιστική & πιθανοτική
Kanousis (2025) [11]	Τιμή	Ελλάδα (EXE / ENTSO-E)	SARIMAX, Random Forest, XGBoost, LSTM	Day-Ahead (24h)	Rolling-origin (TF, Rec, MIMO, Direct)
Μαγκλαράς (2018) [21]	Φορτίο	Ελλάδα (ΔΕΔΔΗΕ) & Ιταλία (Trento)	LSTM, MLP, CNN, ANN	VSTLF / STLF	Recursive, Direct, MIMO, υβριδική
Michalakopoulos et al. (2025) [31]	Τιμή	Ελλάδα, Βέλγιο, Ιρλανδία	LSTM (FFEC), XGBoost, LightGBM, CatBoost	Day-Ahead (24h)	Short training windows (point)
Zelios et al. (2025) [32]	Φορτίο	Ελλάδα	RNN, LSTM, GRU	1h, 2h, 24h	Μεταβλητό μήκος ακολουθίας (point)
Shiblee & Koukaras (2025) [33]	Φορτίο	Ελλάδα (δίκτυο διανομής)	CNN, LSTM, GRU, CNN-LSTM, LightGBM	STLF (24h)	Επιβλεπόμενη μάθηση (point)
Lago et al. (2021) [8]	Τιμή	Ευρώπη (Nord Pool, EPEX, PJM)	Deep Learning (DNN), LEAR	Day-Ahead (24h)	Ολισθαίνον παράθυρο
Hirsch et al. (2024/2025)	Τιμή	Ισπανία, Γερμανία & Λουξεμβούργο	RLin, MLP, FLin, LEAR, DNN, Ensemble (BOA)	Day-Ahead (24h)	Ολισθαίνον παράθυρο (Ensemble)
Kızıldağ et al. (2024) [34]	Τιμή	Τουρκία	Στατιστικές & AI μέθοδοι	Day-Ahead (24h)	Στατιστική ανάλυση & AI (point)
Narajewski & Ziel (2022)	Τιμή	Ευρωπαϊκές αγορές	Probabilistic DNN, LEAR, Ensemble	Day-Ahead & intraday	Πιθανοτική (rolling, Ensemble)
Nikolaïdis (2024)	Φορτίο (res.)	Κύπρος (CERA)	Νευρωνικά δίκτυα (Levenberg-Marquardt)	Day-Ahead (24h)	MIMO
Παρούσα εργασία	Τιμή & φορτίο	Ελλάδα (EXE / ΑΔΜΗΕ)	LightGBM, XGBoost, RF, MLP, SVR, Ensembles	Day-Ahead (24h)	TF, Rec, MIMO, Direct, Walk-Forward MR

Πίνακας 2.1. Αντιπροσωπευτικές εργασίες EPF/ELF και τοποθέτηση της παρούσας εργασίας.

3. Δεδομένα και Μηχανική Χαρακτηριστικών

Η ποιότητα, η πληρότητα και η επεξεργασία των δεδομένων καθορίζουν την απόδοση κάθε μοντέλου μηχανικής μάθησης, ιδιαίτερα στην EPF όπου οι χρονοσειρές εμφανίζουν έντονη μη γραμμικότητα, πολλαπλή εποχικότητα και ακραίες τιμές (price spikes) [35]. Στην παρούσα εργασία αντλούνται δεδομένα από οκτώ ξεχωριστές πηγές, που καλύπτουν την περίοδο Ιανουάριος 2017 - Μάρτιος 2026 με ωριαία ανάλυση. Η ανομοιογένεια των πηγών (διαφορετικές χωρικές κλίμακες, ημερήσια αντί ωριαία ανάλυση, διαφορετικές ζώνες ώρας, κενές τιμές) απαιτεί ενιαία διοχέτευση κανονικοποίησης και συγχώνευσης πριν την κατασκευή χαρακτηριστικών.

Το παρόν κεφάλαιο αναλύει διαδοχικά: (α) τις πηγές ακατέργαστων δεδομένων και τη δομή τους, (β) τον αγωγό κανονικοποίησης και συγχώνευσης, (γ) τη μηχανική χαρακτηριστικών, (δ) την αντιμετώπιση διαρροής δεδομένων, (ε) τον τελικό πίνακα χαρακτηριστικών και (στ) τον διαχωρισμό εκπαίδευσης/αξιολόγησης.

3.1 Πηγές Ακατέργαστων Δεδομένων

Ο Πίνακας 3.1 συνοψίζει τις οκτώ πηγές δεδομένων που χρησιμοποιούνται στην εργασία, με αναφορά στην κάθε πηγή και τον σύνδεσμο πρόσβασης.

Πίνακας 3.1. Πηγές ακατέργαστων δεδομένων.

Δεδομένα	Ανάλυση	Πηγή	Σύνδεσμος
Τιμές DAM (€/MWh)	Ωριαία	ENTSO-E Transparency Platform [36]	transparency.entsoe.eu
Πραγματικό Φορτίο (MW)	Ωριαία	ENTSO-E Transparency Platform [36]	transparency.entsoe.eu
Παραγωγή ανά Τεχνολογία (MW)	15 λεπτά	ENTSO-E Transparency Platform [36]	transparency.entsoe.eu
Τιμή Φυσικού Αερίου TTF (€/MWh)	Ημερήσια	Investing.com [37]	investing.com
Τιμή CO ₂ EUA (€/τ)	Ημερήσια	Investing.com [38]	investing.com
Προβλέψεις day-ahead	ΑΠΕ Ωριαία	ENTSO-E Transparency Platform [36]	transparency.entsoe.eu
Μετεωρολογικά (6 τοποθεσίες)	Ωριαία	Open-Meteo API [39]	open-meteo.com/api
Πρόβλεψη ΑΔΜΗΕ Φορτίου	Ωριαία	ΑΔΜΗΕ / proxy load_lag24	admie.gr

3.1.1 Τιμές Αγοράς Επόμενης Ημέρας — ENTSO-E DAM

Οι ωριαίες τιμές εκκαθάρισης της αγοράς επόμενης ημέρας (DAM) για τη Ζώνη Τιμολόγησης Ελλάδας (BZN|GR) αντλούνται από την πλατφόρμα ENTSO-E Transparency Platform [36]. Τα ακατέργαστα δεδομένα αποθηκεύονται τοπικά σε 11 αρχεία CSV της μορφής

`GUI_ENERGY_PRICES_YYYYMMDD-YYYYMMDD.csv`, που καλύπτουν το διάστημα Δεκέμβριος 2014 - Μάρτιος 2026. Κάθε εγγραφή αντιστοιχεί σε μία ώρα λειτουργίας και εκφράζεται σε €/MWh.

Από το 2024 και εξής, η ENTSO-E μετάβηκε σε ανάλυση 15 λεπτών για την Ελλάδα, αποδίδοντας 4 τιμές ανά ώρα αντί μίας. Στο πλαίσιο της παρούσας εργασίας, η χρονική ανάλυση ορίστηκε ωριαία σε ολόκληρο τον ορίζοντα μελέτης. Η μετατροπή γίνεται αυτόματα: οι χρονοσφραγίδες στρογγυλοποιούνται στην πλησιέστερη ώρα (`floor("H")`) και οι 4 τετάρτωρες τιμές συγχωνεύονται σε μία ωριαία τιμή μέσω αριθμητικού μέσου. Για τα παλαιότερα δεδομένα ωριαίας ανάλυσης, η λειτουργία αυτή παραμένει διαφανής. Η ίδια λογική εφαρμόζεται και στα δεδομένα φορτίου. Η σειρά τιμών είναι ο στόχος πρόβλεψης y_t για την εργασία EPF.

3.1.2 Πραγματικό Ηλεκτρικό Φορτίο — ENTSO-E

Τα ωριαία δεδομένα πραγματικής κατανάλωσης ηλεκτρικής ενέργειας (Actual Total Load) για την Ελλάδα σε MW αντλούνται επίσης από το ENTSO-E Transparency Platform [36]. Τα ακατέργαστα αρχεία CSV βρίσκονται στον κατάλογο `data/raw/load/` και καλύπτουν Ιανουάριο 2015 - Μάρτιο 2026. Εφαρμόζεται η ίδια λογική χειρισμού δεδομένων 15 λεπτών (`mean()`) με αυτήν της σειράς τιμών.

Η σειρά φορτίου έχει διπλό ρόλο: αφενός είναι ο στόχος πρόβλεψης y_t για την εργασία STLF, αφετέρου χρησιμεύει ως εξωγενές χαρακτηριστικό στα μοντέλα τιμής, υπό τη μορφή χρονικά καθυστερημένων τιμών (βλ. Ενότητα 3.4.2).

3.1.3 Πραγματική Παραγωγή ανά Τύπο Τεχνολογίας — ENTSO-E

Τα δεδομένα παραγωγής ηλεκτρικής ενέργειας ανά τύπο τεχνολογίας σε MW αντλούνται από το ENTSO-E Transparency Platform [36]. Τα αρχεία (`AGGREGATED_GENERATION_PER_TYPE_*.csv`) καλύπτουν Δεκέμβριο 2014 - Μάρτιο 2026 σε ανάλυση 15 λεπτών. Εντός της διαδικασίας επεξεργασίας, κάθε αρχείο CSV αναπτύσσεται σε πίνακα με τη χρήση `pivot_table` (index: χρονική σφραγίδα, columns: τύπος τεχνολογίας, aggfunc: "sum"), παράγοντας πέντε στήλες: `gen_solar`, `gen_wind`, `gen_gas`, `gen_lignite`, `gen_hydro`. Τα δεδομένα αυτά αντιπροσωπεύουν πραγματοποιηθείσα παραγωγή που δεν είναι γνωστή τη στιγμή υποβολής προσφορών (D-1, ~12:00 CET) και χρησιμοποιούνται αποκλειστικά υπό χρονική καθυστέρηση (βλ. Ενότητα 3.4.5).

3.1.4 Τιμή Φυσικού Αερίου — Dutch TTF Futures (Ημερήσια)

Η ημερήσια τιμή φυσικού αερίου αντλείται από τα συμβόλαια μελλοντικής εκπλήρωσης του δείκτη Dutch TTF (Title Transfer Facility), που αποτελεί τον κυρίαρχο ευρωπαϊκό δείκτη αναφοράς για τη χονδρική αγορά αερίου [37]. Τα δεδομένα λήφθηκαν χειροκίνητα από την πλατφόρμα Investing.com, εκφράζονται σε €/MWh και χρησιμοποιούνται αποκλειστικά στην εργασία τιμής. Κατά τη συγχώνευση, οι ημερήσιες τιμές επεκτείνονται με `ffill()` σε ωριαία ανάλυση.

Δεδομένου ότι η παραγωγή από φυσικό αέριο συχνά καθορίζει οριακά την τιμή εκκαθάρισης στην ελληνική αγορά, η τιμή TTF ασκεί ισχυρή αιτιακή επίδραση στη DAM [8]. Για το διάστημα Νοέμβριος 2025 - Φεβρουάριος 2026 χρησιμοποιήθηκαν συνθετικές τιμές με γραμμική παρεμβολή μεταξύ σημείων αναφοράς (Δεκ. 2025: 46 €/MWh, Ιαν. 21, 2026: 36,77 €/MWh, Φεβ. 20, 2026: 35 €/MWh). Επειδή η παρεμβολή βασίζεται σε μεταγενέστερα σημεία αναφοράς, εισάγει ήπια εξάρτηση από το μέλλον (look-ahead) στο χαρακτηριστικό `gas_price` για το διάστημα δοκιμής· ο περιορισμός αυτός και η ενδεδειγμένη αντιμετώπισή του (αντικατάσταση με πραγματικά δεδομένα TTF) συζητούνται στο Κεφάλαιο 8.

3.1.5 Τιμή Δικαιωμάτων CO₂ — EU ETS Futures (Ημερήσια)

Οι ημερήσιες τιμές δικαιωμάτων εκπομπών CO₂ αντλήθηκαν από την πλατφόρμα Investing.com και αντιστοιχούν στα συμβόλαια EUA (European Union Allowance) του EU ETS, εκφρασμένες σε €/τόνο CO₂ [38]. Το κόστος CO₂ ενσωματώνεται ως μεταβλητό κόστος παραγωγής για κάθε μονάδα που χρησιμοποιεί ορυκτά καύσιμα και χρησιμοποιείται αποκλειστικά για `task=price`. Η επέκτασή του σε ωριαία ανάλυση ακολουθεί το ίδιο σχήμα `ffill()` με την τιμή αερίου. Η χρήση σύγχρονων ημερήσιων τιμών καυσίμων αποτελεί οριακή επιλογή από πλευρά `leakage`, αποδεκτή στη βιβλιογραφία EPF [8].

3.1.6 Προβλέψεις Παραγωγής Επόμενης Ημέρας — ENTSO-E Extra

Ωριαίες προβλέψεις παραγωγής από ΑΠΕ για την επόμενη ημέρα (`day-ahead`) (`solar/wind/gen_fc_dayahead`), έτσι όπως δημοσιεύονται από τη ENTSO-E πριν τη διεξαγωγή της DAM, φορτώνονται από `data/processed/entsoe_extra_hourly.parquet` (71.640 παρατηρήσεις, Οκτ. 2017 - Δεκ. 2025). Τα δεδομένα αυτά αποτελούν νόμιμα σύγχρονα χαρακτηριστικά: δημοσιεύονται πριν την υποβολή προσφορών. Για κάθε στήλη δημιουργείται δυαδικός δείκτης απόντος (`*_missing`), παράγοντας 6 συνολικές στήλες.

3.1.7 Μετεωρολογικά Δεδομένα — Open-Meteo API

Ωριαία μετεωρολογικά δεδομένα αντλούνται από τη δωρεάν ιστορική API της υπηρεσίας Open-Meteo [39]. Τα επεξεργασμένα δεδομένα αποθηκεύονται στο `data/processed/weather_gr_hourly.parquet` (73.416 παρατηρήσεις, Οκτ. 2017 - Μαρ. 2026). Για κάθε μία από τις έξι γεωγραφικές τοποθεσίες (`gr_mean`, Αθήνα, Θεσσαλονίκη, Πάτρα, Λάρισα, Ηράκλειο) αντλούνται επτά μετεωρολογικές μεταβλητές (θερμοκρασία, υγρασία, κατακρημνίσματα, νεφοκάλυψη, ταχύτητα ανέμου, ριπές ανέμου, ηλιακή ακτινοβολία), αποδίδοντας $6 \times 7 = 42$ πρωτογενείς στήλες. Για κάθε στήλη δημιουργείται δυαδικός δείκτης απόντος, οδηγώντας σε 84 συνολικές στήλες. Τα κενά συμπληρώνονται σε δύο βήματα: `ffill(limit=6)` και ακολούθως συμπλήρωση με μηδενικά (`zero-fill`). Η συμπλήρωση με μηδενικά είναι συνήθης πρακτική όταν συνοδεύεται από δυαδικούς δείκτες απουσίας: τα δένδρικά μοντέλα μπορούν τότε να διακρίνουν μια πραγματική μηδενική τιμή από μια ελλείπουσα, χωρίς να εισάγεται μεροληψία από τεκμαρτές τιμές.

3.1.8 Πρόβλεψη Φορτίου Επόμενης Ημέρας (`load_fc`)

Η ωριαία `day-ahead` πρόβλεψη φορτίου που δημοσιεύει ο ΑΔΜΗΕ αποτελεί νόμιμο σύγχρονο χαρακτηριστικό αποκλειστικά για `task=price`. Το αρχείο `data/processed/load_forecast_hourly.parquet` (Οκτ. 2025 - Δεκ. 2025, 2.207 ώρες) δεν καλύπτει ολόκληρο το εκπαιδευτικό εύρος· για αυτό εφαρμόζεται υποκατάστατο (`proxy`) με `load_lag24` (πραγματικό φορτίο ίδιας ώρας 24 ώρες νωρίτερα). Αξιολόγηση έδειξε ότι η αντικατάσταση ακριβέστερης πρόβλεψης (MAE = 80,7 MW) με την ENTSO-E πρόβλεψη (MAE = 267 MW) μεταβάλλει το τελικό MAE τιμής κατά $< 0,1\%$, υποδηλώνοντας ότι τα μοντέλα τιμής βασίζονται κυρίως στις χρονικές υστερήσεις τιμής και στα επίπεδα καυσίμων.

3.2 Κανονικοποίηση Χρονικού Δείκτη

Μία από τις σημαντικότερες προκλήσεις κατά τη συγχώνευση ανομοιογενών πηγών είναι η αντιμετώπιση ανακολουθιών στη χρονική ανάλυση και τη ζώνη ώρας. Η διοχέτευση εφαρμόζει δύο

βοηθητικές συναρτήσεις πριν από κάθε join.

Η `_ensure_hourly_index()` μετατρέπει τον δείκτη κάθε σειράς δεδομένων σε `pd.DatetimeIndex`, εφαρμόζει `floor("H")`, ταξινομεί χρονολογικά και αφαιρεί τιμές `NaT`. Εάν υπάρχουν πολλαπλές εγγραφές για την ίδια ώρα (π.χ. δεδομένα 15 λεπτών), εφαρμόζεται `groupby(level=0).mean()`, ο οποίος υπολογίζει τον αριθμητικό μέσο όρο των τιμών, εξασφαλίζοντας ότι η τελική εγγραφή κάθε ώρας αντιπροσωπεύει αξιόπιστα τις πραγματικές συνθήκες.

Η `_to_utc_naive_index()` αντιμετωπίζει τις ζώνες ώρας: μετατρέπεται πρώτα σε UTC και στη συνέχεια αφαιρείται η πληροφορία ζώνης (UTC-naive), ώστε να αποτραπούν διπλές ή κενές εγγραφές κατά τις αλλαγές θερινής/χειμερινής ώρας. Κατά τη συγχώνευση, ο αγωγός ανιχνεύει αυτόματα πιθανή μετατόπιση ζώνης ώρας, δοκιμάζοντας $\Delta \in \{-3, \dots, +3\}$ ωρών.

3.3 Διοχέτευση Επεξεργασίας Δεδομένων

Η μετατροπή των ακατέργαστων πηγών στον τελικό πίνακα χαρακτηριστικών γίνεται σε πέντε διαδοχικές φάσεις, που συνοψίζονται γραφικά στο Σχήμα 3.1 (Ενότητα 3.4.7).

Η κεντρική συνάρτηση `process_hourly()` του `src/data.py` διαχειρίζεται ολόκληρη τη διοχέτευση, εκτελούμενη ξεχωριστά για `task=price` και `task=load`. Οι δύο εκδοχές μοιράζονται τον ίδιο πυρήνα επεξεργασίας αλλά διαφέρουν στις εξωγενείς μεταβλητές: η εκδοχή `task=price` ενσωματώνει τις μεταβλητές καυσίμων και την πρόβλεψη φορτίου, τις οποίες η `task=load` παραλείπει εξ ορισμού.

3.4 Μηχανική Χαρακτηριστικών

Ο πίνακας χαρακτηριστικών κατασκευάζεται αποκλειστικά από πληροφορίες γνωστές κατά τον πραγματικό χρόνο πρόβλεψης ($D-1$). Κάθε παρατήρηση (x_t, y_t) αντιστοιχεί σε μία ώρα t , με $x_t \in \mathbb{R}^d$ και y_t την τιμή-στόχο σε €/MWh ή MW.

3.4.1 Ημερολογιακά Χαρακτηριστικά

Τα ημερολογιακά χαρακτηριστικά αποτυπώνουν γνωστές εκ των προτέρων δομές εποχικότητας και ανθρώπινης δραστηριότητας [19]. Η ώρα ημέρας $h \in \{0, \dots, 23\}$ και η ημέρα εβδομάδας $d \in \{0, \dots, 6\}$ κωδικοποιούνται κυκλικά:

$$\left(\sin \frac{2\pi h}{24}, \cos \frac{2\pi h}{24}, \sin \frac{2\pi d}{7}, \cos \frac{2\pi d}{7} \right), \quad (3.1)$$

εξασφαλίζοντας γεωμετρική συνέχεια μεταξύ ώρας 23 και ώρας 0. Επιπλέον συμπεριλαμβάνεται δυαδική μεταβλητή ελληνικών αργιών (`is_holiday`) από τη βιβλιοθήκη `holidays.Greece()`. Η ομάδα αυτή αποδίδει 7 χαρακτηριστικά, κοινά για τις δύο εργασίες.

3.4.2 Χρονικά Καθυστερημένα Χαρακτηριστικά

Ο κύριος κορμός του πίνακα χαρακτηριστικών αποτελείται από χρονικά καθυστερημένες τιμές. Το κεντρικό σύνολο υστερήσεων που εφαρμόζεται σε όλες τις κύριες χρονοσειρές είναι:

$$L = \{1, 2, 3, 6, 12, 24, 48, 168\} \quad (\text{ώρες}), \quad (3.2)$$

επιλεγμένο ώστε να αποτυπωθεί η βραχυπρόθεσμη δυναμική (lags 1-3), οι ιδιαιτερότητες αιχμής/εκτός αιχμής (lags 6, 12), η ημερήσια περιοδικότητα (lags 24, 48) και η εβδομαδιαία εποχικότητα (lag 168). Η τιμή y_{t-168} είναι ισχυρό αναλλοίωτο χαρακτηριστικό στη βιβλιογραφία EPF [19].

Πίνακας 3.2. Σύνολα υστερήσεων ανά σήμα.

Σήμα	Περιγραφή	Σύνολο	# lags
y	Τιμή DAM ή φορτίο (στόχος)	L	8
load	Πραγματικό φορτίο	L	8
residual_load	Φορτίο μείον ΑΠΕ παραγωγή	L	8
gas_price	Τιμή φυσικού αερίου TTF	L	8
co2_price	Τιμή δικαιωμάτων CO ₂	L	8
gen_solar	Παραγωγή ηλιακή	$L' = \{1, 2, 24, 48, 168\}$	5
gen_wind	Παραγωγή αιολική	$L' = \{1, 2, 24, 48, 168\}$	5

Η υπολειμματική ζήτηση ορίζεται ως $\text{residual_load}_t = \text{load}_t - \text{gen_solar}_t - \text{gen_wind}_t$ και αποτυπώνει το τμήμα κατανάλωσης που πρέπει να καλυφθεί από συμβατικές μονάδες, ως ένδειξη οριακής ζήτησης.

3.4.3 Κυλιόμενα Στατιστικά

Για τον στόχο y υπολογίζονται δύο κυλιόμενοι μέσοι:

$$y_{\text{roll}24,t} = \frac{1}{24} \sum_{k=1}^{24} y_{t-k}, \quad (3.3)$$

$$y_{\text{roll}168,t} = \frac{1}{168} \sum_{k=1}^{168} y_{t-k}. \quad (3.4)$$

Ο χρόνος ολίσθησης ξεκινά από $k = 1$ ώστε να μην περιλαμβάνεται η τρέχουσα τιμή y_t , αποτρέποντας διαρροή. Το $y_{\text{roll}24}$ λειτουργεί ως μέτρο βραχυπρόθεσμης τάσης, ενώ το $y_{\text{roll}168}$ καταγράφει το εβδομαδιαίο εποχικό επίπεδο.

3.4.4 Δείκτες Απόντων Τιμών

Για κάθε στήλη που ενδέχεται να εμφανίζει κενές τιμές (42 μετεωρολογικές + 3 ENTSO-E day-ahead), δημιουργείται δυαδική στήλη `{col}_missing` που λαμβάνει τιμή 1 εάν η αρχική τιμή απουσίαζε. Η τεχνική αυτή επιτρέπει στα μοντέλα να διακρίνουν μεταξύ «η τιμή είναι μηδέν» και «η τιμή είναι άγνωστη» [26].

3.4.5 Αντιμετώπιση Διαρροής Δεδομένων

Η διαρροή δεδομένων (data leakage) [35] είναι ένα από τα πιο συχνά και σοβαρά μεθοδολογικά σφάλματα στην εφαρμοσμένη πρόβλεψη χρονοσειρών και οδηγεί σε αισιόδοξες αλλά μη αναπαραγώγιμες εκτιμήσεις απόδοσης. Στην παρούσα εργασία εφαρμόζεται ρητή διόρθωση leakage σε δύο επίπεδα.

Εργασία τιμής. Κατά τη στιγμή υποβολής προσφορών (D-1, ~12:00 CET), οι ποσότητες της επόμενης ημέρας δεν έχουν πραγματοποιηθεί. Ο αγωγός αφαιρεί τις σύγχρονες ($t = 0$) τιμές των: load,

residual_load, gen_solar, gen_wind, gen_gas, gen_lignite, gen_hydro. Οι χρονικά καθυστερημένες εκδοχές ($k \geq 1$) παραμένουν.

Εργασία φορτίου. Αφαιρούνται οι σύγχρονες τιμές των: price, residual_load, gen_solar, gen_wind, gen_gas, gen_lignite, gen_hydro.

Cross-Validation χωρίς διαρροή. Κατά τη βελτιστοποίηση υπερπαραμέτρων με Optuna, το cross-validation εκτελείται με rolling-origin σχήμα: ο επικυρωτής πάντα ακολουθεί χρονικά [40], αποτρέποντας τη «διαρροή μέλλοντος».

3.4.6 Πυκνές Ενδοημερήσιες Υστερήσεις (Dense Intraday Lags) — Μόνο για MIMO/Direct

Το βασικό σύνολο L δεν περιλαμβάνει τις ενδοημερήσιες υστερήσεις lag-4 έως lag-23 (εκτός των ήδη υπαρχόντων lag-6 και lag-12), δηλαδή 18 επιπλέον υστερήσεις. Οι στρατηγικές MIMO και Direct προβλέπουν ολόκληρο το 24ωρο ταυτόχρονα, ως πολλαπλή έξοδο και από μία μόνο αφετηρία, χωρίς αναδρομική τροφοδότηση· έτσι όλες οι ενδοημερήσιες τιμές $y_{t-4}, \dots, y_{t-23}$ είναι ήδη γνωστές, παρατηρημένες τιμές τη στιγμή της πρόβλεψης. Επειδή συνιστούν καθαρή ιστορική πληροφορία και όχι προβλέψεις, προστίθενται ως *πυκνές υστερήσεις* (dense lags) και εμπλουτίζουν την περιγραφή της ενδοημερήσιας δυναμικής:

- Βασικό σύνολο (TF/Rec): 152 χαρακτηριστικά (τιμή) / 133 (φορτίο).
- Dense σύνολο (MIMO/Direct): $152 + 18 = 170$ (τιμή) / $133 + 18 = 151$ (φορτίο).

Στα MIMO/Direct οι dense lags παρέχουν αυτή την καθαρή ενδοημερήσια πληροφορία χωρίς συσσωρευμένο σφάλμα. Στη Recursive στρατηγική, αντίθετα, οι ίδιες υστερήσεις θα συμπληρώνονταν από προβλέψεις του ίδιου του μοντέλου και θα μετέφεραν συσσωρευμένο σφάλμα· γι' αυτό η προσθήκη τους επιδεινώνει την απόδοση (βλ. Κεφάλαιο 6).

3.4.7 Τελικός Πίνακας Χαρακτηριστικών

Ο Πίνακας 3.4 συνοψίζει τις ομάδες χαρακτηριστικών ανά εργασία. Μετά το `dropna()`, τα επεξεργασμένα αρχεία αποθηκεύονται:

Πίνακας 3.3. Επεξεργασμένα αρχεία Parquet μετά τη φάση 5 του αγωγού.


Αρχείο	Εργασία	Γραμμές	Στήλες	Κάλυψη
hourly.parquet	τιμή	80.126	153	27/01/2017 - 20/03/2026
hourly_load.parquet	φορτίο	98.054	134	08/01/2015 - 19/03/2026

Η στήλη «Στήλες» μετρά το σύνολο των στηλών του αρχείου, συμπεριλαμβανομένου του στόχου y . Η `make_xy()` αφαιρεί τον στόχο, οπότε τα διαθέσιμα χαρακτηριστικά είναι 152 (τιμή) και 133 (φορτίο):
 $153 \text{ στήλες} = 152 \text{ χαρακτηριστικά} + \text{στόχος}$, αντίστοιχα $134 = 133 + \text{στόχος}$ (πρβλ. Πίν. 3.4).

Συνολικά, η διοχέτευση εναρμονίζει τις οκτώ ακατέργαστες πηγές σε ενιαία UTC-naive ωριαία ανάλυση και τις διοχετεύει στις πέντε διαδοχικές φάσεις επεξεργασίας, παράγοντας τους δύο πίνακες χαρακτηριστικών που αποθηκεύονται χωριστά σε μορφή `.parquet` για τιμή και φορτίο. Το Σχήμα 3.1 αποτυπώνει αυτή τη ροή από τις πηγές (αριστερά) στον τελικό πίνακα (δεξιά).

Πίνακας 3.4. Ομάδες χαρακτηριστικών, αριθμός μεταβλητών ανά εργασία.

Ομάδα	Περιγραφή	Τιμή	Φορτίο
Ημερολογιακά	hour_sin/cos, dow_sin/cos, hour, dow, is_holiday	7	7
Lags στόχου y	y_{t-k} για $k \in L$, y_roll24 , $y_roll168$	10	10
Lags φορτίου	$load_{t-k}$ για $k \in L$	8	8
Πρόβλεψη φορτίου	load_fc (proxy: load_lag24)	1	---
Lags υπολ. ζήτησης	residual_load $_{t-k}$ για $k \in L$	8	8
Lags ΑΠΕ παραγωγής	gen_solar/wind $_{t-k}$ για $k \in L'$	10	10
Τιμές καυσίμων	gas/co2 + lags $\times 2$	18	---
Μετεωρολογικά	6 τοποθ. $\times 7$ μεταβλ. + δείκτες απόντων	84	84
ENTSO-E ΑΠΕ forecast	solar/wind/gen_fc + δείκτες απόντων	6	6
Σύνολο βασικό		152	133
Dense (MIMO/Direct)	lags y_{t-k} , $k \in \{4, 5, 7, \dots, 23\}$	+18	+18
Σύνολο dense		170	151



Σχήμα 3.1. Διοχέτευση επεξεργασίας δεδομένων πέντε φάσεων: από τις οκτώ ακατέργαστες πηγές (αριστερά) στους δύο τελικούς πίνακες χαρακτηριστικών (δεξιά).

3.5 Κατασκευή Πίνακα Εκπαίδευσης --- `make_xy()`

Πριν την εκπαίδευση κάθε μοντέλου, η `make_xy()` αφαιρεί τον στόχο y από τον πίνακα, διατηρεί αποκλειστικά αριθμητικές στήλες, αντικαθιστά τιμές $\pm\infty$ με NaN και εφαρμόζει `ffill()`. Τέλος αφαιρούνται γραμμές με NaN στον στόχο ή στα χαρακτηριστικά.

Για τη Direct στρατηγική, η `_make_supervised_xy()` κατασκευάζει πίνακα στόχου $Y \in \mathbb{R}^{N \times H}$ με στήλες $[y_{t+1}, \dots, y_{t+H}]$. Με το flag `dense_lags=True`, τα $y_{lag1}, \dots, y_{lag23}$ προστίθενται στον πίνακα X πριν το fit.

3.6 Χρονικός Διαχωρισμός Εκπαίδευσης / Αξιολόγησης

Ο διαχωρισμός εκπαίδευσης/αξιολόγησης ακολουθεί αυστηρά χρονολογική σειρά (expanding window) χωρίς τυχαιοποίηση. Στην παρούσα εργασία εφαρμόζονται τέσσερα σχήματα αξιολόγησης:

1 Μήνας (Δεκέμβριος 2025). Ίδιο σύνολο εκπαίδευσης, αξιολόγηση 744 ωρών. Επιτρέπει σύγκριση στρατηγικών ημερήσιας (24ωρης) έναντι εβδομαδιαίας (168ωρης) αρχικοποίησης.

Q1 2026 — Walk-forward μηνιαία επανεκπαίδευση. Αξιολόγηση: Dec 1, 2025 - Feb 28, 2026 (2.160 ώρες). Ο κόφτης εκπαίδευσης κυλιέται μηνιαία: {30/11/2025, 31/12/2025, 31/01/2026}. Αξιολογεί αν η συχνή ενημέρωση οδηγεί σε σημαντική βελτίωση έναντι στατικά εκπαιδευμένων μοντέλων.

Η χρήση πολλαπλών σχημάτων αξιολόγησης επιτρέπει ανάλυση ευαισθησίας ως προς τον ορίζοντα (βραχύς έναντι 3μηνου), τη σταθερότητα αγοράς (Δεκέμβριος έναντι Q4) και την προσαρμοστικότητα (στατικά έναντι walk-forward).


3.7 Περιγραφική Ανάλυση

Η κατανόηση των στατιστικών ιδιοτήτων των δύο χρονοσειρών-στόχων είναι απαραίτητη πριν την εκπαίδευση οποιουδήποτε μοντέλου. Η ανάλυση που ακολουθεί εξετάζει διαδοχικά την πλήρη χρονοσειρά, την εποχική εξέλιξη ανά έτος, τα ωριαία και εβδομαδιαία μοτίβα, τη στοχαστική δομή αυτοσυσχέτισης, τους χάρτες ενδοημερήσιας εξάρτησης, και την αλληλεπίδραση τιμής με φυσικό αέριο και ΑΠΕ.

3.7.1 Χρονοσειρά Τιμής Ηλεκτρικής Ενέργειας

Η χρονοσειρά καλύπτει περίπου εννέα χρόνια (Ιανουάριος 2017 - Νοέμβριος 2025), με σύνολο ~ 80.000 ωριαίων παρατηρήσεων. Το Σχήμα 3.2 αποτυπώνει τη σειρά σε δύο επίπεδα ανάλυσης. Στο πάνω πάνελ φαίνεται η ωριαία τιμή (μπλε) μαζί με τον 30-ήμερο κυλιόμενο μέσο (κόκκινη γραμμή), που αποκαλύπτει τις μεσοπρόθεσμες τάσεις αφαιρώντας τη βραχυπρόθεσμη διακύμανση. Η σκιασμένη περιοχή Ιουνίου 2021 έως Δεκεμβρίου 2022 σηματοδοτεί την ευρωπαϊκή ενεργειακή κρίση, κατά την οποία οι τιμές υπερέβησαν τα 300 €/MWh. Από το 2023 και εξής παρατηρείται σταδιακή επιστροφή σε προ-κρίσης επίπεδα. Το κάτω πάνελ παρουσιάζει τη μηνιαία κατανομή μέσω boxplots, που αναδεικνύει την αυξημένη διασπορά των καλοκαιρινών μηνών (Ιούλιος-Αύγουστος) και την εξαιρετική μεταβλητότητα των ετών κρίσης.

Στατιστικά, η τυπική απόκλιση της τιμής κυμαίνεται ανάλογα με το καθεστώς αγοράς: 33,6 €/MWh (Δεκέμβριος 2025, μέσος 110,4 €/MWh), 41,7 €/MWh (Ιανουάριος 2026) και 45,4 €/MWh (Φεβρουάριος 2026). Η πτώση του μέσου τον Φεβρουάριο 2026 (77,8 €/MWh έναντι 110 €/MWh τον



Σχήμα 3.2. Ωριαία τιμή ηλεκτρικής ενέργειας (€/MWh) στην ελληνική αγορά (Ιαν. 2017 - Μαρ. 2026). Πάνω: ωριαίες τιμές (μπλε) και 30-ήμερος κυλιόμενος μέσος (κόκκινος)- κίτρινη σκίαση για την περίοδο ενεργειακής κρίσης 2021-2022 και πράσινη για τα lockdown COVID-19. Κάτω: μηνιαία κατανομή τιμών (boxplots) για ολόκληρη την περίοδο.


Ιανουάριο) αποδίδεται σε αυξημένη υδροηλεκτρική παραγωγή και είναι το κεντρικό παράδειγμα μεταβολής καθεστώτος (regime shift) που αντιμετωπίζουν τα μοντέλα στα πειράματα Q1 2026.

Σε αντίθεση, το φορτίο χαρακτηρίζεται από σαφώς μικρότερη σχετική μεταβλητότητα: κυμαίνεται μεταξύ ~ 4.500 και ~ 9.000 MW με τυπική απόκλιση $\sim 18\%$ του μέσου, έναντι $\sim 40\%$ για τιμή σε Q1 2026. Αυτή η διαφορά εξηγεί γιατί τα μοντέλα φορτίου επιτυγχάνουν sMAPE $\sim 1,5\text{-}2\%$ ενώ τα μοντέλα τιμής κυμαίνονται στο $\sim 15\text{-}25\%$.

3.7.2 Χρονοσειρά Ηλεκτρικού Φορτίου

Το Σχήμα 3.3 αποτυπώνει την αντίστοιχη χρονοσειρά φορτίου με την ίδια διάταξη δύο πάνελ. Στο πάνω πάνελ η ωριαία κατανάλωση (πορτοκαλί) και ο 30-ήμερος κυλιόμενος μέσος (κόκκινη γραμμή) αναδεικνύουν το επαναλαμβανόμενο εποχικό μοτίβο, χωρίς τις απότομες μεταβολές καθεστώτος που χαρακτηρίζουν την τιμή. Το κάτω πάνελ παρουσιάζει τη μηνιαία κατανομή μέσω boxplots, με σταθερότερη διασπορά διαχρονικά. Η οπτική σύγκριση των δύο σειρών αναδεικνύει άμεσα τη μεγαλύτερη κανονικότητα του φορτίου, που εξηγεί την ανώτερη προβλεψιμότητά του.

Παρά τη φαινομενική ομαλότητα, η συγκεντρωτική εννεαετής απεικόνιση συμπιέζει τη λεπτομερή εποχική δομή και των δύο σειρών: η μακροχρόνια μετατόπιση επιπέδου επικαλύπτει το επαναλαμβανόμενο ετήσιο μοτίβο. Για να διαχωριστούν οι δύο αυτές συνιστώσες, η επόμενη ενότητα σχεδιάζει τα μηνιαία προφίλ κάθε έτους χωριστά, αναδεικνύοντας ποιο μέρος της διακύμανσης είναι σταθερά εποχικό και ποιο οφείλεται σε μεταβολές καθεστώτος.




Σχήμα 3.3. Ωριαίο ηλεκτρικό φορτίο (MW) στην ελληνική αγορά (Ιαν. 2017 - Νοεμ. 2025). Πάνω: ωριαίο φορτίο (πορτοκαλί) και 30-ήμερος κυλιόμενος μέσος (κόκκινος)· πράσινη σκίαση για τα lockdown COVID-19. Κάτω: μηνιαία κατανομή φορτίου (boxplots) για ολόκληρη την περίοδο.

3.7.3 Εποχιακή Εξέλιξη ανά Έτος

Για να διαχωριστεί η βραχυπρόθεσμη από τη μακροπρόθεσμη εποχικότητα, το Σχήμα 3.4 παρουσιάζει τη μέση μηνιαία τιμή ΗΑ και το μέσο μηνιαίο φορτίο για κάθε έτος ξεχωριστά. Στις τιμές (πάνω πάνελ), τα έτη 2021 και 2022 (έντονες γραμμές) αποκλίνουν από την υπόλοιπη ομάδα: κορυφές >200 €/MWh το καλοκαίρι του 2022 αντικατοπτρίζουν τα υψηλά επίπεδα TTF και τη μειωμένη υδροηλεκτρική παραγωγή. Η ύπαρξη αυτών των «μεικτών καθεστώτων» (mixed regimes) στο σύνολο εκπαίδευσης δυσκολεύει τη γενίκευση των μοντέλων σε νέες συνθήκες αγοράς.

Στο φορτίο (κάτω πάνελ), η εικόνα είναι σαφώς πιο σταθερή: το εποχικό μοτίβο (αιχμή θέρους Ιούλιος-Αύγουστος, δευτερεύουσα αιχμή χειμώνα Ιανουάριος) επαναλαμβάνεται ομοιόμορφα σε όλα τα έτη με μικρή χρονο-διακύμανση. Αυτή η σταθερότητα εξηγεί την ανώτερη προβλεψιμότητα του φορτίου σε σχέση με την τιμή.


Seasonal Patterns: Day-Ahead Price and System Load (Greek Electricity Market, 2017-2025)

Σχήμα 3.4. Μηνιαία μέση τιμή ηλεκτρικής ενέργειας (πάνω) και φορτίου (κάτω) ανά έτος (2017-2025). Κάθε γραμμή αντιστοιχεί σε ένα ημερολογιακό έτος· τα έτη 2021-2022 σχεδιάζονται με έντονη γραμμή.

3.7.4 Ωριαία και Εβδομαδιαία Εποχικότητα

Πέρα από τη μηνιαία εποχικότητα, η ημερήσια και εβδομαδιαία δομή αποτελούν τα κυρίαρχα μοτίβα για τη βραχυπρόθεσμη πρόβλεψη. Το Σχήμα 3.5 αποτυπώνει το ενδοημερήσιο προφίλ τιμής σε τρία πάνελ: ανά εποχή, ανά ημέρα εβδομάδας και ως θερμικό χάρτη (ημέρα $\times$ ώρα). Φαίνονται δύο χαρακτηριστικές ωριαίες αιχμές: πρωινή (08:00-10:00, εκκίνηση βιομηχανίας) και βραδινή (19:00-21:00, επιστροφή νοικοκυριών), με νυκτερινό βαθούλωμα (03:00-05:00). Το εποχικό πάνελ αναδεικνύει την υψηλότερη στάθμη και μεταβλητότητα του χειμώνα και του καλοκαιριού, ενώ το εβδομαδιαίο μοτίβο επιβεβαιώνει τη χαρακτηριστική πτώση τιμής το Σαββατοκύριακο (~15% κάτω από τον μέσο εργάσιμων ημερών), λόγω μειωμένης βιομηχανικής ζήτησης.


Το Σχήμα 3.6 παρουσιάζει το αντίστοιχο ανάλυση για το φορτίο. Το ωριαίο προφίλ εμφανίζει σαφή αιχμή μεσημεριανής ζήτησης (12:00-13:00) και στενότερη ζώνη $\pm 1\sigma$ σε σχέση με την τιμή, αντικατοπτρίζοντας τη μεγαλύτερη ρυθμικότητα του φορτίου. Η εβδομαδιαία πτώση Σαββατοκύριακου υπάρχει αλλά είναι λιγότερο έντονη. Αυτά τα μοτίβα δικαιολογούν άμεσα τη συμπερίληψη των

Day-Ahead Price: Seasonal, Intraday and Weekly Patterns

Σχήμα 3.5. Ενδοημερήσια μοτίβα τιμής ΗΑ. Πάνω: μέσο ωριαίο προφίλ ανά εποχή· κάτω αριστερά: μέσο ωριαίο προφίλ ανά ημέρα εβδομάδας (εργάσιμες μπλε, Σαββατοκύριακο πορτοκαλί)· κάτω δεξιά: θερμικός χάρτης μέσης τιμής (ημέρα εβδομάδας × ώρα).

ημερολογιακών χαρακτηριστικών hour_sin/cos και dow_sin/cos στο σύνολο εισόδου των μοντέλων.

System Load: Seasonal, Intraday and Weekly Patterns



Σχήμα 3.6. Ενδοημερήσια μοτίβα ηλεκτρικού φορτίου, με ίδια διάταξη όπως η τιμή (Σχ. 3.5). Πάνω: προφίλ ανά εποχή· κάτω αριστερά: προφίλ ανά ημέρα εβδομάδας· κάτω δεξιά: θερμικός χάρτης μέσου φορτίου (ημέρα εβδομάδας × ώρα).


3.7.5 Αυτοσυσχέτιση και Επιλογή Υστερήσεων

Η συνάρτηση αυτοσυσχέτισης (ACF) και η μερική αυτοσυσχέτιση (PACF) ποσοτικοποιούν τη στοχαστική δομή και τεκμηριώνουν την επιλογή του συνόλου υστερήσεων L [2]. Χρησιμοποιούμε την ACF/PACF εδώ αποκλειστικά ως εργαλείο επιλογής χαρακτηριστικών, όχι για βαθμονόμηση SARIMA.


Στο Σχήμα 3.7 η ACF της τιμής εμφανίζει κυματοειδή μορφή με ισχυρές κορυφές στα lag-24 , lag-48 , ..., lag-168 (ημερήσιες αρμονικές στα πολλαπλάσια των 24 ωρών και εβδομαδιαία αρμονική στο lag-168), που τεκμηριώνουν την πολλαπλή εποχικότητα. Ξεχωρίζει η υψηλή στάθμη βάσης: ακόμη και στα ενδιάμεσα κοιλώματα η ACF παραμένει κοντά στο 0,7 και δεν αποσβένει έως το lag-168 , ένδειξη μακράς μνήμης που οφείλεται στα αργά μεταβαλλόμενα καθεστώτα τιμής (επίπεδα καυσίμων, ενεργειακή κρίση). Η PACF κυριαρχείται από το lag-1 ($\approx 1,0$) με δεύτερη συνεισφορά στο lag-2 ($\approx 0,8$) και ταχεία απόσβεση, με αμυδρές κορυφές γύρω από τα lag-24 και lag-48 .

Η μακρά μνήμη της τιμής αντιπαράτιθεται με την πολύ πιο τοπική εξάρτηση του φορτίου. Το αντίστοιχο διάγραμμα για το φορτίο (Σχήμα 3.8) παρουσιάζει καθαρότερο ημερήσιο κύκλο: η ACF ταλαντώνεται έντονα μεταξύ βαθιών κοιλωμάτων ($\approx 0,1$ στα 12ωρα αντι-φάσης) και κορυφών $\approx 0,9$ στα πολλαπλάσια των 24 ωρών. Η PACF κυριαρχείται και εδώ από το lag-1 , με ασθενέστερη συνεισφορά lag-2 ($\approx 0,5$) από ό,τι στην τιμή.

Η αντιπαράβολή των δύο διαγραμμάτων αναδεικνύει τη βασική διαφορά των δύο σειρών. Στην τιμή η ημερήσια ταλάντωση υπερτίθεται σε υψηλό υπόβαθρο επιμονής (κοιλώματα $\approx 0,7$), ενώ



Σχήμα 3.7. Συνάρτηση αυτοσυσχέτισης (ACF, αριστερά) και μερικής αυτοσυσχέτισης (PACF, δεξιά) της ωριαίας τιμής ΗΑ για lags 1-168 ώρες. Οι κατακόρυφες διακεκομμένες γραμμές σημειώνουν τα lag-24, 48 και 168.



Σχήμα 3.8. Συνάρτηση αυτοσυσχέτισης (ACF, αριστερά) και μερικής αυτοσυσχέτισης (PACF, δεξιά) του ωριαίου ηλεκτρικού φορτίου για lags 1-168 ώρες. Οι κατακόρυφες διακεκομμένες γραμμές σημειώνουν τα lag-24, 48 και 168.

στο φορτίο ο ημερήσιος κύκλος κυριαρχεί με κοιλώματα που πέφτουν κοντά στο μηδέν· το φορτίο είναι πιο τακτικό και η δομή του πιο προβλέψιμη. Και στις δύο σειρές η PACF επικεντρώνεται στο lag-1, δομή τύπου AR(1), που μαζί με τις εποχικές κορυφές δικαιολογεί άμεσα το βασικό σύνολο $L = \{1, 2, 3, 6, 12, 24, 48, 168\}$: καλύπτει τις στατιστικά σημαντικές υστερήσεις χωρίς πλεονασμό.


3.7.6 Ενδοημερήσια Εξάρτηση Ημέρας D από D-1

Για την ποσοτικοποίηση της ισχυρής ενδοημερήσιας αυτοσυσχέτισης κατασκευάστηκαν πίνακες Pearson 24×24 , στους οποίους κάθε στοιχείο (h, l) εκφράζει:

$$\rho_{hl} = \text{corr}(r_t^{(h)}, r_{t-1}^{(l)}), \quad (3.5)$$


όπου $r_t^{(h)} = y_{t,h} - \bar{y}_t$ είναι η αποκεντρωμένη τιμή της ώρας h ημέρας t . Η αφαίρεση του ημερήσιου μέσου αναδεικνύει την καθαρή ενδοημερήσια δομή.

Στο Σχήμα 3.9 για την τιμή, η κύρια διαγώνιος ($h = l$) εμφανίζει τις υψηλότερες συσχετίσεις ($r > 0,8$): η τιμή της ίδιας ώρας την προηγούμενη ημέρα είναι ο ισχυρότερος μεμονωμένος προβλεπτής. Οι ισχυρές off-diagonal συσχετίσεις μεταξύ γειτονικών ωρών αιχμής (08:00-20:00) δικαιολογούν την προσθήκη dense lags ($y_{t-4}, \dots, y_{t-23}$) για τα MIMO/Direct μοντέλα.



Σχήμα 3.9. Χάρτης Pearson ενδοημερήσιας συσχέτισης (24×24) μεταξύ ώρας h ημέρας D και ώρας l ημέρας $D - 1$ για την τιμή HA (2017-2025). Οι ισοϋψείς γραμμές σημειώνουν τα $r = 0,7$ και $r = 0,9$.

Η ίδια αντίθεση τιμής-φορτίου που παρατηρήθηκε στην ACF επανεμφανίζεται και στο επίπεδο της ενδοημερήσιας συσχέτισης μεταξύ διαδοχικών ημερών. Το φορτίο (Σχήμα 3.10) εμφανίζει ισχυρότερη και πιο «καθαρή» δομή (ρ_{hh} έως $\sim 0,9$), συνεπές με τη μεγαλύτερη ημερήσια τακτικότητα του. Η δομή κατά μπλοκ είναι πιο εμφανής σε σχέση με την τιμή, επιβεβαιώνοντας ότι το lag-24 αποτελεί ακόμα ισχυρότερο χαρακτηριστικό για φορτίο από ό,τι για τιμή.




Σχήμα 3.10. Χάρτης Pearson ενδοημερήσιας συσχέτισης (24×24) μεταξύ ώρας h ημέρας D και ώρας l ημέρας $D - 1$ για το ηλεκτρικό φορτίο (2017-2025). Η κλίμακα χρωμάτων είναι ανεξάρτητη, προσαρμοσμένη στο υψηλότερο εύρος συσχέτισης του φορτίου (πρβλ. Σχ. 3.9).

3.7.7 Επίδραση Φυσικού Αερίου και Ανανεώσιμων Πηγών

Στην ελληνική αγορά, οι μονάδες φυσικού αερίου καθορίζουν συχνά οριακά την τιμή εκκαθάρισης. Αυτό αποτυπώνεται στο Σχήμα 3.11: η συσχέτιση τιμής HA - τιμής TTF ανέρχεται σε $r \approx 0,74$ για την περίοδο 2017-2025. Η κλίση της OLS αντικατοπτρίζει πόσα €/MWh αυξάνεται η τιμή για κάθε +1 €/MWh αύξηση του αερίου. Η σημαντική διασπορά, ιδίως σε έτη υψηλής ΑΠΕ παραγωγής (2020, 2023), είναι αναμενόμενη: όταν οι ανανεώσιμες πηγές εκτοπίζουν τις αεριοστροβιλικές μονάδες, η σχέση αποσυνδέεται. Αυτή η υπό συνθήκη μη γραμμικότητα αποτελεί έναν από τους βασικούς λόγους που τα μοντέλα ML υπερτερούν γραμμικών παλινδρομήσεων.


Συγκεντρωτικά, η περιγραφική ανάλυση σκιαγραφεί δύο σειρές με διακριτό χαρακτήρα: μια τιμή με έντονη μεταβλητότητα, μακρά μνήμη και υπό συνθήκη εξάρτηση από τα καύσιμα, και ένα φορτίο με ισχυρή ημερήσια τακτικότητα και υψηλή προβλεψιμότητα. Και οι δύο όμως μοιράζονται την πολλαπλή εποχικότητα (ημερήσια, εβδομαδιαία, ετήσια) και τις ασυνέχειες καθεστώτος που τεκμηρίωσαν τα προηγούμενα σχήματα. Αυτά τα χαρακτηριστικά καθορίζουν τόσο την επιλογή χαρακτηριστικών όσο και τον τρόπο αξιολόγησης: κάθε σχήμα εκπαίδευσης πρέπει να σέβεται τη χρονική σειρά και να εκθέτει τα μοντέλα στις ίδιες μεταβολές καθεστώτος που θα αντιμετωπίσουν στην πράξη. Η επόμενη ενότητα οπτικοποιεί ακριβώς αυτόν τον διαχωρισμό.



Σχήμα 3.11. Αριστερά: διάγραμμα διασποράς ημερήσιας μέσης τιμής HA έναντι τιμής φυσικού αερίου TTF (2017-2025), χρωματισμένο ανά έτος, με προσρμογή OLS (κόκκινη γραμμή) και αναγραφή της κλίσης της. Δεξιά: χρονοσειρά τιμής HA και τιμής αερίου με διπλό κατακόρυφο άξονα, που αναδεικνύει τη συγχρονισμένη εξέλιξή τους.

3.7.8 Διαχωρισμός Εκπαίδευσης και Αξιολόγησης

Η αυστηρά χρονολογική διαίρεση (expanding window, χωρίς τυχαιοποίηση) αποτελεί μεθοδολογική απαίτηση για EPF: οποιαδήποτε τυχαία κατανομή θα επέτρεπε στο μοντέλο να «βλέπει» μελλοντικές τιμές κατά την εκπαίδευση, οδηγώντας σε φαινομενικά άριστα αλλά μη αναπαραγώγιμα αποτελέσματα [40]. Το Σχήμα 3.12 οπτικοποιεί τον διαχωρισμό για την περίοδο αξιολόγησης Q1 2026 (Δεκ. 2025 - Φεβ. 2026). Η εκπαίδευση καλύπτει ολόκληρο το ιστορικό (Ιαν. 2017 - Νοεμ. 2025). Η αξιολόγηση γίνεται σε walk-forward σχήμα: για το Q1 2026 ο κόφτης εκπαίδευσης κυλίζει μηνιαία ({30/11/2025, 31/12/2025, 31/01/2026}), χωρίς validation set εντός της περιόδου αξιολόγησης. Το σχήμα παρουσιάζει δύο πάνελ (τιμή πάνω, φορτίο κάτω): η κατακόρυφη διακεκομμένη γραμμή σημειώνει το σημείο κοπής εκπαίδευσης (τέλος Νοεμβρίου 2025) και η σκιασμένη περιοχή την περίοδο δοκιμής.



Σχήμα 3.12. Χρονικός διαχωρισμός εκπαίδευσης (Ιαν. 2017 - Νοεμ. 2025) και αξιολόγησης (κόκκινο, Δεκ. 2025 - Φεβ. 2026), για την τιμή (πάνω) και το φορτίο (κάτω).

4. Μεθοδολογία

4.1 Αλγόριθμοι Μηχανικής Μάθησης

4.1.1 LightGBM

Το LightGBM [24] αναπτύσσει τα δέντρα leaf-wise, με ταχύτερη σύγκλιση και ελαφρώς υψηλότερη ευαισθησία σε υπερπροσαρμογή έναντι της level-wise ανάπτυξης (§2.4, Σχ. 2.2). Εδώ η υπερπροσαρμογή ελέγχεται μέσω `num_leaves`, `min_child_samples` και `subsample`. Χρησιμοποιείται σε όλες τις στρατηγικές (TF, Rec, MIMO, Direct) και προτιμάται για τις TF/Rec λόγω ταχύτητας εκπαίδευσης: ένα μοντέλο με $n \approx 1.000$ δέντρα εκπαιδεύεται σε $\sim 1-2$ λεπτά σε CPU, επιτρέποντας δεκάδες επαναλήψεις Optuna.

4.1.2 XGBoost

Το XGBoost [23] χτίζει τα δέντρα level-wise, παράγοντας πιο συμμετρικές δομές (§2.4). Εκπαιδεύεται πιο αργά από το LightGBM, αλλά εμπειρικά παράγει πιο σταθερά αποτελέσματα σε δεδομένα υψηλής μεταβλητότητας - ιδιότητα που αναδεικνύεται στην αξιολόγηση Q4 2025 και Q1 2026.

4.1.3 Random Forest

Το Random Forest [22] ακολουθεί parallel bagging - ανεξάρτητα δέντρα σε τυχαία υποσύνολα δεδομένων και χαρακτηριστικών, με μέσο όρο των προβλέψεων - αντί για το sequential boosting των LightGBM/XGB (§2.4). Η ανεξαρτησία των δέντρων το καθιστά φυσικά ανθεκτικό σε ακραίες τιμές και έντονες διακυμάνσεις, όπως επαληθεύεται στην περίοδο υψηλής μεταβλητότητας του Ιανουαρίου 2026.

Σε περιβάλλον Windows η παράλληλη εκτέλεση (multiprocessing) προκαλεί προβλήματα σταθερότητας· για τον λόγο αυτό το RF εκπαιδεύεται μονονηματικά (`n_jobs=1`), ενώ η επιλογή `max_features="sqrt"` μειώνει τον χρόνο εκπαίδευσης περίπου κατά $9\times$.

4.1.4 Support Vector Regression

Το SVR [25] εκπαιδεύεται με πυρήνα RBF και ε -ανεκτική απώλεια, ελαχιστοποιώντας τη νόρμα του μοντέλου (εξ. 2.6-2.7, §2.4.2). Λόγω της κυβικής επεκτασιμότητας ($O(n^3)$), εκπαιδεύεται σε υποσύνολο 5.000 τυχαίων δειγμάτων με τις εισόδους κανονικοποιημένες μέσω StandardScaler· ο περιορισμός αυτός εξηγεί τη γενικά υποδεέστερη απόδοσή του σε μεγάλες δοκιμαστικές περιόδους.

Μεροληψία υπό μεταβολή καθεστώτος. Πέρα από το υπολογιστικό κόστος, ο πυρήνας ακτινικής βάσης (RBF kernel) $k(\mathbf{z}, \mathbf{z}') = \exp(-\gamma \|\mathbf{z} - \mathbf{z}'\|^2)$ εισάγει μια δομική αδυναμία γενίκευσης εκτός του εύρους της κατανομής εκπαίδευσης. Η πρόβλεψη γράφεται ως σταθμισμένο άθροισμα τοπικών

αποκρίσεων γύρω από τα διανύσματα υποστήριξης,

$$f(\mathbf{z}) = \sum_{i \in \mathcal{S}} \alpha_i k(\mathbf{z}, \mathbf{z}_i) + b, \quad (4.1)$$

όπου $\mathcal{S}$ το σύνολο των διανυσμάτων υποστήριξης. Επειδή ο RBF είναι τοπικός, για κάθε δοκιμαστικό σημείο $\mathbf{z}^*$ που απέχει σημαντικά από όλα τα $\mathbf{z}_i$ ισχύει $k(\mathbf{z}^*, \mathbf{z}_i) \rightarrow 0$, οπότε $f(\mathbf{z}^*) \rightarrow b$. Η πρόβλεψη καταρρέει προς τον σταθερό όρο b , ο οποίος είναι αγκυρωμένος κοντά στη μέση τιμή των στόχων εκπαίδευσης. Όταν συμβεί έντονη μεταβολή καθεστώτος (regime shift) - όπως η πτώση της μέσης τιμής από 108,7 σε 78,3 €/MWh τον Φεβρουάριο 2026 - το νέο επίπεδο του στόχου βρίσκεται εκτός του φερόμενου εύρους των διανυσμάτων υποστήριξης. Το μοντέλο αδυνατεί να παρεκβάλει και παράγει συστηματική μεροληψία (bias), προβλέποντας σταθερά κοντά στο παρωχημένο μέσο επίπεδο. Η ε -ανεκτική απώλεια επιτείνει το φαινόμενο, καθώς κλειδώνει τα διανύσματα υποστήριξης στο κέντρο της αρχικής κατανομής και αδρανοποιεί τη λεπτή προσαρμογή στις ακραίες περιοχές. Αυτό θεμελιώνει θεωρητικά τη μειωμένη ανθεκτικότητα του SVR στις περιόδους μεταβολής καθεστώτος.

4.1.5 Multi-Layer Perceptron

Το MLP υλοποιείται σε PyTorch με αρχιτεκτονική (512, 256, 128) νευρώνων για τιμή και (256, 128) για φορτίο, ενεργοποίηση ReLU, Dropout και BatchNormalization. Η εκπαίδευση γίνεται με Adam optimizer (learning rate 5×10^{-4}) και early stopping (υπομονή 20 εποχών, παρακολούθηση validation loss). Για τη βελτιστοποίηση υπερπαραμέτρων MLP χρησιμοποιείται ξεχωριστό Optuna study (τυνάρει hidden layers, dropout, learning rate, weight decay, batch size).

4.2 Στρατηγικές Πρόβλεψης Ορίζοντα 24 Ωρών

Οι τέσσερις στρατηγικές έχουν κοινό σκοπό: να προβλέψουν τις επόμενες 24 ώρες της τιμής ή του φορτίου. Διαφέρουν στον τρόπο που χειρίζονται την εξάρτηση μεταξύ των ωρών (βλ. Σχήμα 2.5 στην § 2.5). Ο Πίνακας 4.1 συνοψίζει τα κυριότερα χαρακτηριστικά τους.

Ο εβδομαδιαίος ορίζοντας $H = 168$ αξιολογήθηκε επίσης κατά την έρευνα, αλλά δεν κρατήθηκε ως κύριος άξονας παρουσίασης: πολλαπλασιάζει τον όγκο των αποτελεσμάτων χωρίς να μεταβάλλει τα συμπεράσματα, ενώ το επιχειρησιακό σενάριο της ημερήσιας δημοπρασίας DAM αντιστοιχεί στο $H = 24$. Επιλεγμένα αποτελέσματα $H = 168$ παρατίθενται μόνο όπου αναδεικνύουν τη συσσώρευση σφάλματος της αναδρομικής (Πίν. 8.1).

Πίνακας 4.1. Συγκριτική παρουσίαση των τεσσάρων στρατηγικών πρόβλεψης $H = 24$ ωρών.

Στρατηγική	Lagged εισόδοι	Error accum.	Μοντέλα	Χαρακτηρισμός
TF	Πραγματικές τιμές	Μηδέν	1	Άνω φράγμα (oracle)
Rec	Προβλέψεις	Σταδιακό	1	Αυτοπαλίνδρομη
MIMO	Παρελθοντικές υστερήσεις	Μηδέν	1 (multi-out)	Ταυτόχρονη πρόβλεψη
Direct	Παρελθοντικές υστερήσεις	Μηδέν	$H = 24$	Ανεξάρτητα μοντέλα ανά ώρα

Κοινός συμβολισμός. Έστω t η τελευταία διαθέσιμη ώρα (origin), που αντιστοιχεί στο τέλος της ημέρας $D - 1$, και $h \in \{1, \dots, 24\}$ ο ορίζοντας πρόβλεψης. Ορίζουμε το διάνυσμα εξωγενών χαρακτηριστικών $\mathbf{x}_\tau \in \mathbb{R}^m$ (ημερολογιακά χαρακτηριστικά, τιμή αερίου, τιμή CO₂, ημερήσια πρόβλεψη φορτίου), όλα γνωστά ήδη στο κλείσιμο πύλης $D - 1$, και το διάνυσμα καθυστερημένων τιμών στόχου $\ell_\tau = [y_{\tau-1}, y_{\tau-2}, \dots, y_{\tau-168}]$. Το διάνυσμα εισόδου σχηματίζεται ως η συνένωση $\mathbf{z}_\tau = [\ell_\tau, \mathbf{x}_\tau]$. Η ουσιαστική διαφορά των τεσσάρων στρατηγικών συνίσταται αποκλειστικά στο ποια

τιμή τροφοδοτεί κάθε συνιστώσα του ℓ όταν ο δείκτης υστέρησης πέφτει εντός του υπό πρόβλεψη 24ώρου, δηλαδή για $\tau - k > t$.

4.2.1 Teacher-Forcing (TF)

Το TF μοντέλο εκπαιδεύεται ως κλασικό μοντέλο παλινδρόμησης μίας εξόδου: για κάθε παρατήρηση t , ο στόχος είναι y_t και τα χαρακτηριστικά περιλαμβάνουν τις καθυστερημένες τιμές $y_{t-1}, y_{t-2}, \dots, y_{t-168}$. Κατά την αξιολόγηση, κάθε συνιστώσα υστέρησης - συμπεριλαμβανομένων των ενδοημερήσιων ($t + h - k > t$) - τροφοδοτείται με την *πραγματική* παρατήρηση:

$$\mathbf{z}_{t+h}^{\text{TF}} = \left[\underbrace{y_{t+h-1}, y_{t+h-2}, \dots, y_{t+h-168}}_{\text{πραγματικές υστερήσεις}}, \mathbf{x}_{t+h} \right], \quad \hat{y}_{t+h} = f(\mathbf{z}_{t+h}^{\text{TF}}), \quad h = 1, \dots, 24 \quad (4.2)$$

Κάθε ώρα αξιολογείται μεμονωμένα, χωρίς συσσώρευση σφάλματος. Ωστόσο, η αξιολόγηση Teacher-Forcing τροφοδοτεί σε κάθε βήμα την *πραγματική* καθυστερημένη τιμή του στόχου: για την πρόβλεψη της ώρας $t + h$ χρησιμοποιείται η πραγματική y_{t+h-1} . Για ορίζοντες $h > 1$ εντός της ημέρας, η τιμή αυτή αντιστοιχεί σε ενδιάμεσες ώρες που δεν έχουν ακόμη πραγματοποιηθεί τη στιγμή υποβολής προσφορών (D-1, ~12:00 CET). Συνεπώς, το TF λειτουργεί ως ιδεατό μοντέλο αναφοράς (oracle) που ορίζει το άνω φράγμα της απόδοσης: τροφοδοτείται με τις πραγματικές ιστορικές τιμές σε κάθε βήμα, ποσοτικοποιώντας τη μέγιστη εφικτή ακρίβεια. Χρησιμεύει ως μέτρο του κόστους που επιφέρει η απουσία πρόσβασης στις πραγματικές ενδιάμεσες τιμές. Οι στρατηγικές Recursive, MIMO και Direct προβλέπουν ολόκληρο το 24ωρο από την τελευταία διαθέσιμη ώρα, χωρίς πρόσβαση σε ενδιάμεσες πραγματικές τιμές.

4.2.2 Recursive (Rec)

Η Rec στρατηγική χρησιμοποιεί το ίδιο μοντέλο μίας εξόδου, αλλά αντικαθιστά κάθε ενδοημερήσια υστέρηση με την αντίστοιχη πρόβλεψη που έχει ήδη παραχθεί. Ορίζουμε τον τελεστή διαθεσιμότητας

$$\tilde{y}_\tau = \begin{cases} y_\tau, & \tau \leq t \quad (\text{παρατηρηθείσα ιστορία}), \\ \hat{y}_\tau, & \tau > t \quad (\text{πρόβλεψη προηγούμενου βήματος}), \end{cases} \quad (4.3)$$

οπότε το διάνυσμα εισόδου και η πρόβλεψη σχηματίζονται αναδρομικά ως

$$\mathbf{z}_{t+h}^{\text{Rec}} = [\tilde{y}_{t+h-1}, \tilde{y}_{t+h-2}, \dots, \tilde{y}_{t+h-168}, \mathbf{x}_{t+h}], \quad \hat{y}_{t+h} = f(\mathbf{z}_{t+h}^{\text{Rec}}), \quad h = 1, \dots, 24 \quad (4.4)$$

όπου σε κάθε βήμα η νέα πρόβλεψη $\hat{y}_{t+h}$ προστίθεται στο σύνολο των διαθέσιμων τιμών και τροφοδοτεί τα επόμενα βήματα ($\tilde{y}_{t+h} \leftarrow \hat{y}_{t+h}$).

Η αναδρομή αυτή εισάγει σφάλμα σε κάθε βήμα. Για να αντιμετωπιστεί αυτό, εφαρμόζεται Scheduled Sampling κατά την εκπαίδευση (βλ. Ενότητα 2.6), ώστε το μοντέλο να εκπαιδευτεί με αναφορά τόσο σε πραγματικές όσο και σε θορυβώδεις τιμές.

4.2.3 MIMO (Multi-Input Multi-Output)

Το MIMO μοντέλο σχηματίζει ένα *μοναδικό* διάνυσμα εισόδου από το origin t , χρησιμοποιώντας αποκλειστικά υστερήσεις ℓ_t με δείκτη $\leq t$ (καμία ενδοημερήσια συνιστώσα), και απεικονίζει το διάνυσμα αυτό απευθείας σε ολόκληρο τον ορίζοντα 24 εξόδων:

$$\mathbf{z}_t^{\text{MIMO}} = [y_t, y_{t-1}, \dots, y_{t-168}, \mathbf{x}_t], \quad [\hat{y}_{t+1}, \hat{y}_{t+2}, \dots, \hat{y}_{t+24}]^\top = F(\mathbf{z}_t^{\text{MIMO}}) \quad (4.5)$$

Καθώς το $\mathbf{z}_t^{\text{MIMO}}$ παραμένει σταθερό για όλους τους ορίζοντες h , δεν υπάρχει αναδρομική τροφοδότηση ($\tilde{y}_\tau$ με $\tau > t$ δεν εμφανίζεται ποτέ) και επομένως κανένας μηχανισμός συσσώρευσης σφάλματος.

Στην υλοποίηση χρησιμοποιείται `MultiOutputRegressor` (για `LightGBM`, `RF`, `SVR`, `MLP`) ή το `XGBoost API` με διαστάσεις εξόδου. Δεδομένου ότι δεν υπάρχει αναδρομική τροφοδότηση, η ποιότητα των χαρακτηριστικών δεν υποβαθμίζεται για τις απομακρυσμένες ώρες. Τα `dense lags` βοηθούν εδώ: τα $y_{\text{lag}4}, \dots, y_{\text{lag}23}$ αναπαριστούν καθαρή ιστορία (όχι προβλέψεις) και παρέχουν πλούσια ενδομερήσια πληροφορία.

Two-stage MIMO για τιμή. Για τα μοντέλα `RF`, `SVR` και `MLP` η πρόβλεψη τιμής ακολουθεί δύο στάδια: (1) εκπαίδευση μοντέλου MIMO φορτίου $H = 24$ (`LGBM` ή `XGBoost`), (2) χρήση των προβλεπόμενων τιμών φορτίου ως επιπλέον 24 χαρακτηριστικά ($\hat{y}_{t+1}^{\text{load}}, \dots, \hat{y}_{t+24}^{\text{load}}$) στο μοντέλο τιμής (176 χαρακτηριστικά συνολικά). Η αλυσίδα αυτή εκμεταλλεύεται τη δομική σχέση τιμής-φορτίου χωρίς να εισάγει `leakage`.

4.2.4 Direct Multistep

Η `Direct` στρατηγική εκπαιδεύει $H = 24$ ανεξάρτητα μοντέλα, ένα ανά ορίζοντα. Όπως και στο MIMO, το διάνυσμα υστερήσεων αντλείται αποκλειστικά από το `origin t` (δείκτες $\leq t$), ενώ τα εξωγενή χαρακτηριστικά λαμβάνονται για τη συγκεκριμένη ώρα-στόχο $t + h$:

$$\mathbf{z}_{t,h}^{\text{Dir}} = [y_t, y_{t-1}, \dots, y_{t-168}, \mathbf{x}_{t+h}], \quad \hat{y}_{t+h} = f_h(\mathbf{z}_{t,h}^{\text{Dir}}), \quad h = 1, \dots, 24 \quad (4.6)$$

Κάθε μοντέλο f_h εκπαιδεύεται αποκλειστικά στον υπολογισμό της τιμής h ώρες αργότερα. Απαιτεί $H \times$ παραπάνω χρόνο εκπαίδευσης, αλλά εξαλείφει τη συσσώρευση σφάλματος. Στην υλοποίηση αντιστοιχεί στο `LightGBM Direct` (24 ανεξάρτητα μοντέλα).


4.3 Scheduled Sampling

Το `Scheduled Sampling` [30] προσαρμόζεται ως εξής για αλγόριθμους `gradient boosting`:

1. Αρχικοποίηση του μοντέλου με $\varepsilon_0 = 0,10$ (10% των `lagged` χαρακτηριστικών αντικαθίστανται από `pseudo-προβλέψεις`).
2. Εκτέλεση ημερήσιου 24ωρου `recursive loop` για κάθε ημέρα εκπαίδευσης: για κάθε ώρα $h \in \{1, \dots, 24\}$, αποφασίζεται τυχαία (με πιθανότητα ε) αν το y_{lag_k} θα είναι η πραγματική τιμή ή η προβλεπόμενη.
3. Επανάληψη για $N_{\text{iter}} = 3$ επαναλήψεις, αυξάνοντας το ε γραμμικά:

$$\varepsilon_t = \varepsilon_{\min} + \frac{t}{N_{\text{iter}} - 1} (\varepsilon_{\max} - \varepsilon_{\min}), \quad \varepsilon_{\min} = 0,10, \quad \varepsilon_{\max} = 0,40 \quad (4.7)$$

Αυτή η διαδικασία κάνει το μοντέλο ανθεκτικό στον θόρυβο των `lagged` εισόδων κατά τη `recursive` χρήση. Ειδικά για το φορτίο, το `Scheduled Sampling` βελτιώνει σημαντικά τα αποτελέσματα (βλ. Κεφάλαιο 6).



Σχήμα 4.1. Πρόγραμμα Scheduled Sampling: η πιθανότητα ε χρήσης προβλεπόμενης τιμής αντί πραγματικής αυξάνει γραμμικά από 0,10 έως 0,40 σε τρία περάσματα εκπαίδευσης, υλοποιώντας τη μετάβαση teacher-forcing $\rightarrow$ autoregressive (βλ. Εξ. 4.7).

4.4 Βελτιστοποίηση Υπερπαραμέτρων με Optuna

Η βελτιστοποίηση γίνεται ανεξάρτητα για κάθε αλγόριθμο και κάθε εργασία, χρησιμοποιώντας το Optuna με τον αλγόριθμο TPE. Ο Πίνακας 4.2 συνοψίζει τα εύρη αναζήτησης και τις βέλτιστες τιμές.

Πίνακας 4.2. Εύρη αναζήτησης υπερπαραμέτρων (Optuna) και βέλτιστες τιμές για το καλύτερο μοντέλο κάθε αλγόριθμου (εργασία τιμής, TF/Rec στρατηγική).

Αλγόριθμος	Υπερπαραμέτρος	Εύρος	Βέλτιστη τιμή
LightGBM	n_estimators	[200, 2000]	900
	learning_rate	[0.005, 0.15]	0.027
	num_leaves	[15, 255]	26
	min_child_samples	[10, 100]	54
	subsample	[0.5, 1.0]	0.925
XGBoost	n_estimators	[200, 1500]	405
	learning_rate	[0.01, 0.30]	0.030
	max_depth	[3, 12]	12
	subsample	[0.5, 1.0]	0.85
MLP	hidden_layers	{(128,64),(256,128),(512,256,128)}	(512,256,128)
	dropout	[0.0, 0.5]	0.37
	learning_rate	[10^{-4} , 10^{-2}]	$9,6 \times 10^{-4}$
SVR	C	[10^{-1} , 10^3] (log)	50.0
	epsilon	[10^{-3} , 1.0] (log)	0.05
LGBM (MIMO)	n_estimators	[300, 2000]	900
	num_leaves	[15, 127]	26

TF/Rec Βελτιστοποίηση. Για τα TF και Rec μοντέλα χρησιμοποιείται **ημερήσιο rolling-origin CV**: κάθε fold αξιολογεί το μοντέλο σε ένα 24ωρο παράθυρο, ακολουθώντας αυστηρά χρονολογική σειρά ώστε να μην υπάρχει διαρροή από το μέλλον (no look-ahead). Το παράθυρο εκπαίδευσης επεκτείνεται σωρευτικά: κάθε νέο fold προσθέτει τα δεδομένα του προηγούμενου 24ώρου στο training set. Αυτό προσομοιώνει πιστά τον πραγματικό τρόπο ανάπτυξης του μοντέλου στην αγορά. Για τα Rec μοντέλα η αξιολόγηση στο CV εκτελείται επίσης αναδρομικά (recursive prediction, όχι teacher-forcing), ώστε η CV-απόδοση να αντικατοπτρίζει πραγματικές συνθήκες χρήσης και να μην υπερεκτιμά λόγω διαρροής teacher-forcing. Ο αριθμός των splits ορίζεται σε 3-5, καλύπτοντας τις τελευταίες εβδομάδες του εκπαιδευτικού συνόλου.

MIMO/Direct Βελτιστοποίηση. Για τα MIMO και Direct μοντέλα η δομή του CV διαφέρει: αντί για 1-step-ahead αξιολόγηση, κάθε fold αξιολογεί το μοντέλο σε πλήρη 24ωρα προβλεπτικά παράθυρα. Η συνάρτηση κόστους του Optuna είναι το μέσο MAE σε ολόκληρο τον ορίζοντα $H = 24$, ισοσταθμίζοντας όλες τις ώρες. Αυτή η επιλογή είναι κρίσιμη: ένα μοντέλο που ελαχιστοποιεί μόνο το σφάλμα για $h = 1$ θα αποδίδει κακά για $h = 20-24$. Εναλλακτικά, θα μπορούσε να χρησιμοποιηθεί weighted MAE που να δίνει μεγαλύτερη βαρύτητα στους απόμακρους ορίζοντες, αλλά η ισοσταθμία αποδείχθηκε ισοδύναμη στην πράξη.

Walk-forward Βελτιστοποίηση. Στο πλαίσιο της walk-forward μηνιαίας επανεκπαίδευσης (βλ. § 2.7) τίθεται το ερώτημα πόσο συχνά πρέπει να επαναλαμβάνεται η πλήρης βελτιστοποίηση. Η ανεξάρτητη εκτέλεση Optuna (40-60 trials) κάθε μήνα θα ήταν πληρέστερη αλλά απαιτητική υπολογιστικά. Η λύση που υιοθετείται είναι **CachedOptuna**: για τον Δεκέμβριο 2025 χρησιμοποιούνται προ-υπολογισμένες βέλτιστες υπερπαραμέτροι από Optuna σε πλήρες εκπαιδευτικό σύνολο (40-60 trials, cutoff Νοε. 2025). Για Ιανουάριο και Φεβρουάριο 2026 εκτελείται γρήγορο Optuna (15 trials, 2 splits) με ενημερωμένα δεδομένα, χωρίς να ξεκινά από μηδέν: ο αλγόριθμος TPE αρχικοποιείται με τις cached παραμέτρους ως σημείο εκκίνησης. Η προσέγγιση αυτή μειώνει τον χρόνο βελτιστοποίησης κατά ~70% διατηρώντας παρεμφερή ποιότητα υπερπαραμέτρων.

4.5 Ensembles

Για κάθε στρατηγική κατασκευάζονται δύο σύνολα ensembles:

Ensemble-Best3 (1/MAE weighted). Επιλέγονται τα 3 καλύτερα μοντέλα βάσει ιστορικού MAE και σταθμίζονται αντιστρόφως ανάλογα με το σφάλμα τους:

$$\hat{y}_t^{\text{ens}} = \frac{\sum_{i=1}^3 w_i \hat{y}_t^{(i)}}{\sum_{i=1}^3 w_i}, \quad w_i = \frac{1}{\text{MAE}_i} \quad (4.8)$$

Ensemble-All (1/MAE weighted). Ίδια στάθμιση αλλά με όλα τα διαθέσιμα μοντέλα (εξαιρείται μόνο το SVR για τιμή λόγω κακής σχετικής απόδοσης).

Αποφυγή διαρροής στη σύνθεση. Η επιλογή των τριών μοντέλων και τα βάρη w_i προκύπτουν αποκλειστικά από *validation* σφάλμα (στο walk-forward, το MAE του *προηγούμενου* μήνα) και ποτέ από το σύνολο δοκιμής: διαφορετικά η σύνθεση θα ενσωμάτωνε look-ahead πληροφορία (επιλογή και στάθμιση των μοντέλων με γνώση της μελλοντικής τους επίδοσης). Υπό αυτό το αυστηρό σχήμα, το Ensemble-Best3 δεν υπερτερεί συστηματικά του καλύτερου μεμονωμένου μοντέλου: για την τιμή το leak-free Ensemble δίνει $\approx 11,6$ €/MWh έναντι 10,46 €/MWh του μεμονωμένου TF-LGBM-MR, ενώ για το φορτίο τα δύο είναι ισοδύναμα (≈ 69 MW). Για τον λόγο αυτό, ως κύριο μοντέλο αναφοράς χρησιμοποιείται το μεμονωμένο TF-LGBM-MR και το ensemble παρουσιάζεται ως ισοδύναμη, ανθεκτική εναλλακτική.

4.6 Μετρικές Αξιολόγησης

Η αξιολόγηση κάθε μοντέλου βασίζεται σε τρεις μετρικές:

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |y_t - \hat{y}_t| \quad (4.9)$$

Κύρια μετρική αξιολόγησης. Είναι ανθεκτική σε ακραίες τιμές και εύκολα ερμηνεύσιμη (€/MWh ή MW).

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (y_t - \hat{y}_t)^2} \quad (4.10)$$

Τιμωρεί δυσανάλογα τα μεγάλα σφάλματα, επομένως είναι ευαίσθητη στα price spikes.

$$\text{sMAPE} = \frac{100}{T} \sum_{t=1}^T \frac{|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|} \quad (4.11)$$

Κανονικοποιημένη εκδοχή του ποσοστιαίου σφάλματος, συμμετρική ως προς υπερ- και υπο-εκτίμηση. Χρήσιμη για σύγκριση μεταξύ περιόδων διαφορετικού επιπέδου τιμής. Η κύρια μετρική για την κατάταξη είναι το MAE.

4.7 Βασικές Αναφορές (Baselines)

Στην προκειμένη εργασία χρησιμοποιούνται τέσσερις αναφορές (baselines):

- **Naive-1:** $\hat{y}_{t+1} = y_t$ (επανάληψη τελευταίας τιμής),
- **Naive-24:** $\hat{y}_{t+h} = y_{t+h-24}$ (ίδια ώρα χθεσινής ημέρας),
- **Naive-168:** $\hat{y}_{t+h} = y_{t+h-168}$ (ίδια ώρα προηγούμενης εβδομάδας),
- **Seasonal Profile:** $\hat{y}_{t+h} = \text{mean}\{y_\tau : \tau \in \mathcal{T}_{\text{tr}}, (\text{hod}_\tau, \text{dow}_\tau) = (\text{hod}_{t+h}, \text{dow}_{t+h})\}$, ο μέσος όρος του εκπαιδευτικού συνόλου $\mathcal{T}_{\text{tr}}$ ανά (ώρα ημέρας, ημέρα εβδομάδας).


Ένα μοντέλο θεωρείται αξιόλογο μόνο αν υπερτερεί τουλάχιστον του Naive-1. Για τη στρατηγική MIMO, ο πιο φυσικός baseline είναι το Naive-24, καθώς αμφότερα προβλέπουν ολόκληρη 24ωρη ημέρα από τα ίδια ιστορικά δεδομένα.

5. Διαδραστικό Εργαλείο Οπτικοποίησης Αποτελεσμάτων

Η ταυτόχρονη σύγκριση πολλαπλών μοντέλων και στρατηγικών πρόβλεψης σε πολλαπλές χρονικές περιόδους παράγει έναν ιδιαίτερα σύνθετο όγκο δεδομένων. Για την αποτελεσματική διαχείριση και ανάλυση των αποτελεσμάτων αναπτύχθηκε μία διαδραστική πλατφόρμα οπτικοποίησης (dashboard). Η πλατφόρμα υλοποιήθηκε σε React με TypeScript και Vite, ενώ τα διαγράμματα αποδίδονται με τη βιβλιοθήκη Recharts.

5.1 Συνολική Όψη της Εφαρμογής


Η οθόνη οργανώνεται σε τέσσερις ζώνες, που ο χρήστης διαβάζει από πάνω προς τα κάτω (Σχήμα 5.1). Στην κορυφή βρίσκεται (1) ο **πίνακας ελέγχου** με όλα τα χειριστήρια. Ακολουθεί (2) το **γράφημα χρονοσειράς** με τις πραγματικές τιμές και τις προβλέψεις κάθε ορατού μοντέλου σε ωριαία ανάλυση. Κάτω από αυτό βρίσκονται (3) οι **πίνακες μετρικών**, που κατατάσσουν χωριστά τα μοντέλα μηχανικής μάθησης και τα μοντέλα αναφοράς, και τέλος (4) ο **συγκεντρωτικός πίνακας κατάταξης**, που ενοποιεί όλα τα μοντέλα σε ενιαία λίστα με την κατηγορία καθενός.



Σχήμα 5.1. Συνολική όψη του dashboard με τις τέσσερις ζώνες: (1) πίνακας ελέγχου, (2) γράφημα χρονοσειράς, (3) πίνακες μετρικών, (4) συγκεντρωτικός πίνακας κατάταξης.

5.2 Τυπική Ροή Χρήσης

Ο χρήστης διαμορφώνει το πλαίσιο της έρευνας επιλέγοντας το μέγεθος, τη στρατηγική, τη χρονική περίοδο και τα ορατά διαγράμματα στον πίνακα ελέγχου.



Σχήμα 5.2. Ο πίνακας ελέγχου σε μεγέθυνση.

Οι λειτουργίες συνοψίζονται στον Πίνακα 5.1.

Πίνακας 5.1. Πίνακας αναφοράς χειριστηρίων του dashboard.

Χειριστήριο	Επιλογές	Λειτουργία
Task	Price, Load	Επιλογή τιμής ή φορτίου
Strategy	TF, Rec, MIMO, Direct	Επιλογή στρατηγικής πρόβλεψης
Period	Dec 2025, Q1 2026	Επιλογή χρονικού ορίζοντα
View	All, ML, Baselines, Best	Εμφάνιση: All όλα τα μοντέλα, ML μόνο μοντέλα μηχανικής μάθησης, Baselines μόνο μοντέλα αναφοράς, Best καλύτερο μοντέλο και καλύτερο baseline
Models Show	ανά μοντέλο	Εμφάνιση/απόκρυψη καμπυλών
Zoom (From/To)	date picker	Επιλογή συγκεκριμένου χρονικού διαστήματος
↓ CSV	---	Κατέβασμα δεδομένων σε αρχείο csv
Sort by	MAE, RMSE, sMAPE	Κατάταξη κατά MAE

Στην πράξη, σχεδόν όλες οι λειτουργίες φαίνονται στο Σχήμα 5.3, που συγκεντρώνει τρεις προβολές της ίδιας εφαρμογής.

Στην πάνω προβολή η τιμή προβλέπεται με Recursive στο Q1 2026. Το φίλτρο ML κρατά μόνο τους αλγορίθμους μηχανικής μάθησης και το zoom εστιάζει σε στενότερο διάστημα, ώστε να φανεί η απόκλιση των καμπυλών από τη συσσώρευση σφάλματος. Στη μεσαία προβολή η ίδια τιμή εξετάζεται με MIMO στον Δεκέμβριο 2025 με πατημένο το Baselines, οπότε μένουν μόνο τα μοντέλα αναφοράς (Naive, Seasonal Profile). Στην κάτω προβολή η εργασία γίνεται φορτίο με Direct και το φίλτρο Best κρατά τρεις καμπύλες, το κορυφαίο μοντέλο, το καλύτερο baseline και την πραγματική τιμή.

Η χρησιμότητα ενισχύεται από δύο βοηθητικά εργαλεία (Σχήμα 5.4). Με το hover, σταματώντας τον δείκτη σε μία ώρα, εμφανίζονται μαζί οι τιμές όλων των ενεργών μοντέλων δίπλα στην πραγματική, κάτι που καθιστά δυνατό να εξεταστεί ένα spike της τιμής. Ο χρήστης έχει τη δυνατότητα να απομονώσει οποιοδήποτε χρονικό διάστημα επιθυμεί για να εστιάσει την ανάλυσή του.

Οι αλλαγές αυτές ενημερώνουν αυτόματα τους δείκτες σφάλματος (MAE, RMSE, sMAPE) στους πίνακες. (Σχήμα 5.5). Η κατάταξη χωρίζεται σε μοντέλα μηχανικής μάθησης και μοντέλα αναφοράς, ώστε η σύγκριση να γίνεται μέσα σε ομοιογενείς ομάδες. Το Sort by ταξινομεί κατά MAE, RMSE ή sMAPE και το ↓ CSV κατεβάζει τις τρέχουσες μετρικές σε αρχείο. Στη βάση της σελίδας βρίσκεται ο συγκεντρωτικός πίνακας με όλα τα μοντέλα της εκάστοτε στρατηγικής.

Η διάταξη εξυπηρετεί διαφορετικούς χρήστες. Ο ερευνητής εστιάζει σε spikes με το hover και συγκρίνει στρατηγικές αλλάζοντας tab. Ο αναλυτής της αγοράς ελέγχει μια συγκεκριμένη εβδομάδα με το zoom και εξαγεί τις μετρικές σε CSV. Όποιος θέλει μόνο τη συνολική εικόνα χρησιμοποιεί το Best και τον ενιαίο πίνακα.

5.3 Σύνοψη

Στην παρούσα εργασία το dashboard λειτούργησε ως βοηθητικό ερευνητικό εργαλείο. Η άμεση οπτικοποίηση κάθε συνδυασμού μοντέλου, στρατηγικής και περιόδου επέτρεψε να εντοπιστούν γρήγορα αδυναμίες, να συγκριθούν στρατηγικές χωρίς εκτέλεση κώδικα και να παρθούν αποφάσεις. Στο επόμενο κεφάλαιο, η ποιοτική και οπτική εκτίμηση που εμπλουτίζεται με ποσοτική ανάλυση και στατιστική επαλήθευση.



(α') Recursive, Price, Q1 2026, ML, zoom.




(β') MIMO, Price, Baselines, Dec 2025.



(γ') Direct, Load, Best, Dec 2025.


Σχήμα 5.3. Τρεις προβολές της εφαρμογής για διαφορετικούς συνδυασμούς εργασίας, στρατηγικής, περιόδου και φίλτρου.



(α') Ωριαία σύγκριση (hover).

(β') Επιλογή περιόδου.

Σχήμα 5.4. Δύο λειτουργίες λεπτομερούς ανάγνωσης: (α) το tooltip του hover για ένα χρονικό βήμα και (β) ο επιλογέας ημερομηνίας για μια υποπερίοδο.



Σχήμα 5.5. Πίνακες μετρικών: επάνω οι αυτόνομες κατατάξεις των μοντέλων μηχανικής μάθησης (αριστερά) και των μοντέλων αναφοράς (δεξιά), και κάτω ο ενιαίος συγκεντρωτικός πίνακας όλων των μοντέλων, με επιλογή ταξινόμησης Sort by.

6. Αποτελέσματα Αξιολόγησης

Τα αποτελέσματα παρουσιάζονται σε δύο μέρη. Πρώτα η στατική εκπαίδευση, με ημερομηνία αποκοπής στις 30 Νοεμβρίου 2025 και περίοδο αξιολόγησης τον Δεκέμβριο 2025. Η προσέγγιση αυτή χρησιμεύει ως βάση αναφοράς για τη σύγκριση κάθε στρατηγικής κάτω από σταθερές συνθήκες. Έπειτα η μηνιαία walk-forward επανεκπαίδευση στο Q1 2026, η οποία επιτρέπει στα μοντέλα να προσαρμόζονται στις μεταβαλλόμενες συνθήκες και διακυμάνσεις της αγοράς.

6.1 Ρύθμιση Πειραμάτων

Στην Αγορά Επόμενης Ημέρας [Day-Ahead Market (DAM)], οι προσφορές κλείνουν στις 12:00 CET της προηγούμενης ημέρας (D-1). Η στρατηγική Teacher-Forcing (TF) χρησιμοποιεί τις πραγματικές τιμές σε κάθε βήμα και λειτουργεί ως μοντέλο αναφοράς (oracle) που ορίζει το θεωρητικό άνω φράγμα της απόδοσης. Οι στρατηγικές Recursive, MIMO και Direct προβλέπουν ολόκληρο το 24ωρο χρησιμοποιώντας μόνο τη διαθέσιμη πληροφορία πριν από το κλείσιμο της πύλης (gate closure).

Η ανάλυση σημαντικότητας χαρακτηριστικών [feature importance] (Κεφ. 7) επιβεβαιώνει αυτή τη διάκριση: στην Teacher-Forcing η πραγματική τιμή της προηγούμενης ώρας συγκεντρώνει το 88% της βαρύτητας, ενώ οι διαθέσιμες προβλέψεις στο κλείσιμο της πύλης (φορτίο και ΑΠΕ επόμενης ημέρας) επηρεάζουν αθροιστικά μόλις κατά 0,6% (βλ. Κεφ. 7). Η υψηλή επίδοση της TF οφείλεται αποκλειστικά στην πρόσβαση στα πραγματικά προηγούμενα δεδομένα, επομένως δεν αποτελεί ρεαλιστική εκτίμηση για τις πραγματικές συνθήκες της αγοράς.

Τα μοντέλα Μηχανικής Μάθησης εκπαιδεύονται από τον Ιανουάριο 2017 έως τις 30 Νοεμβρίου 2025, με βελτιστοποίηση υπερπαραμέτρων μέσω Optuna. Εξαίρεση αποτελεί το μοντέλο SVR, το οποίο σε ορισμένες περιπτώσεις εκπαιδεύεται σε περιορισμένο εύρος 5.000 ωρών για τη μείωση του υπολογιστικού κόστους. Η επίδοση συγκρίνεται με τέσσερα βασικά μοντέλα αναφοράς (Naive-1, Naive-24, Naive-168 και Seasonal Profile). Ο Πίνακας 6.1 συγκεντρώνει τις τιμές τους για τις δύο περιόδους ελέγχου (Δεκέμβριος 2025: 744 ώρες· Q1 2026: 2.160 ώρες). Με τον όρο Q1 2026 αναφερόμαστε στο τρίμηνο δοκιμής Δεκέμβριος 2025 - Φεβρουάριος 2026, και όχι στο ημερολογιακό πρώτο τρίμηνο (Ιανουάριος - Μάρτιος).

Πίνακας 6.1. Επίδοση μοντέλων αναφοράς (benchmarks) για την τιμή DAM και το ηλεκτρικό φορτίο, μηνιαία αξιολόγηση.

Περίοδος	Στόχος	Μοντέλο Αναφοράς	MAE	RMSE	sMAPE (%)
Δεκ. 2025	Τιμή (€/MWh)	Naive-1	13,709	22,748	13,013
		Seasonal Profile	18,127	27,388	17,293
		Naive-24	20,032	31,257	20,288
		Naive-168	27,504	40,912	27,324
	Φορτίο (MW)	Naive-1	260,077	328,760	4,679
		Seasonal Profile	291,557	396,534	5,038
		Naive-24	309,920	435,517	5,430
		Naive-168	313,240	419,529	5,417
Q1 2026	Τιμή (€/MWh)	Naive-1	15,433	26,781	22,635
		Naive-24	23,321	37,008	34,260
		Seasonal Profile	25,254	38,377	31,244
		Naive-168	29,204	44,537	37,895
	Φορτίο (MW)	Naive-1	271,185	344,041	4,761
		Naive-24	345,694	487,585	5,909
		Seasonal Profile	348,502	494,348	5,832
		Naive-168	369,785	530,274	6,229

Οι τιμές του Πίνακα 6.1 αφορούν πρόβλεψη ενός βήματος (Teacher-Forcing, Recursive). Από τα μοντέλα αναφοράς, το Naive-1 δίνει το χαμηλότερο σφάλμα (13,7 €/MWh, τιμή Δεκ.), καθώς η τιμή μιας ώρας μοιάζει πολύ με εκείνη της επόμενης. Το Naive-24 (20,0 €/MWh) αντιγράφει την προηγούμενη ημέρα και αστοχεί όταν η τιμή ανεβαίνει ή πέφτει από μέρα σε μέρα, ενώ το Naive-168 (27,5 €/MWh) έχει τη χειρότερη απόδοση, επαναλαμβάνοντας την αντίστοιχη ώρα της προηγούμενης εβδομάδας. Το Seasonal Profile (18,1 €/MWh), ως μέσος όρος τεσσάρων εβδομάδων, δίνει μια ομαλή αλλά χονδρική εκτίμηση. Στο Q1 όλες οι αναφορές χειροτερεύουν για την τιμή, ενώ για το φορτίο μένουν σχεδόν αμετάβλητες, ένδειξη ότι η δυσκολία της περιόδου αφορά κυρίως την τιμή.

Για τις στρατηγικές ταυτόχρονης ημερήσιας πρόβλεψης (MIMO, Direct) η φυσική αναφορά είναι το Naive-24, δηλαδή η ίδια ώρα της προηγούμενης ημέρας, υπολογισμένη στο αντίστοιχο ημερήσιο σχήμα $H = 24$: 18,212 €/MWh για την τιμή και 309,920 MW για το φορτίο τον Δεκέμβριο 2025. Σε αυτό το πλαίσιο το Naive-1 δεν αποτελεί ισοδύναμη αναφορά, καθώς προϋποθέτει πρόσβαση στην αμέσως προηγούμενη πραγματική ώρα.

Η αξιολόγηση των στρατηγικών πραγματοποιείται σε δύο στάδια. Αρχικά, οι αρχιτεκτονικές TF, Recursive, MIMO και Direct εξετάζονται υπό στατική εκπαίδευση με βάση αποκλειστικά τα αποτελέσματα του Δεκεμβρίου 2025. Ο μήνας αυτός χρησιμοποιείται ως ελεγχόμενη περίοδος αναφοράς (control period), επιτρέποντας τη σύγκριση της δομικής συμπεριφοράς των αλγορίθμων υπό σταθερές συνθήκες. Στη συνέχεια, η ανάλυση μεταφέρεται στο τρίμηνο Q1 2026. Λόγω της μεταβολής καθεστώτος (regime shift) κατά την περίοδο αυτή, οι στατικές επιδόσεις δεν αναλύονται σε επίπεδο αναλυτικών πινάκων ανά στρατηγική· αντ' αυτού, συμπυκνώνονται και αντιπαραβάλλονται απευθείας με τις επιδόσεις της μηνιαίας walk-forward επανεκπαίδευσης, μέσω του δείκτη Retraining Premium και του τελικού συγκεντρωτικού πίνακα.

6.2 Στατική Εκπαίδευση: Δεκέμβριος 2025

Η στατική αξιολόγηση του Δεκεμβρίου 2025 αποτελεί το πρώτο πειραματικό στάδιο του Κεφαλαίου. Τα μοντέλα εκπαιδεύονται μία φορά, με ημερομηνία αποκοπής την 30ή Νοεμβρίου 2025, και αξιολο-

γούνται στον Δεκέμβριο 2025, δηλαδή σε 744 ωριαίες παρατηρήσεις. Με τον τρόπο αυτό εξετάζεται η συμπεριφορά των στρατηγικών πρόβλεψης υπό κοινό και σταθερό εκπαιδευτικό πλαίσιο, πριν εισαχθεί η μηνιαία walk-forward επανεκπαίδευση του Q1 2026.

Η ενότητα οργανώνεται ανά στρατηγική πρόβλεψης. Πρώτα παρουσιάζεται το Teacher-Forcing, το οποίο λειτουργεί ως ιδεατό μοντέλο αναφοράς. Στη συνέχεια εξετάζεται η Recursive στρατηγική, που αποτελεί πρακτικά εφαρμόσιμη αναδρομική προσέγγιση. Τέλος, παρουσιάζονται οι στρατηγικές MIMO και Direct, οι οποίες προβλέπουν ολόκληρο το 24ωρο από μία κοινή ημερήσια αφετηρία. Στο τέλος της ενότητας παρατίθεται συγκεντρωτική σύνοψη των καλύτερων αποτελεσμάτων κάθε στρατηγικής για την τιμή DAM και το ηλεκτρικό φορτίο.

6.2.1 Teacher-Forcing (TF)

Η στρατηγική Teacher-Forcing παράγει τις ωριαίες προβλέψεις διαδοχικά, χρησιμοποιώντας την πραγματική τιμή του προηγούμενου βήματος ως είσοδο. Με τον τρόπο αυτό εξαλείφει τη συσσώρευση σφάλματος (error accumulation) και λειτουργεί ως ιδεατό μοντέλο αναφοράς (oracle). Ωστόσο, απαιτεί τη σταδιακή διαθεσιμότητα των πραγματικών δεδομένων, κάτι που δεν ισχύει στο gate closure της Αγοράς Επόμενης Ημέρας. Επομένως, η επίδοση της TF δεν πρέπει να ερμηνεύεται ως πλήρως αναπτυξίσιμη επιχειρησιακή λύση, αλλά ως άνω φράγμα απόδοσης.

Οι Πίνακες 6.2 και 6.3 παρουσιάζουν τα αποτελέσματα Teacher-Forcing για τον Δεκέμβριο 2025.

Πίνακας 6.2. TF, πρόβλεψη τιμής, Δεκέμβριος 2025 (744h).

Μοντέλο	MAE (€/MWh)	RMSE (€)	sMAPE (%)	Κατ.
Ensemble-Best3	9,943	15,994	10,697	1
XGBoost	10,204	16,170	11,087	2
LightGBM	10,334	16,236	11,178	3
RandomForest	11,220	18,206	11,467	4
MLP-Optuna	11,737	17,191	12,371	5
SVR	13,432	19,070	13,666	6
Naive-1 (baseline)	13,709	22,748	13,013	---

Πίνακας 6.3. TF, πρόβλεψη φορτίου, Δεκέμβριος 2025 (744h).

Μοντέλο	MAE (MW)	RMSE (MW)	sMAPE (%)	Κατ.
Ensemble-Best3	72,916	96,945	1,260	1
XGBoost	75,885	98,951	1,311	2
LightGBM	76,324	101,752	1,316	3
MLP-Optuna	78,992	106,963	1,370	4
RandomForest	96,539	133,149	1,671	5
SVR	141,406	199,114	2,469	6
Naive-1 (baseline)	260,077	328,760	4,679	---
Seasonal Profile	291,557	396,534	5,038	---

Στο πλαίσιο της στρατηγικής Teacher-Forcing, το Ensemble-Best3 επιτυγχάνει την καλύτερη επίδοση τόσο στην τιμή όσο και στο φορτίο. Στην πρόβλεψη της τιμής DAM καταγράφει MAE 9,943 €/MWh, ενώ τα XGBoost και LightGBM ακολουθούν με μικρή διαφορά. Το αποτέλεσμα αυτό επιβεβαιώνει τη σταθερή συμπεριφορά των gradient boosting μοντέλων στο πρόβλημα της τιμής, αλλά και την

πρόσθετη αξία του συνδυασμού μοντέλων.

Στο ηλεκτρικό φορτίο, το Ensemble-Best3 επιτυγχάνει MAE 72,916 MW και sMAPE 1,260%. Το σχετικό σφάλμα είναι πολύ χαμηλότερο από εκείνο της τιμής, γεγονός που αντανακλά τη μεγαλύτερη κανονικότητα, εποχικότητα και αυτοσυσχέτιση του φορτίου. Η SVR παρουσιάζει τη χαμηλότερη επίδοση μεταξύ των μοντέλων μηχανικής μάθησης, ιδίως στο φορτίο, καθώς εκπαιδεύτηκε σε περιορισμένο ιστορικό εύρος για τη μείωση του υπολογιστικού κόστους.

6.2.2 Recursive (Rec)

Η Recursive στρατηγική χρησιμοποιεί ένα ενιαίο μοντέλο που προβλέπει μία χρονική στιγμή τη φορά και στη συνέχεια εισάγει την προηγούμενη πρόβλεψη ως είσοδο για την επόμενη ώρα. Η προσέγγιση αυτή είναι πρακτικά εφαρμόσιμη στον ορίζοντα της DAM, καθώς δεν απαιτεί πρόσβαση σε πραγματικές ενδοημερήσιες τιμές της ημέρας πρόβλεψης. Το βασικό της μειονέκτημα είναι η πιθανή συσσώρευση σφάλματος όσο η πρόβλεψη προχωρά βαθύτερα στον 24ωρο ορίζοντα.

Πίνακας 6.4. Rec $H = 24$, πρόβλεψη τιμής, Δεκέμβριος 2025 (31 ημερήσια τμήματα).

Μοντέλο	MAE (€/MWh)	RMSE (€)	sMAPE (%)	Κατ.
Ensemble-Top3 (LGBM+RF+XGB)	13,960	21,958	13,649	1
Ensemble-All-24h (1/MAE)	13,996	21,641	13,771	2
LGBM-Daily-Optuna	14,494	22,511	14,208	3
RF-Daily-SS	14,607	23,015	14,072	4
XGB-Daily-SS-Optuna Dense	14,816	23,088	14,743	5
MLP-SS	15,169	22,065	14,791	6
SVR-Rec	18,549	25,602	17,608	7

Πίνακας 6.5. Rec $H = 24$, πρόβλεψη φορτίου, Δεκέμβριος 2025 (31 ημερήσια τμήματα).

Μοντέλο	MAE (MW)	RMSE (MW)	sMAPE (%)	Κατ.
LGBM-Daily-SS-Optuna	80,704	106,076	1,387	1
Ensemble-Top3 (1/MAE)	92,126	121,919	1,581	2
XGB-Daily-Optuna	99,575	131,606	1,702	3
RF-Daily-SS	117,740	164,388	2,034	4
MLP-SS	122,604	160,775	2,108	5
SVR-Rec	184,739	254,578	3,220	6

Στην πρόβλεψη της τιμής DAM, το Ensemble-Top3 επιτυγχάνει την καλύτερη αναδρομική επίδοση με MAE 13,960 €/MWh. Η τιμή αυτή βρίσκεται πολύ κοντά στο Naive-1 (13,709 €/MWh), αλλά δεν το υπερβαίνει. Το αποτέλεσμα αυτό δείχνει ότι, στη στατική εκπαίδευση του Δεκεμβρίου, η Recursive στρατηγική περιορίζεται από τη συσσώρευση σφάλματος. Παρότι τα δενδρικά μοντέλα αξιοποιούν μη γραμμικές σχέσεις και εξωγενή χαρακτηριστικά, η αναδρομική χρήση των ίδιων των προβλέψεων τους αυξάνει το σφάλμα κατά την εξέλιξη του 24ωρου ορίζοντα.

Στο ηλεκτρικό φορτίο, αντίθετα, η Recursive στρατηγική εμφανίζει πολύ ισχυρότερη συμπεριφορά. Το LGBM-Daily-SS-Optuna επιτυγχάνει MAE 80,704 MW και πλησιάζει αρκετά την επίδοση του Teacher-Forcing. Η διαφορά αυτή εξηγείται από τη σταθερότερη ημερήσια και εβδομαδιαία δομή του φορτίου, η οποία περιορίζει την αποσταθεροποίηση των αναδρομικών εισόδων. Η Προγραμματισμένη Δειγματοληψία (Scheduled Sampling) συμβάλλει επιπλέον στη μείωση του χάσματος μεταξύ συνθηκών εκπαίδευσης και συνθηκών εκτέλεσης.

6.2.3 MIMO και Direct

Οι στρατηγικές MIMO και Direct προβλέπουν ολόκληρο το 24ωρο από μία κοινή ημερήσια αφετηρία, χωρίς αναδρομική ανατροφοδότηση με ενδιάμεσες προβλέψεις. Για τον λόγο αυτό η καταλληλότερη αναφορά τους δεν είναι το Naive-1, αλλά το Naive-24, δηλαδή η τιμή της ίδιας ώρας της προηγούμενης ημέρας. Η σύγκρισή τους με το Naive-24 είναι μεθοδολογικά πιο δίκαιη, καθώς μοιράζεται το ίδιο βασικό σύνολο διαθέσιμης πληροφορίας.

MIMO. Η στρατηγική MIMO (Multi-Input Multi-Output) χρησιμοποιεί ένα ενιαίο μοντέλο για την ταυτόχρονη παραγωγή του διανύσματος των 24 ωρών της επόμενης ημέρας. Με τον τρόπο αυτό αποφεύγει τη συσσώρευση σφάλματος, επειδή οι προβλέψεις δεν τροφοδοτούνται αναδρομικά στο μοντέλο. Ωστόσο, δεν διαθέτει ενδοημερήσια ανατροφοδότηση και άρα βασίζεται αποκλειστικά στην πληροφορία που είναι διαθέσιμη στην αρχή του ημερήσιου ορίζοντα.

Πίνακας 6.6. MIMO $H = 24$, πρόβλεψη τιμής, Δεκέμβριος 2025.

Μοντέλο	MAE (€/MWh)	RMSE (€)	sMAPE (%)	Κατ.
Ensemble-Best3 (1/MAE)	14,512	21,560	13,568	1
XGB MIMO Dense	14,919	22,044	13,852	2
RF MIMO+Load Dense	15,139	22,977	13,901	3
MLP MIMO+Load Dense	19,325	25,646	18,612	4
SVR MIMO+Load	20,410	30,598	18,936	5
Naive-24 (αναφορά)	18,212	27,436	17,741	---
Seasonal Profile	18,392	27,458	17,333	---

Στην πρόβλεψη της τιμής, το Ensemble-Best3 ηγείται με MAE 14,512 €/MWh, επιτυγχάνοντας μείωση σφάλματος κατά 20,3% έναντι του Naive-24. Οι tree-based dense υλοποιήσεις ακολουθούν με μικρή απόσταση, ενώ τα μοντέλα MLP και SVR υστερούν έναντι της αναφοράς.

Πίνακας 6.7. MIMO $H = 24$, πρόβλεψη φορτίου, Δεκέμβριος 2025. Το † δηλώνει μοντέλο που εξαιρείται λόγω αστοχίας.

Μοντέλο	MAE (MW)	RMSE (MW)	sMAPE (%)	Κατ.
Ensemble-Best3 (1/MAE)	188,078	294,694	3,218	1
RF MIMO	219,250	313,966	3,758	2
MLP MIMO	219,884	308,093	3,789	3
SVR MIMO	586,623	709,802	10,406	†
Seasonal Profile	291,557	396,534	5,038	---
Naive-24 (αναφορά)	309,920	435,517	5,430	---

Στο ηλεκτρικό φορτίο, το Ensemble-Best3 παραμένει κορυφαίο με MAE 188,078 MW, σημειώνοντας βελτίωση 39,3% έναντι του Naive-24. Η SVR καταρρέει (586,623 MW, sMAPE 10,406%), γεγονός που δείχνει τη μειωμένη ανθεκτικότητα του RBF πυρήνα στο συγκεκριμένο σχήμα εκπαίδευσης.

Direct. Η Direct στρατηγική εκπαιδεύει 24 ανεξάρτητα υπομοντέλα, ένα για κάθε ώρα της επόμενης ημέρας. Η προσέγγιση αυτή επιτρέπει εξειδικευμένη προσαρμογή στα ωριαία μοτίβα, θυσιάζοντας όμως τη χρονική συνοχή μεταξύ διαδοχικών προβλέψεων.

Πίνακας 6.8. Direct $H = 24$, πρόβλεψη τιμής, Δεκέμβριος 2025.

Μοντέλο	MAE (€/MWh)	RMSE (€)	sMAPE (%)	Κατ.
LGBM Direct Dense	14,543	21,788	13,559	1
Ensemble-All-24h (1/MAE)	14,641	21,499	13,683	2
XGB Direct Dense	15,092	21,698	14,125	3
Naive-24 (αναφορά)	18,212	27,436	17,741	---
Seasonal Profile	18,392	27,458	17,333	---

Στην πρόβλεψη της τιμής, το LGBM Direct Dense προηγείται με MAE 14,543 €/MWh, επιτυγχάνοντας μείωση σφάλματος κατά 20,1% έναντι του Naive-24.

Πίνακας 6.9. Direct $H = 24$, πρόβλεψη φορτίου, Δεκέμβριος 2025.

Μοντέλο	MAE (MW)	RMSE (MW)	sMAPE (%)	Κατ.
XGB Direct Dense	188,033	296,611	3,218	1
Ensemble-All-24h (1/MAE)	189,114	298,794	3,232	2
LGBM Direct Dense	194,417	304,411	3,314	3
Seasonal Profile	291,557	396,534	5,038	---
Naive-24 (αναφορά)	309,920	435,517	5,430	---

Στο ηλεκτρικό φορτίο, το XGB Direct Dense καταγράφει την καλύτερη επίδοση της στρατηγικής με MAE 188,033 MW, δηλαδή πρακτικά ισοδύναμη με την καλύτερη MIMO επίδοση. Συνολικά, οι MIMO και Direct εμφανίζουν πολύ κοντινά επίπεδα σφάλματος και στις δύο εργασίες. Η προσθήκη πυκνών υστερήσεων (dense lags), αν και σχεδιάστηκε αρχικά για την Direct αρχιτεκτονική, ωφελεί και τη MIMO στρατηγική, επειδή παρέχει λεπτομερέστερη περιγραφή της ενδοημερήσιας δομής χωρίς αναδρομική διάδοση σφάλματος.

6.2.4 Συνολική Σύνοψη Στατικής Αξιολόγησης


Οι προηγούμενες υποενότητες παρουσιάζουν αναλυτικά τα αποτελέσματα κάθε στρατηγικής. Για να είναι πιο άμεση η σύγκριση, οι Πίνακες 6.10 και 6.11 συγκεντρώνουν το καλύτερο αποτέλεσμα κάθε στρατηγικής για την τιμή DAM και το ηλεκτρικό φορτίο αντίστοιχα. Στις στρατηγικές TF και Recursive η σύγκριση γίνεται ως προς το Naive-1, ενώ στις MIMO και Direct ως προς το Naive-24, επειδή οι τελευταίες προβλέπουν ολόκληρο το ημερήσιο προφίλ από μία κοινή αφετηρία.

Πίνακας 6.10. Στατική εκπαίδευση, Δεκέμβριος 2025: καλύτερο μοντέλο ανά στρατηγική για την τιμή DAM.


Στρατηγική	Καλύτερο μοντέλο	MAE	RMSE	sMAPE (%)	Δ MAE
TF	Ensemble-Best3	9,943	15,994	10,697	+27,5% έναντι Naive-1
Recursive	Ensemble-Top3	13,960	21,958	13,649	-1,8% έναντι Naive-1
MIMO	Ensemble-Best3	14,512	21,560	13,568	+20,3% έναντι Naive-24
Direct	LGBM Direct Dense	14,543	21,788	13,559	+20,1% έναντι Naive-24

Πίνακας 6.11. Στατική εκπαίδευση, Δεκέμβριος 2025: καλύτερο μοντέλο ανά στρατηγική για το ηλεκτρικό φορτίο.

Στρατηγική	Καλύτερο μοντέλο	MAE	RMSE	sMAPE (%)	Δ MAE
TF	Ensemble-Best3	72,916	96,945	1,260	+72,0% έναντι Naive-1
Recursive	LGBM-Daily-SS-Optuna	80,704	106,076	1,387	+69,0% έναντι Naive-1
MIMO	Ensemble-Best3	188,078	294,694	3,218	+39,3% έναντι Naive-24
Direct	XGB Direct Dense	188,033	296,611	3,218	+39,3% έναντι Naive-24



Σχήμα 6.1. Στατική εκπαίδευση, Δεκέμβριος 2025: καλύτερο MAE ανά στρατηγική για την τιμή DAM.



Σχήμα 6.2. Στατική εκπαίδευση, Δεκέμβριος 2025: καλύτερο MAE ανά στρατηγική για το ηλεκτρικό φορτίο.

Η συνολική σύνοψη αναδεικνύει δύο βασικές διαφοροποιήσεις. Στην τιμή DAM, το Teacher-Forcing έχει καθαρά την καλύτερη επίδοση, αλλά η υπεροχή του πρέπει να ερμηνευθεί ως ιδεατό άνω φράγμα, επειδή χρησιμοποιεί πραγματικές ενδοημερήσιες υστερήσεις. Από τις πρακτικά εφαρμόσιμες στρατηγικές, οι MIMO και Direct βελτιώνουν αισθητά το Naive-24, ενώ η Recursive υπολείπεται οριακά του Naive-1. Αυτό δείχνει ότι στην τιμή η αναδρομική διάδοση σφάλματος είναι ουσιαστικότερος περιορισμός από ό,τι στο φορτίο.

Στο ηλεκτρικό φορτίο, η εικόνα είναι διαφορετική. Η Recursive στρατηγική πλησιάζει αρκετά το Teacher-Forcing και υπερβαίνει κατά πολύ το Naive-1, γεγονός που δείχνει ότι η ισχυρή ημερήσια και εβδομαδιαία κανονικότητα του φορτίου περιορίζει τη συσσώρευση σφάλματος. Οι MIMO και Direct βελτιώνουν επίσης σημαντικά το Naive-24, όμως παραμένουν αρκετά μακριά από τις στρατηγικές που αξιοποιούν διαδοχική ενδοημερήσια πληροφορία. Τα Σχήματα 6.1 και 6.2 οπτικοποιούν αυτή τη διαφορά: στην τιμή η απόσταση του Teacher-Forcing από τις εφαρμόσιμες στρατηγικές είναι εμφανής, ενώ στο φορτίο η Recursive στρατηγική παραμένει πολύ κοντά στο ιδεατό όριο. Η στατική αξιολόγηση, επομένως, δείχνει ήδη ότι η επιλογή στρατηγικής είναι εξίσου σημαντική με την επιλογή αλγορίθμου και ότι τα δύο σήματα, τιμή και φορτίο, δεν αντιδρούν με τον ίδιο τρόπο στον 24ωρο ορίζοντα πρόβλεψης.

6.3 Walk-Forward Μηνιαία Επανεκπαίδευση, Q1 2026

Η walk-forward μηνιαία επανεκπαίδευση εφαρμόζεται κατά το πρώτο τρίμηνο του 2026 (Q1 2026: 2.160 ώρες αξιολόγησης), με σκοπό την ενσωμάτωση της πιο πρόσφατης πληροφορίας της αγοράς στα μοντέλα πρόβλεψης. Η διαδικασία αυτή επεκτείνει το σύνολο εκπαίδευσης (training set) κατά έναν πλήρη μήνα σε κάθε βήμα, επιτρέποντας στους αλγορίθμους να προσαρμόζουν τις παραμέτρους τους στις μεταβαλλόμενες συνθήκες. Στις υποενότητες που ακολουθούν, παρουσιάζονται αρχικά τα αποτελέσματα της στρατηγικής Teacher-Forcing (TF) υπό το πλαίσιο της μηνιαίας ανανέωσης δεδομένων, προκειμένου να ποσοτικοποιηθεί το θεωρητικό όφελος της δυναμικής εκπαίδευσης σε

σχέση με τη στατική προσέγγιση.

6.3.1 Αποτελέσματα Στρατηγικής Teacher-Forcing (TF) Walk-Forward

Οι Πίνακες 6.12 και 6.13 συγκεντρώνουν τις συνολικές επιδόσεις των μοντέλων Μηχανικής Μάθησης για την τιμή DAM και το ηλεκτρικό φορτίο αντίστοιχα, κατά την περίοδο Q1 2026, χρησιμοποιώντας τη στρατηγική Teacher-Forcing με μηνιαία επανεκπαίδευση.

Πίνακας 6.12. Walk-forward TF, πρόβλεψη τιμής DAM, Q1 2026 (2.160h).

Κατ.	Μοντέλο	MAE (€/MWh)	RMSE (€)	sMAPE (%)
1	TF-LGBM-MR	10,463	15,682	20,600
2	Ensemble-TF-Best3	10,491	15,726	20,589
3	TF-XGB-MR	10,913	16,148	21,008
4	Ensemble-TF-All	11,041	16,214	20,901
5	TF-RF-MR	12,806	19,089	21,825
6	TF-MLP-MR	15,620	22,458	25,047
---	Στατικό TF Best3	14,478	22,193	25,085
---	Naive-1 (baseline)	15,433	26,781	22,635

Στην πρόβλεψη της τιμής DAM για το πρώτο τρίμηνο του 2026 (Πίνακας 6.12), το μοντέλο TF-LGBM-MR σημειώνει το χαμηλότερο MAE (10,463 €/MWh), με το Ensemble-TF-Best3 να ακολουθεί στα 10,491 €/MWh εξασφαλίζοντας παράλληλα το βέλτιστο sMAPE (20,589%). Η σύγκριση αυτή με το Στατικό TF Best3 (14,478 €/MWh) μεταφράζεται σε μείωση του σφάλματος κατά 27,7%, γεγονός που αναδεικνύει τη σημασία της επανεκπαίδευσης σε πρόσφατα δεδομένα.

Επειδή το κεντρικό αυτό αποτέλεσμα αφορά ακριβώς την τιμή, το σήμα όπου το *gas_price* της δοκιμαστικής περιόδου εμφανίζει ήπιο look-ahead λόγω της συνθετικής παρεμβολής (§3), σημειώνεται ότι το εύρημα δεν στηρίζεται σε αυτό το χαρακτηριστικό: στα νικητήρια μοντέλα TF/Recursive κυριαρχεί το αυτοπαλίνδρομο σήμα (*Price_lag1* έως 88,3%), ενώ το *gas_price* αποκτά μη αμελητέο βάρος μόνο στις πολυβηματικές δομές MIMO/Direct (Κεφ. 7). Η επανεκπαίδευση κερδίζει μέσω της προσαρμογής στη μετατόπιση επιπέδου της τιμής (§6.3.2), όχι μέσω του αερίου· ο περιορισμός και η αντιμετώπισή του αναλύονται στο Κεφ. 8.

Πίνακας 6.13. Walk-forward TF, πρόβλεψη ηλεκτρικού φορτίου, Q1 2026 (2.160h).

Κατ.	Μοντέλο	MAE (MW)	RMSE (MW)	sMAPE (%)
1	Ensemble-TF-Best3	67,729	89,324	1,156
2	TF-LGBM-MR	69,435	92,490	1,182
3	TF-XGB-MR	72,925	95,540	1,242
4	TF-MLP-MR	88,493	116,316	1,518
---	Στατικό TF Best3	96,751	122,049	1,685
---	Naive-1 (baseline)	267,151	335,879	4,696


Στην πρόβλεψη του ηλεκτρικού φορτίου (Πίνακας 6.13), το Ensemble-TF-Best3 καταγράφει την καλύτερη επίδοση με MAE 67,729 MW και sMAPE 1,156%. Η μηνιαία επανεκπαίδευση μειώνει το σφάλμα κατά 30% σε σχέση με το Στατικό TF Best3 (96,751 MW).

Παρά τη μείωση του MAE, η ποσοστιαία μετρική sMAPE δείχνει ότι η πραγματική βελτίωση στο φορτίο είναι οριακή (μόλις $\Delta sMAPE = -0,529\%$). Αντίθετα, στην τιμή η πτώση του σφάλματος

είναι πολύ μεγαλύτερη ($\Delta\text{sMAPE} = -4,496\%$). Η σύγκριση αυτή, επειδή γίνεται σε κοινή ποσοστιαία κλίμακα, εξαλείφει τη διαφορά των μονάδων μέτρησης (€/MWh έναντι MW) και αποδεικνύει ότι η επανεκπαίδευση ωφελεί ουσιαστικά την τιμή, κάτι που θα δειχθεί και στα σχήματα που ακολουθούν.

6.3.2 Ανάλυση Μεταβολής Καθεστώτος

Η ασύμμετρη αυτή συμπεριφορά ανάμεσα στα δύο σήματα συνδέεται άμεσα με τη στατιστική εξέλιξη των πραγματικών δεδομένων. Η αιτία εντοπίζεται στην εξέλιξη της τιμής DAM και του ηλεκτρικού φορτίου κατά το πρώτο τρίμηνο του 2026, όπως αποτυπώνεται στα Σχήματα 6.3 και 6.4. Η μαύρη έντονη γραμμή αντιπροσωπεύει τον κυλιόμενο μέσο όρο 30 ημερών (level) και η πράσινη γραμμή την κυλιόμενη τυπική απόκλιση 30 ημερών, η οποία αποδίδει τη μεταβλητότητα (volatility) της αγοράς.




Σχήμα 6.3. Μεταβολή καθεστώτος Q1 2026: κυλιόμενος μέσος και κυλιόμενη μεταβλητότητα 30 ημερών του πραγματικού σήματος, Τιμή DAM (€/MWh).

Στο Σχήμα 6.3 για την τιμή DAM, η γκριζα ζώνη ορίζει τον Φεβρουάριο ως την περίοδο χαμηλών τιμών, ενώ η κόκκινη διακεκομμένη γραμμή στα μέσα του μήνα εντοπίζει στατιστικά το ακριβές σημείο της δομικής αλλαγής (change-point). Εδώ παρατηρείται μια βίαιη μεταβολή καθεστώτος (regime shift), καθώς η αγορά υποχωρεί από τις υψηλές τιμές της περιόδου εκπαίδευσης (110 ± 34 €/MWh) και σταθεροποιείται στο νέο καθεστώς του Φεβρουαρίου στα 78 €/MWh (πτώση 28%), με τη μεταβλητότητα όμως να αυξάνεται απότομα στα ± 45 €/MWh. Οι δύο αυτές κατανομές δεν επικαλύπτονται. Αυτό το covariate shift αποπροσανατολίζει τα στατικά μοντέλα. Έχοντας εκπαιδευτεί

αποκλειστικά σε υψηλές τιμές, αδυνατούν να αναγνωρίσουν το νέο επίπεδο της αγοράς, κάνοντας τη walk-forward επανεκπαίδευση απολύτως αναγκαία.

Μεταβολή Καθεστώτος Αγοράς — Φορτίο (Q1 2026)



Σχήμα 6.4. Μεταβολή καθεστώτος Q1 2026: κυλιόμενος μέσος και κυλιόμενη μεταβλητότητα 30 ημερών του πραγματικού σήματος, Ηλεκτρικό φορτίο (MW).

Αντίθετα, στο Σχήμα 6.4 για το ηλεκτρικό φορτίο η εικόνα είναι διαφορετική, καθώς δεν εντοπίζεται κανένα στατιστικό σημείο αλλαγής. Αν και ο κυλιόμενος μέσος (level) σχηματίζει μια καμπύλη λόγω της φυσικής μετάβασης από τον χειμώνα στην άνοιξη, η μέση ζήτηση μεταβάλλεται ελάχιστα (πτώση μόλις 7%), ενώ η μεταβλητότητα μειώνεται ελαφρώς. Το κρίσιμο εύρημα είναι ότι η ζώνη της εκπαίδευσης (5707 ± 951 MW) και η ζώνη του Φεβρουαρίου (5567 ± 839 MW) επικαλύπτονται σχεδόν ολοκληρωτικά. Το σήμα δεν βγαίνει ποτέ εκτός των ορίων που ήδη γνωρίζουν τα μοντέλα. Επειδή οι συνθήκες δεν άλλαξαν δομικά, τα στατικά μοντέλα παραμένουν «διαβασμένα», γεγονός που εξηγεί γιατί συνεχίζουν να προβλέπουν με υψηλή ακρίβεια και το όφελος της επανεκπαίδευσης είναι σχεδόν μηδενικό.

Για την αξιολόγηση των μοντέλων σε πραγματικές συνθήκες, η ανάλυση επεκτείνεται παρακάτω στις εφαρμόσιμες στρατηγικές πολλαπλών βημάτων (Recursive, MIMO, Direct) με μηνιαία επανεκπαίδευση, εξετάζοντας το Retraining Premium και τη συμπεριφορά τους στη μεταβολή καθεστώτος.

6.3.3 Αντίκτυπος Επανεκπαίδευσης

Η σύγκριση των στατικών μοντέλων με τις walk-forward εκδόσεις τους ποσοτικοποιεί την επίδραση της μηνιαίας ανανέωσης των δεδομένων. Η ανάλυση εξετάζει την εξέλιξη του σφάλματος ανά μήνα για να προσδιορίσει τη στιγμή διαφοροποίησης των δύο προσεγγίσεων και στη συνέχεια μετρά τη


συνολική ποσοστιαία μεταβολή των δεικτών MAE και sMAPE.

Ο Πίνακας 6.14 συγκεντρώνει το καλύτερο μοντέλο κάθε στρατηγικής υπό μηνιαία επανεκπαίδευση, για τιμή DAM και φορτίο, ώστε οι τέσσερις αρχιτεκτονικές να συγκρίνονται σε κοινή βάση. Η Teacher-Forcing παρατίθεται ως oracle αναφορά: χρησιμοποιεί τις πραγματικές πρόσφατες υστερήσεις και δεν είναι αναπτυξίσιμη στο κλείσιμο της πύλης. Η αναπτυξίσιμη σύσταση είναι η Recursive, η οποία με το Rec-XGB-SS-DO-MR επιτυγχάνει 18,534 €/MWh στην τιμή και 70,641 MW στο φορτίο, υπερέχοντας τόσο των πολυβηματικών στρατηγικών (MIMO, Direct) όσο και του Naive-1 και στις δύο εργασίες.

Πίνακας 6.14. Walk-forward μηνιαία επανεκπαίδευση, Q1 2026 (2.160h): καλύτερο μοντέλο ανά στρατηγική για τιμή DAM και φορτίο.

Στρατηγική	Μοντέλο	Τιμή DAM		Φορτίο	
		MAE (€/MWh)	sMAPE (%)	MAE (MW)	sMAPE (%)
Teacher-Forcing [†]	TF-LGBM / Ens-Best3	10,463	20,600	67,729	1,156
Recursive [‡]	Rec-XGB-SS-DO-MR	18,534	25,749	70,641	1,204
MIMO	Ensemble-Best3 MR	19,012	26,423	206,786	3,456
Direct	LGBM Direct Dense MR	19,875	27,315	218,623	3,596
Naive-1 (baseline)	---	15,433	22,635	267,151	4,696


[†]: oracle, μη αναπτυξίσιμη (χρησιμοποιεί πραγματικές πρόσφατες υστερήσεις). [‡]: συνιστώμενη αναπτυξίσιμη στρατηγική.



Σχήμα 6.5. Μηνιαία ανάλυση MAE στην τιμή DAM: Στατική εκπαίδευση έναντι Walk-Forward Monthly Retrain, Q1 2026.


Το Σχήμα 6.5 δείχνει το MAE της τιμής DAM ανά μήνα, συγκρίνοντας τα στατικά μοντέλα (συμπαγείς μπάρες) με τα αντίστοιχα walk-forward (γραμμωτές μπάρες). Η διαφοροποίηση εμφανίζεται αμέσως τον Ιανουάριο, μετά τον πρώτο κύκλο επανεκπαίδευσης, όπου η walk-forward στρατηγική μειώνει άμεσα το σφάλμα. Το πλεονέκτημα αυτό διευρύνεται έντονα τον Φεβρουάριο κατά τη μεταβολή καθεστώτος, όπου η στατική Teacher-Forcing καταρρέει, ενώ η walk-forward συγκρατεί το

σφάλμα. Η επανεκπαίδευση προσδίδει ανθεκτικότητα από τον πρώτο μήνα, η οποία εδραιώνεται με την πάροδο του χρόνου.



Σχήμα 6.6. Μηνιαία ανάλυση MAE στο ηλεκτρικό φορτίο: Στατική εκπαίδευση έναντι Walk-Forward Monthly Retrain, Q1 2026.


Το Σχήμα 6.6 παρουσιάζει την αντίστοιχη μηνιαία πορεία για το ηλεκτρικό φορτίο, όπου η εικόνα αντιστρέφεται. Σε όλο το τρίμηνο, οι μπάρες της στατικής και της walk-forward εκπαίδευσης για τις ίδιες στρατηγικές έχουν σχεδόν ίδιο ύψος. Η επανεκπαίδευση δεν προσφέρει καμία διαφοροποίηση από μήνα σε μήνα. Το σταθερό στατιστικό καθεστώς στη ζήτηση καθιστά τη στατική εκπαίδευση εξίσου ισχυρή.



Σχήμα 6.7. Συνολική διαφορά επίδοσης (Walk-Forward vs Static) ανά στρατηγική στην τιμή DAM, Q1 2026.

Το Σχήμα 6.7 δείχνει τη συνολική μεταβολή του σφάλματος με τη walk-forward εκπαίδευση. Στην

τιμή DAM, η επανεκπαίδευση έχει θετικό πρόσημο, καθώς καταγράφει θετικό αντίκτυπο στις τρεις από τις τέσσερις στρατηγικές, με τη MIMO και την Teacher-Forcing να παρουσιάζουν τη μεγαλύτερη βελτίωση. Αντίθετα, η Recursive είναι η μόνη που εμφανίζει αρνητική μεταβολή, η οποία όμως κρίνεται αμελητέα αφού η επίδραση στο συνολικό sMAPE περιορίζεται μόλις στο $-0,11$ ποσοστιαίες μονάδες (pp).



Σχήμα 6.8. Συνολική διαφορά επίδοσης (Walk-Forward vs Static) ανά στρατηγική στο ηλεκτρικό φορτίο, Q1 2026.

Στο Σχήμα 6.8 για το ηλεκτρικό φορτίο, ο αντίκτυπος της επανεκπαίδευσης είναι αμελητέος σε όλες τις στρατηγικές, είτε με θετικό είτε με αρνητικό πρόσημο. Η Teacher-Forcing και η Direct καταγράφουν μια οριακή αρνητική μεταβολή, ενώ η Recursive και η MIMO σημειώνουν μια εξίσου μικρή βελτίωση. Χαρακτηριστικό της σταθερότητας του σήματος είναι ότι η μεγαλύτερη μεταβολή στο σύνολο του φορτίου εντοπίζεται στην Direct και είναι μόλις $-0,15$ pp στον δείκτη sMAPE.


Συνολικά, η μηνιαία επανεκπαίδευση κρίνεται απαραίτητη και αποδοτική στην τιμή DAM, καθώς προστατεύει τα μοντέλα από δομικές μεταβολές καθεστώτος. Αντίθετα, στο ηλεκτρικό φορτίο ο αντίκτυπος είναι αμελητέος, αφού η σταθερότητα του σήματος επιτρέπει στα στατικά μοντέλα να διατηρούν την ακρίβειά τους.

6.4 Συγκριτική Αξιολόγηση Στρατηγικών Πρόβλεψης

Η αξιολόγηση μετατοπίζεται πλέον από τους συγκεντρωτικούς δείκτες σφάλματος στην εις βάθος εξέταση της συμπεριφοράς των τεσσάρων στρατηγικών πρόβλεψης. Οι μέσες μετρικές MAE, RMSE και sMAPE αποτυπώνουν τη συνολική απόδοση, αδυνατούν όμως να αποκαλύψουν πού και πώς αστοχεί κάθε αρχιτεκτονική μέσα στο 24ωρο ή στις κρίσιμες στιγμές της αγοράς. Για τον λόγο αυτό, η ανάλυση δομείται σε τρεις άξονες: τη στατιστική φύση και μεροληψία των σφαλμάτων, τη χρονική εξέλιξη της ακρίβειας σε ωριαίο και κυκλικό επίπεδο, και τέλος την ανθεκτικότητα των αρχιτεκτονικών στις ακραίες συνθήκες αιχμής της αγοράς.


6.4.1 Στατιστική Κατανομή και Μεροληψία Σφαλμάτων

Τα διαγράμματα πλαισίου-απολήξεων (box plots) αποτυπώνουν γραφικά τη στατιστική κατανομή των απόλυτων σφαλμάτων πρόβλεψης. Ένα στενό κεντρικό πλαίσιο με κοντές απολήξεις υποδηλώνει μια σταθερή και αξιόπιστη στρατηγική. Αυτό συμβαίνει διότι το πλαίσιο ορίζει το ενδοτεταρτημοριακό εύρος (IQR) όπου συγκεντρώνεται το 50% των σφαλμάτων, η εσωτερική γραμμή δείχνει τη διάμεσο (median), ενώ οι οριζόντιες απολήξεις (whiskers) περιορίζουν το εύρος των μεγάλων σφαλμάτων από την 5η έως την 95η εκατοστιαία θέση.



Σχήμα 6.9. Κατανομή απόλυτων σφαλμάτων πρόβλεψης στην τιμή DAM, Q1 2026.

Το Σχήμα 6.9 δείχνει την κατανομή των σφαλμάτων για την τιμή DAM. Οι μονοβηματικές στρατηγικές (Teacher-Forcing και Recursive) επικρατούν με στενότερα πλαίσια και χαμηλότερα σφάλματα. Ωστόσο, ακόμη και σε αυτές, οι απολήξεις (whiskers) εκτείνονται αναλογικά πολύ ψηλότερα από τη διάμεσο. Το γεγονός αυτό φανερώνει ότι στην αγορά της τιμής DAM τα ακραία σφάλματα παραμένουν πολύ έντονα γενικά, λόγω των ξαφνικών εξάρσεων (spikes). Αντίθετα, οι πολυβηματικές προσεγγίσεις (MIMO και Direct) εμφανίζουν πολύ πιο απλωμένες κατανομές, επιβεβαιώνοντας τη μειωμένη σταθερότητά τους.




Σχήμα 6.10. Κατανομή απόλυτων σφαλμάτων πρόβλεψης στο ηλεκτρικό φορτίο, Q1 2026.

Στο Σχήμα 6.10 για το ηλεκτρικό φορτίο, η στατιστική απόκλιση μεταξύ μονοβηματικών και πολυβηματικών στρατηγικών διευρύνεται σημαντικά. Η σταθερότητα και η κυκλικότητα του φορτίου επιτρέπουν στα μονοβηματικά μοντέλα να αξιοποιούν την προηγούμενη τιμή, επιτυγχάνοντας πολύ μικρότερα και λιγότερο ακραία σφάλματα. Οι απολήξεις (whiskers) των καλών μοντέλων συγκρατούνται αναλογικά πολύ κοντά στις διαμέσους τους. Στον αντίποδα, οι πολυβηματικές στρατηγικές (MIMO και Direct) αποτυγχάνουν με κατανομές τεράστιου εύρους και ακραίες απολήξεις που αγγίζουν τα 700 MW.

Η παράλληλη εξέταση των δύο σχημάτων αναδεικνύει δύο χαρακτηριστικά. Πρώτον, η διαφορά απόδοσης μεταξύ μονοβηματικών και πολυβηματικών μοντέλων είναι μεγαλύτερη στο ηλεκτρικό φορτίο από ό,τι στην τιμή DAM. Στο φορτίο η απώλεια της άμεσης αναδρομικής πληροφορίας στις MIMO και Direct διευρύνει το εύρος της κατανομής και των απολήξεων, σε αντίθεση με τη συγκρατημένη εικόνα της τιμής. Δεύτερον, η Recursive μεταβάλλει συμπεριφορά ανάλογα με το σήμα: στην ευμετάβλητη τιμή DAM δυσκολεύεται και πλησιάζει τις πολυβηματικές δομές, ενώ στο σταθερό και κυκλικό φορτίο προσεγγίζει την Teacher-Forcing.


6.4.2 Χρονικές και Κυκλικές Συνθήκες Πρόβλεψης

Η ωριαία μεροληψία (bias) μετρά τη συστηματική τάση των μοντέλων να υποεκτιμούν ή να υπερεκτιμούν την πραγματική τιμή του σήματος σε κάθε ώρα του 24ώρου. Η ανάλυση αυτή δείχνει την κατεύθυνση του σφάλματος και, κατά συνέπεια, τυχόν δομικά σφάλματα σε συγκεκριμένες περιόδους της ημέρας, ενώ η ερμηνεία της υποεκτίμησης ή υπερεκτίμησης ορίζεται βάσει του προσήμου της διαφοράς.



Σχήμα 6.11. Προφίλ ωριαίας μεροληψίας (Bias) στην τιμή DAM, Q1 2026. Θετικές τιμές υποδηλώνουν υποεκτίμηση και αρνητικές τιμές υπερεκτίμηση.

Το Σχήμα 6.11 δείχνει την ωριαία μεροληψία για την τιμή DAM. Όλες οι στρατηγικές παρουσιάζουν συστηματική υπερεκτίμηση (αρνητικό bias) κατά το μεγαλύτερο μέρος της ημέρας. Το φαινόμενο κλιμακώνεται στις πολυβηματικές προσεγγίσεις MIMO και Direct, οι οποίες αγγίζουν αρνητικές τιμές έως -25 €/MWh. Η συμπεριφορά αντιστρέφεται απότομα μόνο στις μεγάλες αιχμές (ώρα 7 και ώρες 19-21), όπου όλα τα μοντέλα εμφανίζουν θετικό bias (υποεκτίμηση), αποτυγχάνοντας να φτάσουν την κορυφή των spikes της αγοράς.




Σχήμα 6.12. Προφίλ ωριαίας μεροληψίας (Bias) στο ηλεκτρικό φορτίο, Q1 2026. Θετικές τιμές υποδηλώνουν υποεκτίμηση και αρνητικές τιμές υπερεκτίμηση.

Στο Σχήμα 6.12 αποτυπώνεται η ωριαία μεροληψία για το ηλεκτρικό φορτίο. Η μεροληψία ακο-

λουθεί την κυκλικότητα της ζήτησης, εναλλάσσοντας πρόσημο μέσα στο 24ωρο. Όλα τα μοντέλα παρουσιάζουν υπερεκτίμηση (αρνητικό bias) νωρίς το πρωί (5-6) και το απόγευμα (16-17), ενώ γυρίζουν σε υποεκτίμηση (θετικό bias) το μεσημέρι (12) και το βράδυ (21). Οι πολυβηματικές στρατηγικές εμφανίζουν εμφανώς μεγαλύτερο εύρος διακύμανσης από τις μονοβηματικές.


Στις ώρες αιχμής, το πρωί (08:00-10:00) και κυρίως το βράδυ (18:00-21:00), η πλειοψηφία των μοντέλων τείνει προς υποεκτίμηση τόσο στην τιμή όσο και στο φορτίο. Αυτό σημαίνει ότι κατά την απότομη άνοδο της ζήτησης και των τιμών, οι στρατηγικές υποτιμούν συστηματικά τόσο το μέγεθος όσο και την ταχύτητα αυτής.

Το ωριαίο προφίλ σφάλματος (Hourly MAE) υπολογίζει τη μέση ακρίβεια των προβλέψεων ανά ώρα, αποκαλύπτοντας αν το σφάλμα ακολουθεί την κυκλικότητα της αγοράς και σε ποια ακριβώς σημεία το μοντέλο αποτυγχάνει συστηματικά.



Σχήμα 6.13. Ωριαίο προφίλ σφάλματος (Hourly MAE) στην τιμή DAM, Q1 2026.

Όπως φαίνεται στο γράφημα του Σχήματος 6.13, τα μεγαλύτερα σφάλματα εντοπίζονται στις ώρες αιχμής (πρωί και βράδυ), όπου το MAE ξεπερνά τα 30 €. Σε αυτές τις συνθήκες υψηλής μεταβλητότητας, οι στρατηγικές Direct, MIMO και Recursive αστοχούν, ενώ η Teacher-Forcing (TF) διατηρεί την καλύτερη επίδοση σε όλο το 24ωρο.




Σχήμα 6.14. Ωριαίο προφίλ σφάλματος (Hourly MAE) στο ηλεκτρικό φορτίο, Q1 2026.

Η ανάλυση των Hourly MAE και Bias αποκαλύπτει ότι η φύση των μεγάλων σφαλμάτων διαφέρει ριζικά ανάμεσα στα δύο προβλήματα. Στην περίπτωση της τιμής, η έξαρση του σφάλματος στις ώρες αιχμής εμφανίζει τη χαρακτηριστική μορφή «Μ», η οποία συμπίπτει με τη συστηματική υποεκτίμηση (under-prediction) των κορυφών. Στο φορτίο, το μεγάλο σφάλμα συνδέεται καθολικά με τη συστηματική υπερεκτίμηση (over-prediction) της ζήτησης κατά τις μεσημεριανές ώρες. Ωστόσο, δεν παρατηρείται κοινή μορφή για όλες τις στρατηγικές, καθώς οι πολυβηματικές προσεγγίσεις (Direct, MIMO) παρουσιάζουν μόνιμη και εντονότερη κατακόρυφη αύξηση της αστοχίας.

6.4.3 Ανθεκτικότητα σε Ακραίες Συνθήκες Αιχμής (Spikes)

Ως spikes τιμές ορίζονται όσες ώρες (22 συνολικά σε όλο το πρώτο τρίμηνο του 2026) η πραγματική τιμή ξεπέρασε το 99ο εκατοστημόριο (246 €/MWh). Οι συγκεκριμένες 22 χρονικές στιγμές επισημαίνονται με έντονα κόκκινα σημεία στο Σχήμα 6.15.


Επισήμανση Αιχμών Τιμής (Q1 2026)



Σχήμα 6.15. Χρονική κατανομή και εντοπισμός των ακραίων εξάρσεων (spikes) της τιμής DAM, Q1 2026.

Το κριτήριο αστοχίας (miss rate) για την ακρίβεια πρόβλεψης των αιχμών ορίζεται σε απόλυτο σφάλμα άνω των 20 €/MWh. Όλες οι στρατηγικές καταγράφουν υψηλά ποσοστά αποτυχίας, επιβεβαιώνοντας την αδυναμία των μοντέλων να προβλέψουν με ακρίβεια τις εξάρσεις, όπως αποτυπώνεται στο ραβδόγραμμα του Σχήματος 6.16.


Ποσοστό Αστοχίας Αιχμών Τιμής ανά Στρατηγική



Σχήμα 6.16. Ποσοστό αστοχίας (Miss Rate) των μοντέλων κατά τις ώρες αιχμής της τιμής DAM.


Ως spikes φορτίου ορίζονται οι ώρες όπου η ζήτηση ξεπέρασε το 99ο εκατοστημόριο (8.060 MW). Προκύπτει συμπτωματικά το ίδιο ακριβώς πλήθος (22 ώρες αιχμής) με την τιμή DAM, επιτρέποντας μια δίκαιη σύγκριση των δειγμάτων. Ωστόσο, οι ώρες αυτές δεν είναι διάσπαρτες, αλλά συγκεντρώνονται όλες μέσα σε ένα χρονικό παράθυρο λίγων μόνο ημερών στα μέσα Ιανουαρίου, λόγω των ακραίων καιρικών συνθηκών που καταπόνησαν το σύστημα, όπως αποτυπώνεται στη χρονοσειρά

του Σχήματος 6.17.



Σχήμα 6.17. Χρονική συγκέντρωση των ακραίων εξάρσεων (spikes) του ηλεκτρικού φορτίου, Q1 2026.

Στο ραβδόγραμμα του Σχήματος 6.18, η εικόνα ανατρέπεται ριζικά. Η Teacher-Forcing (WF-TF) σημειώνει τη χαμηλότερη αστοχία με miss rate μόλις 5%, η Recursive ακολουθεί με 14%, ενώ οι MIMO (64%) και Direct (100%) αποτυγχάνουν καθολικά.




Σχήμα 6.18. Ποσοστό αστοχίας (Miss Rate) των μοντέλων κατά τις ώρες ακραίου ηλεκτρικού φορτίου.

Η σύγκριση παραμένει δίκαιη: τα 200 MW αντιπροσωπεύουν μόλις το 2, 5% της ακραίας ζήτησης, έναντι του 8% της τιμής (20 €/MWh). Παρότι ο έλεγχος είναι αυστηρότερος στο φορτίο, αυτό εξακολουθεί να παρουσιάζει πολύ χαμηλότερη αστοχία, επιβεβαιώνοντας ότι είναι πιο προβλέψιμο μέγεθος από την τιμή.

Η παραπάνω στατιστική συμπεριφορά γίνεται άμεσα κατανοητή μέσω της ποιοτικής εξέτασης δύο χαρακτηριστικών επεισοδίων στα Σχήματα 6.19 (τιμή DAM) και 6.20 (ηλεκτρικό φορτίο), τα οποία αποτυπώνουν τον τρόπο με τον οποίο οι στρατηγικές αντιδρούν σε πραγματικό χρόνο σε επεισόδια αιχμής.


Επεισόδιο Αιχμής — Δεκέμβριος 2025



Σχήμα 6.19. Πραγματική απόκριση των στρατηγικών πρόβλεψης κατά τη διάρκεια ενός επεισοδίου έξαρσης (spike) της τιμής DAM.

Στην τιμή DAM (Σχήμα 6.19), κατά την κορυφή της έξαρσης (> 270 €/MWh), η Teacher-Forcing (WF-TF) είναι η μόνη που ακολουθεί την πορεία της ανόδου, περιορίζοντας τη μονοβηματική αστοχία στην ελάχιστη υποεκτίμηση των -42 €/MWh. Αντίθετα, οι υπόλοιπες στρατηγικές αποτυγχάνουν πλήρως να ακολουθήσουν το spike, με τη Recursive να μένει χαμηλά και τις πολυβηματικές (MIMO, Direct) να καταγράφουν σφάλματα που ξεπερνούν κατά πολύ τα 100 €/MWh.

Επεισόδιο Αιχμής — Ιανουάριος 2026



Σχήμα 6.20. Πραγματική απόκριση των στρατηγικών πρόβλεψης κατά τη διάρκεια ενός επεισοδίου αιχμής του ηλεκτρικού φορτίου.


Στο ηλεκτρικό φορτίο (Σχήμα 6.20), όπου η πραγματική αιχμή προσεγγίζει τα 9.000 MW, η Teacher-Forcing και η Recursive ακολουθούν ικανοποιητικά την καμπύλη, με την καλύτερη προσέγγιση να

σημειώνει ελάχιστη υποεκτίμηση -186 MW. Στον αντίποδα, οι πολυβηματικές MIMO και Direct αδυνατούν να ακολουθήσουν την κορυφή, εμφανίζοντας έντονο flat-lining που ξεπερνά το όριο αστοχίας των 200 MW.

Συνολικά, από τα παραπάνω συμπεραίνουμε ότι οι μονοβηματικές στρατηγικές προσεγγίζουν καλύτερα τις ακραίες συνθήκες (spikes) καθώς διαθέτουν πιο πρόσφατη πληροφορία, ενώ οι πολυβηματικές κρίνονται ακατάλληλες να διαχειριστούν τέτοιες ακραίες καταστάσεις και, κατ' επέκταση, το ρίσκο, τόσο όσον αφορά την τιμή αλλά και το φορτίο, παρόλη την περιοδικότητα του.


6.5 Στατιστική Επικύρωση των Προβλέψεων (Diebold-Mariano)

Οι κατατάξεις των προηγούμενων ενοτήτων εγείρουν ερώτημα εγκυρότητας: Αντανακλούν οι διαφορές σφάλματος ουσιαστική υπεροχή ή θόρυβο της δοκιμαστικής περιόδου; Ο έλεγχος Diebold-Mariano (DM) απαντά συγκρίνοντας κατά ζεύγη τα σφάλματα δύο στρατηγικών και αποδίδοντας στατιστική σημασία στη διαφορά τους. Εφαρμόζουμε τη διόρθωση Harvey-Leybourne-Newbold για μικρά δείγματα και τη διόρθωση Holm-Bonferroni για τις πολλαπλές συγκρίσεις, ώστε κάθε «νίκη» να στηρίζεται σε αυστηρό στατιστικό θεμέλιο ($T = 2.160$ ώρες, $p = 0,05$).



Σχήμα 6.21. Κατάταξη μοντέλων βάσει στατιστικά σημαντικών νικών DM-HLN ($p < 0,05$) έναντι των υπολοίπων, τιμή DAM, Q1 2026.

Στην τιμή DAM (Σχ. 6.21) η Walk-Forward TF υπερτερεί στατιστικά και των 18 υπολοίπων μοντέλων ($p < 0,001$). Εντός της ομάδας Walk-Forward TF οι αλγόριθμοι δεν απέχουν στατιστικά μεταξύ τους, κάτι που επιβεβαιώνει ξανά ότι η επιλογή στρατηγικής είναι διαχωριστικός παράγοντας. Ακολουθούν η στατική TF, οι αναδρομικές και τελευταίες οι MIMO/Direct, που δεν ξεπερνούν στατιστικά καμία μονοβηματική προσέγγιση. Ο έλεγχος επικυρώνει την κατάταξη της §6.4: η υπεροχή της walk-forward επανεκπαίδευσης δεν οφείλεται στην τύχη της περιόδου.



Σχήμα 6.22. Κατάταξη μοντέλων βάσει στατιστικά σημαντικών νικών DM-HLN ($p < 0,05$) έναντι των υπολοίπων, ηλεκτρικό φορτίο, Q1 2026.

Στο φορτίο (Σχ. 6.22) η εικόνα αλλάζει στο κρίσιμο σημείο: η Walk-Forward αναδρομική (Rec-XGB-SS) είναι στατιστικά αδιάκριτη από την ιδεατή Walk-Forward TF, παρότι δεν διαθέτει πρόσβαση στις πραγματικές ενδοημερήσιες τιμές. Η ισχυρή ενδοημερήσια αυτοσυσχέτιση του φορτίου συγκρατεί τη συσσώρευση σφάλματος, ενώ στην τιμή οι αιχμές τη μεγεθύνουν. Οι MIMO και Direct παραμένουν στατιστικά κατώτερες κάθε μονοβηματικής στρατηγικής.

Συνολικά, ο έλεγχος DM μετατρέπει τις αριθμητικές διαφορές των πινάκων σε στατιστικά τεκμηριωμένα συμπεράσματα: η υπεροχή της walk-forward επανεκπαίδευσης στην τιμή και η ισοδυναμία αναδρομικής και Teacher-Forcing στο φορτίο είναι ανθεκτικές ιδιότητες, όχι τυχαία ευρήματα της δοκιμαστικής περιόδου.

6.6 Σύγκριση με Σχετικές Εργασίες

Αντιπαράβλλουμε τα ευρήματά μας με τη διεθνή και την εγχώρια βιβλιογραφία, εστιάζοντας στα σημεία σύγκλισης και απόκλισης με μελέτες πρόβλεψης τιμής και φορτίου με έμφαση στην ελληνική αγορά. Το μεθοδολογικό πλαίσιο των εργασιών αυτών συνοψίζεται στον Πίνακα 2.1 του Κεφαλαίου 2.

6.6.1 Μεθοδολογική ευθυγράμμιση με την ελληνική αγορά

Οι εγχώριες μελέτες εξετάζουν κάθε σήμα μεμονωμένα: ο Kanousis [11] και ο Κοντράρος [12] την τιμή της Αγοράς Επόμενης Ημέρας, ο Μαγκλαράς [21] καθώς και οι Shiblee και Koukaras [33] το ηλεκτρικό φορτίο. Η παρούσα εργασία μοντελοποιεί ταυτόχρονα και τα δύο σήματα και αξιοποιεί τη μεταξύ τους σχέση, τροφοδοτώντας την προβλεπόμενη ζήτηση ως είσοδο για την τιμή.

Η δική μας αξιολόγηση έδειξε ότι η αντικατάσταση της ακριβέστερης πρόβλεψης (MAE = 80,7 MW) με την ENTSO-E πρόβλεψη (MAE = 267 MW) μεταβάλλει το τελικό MAE τιμής κατά $< 0,1\%$, υποδη-

λώνοντας ότι τα μοντέλα τιμής βασίζονται κυρίως στις χρονικές υστερήσεις τιμής. Το εύρημα αυτό, ότι οι προσεγγίσεις Μηχανικής Μάθησης και συγκεκριμένα οι δομές Gradient Boosting (LightGBM) μπορούν να ξεπεράσουν αισθητά τις επίσημες επιχειρησιακές προβλέψεις της πλατφόρμας ENTSO-E στο ελληνικό σύστημα, επιβεβαιώνεται καθολικά και από τους Shiblee και Koukaras [33], οι οποίοι ανέδειξαν επίσης το αυτόνομο LightGBM ως το κορυφαίο μοντέλο για το φορτίο.

Σε επίπεδο τάξης μεγέθους, τα σφάλματα της παρούσας εργασίας κινούνται στο ίδιο εύρος με τις εγχώριες μελέτες της ελληνικής αγοράς και του φορτίου. Ενδεικτικά, οι τιμές σφαλμάτων για την τιμή DAM (όπου στη δική μας αναδρομική LightGBM υλοποίηση καταγράφεται MAE 14,028 €/MWh, έναντι MAE 12,502 €/MWh του Kanousis [11] και MAE 12,030 €/MWh της μελέτης του ΕΜΠ [31]) και για το ηλεκτρικό φορτίο (όπου οι Shiblee και Koukaras σημειώνουν test MAE 69,12 MW και η δική μας Recursive LightGBM υλοποίηση MAE 80,704 MW) κινούνται σε εξίσου χαμηλά επίπεδα. Η διαφορετική περίοδος δοκιμής, το επίπεδο και η μεταβλητότητα των τιμών/φορτίου, καθώς και ο ορισμός του σφάλματος καθιστούν κάθε αριθμητική αντιπαραβολή ενδεικτική και όχι αυστηρή (Πίν. 2.1).

Η ισχυρότερη σύγκλιση προκύπτει με τη μελέτη της ομάδας του ΕΜΠ [31], η οποία αξιολογεί LSTM, XGBoost, LightGBM και CatBoost σε Ελλάδα, Βέλγιο και Ιρλανδία υπό το ίδιο καθεστώς προβλεπόμενων χαρακτηριστικών. Τα ευρήματά μας επιβεβαιώνουν δύο πορίσματα της: το LightGBM παραμένει το ακριβέστερο και αποδοτικότερο μοντέλο, και η χρονική εγγύτητα των δεδομένων εκπαίδευσης βελτιώνει την προσαρμογή στις εποχικές μεταβολές και τις αιχμές, όπως ποσοτικοποιεί το Retraining Premium μας (Σχ. 6.7). Η διαφορά εντοπίζεται στον μηχανισμό ανανέωσης, όχι στο συμπέρασμα: οι ερευνητές του ΕΜΠ επιτυγχάνουν στηρίζονται αποκλειστικά σε πρόσφατα μέσω σύντομων κυλόμενων παραθύρων με "νικητή" το παράθυρο 45-60 ημερών ενώ εμείς διατηρούμε ολόκληρο το ιστορικό και το εμπλουτίζουμε μηνιαία. Παρά τη διαφορά, το συμπέρασμα ταυτίζεται: στη μεταβλητή ελληνική αγορά η ανανέωση των δεδομένων έχει μεγαλύτερη επιρροή από κάθε άλλη σχεδιαστική επιλογή.

6.6.2 Αναδρομική πρόβλεψη και η θεωρία συσσώρευσης σφάλματος

Η κλασική ταξινόμηση των στρατηγικών [1, 29] αποδίδει στην αναδρομική πρόβλεψη δομική μειονεξία έναντι των multiple output αρχιτεκτονικών, λόγω της συσσώρευσης σφάλματος κατά την ανατροφοδότηση [41]. Τα ευρήματά μας για το φορτίο αντιστρέφουν τη θέση αυτή: η αναδρομική walk-forward κυριαρχεί των MIMO και Direct και πλησιάζει το ιδεατό άνω φράγμα (Πίνακας 6.13), ενώ οι πολυέξοδες δομές εκτινάσσονται ακριβώς στις ημερήσιες αιχμές (Σχ. 6.14), όπου λείπει η ενδοημερήσια ανατροφοδότηση.

Να σημειωθεί ότι στην παρούσα εργασία η Recursive στρατηγική χωρίζεται σε αυτόνομα 24ωρα. Με το καθημερινό reset στο gate closure, η αναδρομική διαδικασία περιορίζεται αυστηρά εντός της ημέρας κοιτάζοντας το πολύ έως 23 ώρες πίσω, οπότε το σφάλμα δεν προλαβαίνει να συσσωρευτεί σε μεγάλο βαθμό.

6.6.3 Επανεκπαίδευση και μεταβολή καθεστώτος

Η βιβλιογραφία αναγνωρίζει ποιοτικά και ποσοτικά ότι τα στατικά μοντέλα χάνουν ακρίβεια στις εποχικές μεταβάσεις. Στην εργασία μας, η αξία της μηνιαίας επανεκπαίδευσης αποτυπώνεται αρχικά στο Σχήμα 6.5, όπου η walk-forward προσέγγιση συγκρατεί το σφάλμα της τιμής DAM σε χαμηλότερα επίπεδα σε σχέση με τη στατική εκπαίδευση, με τη διαφοροποίηση να γίνεται πιο ορατή από τον Ιανουάριο.

Η συνολική αποτίμηση αυτού του οφέλους ανά στρατηγική επιβεβαιώνεται από τα διαγράμματα διαφοράς επίδοσης (Σχήματα 6.7 και 6.8). Τα αποτελέσματα δείχνουν ότι η επανεκπαίδευση έχει ου-

σιαστικό αντίκτυπο στην τιμή DAM. Αντίθετα, στο ηλεκτρικό φορτίο η επίδρασή της είναι μικρότερη διότι, όπως εξηγήσαμε βάσει του Σχήματος 6.4, δεν υπήρχε μεταβολή καθεστώτος.

Το εύρημα αυτό συμφωνεί με τις παρατηρήσεις της ομάδας του ΕΜΠ [31] για την ανάγκη χρήσης πρόσφατων δεδομένων στην ελληνική αγορά, επεκτείνοντάς το σε τέσσερις διαφορετικές στρατηγικές πρόβλεψης.

6.6.4 Πολυπλοκότητα μοντέλου και αξία των συνδυαστικών μετρικών

Έναντι προσεγγίσεων που στρέφονται σε σύνθετα δίκτυα βαθιάς μάθησης, τα ευρήματά μας δείχνουν ότι ελαφριά tree-based μοντέλα, με κατάλληλη αρχιτεκτονική εισόδων (πυκνές υστερήσεις) και walk-forward επανεκπαίδευση, επιτυγχάνουν εφάμιλλη ή ανώτερη ακρίβεια. Η μηχανική χαρακτηριστικών υπερτερεί της αλγοριθμικής πολυπλοκότητας, συμβατά με την έμφαση του Κοντράρου [12] στην επιλογή χαρακτηριστικών και με την πρακτική των ανοιχτών σημείων αναφοράς [8].

6.7 Σύνοψη Αποτελεσμάτων και Συμπεράσματα

Η αξιολόγηση του κεφαλαίου οδηγεί σε ένα κεντρικό συμπέρασμα: το χρονικό πλαίσιο εκπαίδευσης και η μηχανική χαρακτηριστικών έχουν μεγαλύτερη βαρύτητα από την επιλογή αλγορίθμου. Η μηνιαία walk-forward επανεκπαίδευση μειώνει το MAE της τιμής DAM κατά 27,7% (14,478 → 10,463 €/MWh), με ανάλογη πτώση σε RMSE και sMAPE, ενώ στο φορτίο το όφελος είναι προς αμφισβήτηση. Η ασυμμετρία εξηγείται από τη δομική μετατόπιση του επιπέδου της τιμής τον Φεβρουάριο 2026 (§6.3.2), την οποία το ομαλό φορτίο δεν εμφανίζει· σε κοινή ποσοστιαία κλίμακα η επανεκπαίδευση κερδίζει −4,496 μονάδες sMAPE στην τιμή έναντι −0,529 στο φορτίο.

Ανάμεσα στις εφαρμόσιμες για πρόβλεψη DAM στρατηγικές, η αναδρομική (Recursive) είναι η ακριβέστερη (Σχ. 6.21). Ο ημερήσιος μηδενισμός της αναδρομικής διαδικασίας περιορίζει τη συσσώρευση σφάλματος εντός του 24ώρου, αναιρώντας στην πράξη το θεωρητικό μειονέκτημα που της αποδίδει η κλασική ταξινόμηση έναντι των multistep δομών. Στο φορτίο, όπου η ενδοημερήσια αυτοσυσχέτιση είναι ισχυρή, η Recursive walk-forward πλησιάζει το ιδεατό Teacher-Forcing (70,641 έναντι 67,729 MW) και ο έλεγχος Diebold-Mariano τις βρίσκει στατιστικά αδιάκριτες ($p = 0,769$, §6.5, Σχ. 6.22).

Στις ακραίες συνθήκες η διαφορά γίνεται καθοριστική. Στις αιχμές ζήτησης (spikes) του Ιανουαρίου, η Direct αστοχεί στο 100% των ωρών αιχμής και η MIMO στο 64%, έναντι 14% της Recursive και 5% της Teacher-Forcing (Σχ. 6.18). Η αστοχία τους οφείλεται σε συστηματική υποεκτίμηση συγκεντρωμένη στις ώρες αιχμής (Σχ. 6.13, 6.11), όπου λείπει η ενδοημερήσια ανατροφοδότηση. Το ηλεκτρικό φορτίο παραμένει συνολικά πιο προβλέψιμο από την τιμή (sMAPE 1,3% έναντι 10,7%), ακόμη και υπό αυστηρότερο κριτήριο αιχμής.

Ο έλεγχος Diebold-Mariano (§6.5) επικυρώνει ότι οι διαφορές αυτές είναι ανθεκτικές και όχι τυχαίες. Το Κεφάλαιο 7 ερμηνεύει το γιατί μέσω της ανάλυσης σημαντικότητας χαρακτηριστικών, αναδεικνύοντας ποια χαρακτηριστικά και σε τι ποσοστό αξιοποιεί κάθε στρατηγική.

7. Ανάλυση Σημαντικότητας Χαρακτηριστικών

Η ανάλυση σημαντικότητας χαρακτηριστικών (feature importance) προσφέρει ερμηνευσιμότητα στα μοντέλα μηχανικής μάθησης, δείχνοντας τους παράγοντες που διαμορφώνουν τις προβλέψεις [22, 24]. Στο παρόν κεφάλαιο εξετάζουμε πώς η επιλογή της στρατηγικής πρόβλεψης (Teacher-Forcing, Recursive, MIMO, Direct) μετατοπίζει τη βαρύτητα που αποδίδουν τα μοντέλα σε χρονικές υστερήσεις, εξωγενείς μεταβλητές και ημερολογιακά χαρακτηριστικά. Το ερώτημα δεν είναι ποιο υπόδειγμα προβλέπει καλύτερα, αλλά γιατί κάθε στρατηγική αξιοποιεί διαφορετικά κανάλια πληροφόρησης για να ανασυνθέσει τη δυναμική της αγοράς.

7.1 Μεθοδολογικό Πλαίσιο και Μαθηματική Θεμελίωση

Η αποτίμηση της σημαντικότητας των χαρακτηριστικών πραγματοποιείται μέσω τριών διακριτών μαθηματικών προσεγγίσεων, οι οποίες επιλέγονται με βάση την αρχιτεκτονική δομή του εκάστοτε αλγορίθμου, ώστε να αποτυπώνουν τη συνεισφορά κάθε μεταβλητής στη μείωση του σφάλματος παλινδρόμησης.

1. Κέρδος Πληροφορίας (Gain --- LightGBM, XGBoost). Για τους αλγορίθμους ενίσχυσης κλίσης (gradient boosting), η σημαντικότητα ενός χαρακτηριστικού ισούται με τη συνολική μείωση του σφάλματος που επιφέρουν οι διαχωρισμοί κόμβων πάνω σε αυτό [24]. Έστω $\mathcal{T}$ το σύνολο των εσωτερικών κόμβων όλων των δένδρων και $\mathcal{T}_f \subseteq \mathcal{T}$ οι κόμβοι που διαχωρίζουν με βάση το f . Η κανονικοποιημένη σημαντικότητα ορίζεται ως:

$$Importance_{\text{gain}}(f) = \frac{\sum_{t \in \mathcal{T}_f} \Delta \mathcal{L}(t)}{\sum_{t \in \mathcal{T}} \Delta \mathcal{L}(t)}, \quad (7.1)$$

όπου $\Delta \mathcal{L}(t)$ είναι η μείωση του μέσου τετραγωνικού σφάλματος (MSE) που πετυχαίνει ο διαχωρισμός στον κόμβο t . Ο παρονομαστής, που αθροίζει σε όλους τους κόμβους, κανονικοποιεί ώστε $\sum_f Importance_{\text{gain}}(f) = 1$.

2. Μέση Μείωση Ακαθαρσίας (Mean Decrease Impurity / MDI --- Random Forest). Στο Random Forest, η σημαντικότητα ισούται με τη μέση, σταθμισμένη ανά πλήθος δειγμάτων, μείωση ακαθαρσίας που προκαλούν οι διαχωρισμοί πάνω στο f [22]. Για ένα δάσος $\mathcal{M}$ δένδρων, με $\mathcal{N}_m^f$ τους κόμβους του δένδρου m που διαχωρίζουν με βάση το f :

$$Importance_{\text{MDI}}(f) = \frac{1}{|\mathcal{M}|} \sum_{m \in \mathcal{M}} \sum_{t \in \mathcal{N}_m^f} \frac{N_t}{N} \Delta i(t), \quad (7.2)$$

όπου N_t είναι το πλήθος δειγμάτων στον κόμβο t και N το συνολικό. Η μείωση ακαθαρσίας του κόμβου ορίζεται ως:

$$\Delta i(t) = i(t) - \frac{N_{t_L}}{N_t} i(t_L) - \frac{N_{t_R}}{N_t} i(t_R), \quad (7.3)$$

με $i(t)$ τη διακύμανση (variance) των δειγμάτων στον κόμβο t και t_L, t_R τους θυγατρικούς κόμβους. Η MDI παρουσιάζει γνωστή μεροληψία υπέρ συνεχών μεταβλητών υψηλής καρδιαλότητας, που λαμβάνεται υπόψη κατά την ερμηνεία.

3. Σημαντικότητα μέσω Μετάθεσης (Permutation --- MLP, SVR). Στα μη γραμμικά μοντέλα MLP και SVR, που δεν βασίζονται σε δένδρα, οι έννοιες gain και MDI δεν ορίζονται. Η μέθοδος μετάθεσης μετρά την αύξηση του σφάλματος όταν οι τιμές ενός χαρακτηριστικού αναδιατάσσονται τυχαία, καταστρέφοντας τη σχέση του με τον στόχο:

$$Importance_{perm}(f) = MAE(\mathcal{D}^{\pi(f)}) - MAE(\mathcal{D}), \quad (7.4)$$

όπου $\mathcal{D}$ είναι το σύνολο επικύρωσης και $\mathcal{D}^{\pi(f)}$ το ίδιο σύνολο με τις τιμές του f τυχαία αναδιατεταγμένες (μετάθεση π). Λόγω κόστους, η μετάθεση εφαρμόζεται σε υποδείγματα (800 για το MLP, 150 για το SVR), με αυξημένη στατιστική διακύμανση στις εκτιμήσεις.

7.1.1 Πρωτόκολλο Επεξεργασίας και Παραγωγής Αποτελεσμάτων

Οι χάρτες θερμότητας προκύπτουν από τα πρωτογενή δεδομένα σημαντικότητας των 15 μοντέλων μέσω αυτοματοποιημένης επεξεργασίας. Από κάθε στήλη μοντέλου απομονώνονται τα τρία κορυφαία χαρακτηριστικά και λαμβάνεται η ένωσή τους. Αν προκύψουν πάνω από δέκα, κρατούνται τα δέκα με την καλύτερη μέση κατάταξη σε όλες τις στήλες, ώστε να μην αποκλείονται μεταβλητές κρίσιμες μόνο για συγκεκριμένες στρατηγικές.

Ακολουθούν δύο τύποι χαρτών. Οι χάρτες ανά μοντέλο (Σχ. 7.1 κ.ε.) δείχνουν κάθε αλγόριθμο ξεχωριστά, επειδή το LightGBM και το XGBoost μετρώνται με gain, το Random Forest με MDI και τα MLP/SVR με μετάθεση, οι τιμές διαφορετικών στηλών δεν συγκρίνονται σε απόλυτη κλίμακα. Γι' αυτό το χρώμα κανονικοποιείται ανά στήλη και οι αναγραφόμενοι αριθμοί δίνουν το ωμό ποσοστό συμμετοχής (% share). Οι συγκεντρωτικοί χάρτες ανά στρατηγική (Σχ. 7.9, 7.10) περιλαμβάνουν μόνο τον πρωταθλητή gain κάθε στρατηγικής, καθώς όλες οι στήλες μετρούν την ίδια ποσότητα, η χρωματική κλίμακα είναι ενιαία και η συμπίεση $PowerNorm(\gamma = 0,45)$ αναδεικνύει τις μικρές τιμές των εξωγενών παραγόντων δίπλα στην κυριαρχία της υστέρησης μίας ώρας στο Teacher-Forcing. Η σύμβαση αυτή δεν επαναλαμβάνεται στις επιμέρους λεζάντες.

7.2 Teacher-Forcing και Recursive

Στις δύο μονοβηματικές στρατηγικές το μοντέλο έχει στη διάθεσή του την υστέρηση μίας ώρας: πραγματική στο Teacher-Forcing, προβλεπόμενη στη Recursive. Η σύγκριση των δύο απομονώνει την επίδραση της διάδοσης σφάλματος στην κατανομή βαρύτητας.

Η κυριαρχία του *Price_lag1* είναι πραγματική, αλλά το μέγεθός της είναι χαρακτηριστικό του αλγορίθμου: το φύλλο-προς-φύλλο LightGBM διοχετεύει 88,3% στην υστέρηση μίας ώρας, το XGBoost με περιορισμένο βάθος 63,3%, ενώ το Random Forest υπό MDI την αραιώνει σε 11,2% με τα *Price_lag24* και *Price_lag2* σε παρόμοιο επίπεδο. Η ισχυρή αυτοσυσχέτιση πρώτης τάξης (PACF lag-1 $\approx 1,0$, Κεφάλαιο 3) καθιστά την τιμή της προηγούμενης ώρας σχεδόν επαρκή πρόβλεψη. Οι αλγόριθμοι διαφέρουν στο πόσο επιθετικά την εκμεταλλεύονται, όχι στο ποιο χαρακτηριστικό μετράει. Η επιλογή είναι στατιστικά αποδοτική όσο η δυναμική μένει σταθερή και εύθραυστη σε μεταβολή καθεστώτος.

Στη Recursive η υστέρηση μίας ώρας παύει να είναι παρατήρηση και γίνεται πρόβλεψη με συσσωρευμένο σφάλμα. Το LightGBM περικόπτει το βάρος της σε 8,9% και το μεταφέρει στα *Price_lag2*

Price_lag1	88.3	63.3	11.2	22.7	25.6
Price_lag24	4.8	5.5	8.5	6.2	2.7
Price_lag2		1.9	8.4	3.9	0.8
Price_lag48		0.8	6.3	1.6	0.7
Solar_lag1				4.8	3.9
Price_roll24		0.6	5.8	0.7	0.7
Gen_fc				1.2	4.9
Solar_fc_dayahead				3.9	7.0
Res_load_lag1			0.7	3.1	3.1
Price_lag168	0.6	5.1	5.2	2.3	
	LGBM (gain)	XGB (gain)	RF (MDI)	MLP (perm)	SVR (perm)

Σχήμα 7.1. Σημαντικότητα ανά μοντέλο: Teacher-Forcing, τιμή DAM.

Price_lag1	8.9	12.8	11.6	33.2	30.6
Price_lag24	4.7	18.5	8.4	2.4	3.2
Price_lag2	5.2	6.3	8.8	2.7	0.8
Price_lag48	2.7	5.5	5.9	1.5	0.9
Gen_fc	2.7			3.4	4.9
Res_load_lag1	1.7		0.7	4.7	4.3
Price_roll24	2.1	14.0	5.8	0.5	0.7
Price_lag3	2.7	0.9	3.1	0.5	0.6
Solar_fc_dayahead	2.1			6.7	5.4
Solar_lag1	1.0			10.2	4.1
	LGBM (gain)	XGB (gain)	RF (MDI)	MLP (perm)	SVR (perm)

Σχήμα 7.2. Σημαντικότητα ανά μοντέλο: Recursive, τιμή DAM.

και *Price_lag24*. Το XGBoost με προγραμματισμένη δειγματοληψία πηγαίνει παραπέρα, φορτώνοντας *Price_lag24* (18,5%), κυλιόμενο μέσο 24h (14,0%) και τις πυκνές υστερήσεις 4-23 (συνολικά 17,1%), τις οποίες έμαθε να εμπιστεύεται ακριβώς επειδή η δειγματοληψία το εξέθεσε σε αυτο-παραγόμενες τιμές κατά την εκπαίδευση. Η αναδιανομή αυτή είναι η αποτύπωση της διάδοσης σφάλματος στο επίπεδο των χαρακτηριστικών.

Στο φορτίο η εικόνα είναι αναμενόμενα παρόμοια, με ακόμη ισχυρότερη αυτοσυσχέτιση. Στο Teacher-Forcing (Σχ. 7.3) το *Load_lag1* συγκεντρώνει 92,4% (LightGBM) και 84,0% (XGBoost), υψηλότερα από την τιμή, καθώς η ζήτηση είναι ομαλότερο σήμα. Το Random Forest υπό MDI κατανέμει ομαλότερα, με τα *Load_lag24* (16,5%), *Load_lag2* (10,8%) και *Load_lag168* (10,6%) να αποτυπώνουν τον ημερήσιο και εβδομαδιαίο κύκλο. Η σταθερή παρουσία του *Hour_cos* προμηνύει τον ρόλο της ημερολογιακής δομής, που κυριαρχεί στις πολυβηματικές στρατηγικές.

Load_lag1	92.4	84.0	24.6	41.2	25.3
Hour_cos	3.0	4.7	1.3	5.6	4.0
Load_lag24	1.4	3.2	16.5	0.9	6.5
Load_lag2		0.6	10.8		5.5
Load_roll24			2.3	2.2	3.0
Solar_lag2		0.5	1.2	1.7	1.4
Load_lag3			4.9	0.6	2.2
Res_load_lag1			1.7	19.7	7.4
Solar_lag1			0.8	5.2	1.6
Load_lag168		0.7	10.6		3.1
	LGBM (gain)	XGB (gain)	RF (MDI)	MLP (perm)	SVR (perm)

Σχήμα 7.3. Σημαντικότητα ανά μοντέλο: Teacher-Forcing, ηλεκτρικό φορτίο.

Στη Recursive (Σχ. 7.4) οι δύο αλγόριθμοι αποκλίνουν έντονα. Το LightGBM περικόπτει το *Load_lag1* σε 7,3%, αναδιανέμοντας στις κοντινές υστερήσεις (*Load_lag2*, *Load_lag6*, *Load_lag12*), όπως ακριβώς και στην τιμή. Το XGBoost με προγραμματισμένη δειγματοληψία, αντιθέτως, διατηρεί το *Load_lag1* στο 84,4%: η ομαλότητα του φορτίου κρατά αξιόπιστη ακόμη και την προβλεπόμενη προηγούμενη τιμή. Αυτό εξηγεί, στο επίπεδο των χαρακτηριστικών, γιατί η αναδρομική στρατηγική πλησιάζει στατιστικά το Teacher-Forcing για το φορτίο ($p = 0,769$, §6.5), ενώ στην ευμετάβλητη τιμή η ίδια αραίωση κοστίζει.

7.3 MIMO και Direct

Στις δύο πολυβηματικές στρατηγικές η πρόβλεψη παράγεται χωρίς καμία αυτοπαλίνδρομη ανατροφοδότηση: η μόνη πρόσφατη πληροφορία είναι οι παρατηρούμενες ενδοημερήσιες υστερήσεις, οπότε οι εξωγενείς παράγοντες αποκτούν μεγαλύτερο σχετικό βάρος.

Χωρίς πρόσφατη τιμή, τα μοντέλα χωρίζονται σε δύο ομάδες. Τα δένδρα ενίσχυσης διοχετεύουν


Load_lag1	7.3	84.4	24.6	46.0	22.0
Load_lag24	3.3	3.3	16.1	0.8	7.7
Hour_cos	2.4	6.5	1.3	4.7	4.5
Load_lag2	4.4	0.7	11.2		6.6
Load_roll24	2.1		2.2	2.1	2.5
Load_lag3	3.2		4.9		2.1
Res_load_lag1	2.3		1.7	22.1	6.3
Solar_lag2	2.6		1.2	1.3	1.4
Load_lag12	3.6	0.6	0.9	0.6	1.5
Load_lag6	4.1		0.8		1.0
	LGBM (gain)	XGB (gain)	RF (MDI)	MLP (perm)	SVR (perm)

Σχήμα 7.4. Σημαντικότητα ανά μοντέλο: Recursive, ηλεκτρικό φορτίο.

Gas_lag168		4.6		1.9
Solar_fc_dayahead		0.7	2.0	4.3
Price_lag1	4.9	1.0		4.8
Hour_cos	0.8	1.1	8.1	
Gen_fc			15.9	
Rad_Larissa				3.7
Price_roll24		51.6		3.0
Price_roll168	1.0	16.6		0.8
Price_lag6	3.3	0.5		
Hum_GR_mean			6.5	0.7
	XGB (gain)	RF (MDI)	MLP (perm)	SVR (perm)

Σχήμα 7.5. Σημαντικότητα ανά μοντέλο: MIMO ($H = 24$), τιμή DAM.

τη βραχυπρόθεσμη πληροφορία στις παρατηρούμενες πυκνές υστερήσεις 4-23 (XGBoost: 53,5% συλλογικά), που εδώ είναι καθαρή ιστορία και όχι προβλέψεις, εξηγώντας τη βελτίωση $-7,9\%$ MAE έναντι του MIMO χωρίς πυκνές υστερήσεις. Το Random Forest αντιθέτως αγκυρώνει στους κυλιόμενους μέσους 24h (51,6%) και 168h (16,6%), θυσιάζοντας οξύτητα στις αιχμές για ευστάθεια επιπέδου, ενώ MLP και SVR στρέφονται στις ημερήσιες προβλέψεις παραγωγής και στον καιρό (υγρασία, ακτινοβολία). Η ίδια απουσία αυτοπαλίνδρομου σήματος γεννά αντίθετες στρατηγικές χαρακτηριστικών ανάλογα με τη μεροληψία του εκάστοτε αλγορίθμου.



Σχήμα 7.6. Σημαντικότητα ανά μοντέλο: Direct ($H = 24$), τιμή DAM (LightGBM, XGBoost).

Το Direct αναπαράγει σχεδόν ταυτόσημα το MIMO: το XGBoost κρατά τις ενδοημερήσιες υστερήσεις (*Price_lag6*, *Price_lag19*), το LightGBM στρέφεται στις αιολικές υστερήσεις παραγωγής (48h, 24h) και στον κυλιόμενο μέσο 168h. Η ταύτιση επιβεβαιώνει ότι MIMO και Direct διαφέρουν στη γεωμετρία εκπαίδευσης (ένα κοινό έναντι ανεξάρτητων μοντέλων ανά ορίζοντα), όχι στην πληροφορία που αξιοποιούν. Η επίπεδη κατανομή, με κανένα χαρακτηριστικό άνω του 5%, αποτυπώνει την απουσία πρόσφατης τιμής: η πρόβλεψη στηρίζεται σε πολλά ασθενή αλλά συμπληρωματικά σήματα.

Στο φορτίο, η απουσία πρόσφατης υστέρησης αναδεικνύει με προβλέψιμο τρόπο την ημερολογιακή δομή. Στο MIMO (Σχ. 7.7) το Random Forest αγκυρώνει στον κυλιόμενο μέσο 24h (*Load_roll24*,

31,0%) και στα ωριαία ημερολογιακά (*Hour_cos* 15,7%, *Hour* 14,3%), ενώ το XGBoost διασπείρει το βάρος στις παρατηρούμενες ενδοημερήσιες υστερήσεις (*Load_lag1/2/6/12*). Η ντετερμινιστική ημερήσια και εβδομαδιαία περιοδικότητα του φορτίου υποκαθιστά την πρόσφατη τιμή πολύ αποτελεσματικότερα απ' ό,τι στην τιμή DAM, όπου τον ρόλο αυτό αναλαμβάνουν οι εξωγενείς παράγοντες (φυσικό αέριο, ΑΠΕ).

Load_lag1	6.9	6.2	21.9	20.8
Hour_cos	1.3	15.7	7.6	4.5
Load_roll24		31.0	9.2	3.4
Load_lag6	6.3	2.3		3.1
Dow	1.6	1.4		3.1
Res_load_lag1			6.9	4.7
Hour	0.8	14.3	1.3	
Load_lag24	0.6			8.1
Load_lag2	3.6	2.5		8.3
Load_lag12	6.8	1.5	0.7	
	XGB (gain)	RF (MDI)	MLP (perm)	SVR (perm)


Σχήμα 7.7. Σημαντικότητα ανά μοντέλο: MIMO ($H = 24$), ηλεκτρικό φορτίο.

Το Direct (Σχ. 7.8) επαναλαμβάνει το μοτίβο: το XGBoost κρατά τις ενδοημερήσιες υστερήσεις (*Load_lag1/6/12/3*), ενώ το LightGBM στρέφεται στους κυλιόμενους μέσους (*Load_roll168*, *Load_roll24*), στην ημέρα της εβδομάδας (*Dow*, 3,3%) και στις αιολικές υστερήσεις (*Wind_lag168*). Η ταύτιση MIMO-Direct, ίδια με την τιμή, επιβεβαιώνει ότι η διαφορά τους είναι αμιγώς γεωμετρία εκπαίδευσης και όχι διαθέσιμη πληροφορία.

7.4 Συνολική εικόνα ανά στρατηγική

Συγκεντρώνοντας τους πρωταθλητές gain κάθε στρατηγικής σε ενιαία κλίμακα, η μετατόπιση της βαρύτητας γίνεται άμεσα ορατή. Επειδή και οι τέσσερις στήλες μετρούν την ίδια ποσότητα (gain), τα χρώματα είναι εδώ απευθείας συγκρίσιμα.

Το *Price_lag1* καταρρέει μονοτονικά, $88,3 \rightarrow 8,9 \rightarrow 4,9 \rightarrow 1,4\%$, καθώς η στρατηγική αφαιρεί σταδιακά την πρόσβαση στην πρόσφατη τιμή (TF $\rightarrow$ Rec $\rightarrow$ MIMO $\rightarrow$ Direct). Το κενό που αφήνει το γεμίζουν διαφορετικά σήματα σε κάθε στρατηγική: μακρινότερες υστερήσεις και κυλιόμενοι μέσοι στη Recursive, ενδοημερήσιες υστερήσεις και αιολική παραγωγή στα πολυβηματικά σχήματα. Η εικόνα δείχνει ότι η αυτοπαλίνδρομη κυριαρχία δεν είναι ιδιότητα της τιμής, αλλά της διαθεσιμότητας πρόσφατης πληροφορίας που ορίζει η στρατηγική.




Σχήμα 7.8. Σημαντικότητα ανά μοντέλο: Direct ($H = 24$), ηλεκτρικό φορτίο (LightGBM, XGBoost).

Το φορτίο ακολουθεί την ίδια τροχιά κατάρρευσης, $92,4 \rightarrow 7,3 \rightarrow 6,9 \rightarrow 2,6\%$ για το *Load_lag1*, με μία ουσιώδη διαφορά στο τι αναδύεται. Αντί για υστερήσεις παραγωγής, το βάρος μεταναστεύει στα ημερολογιακά χαρακτηριστικά: η ώρα της ημέρας (*Hour_cos*) και η ημέρα της εβδομάδας (*Dow*) κρατούν σταθερό βάρος και κορυφώνονται στο Direct (3,3% η *Dow*). Σημειώνεται ότι η υψηλή συγκέντρωση στο TF (92,4%, ελαφρώς πάνω από την τιμή) αφορά τους πρωταθλητές gain. η εποχική δομή του φορτίου αναδεικνύεται στις μεθόδους που ευνοούν επίπεδες κατανομές (MDI, permutation) και στις πολυβηματικές στρατηγικές.


7.5 Κατηγοριοποίηση χαρακτηριστικών

Τα χαρακτηριστικά κατατάσσονται σε τρεις κατηγορίες, με βάρος που μετατοπίζεται ανά στρατηγική.

Α. Πρωτεύον αυτοπαλίνδρομο σήμα. Τα *Price_lag1* (ή *Load_lag1*) και *Price_lag24* κυριαρχούν στο TF και στη Recursive, όπου το μοντέλο έχει πρόσβαση σε πρόσφατες τιμές. Στο LightGBM-TF το



Σχήμα 7.9. Σημαντικότητα δέκα κορυφαίων χαρακτηριστικών ανά στρατηγική (πρωταθλητές gain), τιμή DAM. Ενιαία κλίμακα $\text{PowerNorm} (\gamma = 0,45)$, ώστε να φαίνονται οι μικρές τιμές δίπλα στο κορυφαίο 88%.



Σχήμα 7.10. Σημαντικότητα δέκα κορυφαίων χαρακτηριστικών ανά στρατηγική (πρωταθλητές gain), ηλεκτρικό φορτίο. Ίδια κλίμακα με το Σχ. 7.9.

Price_lag1 εξηγεί μόνο του 88,3% ενώ στη Recursive πέφτει σε 8,9% λόγω της αραίωσης.

Β. Εξωγενείς παράγοντες αγοράς. Τα *gas_price*, *co2_price*, οι υστερήσεις αιολικής και ηλιακής παραγωγής και οι ημερήσιες προβλέψεις παραγωγής αποκτούν μεγαλύτερο σχετικό βάρος στο MIMO και στο Direct, όπου η αυτοπαλίνδρομη πληροφορία είναι περιορισμένη. Στο LGBM-Direct οι αιολικές υστερήσεις παραγωγής ανέρχονται στις πρώτες θέσεις, αντανakλώντας τη σύνδεση διείσδυσης ΑΠΕ και τιμής εκκαθάρισης.

Γ. Ημερολογιακά και εποχικά. Τα *Hour_sin/cos*, *Dow*, *is_holiday*, *Price_lag168* και *Load_lag168* έχουν σταθερή παρουσία στο φορτίο σε όλες τις στρατηγικές και δευτερεύουσα στην τιμή. Εκφράζουν ντετερμινιστικές δομές (εργάσιμες ώρες, αργίες, εβδομαδιαίος κύκλος), ισχυρότερες για το φορτίο.

Καθώς περνάμε από TF σε Recursive και σε MIMO, η εξάρτηση μετατοπίζεται από το άμεσο *Price_lag1*, σε διασπορά προς μακρινότερες υστερήσεις και εξωγενείς μεταβλητές, και τέλος σε εκτεταμένη χρήση των πυκνών υστερήσεων και των ΑΠΕ/καυσίμων. Η συνέπεια είναι άμεση: η βέλτιστη επιλογή συνόλου χαρακτηριστικών εξαρτάται από τη στρατηγική πρόβλεψης.

7.6 Σύνθεση και συμπεράσματα

Η ανάλυση συμπυκνώνεται σε πέντε μηχανισμούς που εξηγούν τη συμπεριφορά κάθε στρατηγικής.

Teacher-Forcing: αυτοπαλίνδρομη κυριαρχία. Το *Price_lag1* συγκεντρώνει 88,3% της σημαντικότητας στο LightGBM της τιμής, το *Load_lag1* 92,4% στο φορτίο. Η επιλογή είναι στατιστικά αποδοτική αλλά εύθραυστη σε μεταβολή καθεστώτος, όπου η αυτοπαλίνδρομη δυναμική αλλάζει ρυθμό, όπως φάνηκε στην κατάρρευση του SVR στο Q1 2026.

Recursive: κατανεμημένο βάρος, εμφάνιση εξωγενών. Χωρίς πρόσβαση σε πραγματικές ενδοημερήσιες τιμές, το *Price_lag1* υποχωρεί σε 8,9% και το βάρος μεταφέρεται στα *Price_lag24* και *Price_lag168*. Στο XGB-SS-Dense η προγραμματισμένη δειγματοληψία στρέφει το μοντέλο στις πυκνές υστερήσεις 4-23 (17,1% συλλογικά).

MIMO και Direct: στροφή στα εξωγενή. Χωρίς ενδιάμεσες πραγματικές τιμές, το XGB-MIMO Dense αξιοποιεί τις πυκνές υστερήσεις σε ποσοστό 53,5%, ποσοστό που εξηγεί τη βελτίωση −7,9% MAE, ενώ το RF-MIMO two-stage στηρίζεται στο *Price_roll24* (51,6%) ως άγκυρα. Το Direct αναπαράγει την ίδια δομή.

Το παράδοξο των πυκνών υστερήσεων. Οι ίδιες πυκνές υστερήσεις βελτιώνουν το MIMO (−22% MLP, −7,9% XGB, −6,5% LGBM) αλλά επιβαρύνουν τη Recursive (+2,8% LGBM). Στο MIMO οι υστερήσεις είναι πάντα καθαρές ιστορικές τιμές. Στη Recursive γεμίζουν από προβλέψεις, και ο θόρυβος διαδίδεται στα επόμενα βήματα. Η προγραμματισμένη δειγματοληψία μετριάζει μερικώς το πρόβλημα (LGBM-SS-Dense: −1,6% έναντι LGBM-SS).

Φορτίο: ισχυρότερη εποχικότητα, ηπιότερη αραίωση. Υπό gain το φορτίο συγκεντρώνεται στο *Load_lag1* όσο και η τιμή (92,4% έναντι 88,3%), αλλά η εποχική του δομή το θωρακίζει στις πολυβηματικές στρατηγικές: τα ημερολογιακά χαρακτηριστικά κρατούν σταθερό βάρος ακόμη και χωρίς

πρόσφατη υστέρηση. Η ομαλότερη δυναμική επιτρέπει στο Recursive XGB-SS να ανταγωνίζεται στατιστικά το Teacher-Forcing ($p = 0,769$, DM test Q1 2026 §6.5, Σχ. 6.22), σε αντίθεση με την τιμή, όπου η αραιώση κοστίζει.

Συνολικά, η σημαντικότητα είναι συνεπής εντός κάθε στρατηγικής, ανεξάρτητα από τον αλγόριθμο. Η στρατηγική καθορίζει ποια πληροφορία είναι διαθέσιμη, και δευτερευόντως ο αλγόριθμος καθορίζει πώς τη χρησιμοποιεί. Το ίδιο χαρακτηριστικό (y_{t-1}) περνά από 88% στο TF σε 1-5% στο MIMO: η επιλογή συνόλου χαρακτηριστικών δεν είναι ανεξάρτητη από τον σχεδιασμό της πρόβλεψης.

8. Συμπεράσματα

Η εργασία αντιμετώπισε ένα πρακτικό ερώτημα της ελληνικής χονδρεμπορικής αγοράς: ποια στρατηγική και ποιος τρόπος εκπαίδευσης παράγουν αξιόπιστη πρόβλεψη τιμής DAM και ηλεκτρικού φορτίου κάτω από τους πραγματικούς περιορισμούς της Αγοράς Επόμενης Ημέρας, όπου κάθε χαρακτηριστικό πρέπει να είναι γνωστό στο κλείσιμο της πύλης (D-1, 12:00 CET). Το κεφάλαιο συγκεντρώνει τα ευρήματα, διατυπώνει τις συνεισφορές, οριοθετεί τους περιορισμούς και προτείνει συγκεκριμένες επεκτάσεις.

8.1 Σύνοψη Κύριων Ευρημάτων

Η εργασία αξιολόγησε τέσσερις στρατηγικές, δύο τρόπους εκπαίδευσης και πέντε αλγόριθμους, για τιμή DAM και φορτίο. Ως προς τον σκοπό της, τα ευρήματα είναι τα εξής.

Στρατηγική, αλγόριθμος και τρόπος εκπαίδευσης. Το βασικό συμπέρασμα της εργασίας είναι ότι η επιλογή του πλαισίου εκπαίδευσης και της στρατηγικής πρόβλεψης επηρεάζει την ακρίβεια πολύ περισσότερο από την επιλογή του μεμονωμένου αλγορίθμου. Για την πρόβλεψη της τιμής, η μηνιαία επανεκπαίδευση μείωσε το μέσο απόλυτο σφάλμα κατά 27,7% (από 14,478 σε 10,463 €/MWh για το LightGBM). Στο ηλεκτρικό φορτίο, παρότι η επανεκπαίδευση προσφέρει οριακό μόνο όφελος ($\Delta sMAPE = -0,529\%$), η Recursive πλησιάζει την Teacher-Forcing. Οι αλγόριθμοι gradient boosting (LightGBM και XGBoost) προσφέρουν σταθερά την υψηλότερη ακρίβεια. Ωστόσο, η πιο αξιόπιστη επιλογή είναι ο συνδυασμός τους (Ensemble-Best3 με βάση το $1/MAE$) καθώς μειώνει το ρίσκο αστοχίας ενός μεμονωμένου αλγορίθμου.

Πίνακας 8.1. Σύγκριση στρατηγικών Q1 2026 στον επιχειρησιακό ορίζοντα $H=24$ (ημερήσια δημοπρασία DAM).

Στρατηγική	Ορίζ.	Τιμή (€/MWh)	Φορτίο (MW)
Walk-Forward MR (TF Ensemble) [†]	$H=24$	10,491	67,729
Walk-Forward Recursive[‡]	$H=24$	18,534	70,641
Static TF (TF Ensemble) [†]	$H=24$	14,478	96,751
Static Recursive, best single	$H=24$	20,094	102,961
MIMO, best ensemble	$H=24$	20,896	217,088
Naive-24 (ρεαλιστική αναφορά)	---	21,638	343,130
Naive-1 (αναφορά τύπου TF)	---	15,433	267,151

[†]: oracle, μη ρεαλιστική (πραγματικές πρόσφατες υστερήσεις). [‡]: επικρατούσα στρατηγική (Rec-XGB-SS-DO-MR).

Δομικές Διαφορές και Συμπεριφορά των Σημάτων Παρά το κοινό πλαίσιο εκπαίδευσης και αξιολόγησης, τα δύο σήματα παρουσιάζουν εντελώς διαφορετική συμπεριφορά καθώς η τιμή είναι ένα έντονα στοχαστικό σήμα με συχνές αιχμές (spikes). Αντίθετα, το ηλεκτρικό φορτίο είναι ένα ομαλό σήμα με ισχυρή περιοδικότητα και καθαρά ημερολογιακή δομή. Αυτή η δομική διαφορά καθορίζει

σε μεγάλο βαθμό και την επίδοση των στρατηγικών πρόβλεψης. Στην περίπτωση του φορτίου, η αναδρομική Recursive καταφέρνει να πλησιάσει το θεωρητικό άνω φράγμα απόδοσης, ενώ στην τιμή απέχει αισθητά.

Συμπεριφορά σε Περιόδους Έντονης Μεταβλητότητας Τον Φεβρουάριο του 2026 η τιμή έπεσε απότομα από τα 110 ± 34 €/MWh στα 57 €/MWh (-28%) και η μεταβλητότητα εκτινάχθηκε στα ± 45 €/MWh. Τα στατικά μοντέλα βγήκαν εκτός του γνώριμου σε αυτά επίπεδο τιμών και έπεσε αισθητά η απόδοσή τους. Το φορτίο την ίδια περίοδο έμεινε εντός των γνωστών ορίων (5707 ± 951 MW η εκπαίδευση, 5567 ± 839 MW ο Φεβρουάριος), με μια απλή εποχική πτώση 7%. Τα στατικά μοντέλα απέδωσαν ικανοποιητικά και η επανεκπαίδευση προσέφερε οριακή βελτίωση ($\Delta sMAPE = -0,529\%$ στην Teacher-Forcing και μόλις $-0,15\%$ στην Direct). Η Teacher-Forcing (που βασίζεται στις προηγούμενες τιμές) επηρεάστηκε τρομερά από τη βίαιη αλλαγή της τιμής, αλλά κέρδισε τα μέγιστα από την επανεκπαίδευση ($\Delta sMAPE = -4,496\%$). Αντίθετα, η Direct προσέγγιση λόγω των ανεξάρτητων μοντέλων ανά βήμα αποδείχθηκε πιο στιβαρή, με αποτέλεσμα μάλιστα στο σταθερό φορτίο η επανεκπαίδευση να της προσφέρει μηδαμινή βελτίωση ($-0,15\%$).

Τεκμηρίωση σε τρία επίπεδα. Οι συγκρίσεις θεμελιώνονται ποιοτικά, ποσοτικά και στατιστικά. Στο ποιοτικό επίπεδο, η ανάλυση της χρονικής δομής, της κατανομής και της μεροληψίας των σφαλμάτων αναδεικνύει τη συστηματική υποεκτίμηση των αιχμών και τη διαφορετική συσσώρευση σφάλματος ανά στρατηγική. Στο ποσοτικό, οι μετρικές MAE, RMSE και sMAPE δίνουν συμπληρωματική εικόνα (η Direct συγκρατεί το RMSE έναντι της μεγαλύτερης διασποράς της MIMO στις αιχμές). Στο στατιστικό, ο έλεγχος Diebold-Mariano με διόρθωση Harvey-Leybourne-Newbold επικυρώνει τις κατατάξεις: υπεροχή της walk-forward TF στην τιμή ($p < 0,001$), ενώ ισοδυναμία της αναδρομικής στο φορτίο ($p = 0,769$) και υστέρηση των MIMO/Direct έναντι κάθε μονοβηματικής στρατηγικής ($p < 0,001$).

Επίδραση δεδομένων και σημαντικότητα χαρακτηριστικών. Η ποιότητα και η επεξεργασία των δεδομένων επηρεάζουν άμεσα την επίδοση. Οι πυκνές ενδοημερήσιες υστερήσεις ωφελούν σταθερά τις πολυβηματικές στρατηγικές, όπου είναι παρατηρημένες τιμές (MIMO: MLP $-22,3\%$, XGB $-7,9\%$), ενώ στην αναδρομική η επίδρασή τους είναι περιορισμένη και εξαρτάται από τη χρήση προγραμματισμένης δειγματοληψίας. Η ανάλυση σημαντικότητας λειτουργεί σε δύο επίπεδα. Ανά στρατηγική, καθορίζεται από τη διαθέσιμη πληροφορία: το y_{t-1} πέφτει από 88% στο Teacher-Forcing σε 1-5% στο MIMO, και το κενό καλύπτουν μακρινές υστερήσεις, εξωγενείς παράγοντες στην τιμή και ημερολογιακά χαρακτηριστικά στο φορτίο. Ανά αλγόριθμο μεταβάλλεται ο τρόπος αξιοποίησης της ίδιας πληροφορίας. Τα μοντέλα ενίσχυσης κλίσης (gradient boosting) συγκεντρώνουν τη σημαντικότητα σε ελάχιστα χαρακτηριστικά, με το LightGBM και το XGBoost να δίνουν στο *Price_lag1* 88,3% και 63,3% αντίστοιχα. Αντίθετα, τα bagging μοντέλα κατανέμουν την πληροφορία ευρύτερα, με το Random Forest να δίνει στο ίδιο χαρακτηριστικό μόλις 11,2%.

Προγραμματισμένη δειγματοληψία στο φορτίο. Στο φορτίο η προγραμματισμένη δειγματοληψία μειώνει σταθερά το σφάλμα: εκθέτοντας το μοντέλο στις δικές του προβλέψεις κατά την εκπαίδευση, περιορίζει τη συσσώρευση σφάλματος και φέρνει την αναδρομική στο επίπεδο του oracle. Στην τιμή το όφελος δεν είναι σταθερό και εμφανίζεται κυρίως σε περιόδους μεταβολής καθεστώτος.

8.2 Συνεισφορές της Εργασίας

Η εργασία συνεισφέρει σε δύο επίπεδα. Σε μεθοδολογικό επίπεδο, ορίζει ένα ενιαίο πλαίσιο χωρίς διαρροή δεδομένων που συγκρίνει τέσσερις στρατηγικές, δύο τρόπους εκπαίδευσης και πέντε αλγορίθμους με κοινούς κανόνες, χρησιμοποιώντας μόνο πληροφορία διαθέσιμη στο κλείσιμο της πύλης. Στηρίζει τις συγκρίσεις στον έλεγχο Diebold-Mariano με διόρθωση Holm-Bonferroni, πρακτική σπάνια στην ελληνική βιβλιογραφία EPF/ELF. Μοντελοποιεί μαζί τιμή και φορτίο με κοινή υποδομή, και προσφέρει ένα εργαλείο οπτικοποίησης που κάνει τη σύγκριση όλων των μοντέλων προσιτή.

Σε εμπειρικό επίπεδο, μετρά το κέρδος της μηνιαίας επανεκπαίδευσης, δείχνει τα όρια της θεωρίας συσσώρευσης σφάλματος για ομαλά σήματα όπως το φορτίο, περιγράφει πώς οι πυκνές υστερήσεις δρουν διαφορετικά ανά στρατηγική, και χαρτογραφεί τη σημαντικότητα χαρακτηριστικών σε δύο επίπεδα: ανά στρατηγική, όπου αλλάζει η διαθέσιμη πληροφορία, και ανά αλγόριθμο, όπου αλλάζει ο τρόπος αξιοποίησής της.

8.3 Περιορισμοί

Η μελέτη έχει συγκεκριμένες αδυναμίες. Οι τιμές φυσικού αερίου για το διάστημα Νοεμβρίου 2025 έως Φεβρουαρίου 2026 προέκυψαν με παρεμβολή από μεταγενέστερα σημεία, εισάγοντας εξάρτηση από το μέλλον στην τιμή αερίου της δοκιμαστικής περιόδου. Το SVR εκπαιδεύτηκε σε 5.000 από περίπου 80.000 δείγματα λόγω υπολογιστικού κόστους, οπότε τα αποτελέσματά του δεν είναι αντιπροσωπευτικά. Η θερμοκρασία, σημαντική για το φορτίο, μπαίνει μόνο έμμεσα μέσω ημερολογιακών χαρακτηριστικών και κυλιόμενων μέσων, ενώ η αξιολόγηση καλύπτει ένα μόνο τρίμηνο, αφήνοντας ανοιχτή τη γενίκευση σε άλλες εποχές. Η ωριαία συγχώνευση της παραγωγής με άθροισμα αντί μέσου όρου αλλάζει την κλίμακα της υπολειμματικής ζήτησης, καθώς το χαρακτηριστικό αυτό δεν είναι από τα κύρια, η επίδραση κρίνεται μικρή αλλά χρειάζεται έλεγχο. Παράλληλα, η ωριαία συγχώνευση των 15λεπτων δεδομένων εξομαλύνει την πραγματική ενδοημερήσια αστάθεια (intra-hour volatility) εντός της ώρας. Τέλος, το όφελος της προγραμματισμένης δειγματοληψίας στο φορτίο και η επίδραση των πυκνών υστερήσεων στην αναδρομική δεν συνοδεύονται από πλήρες ablation, που μένει για μελλοντική δουλειά.

8.4 Μελλοντική Έρευνα

Οι προτεινόμενες επεκτάσεις πηγάζουν από τα ευρήματα και τους περιορισμούς.

Το σημαντικότερο περιθώριο βελτίωσης βρίσκεται στα δεδομένα. Η αντικατάσταση των συνθετικών τιμών αερίου με πραγματικά ιστορικά αίρει την εξάρτηση από το μέλλον και επιτρέπει αξιόπιστη επανεκτίμηση των μοντέλων τιμής. Η προσθήκη μετεωρολογικής πρόγνωσης (θερμοκρασία, ηλιοφάνεια, ταχύτητα ανέμου) αντικαθιστά τα ημερολογιακά υποκατάστατα στα οποία στηρίζεται σήμερα το φορτίο και αναμένεται να ενισχύσει τις πολυβηματικές στρατηγικές. Η ενοποίηση της παραγωγής σε μέσο όρο και ο επανυπολογισμός της υπολειμματικής ζήτησης διορθώνει το ζήτημα κλίμακας, ενώ η εξέταση ιεραρχικών μοντέλων (hierarchical models) θα μπορούσε να αποτυπώσει τη 15λεπτη ενδοημερήσια αστάθεια. Τέλος, η ακριβέστερη πρόβλεψη αιολικής και ηλιακής παραγωγής, που η ανάλυση σημαντικότητας ανέδειξε ως κύριο εξωγενή παράγοντα της τιμής, αναμένεται να ωφελήσει την πρόβλεψη τιμής.

Στο επίπεδο της μεθόδου, ο ρυθμός επανεκπαίδευσης μπορεί να βελτιστοποιηθεί: το επεκτεινόμενο μηνιαίο παράθυρο μπορεί να συγκριθεί με συντομότερα κυλιόμενα παράθυρα και με online ενημέρωση ημερήσιας συχνότητας, με στόχο ταχύτερη προσαρμογή στη μεταβολή κατανομής και

χαμηλότερο υπολογιστικό κόστος από την πλήρη επανεκπαίδευση.

Ξεχωριστό ζήτημα είναι η μοντελοποίηση των αιχμών. Όλες οι στρατηγικές υποεκτιμούν συστηματικά τις ακραίες τιμές, οπότε μια ασύμμετρη συνάρτηση κόστους ή ένα ειδικό υπόδειγμα για τις αιχμές θα αντιμετώπιζε στοχευμένα αυτή την αδυναμία.

Ευρύτερο ενδιαφέρον έχει η ζήτηση από κέντρα δεδομένων. Κατά τον Διεθνή Οργανισμό Ενέργειας [42], η παγκόσμια κατανάλωσή τους προβλέπεται να διπλασιαστεί προς το 2030 (περίπου 945 TWh, $\approx 3\%$ της παγκόσμιας ζήτησης), με κύριο μοχλό την τεχνητή νοημοσύνη. Η ρητή μοντελοποίηση αυτής της μεγάλης και σχετικά σταθερής νέας βάσης φορτίου, και της επίδρασής της στην αιχμή και στη διαμόρφωση τιμής, είναι επίκαιρη επέκταση για την ελληνική αγορά, όπου ήδη σχεδιάζονται αντίστοιχες εγκαταστάσεις.

8.5 Κλείσιμο

Το πρακτικό συμπέρασμα είναι ότι η στρατηγική πρόβλεψης και ο τρόπος εκπαίδευσης έχουν μεγαλύτερη βαρύτητα από την επιλογή αλγορίθμου: η τακτική ανανέωση των δεδομένων, και όχι η πολυπλοκότητα του μοντέλου, καθορίζει την ακρίβεια στην ελληνική αγορά. Η μεθοδολογική αυστηρότητα, η αποφυγή διαρροής δεδομένων, η πλήρης out-of-sample αξιολόγηση και ο στατιστικός έλεγχος είναι η βάση κάθε αξιόπιστης σύγκρισης στη βιβλιογραφία EPF/ELF.

Οι συστάσεις διαφέρουν ανά χρήστη. Ο έμπορος ενέργειας, που χρειάζεται την τιμή στο κλείσιμο της πύλης, μπορεί να υιοθετήσει αναδρομική με μηνιαία επανεκπαίδευση, με επιφύλαξη για την υποεκτίμηση των αιχμών. Ο Διαχειριστής Συστήματος Μεταφοράς, που προβλέπει φορτίο, μπορεί να βασιστεί στην αναδρομική με μηνιαία επανεκπαίδευση· οι στρατηγικές MIMO και Direct κρίνονται ακατάλληλες. Όπου οι πραγματικές πρόσφατες τιμές είναι διαθέσιμες κατά την πρόβλεψη, όπως στην ενδοημερήσια αγορά ή σε λειτουργία πραγματικού χρόνου, το Teacher-Forcing παύει να είναι θεωρητικό όριο και γίνεται και αυτό πρακτικά αξιοποιήσιμο.

Βιβλιογραφία

- [1] Souhaib Ben Taieb, Gianluca Bontempi, Amir F. Atiya, and Antti Sorjamaa. A review and comparison of strategies for multi-step ahead time series forecasting based on the NN5 forecasting competition. *Expert Systems with Applications*, 39(8):7067--7083, 2012.
- [2] Rafał Weron. Electricity price forecasting: A review of the state-of-the-art with a look into the future. *International Journal of Forecasting*, 30(4):1030--1081, 2014.
- [3] European Parliament and Council. Directives on common rules for the internal market in electricity: 96/92/ec, 2003/54/ec, and 2009/72/ec (third energy package). <https://eur-lex.europa.eu/>, 1996--2009.
- [4] European Commission. Commission regulation (eu) 2015/1222 establishing a guideline on capacity allocation and congestion management. <https://eur-lex.europa.eu/eli/reg/2015/1222/oj/eng>, 2015.
- [5] NEMO Committee. Single day-ahead coupling (sdac). <https://www.nemo-committee.eu/sdac>.
- [6] IPTO (ADMIE). Balancing market. <https://www.admie.gr/en/market/general/balancing-market>.
- [7] Υπουργείο Περιβάλλοντος και Ενέργειας. Νέο κεφάλαιο ανοίγει στην αγορά ενέργειας με την εκκίνηση του target model την 1η Νοεμβρίου. <https://ypen.gov.gr/neo-kefalaio-anoigei-stin-agora-energ/>, 2020.
- [8] Jesus Lago, Grzegorz Marcjasz, Bart De Schutter, and Rafał Weron. Forecasting day-ahead electricity prices: A review of state-of-the-art algorithms, best practices and an open-access benchmark. *Applied Energy*, 293:116983, 2021.
- [9] George Gross and Francisco D. Galiana. Short-term load forecasting. *Proceedings of the IEEE*, 75(12):1558--1573, 1987.
- [10] Tao Hong, Pierre Pinson, Shu Fan, Hamidreza Zareipour, Alberto Troccoli, and Rob J. Hyndman. Probabilistic energy forecasting: Global energy forecasting competition 2014 and beyond. *International Journal of Forecasting*, 32(3):896--913, 2016.
- [11] Αλέξανδρος Κανούσης. Electricity price forecasting through machine learning techniques. Master's thesis, Department of Electrical and Computer Engineering, University of Patras, 2025. <https://hdl.handle.net/10889/30268>.
- [12] Σωτήριος Κοντράρος. Μέθοδοι Υποβοηθούμενες από Τεχνητή Νοημοσύνη για την Πρόβλεψη της Τιμής Ηλεκτρικής Ενέργειας στην Αγορά Επόμενης Ημέρας. Master's thesis, Τμήμα Ηλεκτρολόγων Μηχανικών και Τεχνολογίας Υπολογιστών, Πανεπιστήμιο Πατρών, 2023. <https://hdl.handle.net/10889/25836>.
- [13] Jesus Lago, Fjo De Ridder, and Bart De Schutter. Forecasting spot electricity prices: Deep learning approaches and empirical comparison of traditional algorithms. *Applied Energy*, 221:386--405, 2018.

- [14] Grzegorz Marcjasz, Michał Narajewski, Rafał Weron, and Florian Ziel. Distributional neural networks for electricity price forecasting. *Energy Economics*, 125:106843, 2023.
- [15] Bryan Lim, Sercan Ö. Arik, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4):1748--1764, 2021.
- [16] Ailing Zeng, Muxi Chen, Lei Zhang, and Qiang Xu. Are transformers effective for time series forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37:11121--11128, 2023.
- [17] Thomas G. Dietterich. Ensemble methods in machine learning. In *Multiple Classifier Systems*, pages 1--15. Springer, Berlin, 2000.
- [18] Jakub Nowotarski, Eran Raviv, Stefan Trück, and Rafał Weron. An empirical comparison of alternative schemes for combining electricity spot price forecasts. *Energy Economics*, 46:395--412, 2014.
- [19] Bartosz Uniejewski, Grzegorz Marcjasz, and Rafał Weron. On the importance of the long-term seasonal component in day-ahead electricity price forecasting with NARX neural networks. *International Journal of Forecasting*, 35(4):1520--1532, 2019.
- [20] Grzegorz Marcjasz, Bartosz Uniejewski, and Rafał Weron. On the importance of the long-term seasonal component in day-ahead electricity price forecasting. *Energy Economics*, 79:227--234, 2019.
- [21] Αριστείδης Μαγκλαράς. Βραχυπρόθεσμη Πρόβλεψη Ηλεκτρικού Φορτίου Αξιοποιώντας Τεχνικές Μηχανικής και Βαθιάς Μάθησης. Master's thesis, Τμήμα Ηλεκτρολόγων Μηχανικών και Τεχνολογίας Υπολογιστών, Πανεπιστήμιο Πατρών, 2018. <https://hdl.handle.net/10889/12098>.
- [22] Leo Breiman. Random forests. *Machine Learning*, 45(1):5--32, 2001.
- [23] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785--794, 2016.
- [24] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [25] Alex J. Smola and Bernhard Schölkopf. A tutorial on support vector regression. *Statistics and Computing*, 14(3):199--222, 2004.
- [26] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [27] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735--1780, 1997.
- [28] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [29] Gianluca Bontempi, Souhaib Ben Taieb, and Yann-Aël Le Borgne. Machine learning strategies for time series forecasting. In *Business Intelligence*, pages 62--77, 2012.

- [30] Samy Bengio, Oriol Vinyals, Navdeep Jaitly, and Noam Shazeer. Scheduled sampling for sequence prediction with recurrent neural networks. In *Advances in Neural Information Processing Systems*, volume 28, 2015.
- [31] Vasilis Michalakopoulos, Christoforos Menos-Aikateriniadis, Elissaios Sarmas, Antonis Zakynthinos, Pavlos S. Georgilakis, and Dimitris Askounis. Data-driven day ahead market prices forecasting: A focus on short training set windows. *arXiv preprint arXiv:2506.10536*, 2025.
- [32] Vasileios Zelios, Paris Mastorocostas, George Kandilogiannakis, Anastasios Kesidis, Panagiota Tselenti, and Athanasios Voulodimos. Short-term electric load forecasting using deep learning: A case study in greece with rnn, lstm, and gru networks. *Electronics*, 14(14):2820, 2025.
- [33] Md Fazle Hasan Shiblee and Paraskevas Koukaras. Short-term load forecasting in the greek power distribution system: A comparative study of gradient boosting and deep learning models. *Energies*, 18(19):5060, 2025.
- [34] Mehmet Kızıldağ, Fatih Abut, and Mehmet Fatih Akay. Development of new electricity system marginal price forecasting models using statistical and artificial intelligence methods. *Applied Sciences*, 14(21), 2024.
- [35] Shachar Kaufman, Saharon Rosset, Claudia Perlich, and Ori Stitelman. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, 6(4):1--21, 2012.
- [36] ENTSO-E. ENTSO-E transparency platform. <https://transparency.entsoe.eu>.
- [37] Investing.com. Dutch TTF natural gas futures --- historical data. <https://www.investing.com/commodities/dutch-ttf-gas-cl-futures-historical-data>.
- [38] Investing.com. Carbon emissions futures --- historical data. <https://www.investing.com/commodities/carbon-emissions-historical-data>.
- [39] Open-Meteo. Open-Meteo: Open-source weather API. <https://open-meteo.com>.
- [40] Christoph Bergmeir, Rob J. Hyndman, and Bonsoo Koo. A note on the validity of cross-validation for evaluating autoregressive time series prediction. *Computational Statistics & Data Analysis*, 120:70--83, 2018.
- [41] Pedro M. S. Bento, José A. N. Pombo, Maria do Rosário Alves Calado, and Sílvio J. P. S. Mariano. Smart grid forecasting with MIMO models: A comparative study of machine learning techniques for day-ahead residual load prediction. *Energies*, 17(20):5219, 2024.
- [42] International Energy Agency. Electricity 2024: Analysis and forecast to 2026. Technical report, IEA, Paris, 2024.